정책기반 강화학습 (Policy-Based Reinforcement Learning)

정책을 직접 파라미터화: 로그미분 트릭 · REINFORCE와 CartPole · 베이스라인/어드밴티지로 분산 줄이기

Machine Learning 2 · 10주차

한국과학영재학교 (KSA)

Week 10

이번 주차 개요

- 로봇 관절 힘: $-10 \sim +10$Nm의 **연속값**
- Q-learning/DQN은 행동을 **나열해** $\max_{a'}$를 찾는다
- 행동이 연속이면 후보가 **무한** — argmax 불가능
- 답: $\pi_\theta(a|s)$로 **정책을 직접 학습**, 찾는 대신 샘플링

세 차시의 흐름

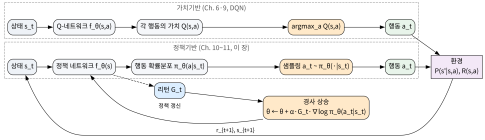
10.1 정리를 세운다 — softmax/조건부 정규 정책, 로그미분 트릭 $\rightarrow$ Policy Gradient Theorem, 엔트로피 보너스, 분산 문제
10.2 정리를 알고리즘으로 — REINFORCE 손계산, 2행동 밴딧, PyTorch CartPole, “리턴을 그대로 쓰는” 함정
10.3 거침을 고친다 — 베이스라인/어드밴티지로 분산 감소, Actor-Critic, REINFORCE vs A2C 비교

이번 장의 REINFORCE/Actor-Critic 기초 위에 Week 11에서 PPO를 세우고, Week 13–14의 로봇 시뮬레이션(Pendulum)이 그 위에 올라간다. 심화 자료: Stanford CS234 (Reinforcement Learning).

10.1 정책 그래디언트 정리

두 경로: 가치기반 vs 정책기반

- **좌측** 가치기반 (Week 6·9): 상태 $s_t \to$ Q-네트워크 $\to$ 각 행동의 가치 $Q(s,a) \to$ **argmax**로 행동 결정.
- **우측** 정책기반 (이번 장): $s_t \to$ 정책 네트워크 $\to$ 확률분포 $\pi_\theta(a|s_t) \to$ **샘플링**해 환경에 행동 전송.
- 환경은 두 경로 모두에 r_{t+1}, s_{t+1} 반환.
- 우측: 리턴 G_t가 **곱수로** 그래디언트를 만들어 policy update(경사 상승).



좌: 점수 내고 **최댓값** 뽑기. 우: 확률 내고 **샘플링**.

핵심 질문: "점수를 올리는 방향"이 아니라 분포 자체를 어떻게 고치겠는가? — Policy Gradient Theorem이 답하는 질문.

“점수 $\rightarrow$ argmax” 중간 단계를 건너뛴다

- Week 6·9: $Q(s,a)$를 먼저 배우고, $\pi(s) = \arg\max_a Q(s,a)$ 로 **간접**적으로 정책 획득.
- **정책기반 방법**: 이 중간 단계를 **건너뛰고**, $\pi_\theta(a|s)$ (행동의 확률분포를 직접 내놓는 함수) 자체를 신경망으로 표현해 학습.
- 연속 공간에서도 “이 행동의 확률밀도가 얼마인가”는 잘 정의됨 $\rightarrow$ argmax 문제가 자연스럽게 해결.

이 선택의 대가, 한 줄로

가치기반 = **표**(각 행동의 “얼마나 좋은지”)를 배우고 뒤에 결정 규칙을 붙임. 정책기반 = 표를 버리고 **행동을 고르는 습관**을 배우고 “습관을 고치는 방향”을 보상으로 직접 계산. “표 $\rightarrow$ 조회” 두 단계가 “샘플링” 한 단계로 **병합**.

용어: 이번 장의 “정책”은

같은 상태에서 **여러 행동**을 각자 다른 확률로 고름 — 샘플링이 곧 탐험. (매 상태에서 항상 같은 행동인 **결정적** $\pi(s) = a$ 는 Week 6·9의 argmax 방식이 본질적 형태, Week 13 DDPG/TD3/SAC에서 다룸.) “정책 = 확률분포”로 읽으면 “정책의 그래디언트”가 $\nabla_\theta \log \pi_\theta(a|s)$, 즉 **확률의 미분**임이 자연스럽게 읽힘.

이산 정책: softmax와 그 두 성질

$$\pi_\theta(a|s) = \text{softmax}(f_\theta(s))_a, \qquad p_a = \pi_\theta(a|s) = \frac{e^{z_a}}{\sum_{a'} e^{z_{a'}}}$$

- $f_\theta(s)$: 상태 $\to$ 각 행동의 **원점수(logit)** 를 내는 신경망. softmax가 "숫자"를 "합이 1인 확률"로 변환.
- 목표: $J(\theta) = \mathbb{E}_{\tau\sim\pi_\theta}[R(\tau)]$ 를 최대화. τ = 궤적(에피소드 전체), $R(\tau)$ = 총 보상.

두 성질 — 이번 절 전체에서 반복 등장

(1) 합이 1 — 한 행동의 확률을 올리면 **나머지는 반드시 내려감** $\to$ one-vs-rest 그래디언트 모양의 이유. **(2) 미분 가능** — θ가 z를, z가 확률을 **매끄럽게** 끔.

"미분 가능한 함수로 표현된 것"이 곧 **파라미터화** = 그래디언트 최적화의 **필요조건**.

연속 정책: 확률분포를 "생성"하는 상태 조건부 정규

이산: 행동 유한 $\rightarrow$ softmax로 나열하면 끝. 연속 ($\mathbb{R}^d$: 로봇 관절 각도, 힘의 크기): **확률밀도를 내는 분포 자체**가 파라미터화 대상. 표준 선택:

$$\pi_\theta(a|s) = \mathcal{N}\big(a\,;\,\mu_\theta(s),\ \Sigma_\theta(s)\big), \qquad a \sim \mathcal{N}\big(\mu_\theta(s),\,\Sigma_\theta(s)\big)$$

- 신경망 출력을 둘로 나눔: **평균** $\mu_\theta(s)$ ("이 상태의 중심 행동") · **분산** $\Sigma_\theta(s)$ ("주변으로 얼마나 넓게 탐색").
- Σ 학습 $\rightarrow$ 탐색 강도가 **상태에 따라 달라지는** 양 $\rightarrow$ 탐색-착취가 ϵ-greedy(Week 2) 같은 전역 상수가 아니라 **상태별로 학습**. (Week 13–14 Pendulum이 바로 이 구조)
- 흔한 변형: 표준편차 $\sigma_\theta(s)$를 **로그 스케일**로 내서 $\Sigma = \mathrm{diag}(\sigma_\theta^2)$. (대각 분산 = 각 관절 독립 탐색 = PPO 기본 설정)

로그밀도도 준비 — 그래디언트 식의 $\log \pi$ 자리에: $\log \pi_\theta(a|s) = -\frac{1}{2}(a-\mu_\theta)^T \Sigma_\theta^{-1}(a-\mu_\theta) - \frac{1}{2}\log|\Sigma_\theta| - \frac{d}{2}\log 2\pi$

왜 정규분포인가 — 세 가지 이유가 겹침

1. **지지가 전체** $\mathbb{R}^d$ — 어떤 연속 행동도 이론적으로 가능한 확률을 가짐.
2. **미분이 깨끗하다** — 평균에 대해선 $\nabla_\mu \log \pi = \Sigma^{-1}(a-\mu)$ 로 **선형**, 자유도 $d(d+1)/2$ 개.
3. **최대 엔트로피 원리** — 이산의 softmax가 합 1 제약하의 "최대 엔트로피 분포"라면, 연속에서는 같은 원리가 **정규분포**를 만듦. (아래 FAQ에서 증명)

한 줄

세 이유가 겹치므로 "연속 정책의 표준 파라미터화 = 조건부 정규분포".

엔트로피 보너스: 탐색이 "학습 목표로" 들어가도 되는가

- softmax 이산 정책: 탐색은 **내장**(모든 로짓에서 모든 행동에 양의 확률). 그런데 훈련하다 π_θ가 **디랙 근사**(한 행동만)로 수렴하면 탐색 **사라짐**.
- 표준 기법 = **엔트로피 보너스**: 목적함수에 엔트로피를 더함.

$$J_{\text{ent}}(\theta) = \mathbb{E}_\tau[R(\tau)] - \beta\,\mathbb{E}_{s\sim\rho}\big[H_\theta(s)\big], \quad H_\theta(s) := -\sum_a \pi_\theta(a|s)\log\pi_\theta(a|s)$$

- $H_\theta(s)$: 행동 분포가 얼마나 "퍼져 있는가". $H > 0$ 유지 $\rightarrow$ 한쪽 확률 1로 수렴하는 퇴화 방지.
- $\beta = 0$: 순수 리턴 최대화. β 큼 $\rightarrow$ 탐색 강화. β **는 작게**(예: 10^{-3}) — 커지면 "탐색만 하고 보상엔 관심 없음".

엔트로피의 그래디언트도 같은 구조: $\nabla_\theta\mathbb{E}_s[H_\theta] = \mathbb{E}_s[\mathbb{E}_{a\sim\pi}[\nabla_\theta \log\pi\,(-\log\pi_\theta(a|s))]]$ — $\nabla_\theta\log\pi$ 로 표현.
REINFORCE·A2C·PPO는 모두 G_t 대신 $-\log\pi$ 를 "가중치"로 쓰는 **같은** 업데이트 식. (PPO 목적함수에도 $\mathbb{E}[\min(r_t\hat{A}_t, \text{clip}(\cdots))] - \beta H$ 로 포함)

“보상을 미분한다”와 벽의 두 얼굴

- “기대 보상을 최대화하는 θ”를 **그대로** 미분하려 하면: 기대 보상은 **무작위로** 행동해 얻은 결과의 평균인데, 그 무작위성 자체가 θ 에 의존.
- 2행동 밴딧(보상 $+1/-1$, 1스텝, $s=1$ 고정)으로 펼쳐보면:

$$J(\theta) = p_0(+1) + p_1(-1) = 2\,p_0(\theta) - 1$$

— θ 에 대해 **매끄럽게** 미분 가능, 벽은 아직 안 보임.

벽은 두 얼굴로 분리된다

(1) 적분의 미분 — ∇_θ 를 $\mathbb{E}$ 안으로 넘기려면 분포가 θ 에 대해 미분 가능해야 함. 이산+유한이면 유한 합으로 안전하나, **행동 연속이거나 상태 고차원**이면 궤적 확률이 **적분** $\rightarrow$ 그 미분은 실제로 불가능.

(2) 단절된 샘플 — 단일 샘플 추정치 $\hat{J} = R(\tau_{\text{sample}})$ 는 θ 에 **무관한 상수**(뽑힌 궤적은 이미 결정된 일) $\rightarrow$ 단일 추정치의 미분은 0.

둘 다 **같은 “분포의 미분” 문제** — 로그미분 트릭이 **동시에** 해결.

로그미분 트릭과 Policy Gradient Theorem

로그미분 트릭 — 항등식 $\nabla_\theta \pi_\theta = \pi_\theta \nabla_\theta \log \pi_\theta$ ($\nabla \log f = \nabla f / f$ 에서, $f > 0$ 이면 무조건 성립): 미분이 확률 **밖으로** 빠져나오지 않고, 다시 **기댓값 형태**로 정리 가능. 최종 결과 — **Policy Gradient Theorem** (Williams, 1992; Sutton et al., 1999):

$$\nabla_\theta J(\theta) = \mathbb{E}_\tau \left[\sum_t \nabla_\theta \log \pi_\theta(a_t|s_t)\, G_t \right]$$

- G_t: 시점 t 부터의 할인된 누적 보상 (Week 3 return).

직관: "결과가 좋았던(G_t 큰) 궤적에서 실제로 고른 행동의 확률을 올리고, 나빴던 행동의 확률은 낮추는" 방향으로 θ 이동.

왜 로그인가: $\nabla \pi$ 는 **절대** 변화율 (p: 0.01→0.02 와 0.9→0.99 를 $+0.01$ 로 동률), $\nabla \log \pi = \nabla \pi / \pi$ 는 **상대** 변화율 ("배율로 올린다"는 표현에 자연스러움). 상대 변화율이 기댓값 안의 가중치가 되므로, "기울어 있는 정도"를 샘플 하나로 추정 가능 — "단절된 단일 샘플" 문제를 푸는 핵심 메커니즘.

유도: 궤적 확률에서 "환경이 사라지는 순간"

궤적 $\tau = (s_0, a_0, r_1, s_1, \dots)$ 의 확률 = 환경 전이확률 $\times$ 정책:

$$P(\tau;\theta) = P(s_0) \prod_t \pi_\theta(a_t|s_t)\; P(s_{t+1}|s_t, a_t)$$

미분(유한 궤적 공간에서 합/미분 교환은 안전):

$$\nabla_\theta J = \sum_\tau R(\tau)\, \nabla_\theta P(\tau;\theta)$$

로그미분 트릭 적용 $\rightarrow$ 다시 기댓값 형태:

$$\nabla_\theta P = P\, \nabla_\theta \log P \quad \Rightarrow \quad \nabla_\theta J = \mathbb{E}_\tau \big[R(\tau)\, \nabla_\theta \log P(\tau;\theta) \big]$$

핵심 단계 — log 로 곱을 합으로 분해:

$$\log P(\tau;\theta) = \log P(s_0) + \sum_t \big[\log \pi_\theta(a_t|s_t) + \log P(s_{t+1}|s_t, a_t) \big]$$

θ 로 미분하면 $\log P(s_0)$ (상수)와 $\log P(s_{t+1}|s_t, a_t)$ (환경, θ 와 무관)은 **미분되자마자 0**:

$$\nabla_\theta \log P(\tau;\theta) = \sum_t \nabla_\theta \log \pi_\theta(a_t|s_t)$$

- 무한 궤적 공간에서는 미분/적분 교환 조건 필요 — 정책 파라미터화가 매끄럽고 궤적 공간의 **측도가 θ 에 무관**할 때

최종 정리: R 을 시점별 리턴 G_t 로, 그리고 model-free

기댓값에 대입한 뒤, $R(\tau) = \sum_t r_t$ 를 시점별 **리턴** $G_t = \sum_{t' \geq t} \gamma^{t'-t} r_{t'}$ 로 바꿈:

$$\nabla_\theta J(\theta) = \mathbb{E}_\tau \left[\sum_t \nabla_\theta \log \pi_\theta(a_t|s_t)\, G_t \right], \qquad \hat{g}(\tau) = \sum_t \nabla_\theta \log \pi_\theta(a_t|s_t)\, G_t$$

- 각 $\nabla_\theta \log \pi(a_t|s_t)$ 가 **자기 시점부터의** G_t 를 가중치로 씀 — "시점 t 의 행동은 t 이후의 보상만 책임진다"는 **인과적 구조**.
- **단일 샘플 추정치** $\hat{g}(\tau)$ 의 **기댓값**이 참 그래디언트 — "단절된 R" 대신 **미분 가능한** $\nabla_\theta \log P$ 를 가중치로 쓴 셈. (10.2절 REINFORCE가 바로 이 $\hat{g}$ 를 계산)

model-free의 핵심 성질이 "사라진 항"에서 온다

$\nabla_\theta \log P(s_{t+1}|s_t, a_t) = 0$ 이라 최종 식에 **환경 파라미터가 하나도** 남지 않음. $\Rightarrow$ **환경 모델을 몰라도 정책을 학습할 수 있다** — Week 4 벨만방정식(환경 모델 전제)과 대비되는 정책기반의 본질.

“확률합 $= 1$” 제약이 만든 모양: one-vs-rest

2행동 softmax, $\theta = [\theta_0, \theta_1]$, 로짓 $z_k = \theta_k s$:

$$\nabla_\theta \log \pi_\theta(0|s) = \big[(1 - p_0)\, s,\ -p_1\, s\big], \qquad \nabla_\theta \log \pi_\theta(1|s) = \big[-p_0\, s,\ (1 - p_1)\, s\big]$$

- **고른 행동**의 파라미터 성분 $(1 - p_a)$, **고르지 않은** 행동 $-p_a$ — **one-vs-rest**.
- 유래 = “확률합 $= 1$”: $p_0 \uparrow$ 면 반드시 $p_1 = 1 - p_0$ 가 $\downarrow$.
- “행동 0 확률 올리는 방향”은 구조적으로 “행동 1 확률 내리는 방향”과 **동일 벡터**.

이 제약이 만든 두 번째 성질은 다음 프레임 — “기대 그래디언트가 0”이라는, 10.2·10.3 베이스라인 논리의 공통 출발점.

수학적 핵심: $\mathbb{E}[\nabla_\theta \log \pi] = 0$

$$\mathbb{E}_{a\sim\pi(\cdot|s)}\left[\nabla_\theta \log \pi_\theta(a|s)\right] = \sum_a \pi_\theta(a|s)\, \nabla_\theta \log \pi_\theta(a|s) = \nabla_\theta \underbrace{\sum_a \pi_\theta(a|s)}_{=1} = 0$$

세 단계:

1. $\nabla \log \pi = \nabla\pi/\pi$ 로 $\pi \nabla \log \pi = \nabla \pi$.
2. 합과 미분의 교환.
3. 확률합이 **상수 1**이므로 그 미분은 0.

숫자로 확인: $p_0 = 0.6,\ p_1 = 0.4$

$$0.6\,[0.4,\ -0.4]\ +\ 0.4\,[-0.6,\ 0.6] = [0.24, -0.24] + [-0.24, 0.24] = [0,\ 0]$$

두 성분이 정확히 상쇄 — 임의의 θ 에서 성립(우연 아님).

기억할 사슬: "확률합 $= 1$" $\rightarrow$ "기대 로그미분 그래디언트 $= 0$" $\rightarrow$ 베이스라인 자유도(10.2·10.3의 논리가 이 정리의 부수 결과로 읽힘).

정규 정책에도 같은 구조: 평균 갱신 = "예측-실제 차이"

이산(softmax)이든 연속(정규)이든 $\nabla_\theta \log \pi$ 의 **형태만** 바뀌고 Policy Gradient Theorem의 구조는 동일. 정규 정책 $\pi_\theta(a|s) = \mathcal{N}(a;\, \mu_\theta(s), \sigma_\theta^2 I)$ (대각 분산, σ 로그 스케일)에서:

$$\nabla_\mu \log \pi_\theta(a|s) = \frac{(a - \mu_\theta(s))}{\sigma_\theta^2}$$

- "실제로 고른 a 가 예측 평균 μ 에서 얼마나 벗어나는가"를 σ^2 로 나눈 벡터.
- $a = \mu$ (예측 정확히 맞음) $\rightarrow$ 그래디언트 **0** — "고칠 것 없음".
- $a > \mu$ 이고 $G_t > 0 \rightarrow \mu$ 를 **올리는** 방향 — "예측보다 큰 행동을 골랐고 결과가 좋았으니, 예측 평균을 그쪽으로".

이번 절에서 기억할 것

평균 μ 의 갱신 = "예측-실제 차이"의 방향 (분산 σ^2 에 대한 그래디언트도 존재 — 10.3 A2C/PPO에서 σ 동시 학습). 이 직관이 Week 11 PPO "왜 σ 를 클리핑하지 않는가" 질문의 출발점.

손으로 한 스텝 (1/2): 좋은 경우 $G_t = +1$

2행동 밴딧(보상 $+1/-1$, 1스텝, $s=1$). $\theta = [1, 0]$, $\alpha = 0.1$, $G_t = +1$ (행동 0 샘플링).

$$p_0 = \text{softmax}([1,0])_0 = \frac{e^1}{e^1 + 1} \approx 0.7311, \qquad p_1 \approx 0.2689$$

$$\nabla_\theta \log \pi_\theta(0|1) = \big[(1 - 0.7311),\ -0.2689\big] = [0.2689,\ -0.2689]$$

갱신(경사 상승 — 최대화이므로 $+$):

$$\theta \leftarrow [1,0] + 0.1 \times 1 \times [0.2689, -0.2689] = [1.0269,\ -0.0269]$$

새 정책: $p_0' \approx \mathbf{0.7415}$, $p_1' \approx 0.2585$.

읽어볼 것

p_0: $0.7311 \to$ **0.7415**로 **올랐다** — 좋은 결과를 낸 행동 0의 확률이 실제로 증가. p_1 도 $0.2689 \to 0.2585$로 **내려감** — one-vs-rest의 "고르지 않은 행동도 갱신된다" 성질.

손으로 한 스텝 (2/2): 나쁜 경우 $G_t = -1$

같은 초기 $\theta = [1, 0]$, 이번엔 $G_t = -1$, **행동 1** 샘플링:

$$\nabla_\theta \log \pi_\theta(1|1) = \big[-0.7311,\ (1 - 0.2689) \big] = [-0.7311,\ 0.7311]$$

$$\theta \leftarrow [1, 0] + 0.1 \times (-1) \times [-0.7311,\ 0.7311] = [1.0731,\ -0.0731]$$

새 정책: $p_0' \approx \mathbf{0.7588}$, $p_1' \approx 0.2412$.

- $G_t = -1$(나쁜 결과)가 행동 1에 부여 $\rightarrow$ "나쁜 결과를 낸 행동 1의 확률을 내리자".
- p_1: $0.2689 \rightarrow 0.2412$로 내려가는 **대신**, 합 1 제약 때문에 p_0 가 **자동으로** 올라감.

"나쁜 행동을 내리면 좋은 행동은 자동으로 올라간다" — 이것이 one-vs-rest 구조의 본질.

10.2절 "손으로 한 번 갱신하기" 블록이 같은 계산 ($\alpha = 0.1$, $G = \pm 3$)을 더 크게 보여준다.

정리의 "약점": 기댓값은 정확하지만 분산이 크다

- 기댓값은 정확하나, 단일 샘플 $\hat{g}(\tau)$ 의 분산이 **크다** — G_t 가 **에피소드 전체** 보상 누적 이라 **운**(초기 상태의 불운, 중간 선택의 불운)에 크게 의존.
- 같은 θ 로 두 에피소드: 행운으로 오래 버튼 쪽은 G_t 크게 양수, 불운으로 일찍 끝난 쪽은 작음(또는 음수). 평균은 참 값에 가깝지만 **단일** 샘플은 멀리.
- **몬테카를로 추정**이 바로 가능한 이유도 기대 형태: 참 그래디언트 $\mathbb{E}_\tau[\cdot]$, 단일 샘플 $\hat{g}$, N 샘플 $\hat{g}_N = \frac{1}{N}\sum_i \hat{g}(\tau_i) \xrightarrow{N\to\infty}$ 참 그래디언트(대수법칙).

10.2절에서 숫자로 확인될 것

REINFORCE CartPole 300 에피소드: 처음 20 에피소드 평균 14.1 $\rightarrow$ 마지막 20 에피소드 평균 99.5. 시드 세 번을 바꾸면 **곡선 모양이 다름** — 어떤 시드는 194 에피소드만에 250 돌파, 다른 시드는 300까지 150 안팎. **같은 알고리즘, 같은 환경, 다른 곡선**.

이산 vs 연속: 두 정책 파라미터화 한눈에

	이산 (softmax)	연속 (정규)
행동 공간	유한 $\{0, 1, \dots\}$	$\mathbb{R}^d$
분포	카테고리컬	가우시안 $\mathcal{N}(\mu, \Sigma)$
신경망 출력	로짓 z_a (각 행동 하나)	평균 μ + 분산 Σ
로그밀도	$\log z_a - \log \sum_{a'} z_{a'}$	$-\frac{1}{2}(a-\mu)^T\Sigma^{-1}(a-\mu) - \frac{1}{2}\log\lvert\Sigma\rvert - \frac{d}{2}\log 2\pi$
$\nabla_\theta \log \pi$	one-vs-rest	$\Sigma^{-1}(a-\mu)$ (평균 부분)
탐색 메커니즘	softmax 자체	분산 Σ 학습
엔트로피	$-\sum_a p_a \log p_a$	$\frac{d}{2}(1 + \log 2\pi e\, \sigma^2)$
사용 장소	CartPole, Atari	로봇 시뮬레이션 (Week 13–14)

구조 동일성이 policy gradient의 힘

둘 다 $\nabla_\theta J = \mathbb{E}[\sum_t \nabla_\theta \log \pi_\theta(a_t|s_t)\, G_t]$ 를 공유 — 다만 $\nabla_\theta \log \pi$ 의 **형태만** 다름.

주의: 엔트로피 행 — 이산(비트 단위)과 연속(자연로그 단위)의 **단위가 다름** $\rightarrow$ β(엔트로피 보너스 계수)를 이산$\leftrightarrow$연속 사이에 직접 이관 불가. Week 13–14에서 β 튜닝 시 직접 부딪힘.

확인 문제 (10.1)

1. **벽의 두 얼굴** — (a) 적분의 미분, (b) 단절된 샘플을 로그미분 트릭이 각각 어떻게 해결하는지 한 문장씩. (힌트: “미분이 확률 밖으로 나간다”의 구체적 의미)
2. **3단계 증명** — $\mathbb{E}[\nabla_\theta \log \pi] = 0$ 증명 중 어느 단계가 실제로 “제약 $\sum_a \pi = 1$”을 쓰나? (힌트: 상수 1의 미분이 0인 사실은 제약 없이는 성립하지 않음)
3. **연속 정책** — $\nabla_\mu \log \pi = (a-\mu)/\sigma^2$ 도출. $a = 5,\ \mu = 3,\ \sigma^2 = 1$ 에서 값 계산하고, $G_t = +2$ 일 때 μ 방향 예측.
4. **이산 vs 연속** — 엔트로피 두 형태의 차이(단위: 비트 vs 냅)와 그것이 β 튜닝에 미치는 실무적 영향.
5. **model-free** — “환경이 사라지는 순간”이 없으면 무엇이 깨지는가? (힌트: “환경 모델을 몰라도 정책 학습”)

역사: “스코어 함수” 뒤에 숨은 100년

- “로그미분 트릭”이라는 **이름**은 RL 문헌에서 1990년대에 정착, **수학**은 훨씬 오래됨.
- $\nabla \log f = \nabla f / f$ 는 미분 공부 첫 달의 기본 공식.
- 기댓값 내 미분을 샘플로 추정하는 기법은 통계학에서 **스코어 함수 추정치**(score function estimator)로 1900년대 초부터 존재 — 스코어 함수 $\nabla_\theta \log f(x;\theta)$ 는 **최대 우도 추정(MLE)**의 핵심(우도의 로그를 미분해 0이 되는 점 찾기).
- Williams (1992)가 정책 그래디언트를 정식 논증할 때, 동일 알고리즘을 스코어 함수 추정치와 **정확히 동일**하게 식별 $\rightarrow$ “RL 발명”이 아니라 **고전 통계 기법의 RL 적용**.

반면 Sutton의 1984년 박사논문에는 이미 “행동의 결과를 보면서 행동 확률을 조정”하는 같은 계열 알고리즘이 있음 — **수학적 근거가 알고리즘 발명 이후에 정식화된** 예. “발명 이후 이론화”가 policy gradient 방법의 특별한 역사. (10.2절 역사에서 다시 만남)

자주 하는 실수 (10.1)

1. $\nabla \log \pi$ 와 $\nabla \pi$ 혼용

- 항등식 $\nabla_\theta \pi = \pi \nabla_\theta \log \pi$ 로 **전환 가능**하나 **동일하지 않음**: 절대 변화율 vs 상대 변화율.
- 실습에서 `log_prob` 대신 `prob` 를 직접 미분하면 **분산이 급격히 증가** — π 가 작은 행동에서 $\nabla \pi$ 도 작아져 **신호가 희미**해짐.

2. 기댓값 내 미분 교환 조건 무시

- ∇_θ 와 $\mathbb{E}$ 교환이 안전하려면: 정책 파라미터화 **매끄럽고**, 궤적 공간의 **측도가 θ 에 무관**해야 함.
- 조건이 깨지면(예: θ 에 의존하는 가변 크기의 유한 합 행동 공간) **정리 자체가 성립하지 않음**.

3. 베이스라인이 행동 a 에 의존하는 값 사용

- b 가 a 에 의존하면 $\mathbb{E}[\nabla_\theta \log \pi \cdot b] = 0$ 이 **깨져 편향** 발생 ("한 적이 많으면 더 크게 빼자"의 $b(a, s)$ 가 예).
- **베이스라인은 상태 s 에만 의존해야 한다**.

FAQ: 정규분포는 왜 "최대 엔트로피" 분포인가

- 이산: "무차별 시 엔트로피 최대" 원리 $\rightarrow$ 모든 행동에 균등 확률 $1/K$ $\rightarrow$ 엔트로피 최대 분포 = **균등 분포**.
- 연속: **같은** 원리를 적용하면 **정규분포**.

증명 (변분법, 간단)

엔트로피 $h(p)$ 를 p 에 대해 최대화하되 $\mathbb{E}_p[x] = \mu$, $\mathbb{E}_p[x^2] = \mu^2 + \sigma^2$ 제약 아래 변분하면, 결과 분포 $p(x) = \exp(-\lambda_0 - \lambda_1 x - \lambda_2 x^2)$ — **정규분포**.

- $\rightarrow$ 정규 정책이 "**가장 보수적** 파라미터화": 평균·분산 제약 아래 엔트로피 최대 = "정보를 최소로 가정"하는 분포. 학습 초기엔 **안전**하나, 복잡한 분포 구조의 행동 공간에선 **표현력 한계**.

한계 극복 연구: GAN 기반 정책, 미분 가능 정상 흐름 (normalizing flow) 정책.

자주 묻는 질문 (10.1)

- **Q: 정책기반이 가치기반보다 항상 나은가? 아님.** 연속 공간에선 사실상 유일 선택지이나, 이산 공간이 작고 데이터가 충분하면 Q-learning/DQN이 더 **안정적** 이고 **데이터 효율적**인 경우가 많음 (10.2 실습에서 CartPole로 직접 비교).
- **Q: 연속 공간의 $\pi_\theta(a|s)$ 는 어떤 형태?** 신경망이 정규분포의 $\mu_\theta(s), \sigma_\theta(s)$ 를 출력, 행동은 그 분포에서 샘플링. 로그미분 트릭은 이산/연속 **동일**($\log \pi$ 가 정규 로그밀도로 바뀔 뿐). Week 13–14 로봇 시뮬레이션이 바로 이 구조.
- **Q: 결정적 정책 $\pi(s) = a$ 에는?** 이 정리는 **확률적** 정책에 대한 것. 결정적 정책은 샘플링 단계가 없으므로 $\nabla_\theta \log \pi$ 대신 $\nabla_\theta a$ 가 등장 (Week 13 DDPG/TD3/SAC). 둘 다 policy gradient family이나 **미분 대상이 다름**.
- **Q: "기댓값이 정확하다"의 정확한 의미?** $\mathbb{E}[\hat{g}(\tau)] = \nabla_\theta J$(참 그래디언트) — 단일 샘플 $\hat{g}(\tau)$ 자체가 참 값과 멀어질 수 있음(분산 큼). "기댓값 정확" $\neq$ "단일 샘플 정확".

10.2 REINFORCE와 실습

위치: 정리에서 알고리즘으로

10.1에서 “무작위 결과인데도 미분할 수 있다”는 큰 걸음 — Policy Gradient Theorem:

$$\nabla_\theta J(\theta) = \mathbb{E}_\tau \left[\sum_t \nabla_\theta \log \pi_\theta(a_t|s_t)\, G_t \right]$$

- 그런데 “식은 얻었다”와 “실행할 수 있다”는 **다른 문제**. 알고리즘으로 바꾸려면 두 질문을 답해야:

1. $\nabla_\theta \log \pi_\theta(a_t|s_t)$ **는 어떤 모양인가?** — softmax 파라미터화에 대해 실제로 미분.
2. $\mathbb{E}_\tau$ **는 어떤 샘플로 추정하나?** — 가장 단순한 선택: 현재 정책으로 에피소드 **한 번** 굴려서, 실제로 관찰한 G_t 와 실제로 고른 행동의 $\log \pi_\theta$ 를 사용.

이번 절의

이 “가능한 가장 단순한” 선택을 **모두** 채택한 알고리즘. 이 **단순함** 그 자체가 교육적 가치 (“역사”에서 다시 볼 것) — 이동 부품을 최소화해서 **코드 한 줄이 정리 한 항과 직접 대응**.

REINFORCE: 정리를 그대로 경사 상승으로

```python
import math

def softmax_policy(theta, state_feature):
    logits = [theta[0]*state_feature, theta[1]*state_feature]
    m = max(logits)
    exps = [math.exp(l - m) for l in logits]   # 수치안정화
    total = sum(exps)
    return [e / total for e in exps]

def reinforce_update(theta, episode, alpha, gamma):
    # episode: [(state_feature, action, reward), ...]
    T = len(episode)
    G = [0.0] * T
    running = 0.0
    for t in reversed(range(T)):            # 루프 1: 리턴 G_t 역산
        running = episode[t][2] + gamma * running
        G[t] = running
    for t, (s, a, r) in enumerate(episode): # 루프 2: 스텝별갱신
        probs = softmax_policy(theta, s)
        if a == 0:
            grad_log_pi = [(1 - probs[0]) * s, -probs[1] * s]
        else:
            grad_log_pi = [-probs[0] * s, (1 - probs[1]) * s]
        theta[0] += alpha * G[t] * grad_log_pi[0]
```

코드가 실제로 하는 일: 두 개의 루프와 one-vs-rest

루프 1 (뒤에서부터): 리턴 G_t 계산

- 마지막 스텝에서 시작해 $G_t = r_t + \gamma G_{t+1}$ 로 **거꾸로 누적**.
- Week 3의 리턴 정의, 그대로.

루프 2 (앞에서부터): 스텝별 갱신

- (a) 현재 π_θ 로 p_0, p_1 계산.
- (b) 실제로 고른 a_t 의 $\log \pi_\theta(a_t|s_t)$ 그래디언트 계산.
- (c) 그걸 G_t 로 **곱해** θ 조금 옮김 ($+=-$ 경사 **상승**).

softmax 그래디언트의 모양 — one-vs-rest

$$\frac{\partial \log \pi_\theta(0|s)}{\partial \theta} = \big[(1-p_0)s,\ -p_1 s\big], \qquad \frac{\partial \log \pi_\theta(1|s)}{\partial \theta} = \big[-p_0 s,\ (1-p_1)s\big]$$

고른 행동 $(1-p_a)$, 나머지는 $-p_a$. 이유 = **확률합 항상 1** — 한 확률을 올리면 다른 것이 **반드시** 내려가므로, "고른 행동을 올리는" 갱신은 "고르지 않은 것을 내리는" 갱신이 **동시에** 됨.

두 루프 순서가 REINFORCE가 **에피소드 완료**를 기다리는 이유: 전체 G_t 를 다 구해야 각 스텝의 가중치가 정해짐.

손으로 한 번 (1/2): 좋은 경우 $G_t = +3$

$\theta = [1, 0]$, $s = 1$, 정책이 **행동 0**을 고랐고 리턴 $G_t = 3.0$ ($\alpha = 0.1$):

$$\text{softmax}([1,0]) = [0.7311,\ 0.2689], \qquad \nabla \log \pi(0|1) = [0.2689,\ -0.2689]$$

$$\theta \leftarrow [1,0] + 0.1 \times 3.0 \times [0.2689, -0.2689] = [1.0807,\ -0.0807]$$

읽어볼 것

p_0: $0.7311 \rightarrow$ **0.7617** 로 **올랐다** — 좋은 결과(큰 양의 리턴)를 낸 행동의 확률이 실제로 증가.

손으로 한 번 (2/2): 나쁜 경우 $G_t = -3$

같은 $\theta = [1, 0]$, $s = 1$, 이번엔 **행동 1**을 고르고 리턴 $G_t = -3.0$:

$$\nabla \log \pi(1|1) = [-0.7311,\ 0.7311]$$

$$\theta \leftarrow [1, 0] + 0.1 \times (-3) \times [-0.7311,\ 0.7311] = [1.2193,\ -0.2193]$$

- p_1: $0.2689 \rightarrow$ **0.1918** 로 **내려가고**, p_0 는 0.8082 로 **올라감**.
- (행동 0을 골라 $G_t = +3$ 인 갱신에서도 **고르지 않은** 행동 1의 확률이 $0.2689 \rightarrow 0.2384$ 로 내려감 — one-vs-rest: θ_1 성분에도 갱신이 들어옴)

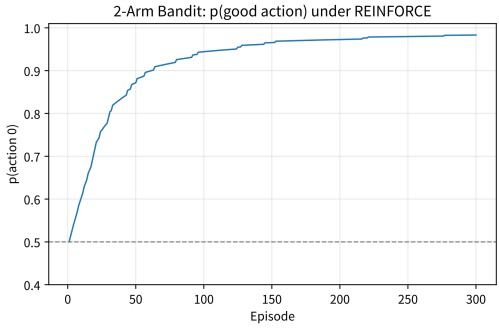
두 경우 공통의 직관

"**좋은 것 많이, 나쁜 것 적게**" — 갱신 방향이 리턴 부호에 따라 정확히 일치.

밴딧 실험: “좋은 행동을 더 선호한다”를 눈으로

- **2-arm 밴딧**: 행동 0 $\rightarrow +1$, 행동 1 $\rightarrow -1$ (1스텝 $\rightarrow G_t = r_t$, γ 무관).
- $\theta = [0, 0]$(반반)에서 시작, $\alpha = 0.05$, **300 에피소드**:

```
p(행동 0): 1회 = 0.5000 -> 50회 = 0.8719
        -> 100회 = 0.9443
        -> 200회 = 0.9727 -> 300회 = 0.9832
최종 theta = [2.0352, -2.0352]
```



“정답”이 있는 환경에서 좋은 행동 확률이 50% $\rightarrow$ 100%에 가까워져야 하는데 **그렇게 된다** — REINFORCE의 “smoke test”.

p(행동 0): 0.5 (무작위) $\rightarrow$ 0.98 (거의 확정), 300 에피소드.

곡선의 “모양”: 학습의 대부분(0.5$\rightarrow$0.87)은 처음 50 에피소드에 집중, 이후 1에 점근하듯 느림.

왜 이렇게 느리게 수렴하는가

힌트

p_0 가 1에 가까워질수록:

- 그래디언트 성분 $(1 - p_0)$ 이 **줄어** "더 올릴 힘"이 약해지고,
- "나쁜 행동"을 샘플링해 자신감을 **교정**해줄 기회도 줄어듦.

$\rightarrow$ 단일 샘플 G_t 로 업데이트하는 **모든** REINFORCE 계열 알고리즘의 **본질적 특성**.

10.3절에서 가치함수로 추정하는 것(또는 더 많은 샘플을 쓰는 것)이 이 "느림"을 공격하는 방법 중 하나.

왜 이게 model-free인가 — 다시 한 번

궤적 확률 $P(\tau;\theta) = \prod_t \pi_\theta(a_t|s_t)\, P(s_{t+1}|s_t, a_t)$ 를 **로그**로 바꾸면, 환경 전이확률 항은 θ 와 **무관**해서 미분하면 **사라짐**. 최종 식에는 정책 π_θ **만** 남고 환경 모델은 전혀 등장하지 않음 — model-free의 핵심 성질이 여기서 나옴.

PyTorch REINFORCE (1/2): PolicyNet과 에피소드 실행

자동 미분을 이용하면 훨씬 **간결**하게 같은 알고리즘:

```python
import torch, torch.nn as nn

class PolicyNet(nn.Module):
    def __init__(self, state_dim, n_actions):
        super().__init__()
        self.net = nn.Sequential(
            nn.Linear(state_dim, 64), nn.ReLU(),
            nn.Linear(64, n_actions))
    def forward(self, x):
        return torch.softmax(self.net(x), dim=-1)

policy = PolicyNet(4, 2)              # CartPole: 상태차원 4, 행동개 2
opt  = torch.optim.Adam(policy.parameters(), lr=1e-2)

def run_episode(env, seed):
    s, _ = env.reset(seed=seed)
    log_probs, rewards = [], []
    for _ in range(500):
        probs = policy(torch.tensor(s, dtype=torch.float32))
        dist  = torch.distributions.Categorical(probs)
        a = dist.sample()
        log_probs.append(dist.log_prob(a))    # log pi_theta(a|s)
```

PyTorch REINFORCE (2/2): 리턴 계산과 업데이트

```python
def reinforce_update(log_probs, rewards, gamma):
    G, returns = 0.0, []
    for r in reversed(rewards):            # 루프 1: 리턴역산
        G = r + gamma * G
        returns.insert(0, G)
    returns = torch.tensor(returns, dtype=torch.float32)
    returns = (returns - returns.mean())   # 분산감소용정규화
            /  (returns.std() + 1e-8)
    loss = -sum(lp * g for lp, g in zip(log_probs, returns))
    # 경사상승이므로 "" 부호반전최소화  ( 프레임워크에서로 +)
    opt.zero_grad(); loss.backward(); opt.step()
```

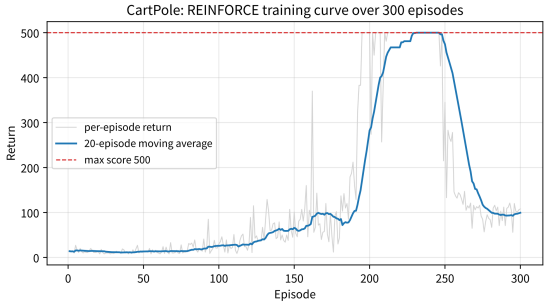
$\log \pi_\theta$ 를 손으로 미분하지 않아도 됨

`torch.distributions.Categorical` 이 `log_prob()` 제공 $\rightarrow$ 10.1절의 $\log \pi_\theta(a_t|s_t)$ 를 **그대로** 획득. 손실을 $-$`log_prob` $\times\, G$ 로 정의하고 `.backward()` 호출 $\rightarrow$ PyTorch가 Policy Gradient Theorem의 그래디언트를 **자동** 계산 (one-vs-rest 식이 정확히 내부 계산 값).

CartPole 300 에피소드: “100대에 포화되지 못한다”

```
처음 20 에피소드 평균 리턴:  14.05
마지막 20 에피소드 평균 리턴: 99.45
학습 중 도달한 최고 리턴:    500.0
```

- seed 0 기준(실제 검증, 실습 노트북에서 재현).
- 정확한 숫자는 시드에 따라 다름 (다른 seed: 마지막 20 평균 144∼191, 최고 359∼500).



연회색 = 에피소드별 리턴, 파란 실선 = 20 에피소드 이동평균(약 13 → 약 100), 빨간 점선 = 만점 500. 개별 에피소드는 큰 변동(노이즈).

큰 그림은 안정적: “10대에서 100대로 오르지만 500에 도달해 포화되지 못한다.”

DQN(Week 9.3)과 비교: 느리고 불안정하게

	처음 20 회 평균	마지막 20 회 평균	최고
REINFORCE (Week 10.2)	14.05	99.45	500
DQN (Week 9.3, 같은 300 에피소드)	–	145.35	500

- REINFORCE는 개선되긴 했으나 (14.05 → 99.45), DQN보다 **훨씬 느리고 불안정하게** 학습.
- 이건 REINFORCE 구현이 **잘못된 게 아니라**, 10.3절의 **"REINFORCE는 분산이 크다"는 알려진 한계**가 실제 숫자로 드러난 것.

다음

10.3 Actor-Critic, Week 11 PPO가 정확히 **이 문제**를 개선하려는 시도.

자주 하는 실수: 리턴을 정규화하지 않고 그대로 쓰기

- `returns = (returns - returns.mean()) / (returns.std() + 1e-8)` 줄을 **빼고** 원래 G_t 를 그대로 쓰면?
- CartPole의 리턴은 **항상 양수**(매 스텝 $+1$) $\rightarrow$ 모든 행동의 그래디언트가 **항상** "그 행동의 확률을 높이는" 방향으로만 움직임.
- 나빴던 행동조차 "**덜 좋았을 뿐** 여전히 양수"라서 그 확률을 계속 높이려 듦.

해결: 평균을 빼면 방향이 생기게 됨

"베이스라인을 빼서 어떤 행동이 평균보다 **나았는지/ 나빴는지**를 상대적으로 비교" (10.3 아이디어)를 가장 단순하게 구현한 것이 바로 이 정규화 — 평균보다 나빴던 행동은 **음수 신호**를 받아 확률이 실제로 **낮아짐**.

“평균을 빼도” 그래디언트 기댓값이 안 바뀌는 이유

상태 s_t 에만 의존(행동과 무관)한 값 $b(s_t)$ 를 빼도, 그래디언트 기댓값은 **그대로**:

$$\mathbb{E}_{a\sim\pi}\Big[(G_t - b(s_t))\,\nabla_\theta \log \pi_\theta(a|s_t)\Big] = \mathbb{E}_{a\sim\pi}\big[G_t \nabla_\theta \log \pi\big] - b(s_t)\underbrace{\mathbb{E}_{a\sim\pi}\big[\nabla_\theta \log \pi_\theta(a|s_t)\big]}_{=\nabla_\theta \sum_a \pi_\theta(a|s_t) = \nabla_\theta 1 = 0}$$

- 핵심은 **밑줄 친 부분**: “각 행동의 확률합이 항상 1”이므로 확률가중평균 그래디언트는 0.
- **베이스라인은 행동을 의존하면 안 된다** — b 가 a 에도 의존하면 이 소거가 깨져 기댓값이 실제로 바뀜(편향).
- 위 정규화 줄 = 이 형태의 가장 단순한 베이스라인 — “**에피소드당 평균 리턴**을 빼기”.

솔직한 비고: 정규화 효과가 시드에 따라 갈릴 수 있다

같은 CartPole에서 정규화 줄을 빼고 재검증한 결과 (마지막 20 에피소드 평균):

	seed 0	seed 1	seed 2
정규화 **있음** (베이스라인)	99.45	191.10	144.20
정규화 **없음** (G_t 그대로)	383.10	139.00	76.15

- seed 0에서는 오히려 "정규화 안 한 쪽"이 더 잘했고, seed **사이의 편차도 넓음**.

"정규화가 무의미하다"는 뜻이 아니라

300 에피소드라는 데이터량으로는 베이스라인의 이득 (분산 감소)이 노이즈에 묻힐 수 있다는 뜻. 베이스라인의 주된 효과는 "더 빠르게"가 아니라 **"에피소드 노이즈 한 방에 학습 곡선을 주행하지 않게"** 하는 것 — 에피소드가 많고 리턴 편차가 클수록 이득이 뚜렷해짐.

베이스라인의 "적은" 형태(에피소드당 평균이 아니라 **상태별** 가치함수 $V(s_t)$)가 10.3절의 Actor-Critic.

역사: 40년 전부터 있는 이름

- “좋은 궤적의 행동 확률을 올리고, 나쁜 궤적의 행동 확률을 내린다”는 아이디어는 생각보다 **오래됨**.
- Sutton의 **1984년** MIT 박사 학위논문에는 이미 “행동의 결과를 보면서 행동 확률을 조정”하는 같은 계열 알고리즘.
- **REINFORCE** (REINforce = reinforcement + force 줄임)라는 구체적 알고리즘은 **1990년대에** 정식 제안.
- Williams (1992): 이 갱신 규칙이 통계학의 고전 기법인 **스코어함수 추정치**와 **정확히 같은 식**임을 보임 (확률적 최적화 문헌에서는 **likelihood ratio method**로 동일 알고리즘이 나타남).

“고전 통계의 미분 추정 기법을 강화학습에 적용한 것”으로 읽을 수도 있음 — 10.1 역사와 같은 뿌리.

REINFORCE는 30년째 안 바뀐 "참고 기준"

- REINFORCE가 30년째 **바뀌지 않는 reference algorithm**.
- 갱신 식 $\theta \leftarrow \theta + \alpha\, G_t \nabla \log \pi_\theta(a_t|s_t)$ 는, 아래 두 가지를 고를 때만 예외로, **오늘날 모든 정책 그래디언트 알고리즘에서 같은 식**:
  - **베이스라인 선택** (10.3 Actor-Critic)
  - **에피소드 경험의 재사용 횟수** (Week 11 PPO)

중요한 포인트

이번 절이 "**빨라서**" 중요한 게 아니라, 이후 모든 개선이 "**REINFORCE의 이 특정 부분을 바꾼 것**"이라는 사실의 **기준점**이 되어서 중요.

자주 묻는 질문 (10.2)

- **Q: 에피소드가 끝날 때까지 갱신 안 한다는 건 Week 5 "몬테카를로" 방식인가? 네.** 실제 관찰된 G_t를 쓰는 점에서 MC와 같은 구조. 다만 분류는 **네 가지 속성**으로: REINFORCE는 **on-policy, model-free, MC 기반, 정책기반**. "정책기반"이 포함된 이유: 배우는 대상이 가치표가 아니라 **정책의 파라미터**, 갱신 방식이 "평균" ($Q \leftarrow Q + \alpha(G - Q)$)이 아니라 "경사 상승" ($\theta \leftarrow \theta + \alpha G \nabla \log \pi$). 정책기반 + **TD** = 10.3 Actor-Critic — "배우는 대상(정책 vs 가치)"과 "갱신 원리(경사 상승 vs 부트스트랩)"은 **독립적인 축**.
- **Q: 최고 리턴 500이 나왔는데, 마지막 20 에피소드 평균이 왜 100 정도?** "최고"는 **단일 행운 에피소드**의 기록 — 분산이 커서 정책이 좋아진 뒤에도 가끔 짧은 에피소드가 나오는 것은 정상. 정책의 "진짜" 수준은 마지막 N 에피소드의 **평균**(또는 별도 평가 롤아웃)으로 판단 (Week 6.3의 "탐욕적 평가로 판단" 교훈과 같음).
- **Q: 긴 지평선 태스크에서는 너무 느럽지 않나요? 그렇다.** 에피소드 하나를 끝까지 기다리는 것은 느리고, G_t는 "여기부터 끝까지" 보상 전체를 담고 있어 분산 큼. 10.3 Actor-Critic은 G_t를 **가치함수 기반 부트스트랩 추정**($G_t - V(s_t)$, 어드밴티지)으로 바꿔 **매 스텝** 갱신 $\rightarrow$ 기다림도 줄고 분산도 줄어듦.

10.2 마무리: REINFORCE가 주는 가치는 “명확함”

한 줄 요약

REINFORCE는 Policy Gradient Theorem의 **가장 단순하고 직접적인 구현** — “결과가 좋았던 궤적에서 고른 행동의 확률을 올리고, 나빴던 행동의 확률은 내린다”는 것을, 관찰된 리턴 G_t 가 좋은/나쁜의 기준으로 삼아 구현.

- 가치는 **속도가 아니라 명확함** — 코드 한 줄이 정리 한 항과 직접 대응.
- 이후 Actor-Critic(10.3) · PPO(Week 11)의 **모든 개선**은 “REINFORCE의 이 특정 부분을 바꾼 것”:

	REINFORCE (10.2)	개선 (10.3, Week 11)
리턴	G_t 그대로	베이스라인 붙인 추정 ($G_t - V(s_t)$)
경험 재사용	에피소드당 1회	여러 회 사용 + 클리핑 (PPO)

10.3 Actor-Critic

Actor-Critic: 분산을 줄이는 개선

- REINFORCE: G_t (실제 관찰된 누적 보상)를 **그대로** 사용 — 하나의 에피소드를 샘플링한 결과라 **노이즈가 크다**(분산 높음).
- **Actor-Critic**: G_t 대신 Week 4·6의 **가치함수** (Critic)로 추정한 기준값을 빼서 분산 감소 — $G_t - V(s_t)$ 의 차이를 **어드밴티지(advantage)**라 부름.
- **정책(Actor)**과 **가치함수(Critic)**를 **동시에** 학습.

핵심 아이디어 (한 줄)

"정책 하나만 학습하는 것보다, **가치함수의 도움**을 받으면 **더 안정적으로** 학습된다." 이 어드밴티지는 Week 11의 PPO에서 **그대로 재사용**됨.

Q-learning이 "얼마나 좋은지 평가한 뒤 최선을 고른다"는 **간접적** 전략이라면, 정책기반 방법은 "무엇을 할지" **자체**를 직접, 연속 행동 공간에서도 학습. 유한 MDP라면 최적 정책 π^* 는 항상 존재 (Week 4) — policy gradient는 그 목표를 향해 **직접** 나아가는 방법.

먼저 문제부터: REINFORCE 신호가 "너무 시끄러운" 이유

- 10.2의 CartPole REINFORCE: 처음 20 에피소드 평균 14.1 $\rightarrow$ 마지막 20 에피소드 평균 99.5, 최고 500 — 배운 것은 배운 것.
- 그런데 **시드를 세 번** 바꿔 실행하면 학습 곡선이 시드마다 **다른 모양**으로 나옴 — 어떤 시드는 98 에피소드만에 리턴 250 돌파, 다른 시드는 300 에피소드 다 배워도 **150 안팎**.
- 이 "거친" 움직임은 코드 버그가 아니라 **REINFORCE 자체의 높은 분산**.

왜 분산이 큰가

G_t 는 "폴이 **몇 스텝 뒤에 무너졌는가**"에 거의 전적으로 의존 (매 스텝 $+1$). 그런데 몇 스텝 뒤로 무너지는가는 "이 스텝의 행동이 좋았는가"와 **별개인 요소** (초기 기울기의 작은 차이, 샘플링의 운). REINFORCE는 그 **운을 신호 크기로 그대로** 받아들임: 운 좋게 오래 버틴 에피소드에선 그 날 행동 **전부**를 크게 강화, 일찍 무너진 에피소드에선 전부 크게 낮춤 — **노이즈 섞인 채** 경사 상승.

“샘플을 더 뽑아 평균”이 바로 먹지 않는 이유

- 이 문제는 Week 5 **중요도 샘플링**과 **같은 뿌리** — “기댓값을 샘플 하나로 추정하면 흔들린다”.
- 그때의 해법 = “**샘플을 더 뽑아 평균**”.

- RL에서는 그 해법이 **그대로 먹지 않음**: 한 에피소드의 샘플은 **현재 정책이 실제로 행동한 결과** 자체라서, “같은 상황에서 더 뽑자”는 말이 쉽게 안 됨 (매 에피소드가 **새 행동의 대가**라는 비용이 있음).

Actor-Critic은 다른 길로 간다

샘플 하나하나에 **“기준값”**을 대고, **절대** 보상이 아니라 **“평균보다 얼마나 더 좋았는지”라는 상대적 향상**으로 신호를 만든다.

베이스라인의 핵심 수학적 사실: 3단계로

$b(s_t)$ 를 **현재 상태 s_t 에만 의존하고, 행동 a_t 에는 전혀 의존하지 않는** 어떤 값이라 하자 (Week 4의 가치함수 $V(s_t)$ 가 대표 예):

$$\mathbb{E}_{a_t\sim\pi(\cdot|s_t)}\big[\nabla_\theta \log \pi_\theta(a_t|s_t)\, b(s_t)\big] = b(s_t)\, \mathbb{E}_{a_t}\big[\nabla_\theta \log \pi_\theta(a_t|s_t)\big] = b(s_t) \underbrace{\sum_{a_t} \nabla_\theta \pi_\theta(a_t|s_t)}_{=0} = 0$$

세 단계:

1. $b(s_t)$ 는 a_t 와 무관한 **상수**라 기댓값 **밖으로** 나옴.
2. $\nabla \log \pi = \nabla \pi / \pi$ 이므로 $\sum_a \pi(a) \nabla \log \pi(a) = \sum_a \nabla \pi(a)$.
3. 모든 행동의 확률 합은 1이고, **상수의 미분은 0**.

한 줄 결론

$$\mathbb{E}\big[(G_t - b(s_t))\, \nabla_\theta \log \pi_\theta(a_t|s_t)\big] = \mathbb{E}\big[G_t\, \nabla_\theta \log \pi_\theta(a_t|s_t)\big] - \underbrace{b(s_t)\, \mathbb{E}\big[\nabla_\theta \log \pi_\theta(a_t|s_t)\big]}_{=0}$$

그래디언트 기댓값(= 진짜 기울기 방향)은 $b(s_t)$ 를 빼도 그대로 — 그런데 **분산만** 줄어듦 (G_t 가

숫자로 검증: 2행동 밴딧 한 스텝

- **1스텝 밴딧**: 행동 0 $\to +1.0$, 행동 1 $\to +1.8$. $s=1$, $\pi(a|s) = \mathrm{softmax}([0,0]) \to p(a=0) = p(a=1) = 0.5$.
- **참값**: $V(s) = 0.5 \times 1.0 + 0.5 \times 1.8 = \mathbf{1.4}$.
- 그래디언트: $\nabla \log \pi(a{=}0) = [0.5, -0.5]$, $\nabla \log \pi(a{=}1) = [-0.5, 0.5]$.

	$a{=}0$ 샘플	$a{=}1$ 샘플	기댓값 (참 기울기)
REINFORCE: $G_t \nabla \log \pi$	$+1.0\,[0.5, -0.5] = [0.5, -0.5]$	$+1.8\,[-0.5, 0.5] = [-0.9, 0.9]$	$0.5[0.5, -0.5] + 0$
베이스라인: $(G_t - V)\nabla \log \pi$	$(1.0 - 1.4)[0.5, -0.5] = [-0.2, 0.2]$	$(1.8 - 1.4)[-0.5, 0.5] = [-0.2, 0.2]$	$[-0.2, 0.2]$

- **기댓값은** $[-0.2, 0.2]$ **로 완전히 같음** — 둘 다 "행동 1(보상 $+1.8$)의 확률을 올리는 방향".
- 그런데 **샘플 하나하나**는 다름: REINFORCE의 첫 성분은 매 스텝 **1.4나 튀어다니는** 신호, 베이스라인 버전은 **두 샘플이 정확히 같은 벡터** — 이 작은 예에서는 분산이 **정확히 0**.

"평균은 그대로, 흔들림은 줄어든다" — 숫자로 보임.

베이스라인이 "틀린 값"이어도 기댓값은 안 바뀐다

- $b = 1.9$ (참값 1.4와 **다른** 값)로 빼면: 샘플은 $[-0.45, 0.45]$ / $[0.05, -0.05]$ 가 되지만, 기댓값은 **여전히** $[-0.2, 0.2]$.

이 사실이 실전적으로 중요한 이유 하나

Critic은 "완벽할 때까지" 기다릴 필요가 없다. 처음부터 정확하지 않아도, **대략 근사한** V 만 있으면 분산은 크게 줄고 기댓값은 안 훼손됨.

$\rightarrow$ "Critic이 **쓰이면서** 학습하고, **학습하면서** 더 정확해진다"는 상호보완 구조가 성립하는 **근거**가 바로 이 불변성.

$$A_t := G_t - V(s_t)$$

$V(s_t) = \mathbb{E}[G_t|s_t]$ 는 "이 상태에서의 **평균적** 수준" $\rightarrow$ A_t = **평균 대비 향상분**. $A_t > 0$: 평균보다 더 좋은 결과 $\rightarrow$ 그 행동 확률 **올림**. $A_t < 0$: 평균보다 나쁨 $\rightarrow$ **내림**. (10.2의 정규화 줄 = "에피소드 내 평균"이라는 가장 느슨한 베이스라인. Actor-Critic은 이를 **상태별** $V(s_t)$로 업그레이드 — 상태 의존적 기준값)

A2C 코드 (1/2): 네트워크와 에피소드 실행

10.2 REINFORCE 코드에서 **딱 두 가지**를 바꿈: (1) G_t 를 $A_t = G_t - V(s_t)$ 로, (2) $V(s_t)$ 를 내주는 **Critic**을 하나 더 붙임.

```
import torch, torch.nn as nn

class ActorCriticNet(nn.Module):
    def __init__(self, state_dim, n_actions):
        super().__init__()
        self.shared = nn.Sequential(
            nn.Linear(state_dim, 64), nn.ReLU())
        self.actor_head = nn.Linear(64, n_actions)  # Actor: 확률
        self.critic_head = nn.Linear(64, 1)         # Critic: V(s)
    def forward(self, x):
        h = self.shared(x)
        return (torch.softmax(self.actor_head(h), dim=-1),
                self.critic_head(h).squeeze(-1))

net = ActorCriticNet(4, 2)          # CartPole: 상태 4, 행동 2
opt = torch.optim.Adam(net.parameters(), lr=1e-3)

def a2c_episode(env, seed, gamma):
    s, _ = env.reset(seed=seed)
    states, log_probs, rewards, nexts = [], [], [], []
    for _ in range(500):
```

A2C 코드 (2/2): 두 손실함수, 두 갱신

```
    # --- 1) Actor 갱신: 에서REINFORCE G_t -> A_t = G_t - V(s_t)만 바꿈 ---
    G, rets = 0.0, []
    for r in reversed(rewards):
        G = r + gamma * G
        rets.insert(0, G)
    rets = torch.tensor(rets)
    vs    = torch.stack([net(st)[1] for st in states])  # V(s_t)
    adv   = rets - vs.detach()          # A_t 상수로( 취급!)
    actor_loss = -sum(lp * ad for lp, ad in zip(log_probs, adv))
    opt.zero_grad(); actor_loss.backward(); opt.step()

    # --- 2) Critic 갱신: Week 의6 TD(0) 값학습그대로   ---
    with torch.no_grad():
        vnext = torch.stack([net(ns)[1] for ns in nexts])
    critic_loss = nn.functional.mse_loss(
        vs, torch.tensor(rewards) + gamma * vnext)
    opt.zero_grad(); critic_loss.backward(); opt.step()
    return sum(rewards)
```

두 손실함수의 역할: 이 학기 배운 것들의 "재조합"

- **Actor 손실** $-\sum_t \log \pi(a_t|s_t)\, A_t$ — 10.2 REINFORCE 손실의 G_t 자리에 A_t 가 들어간 것. 10.2의 정규화 줄이 "에피소드 평균을 뺀 초짜 베이스라인" 이었다면, 여기서는 vs라는 **학습된 네트워크**의 출력이 그 역할.
- **Critic 손실** $(r_t + \gamma V(s_{t+1}) - V(s_t))^2$ — Week 6의 **TD(0) 값 학습**을 **그대로** 사용.

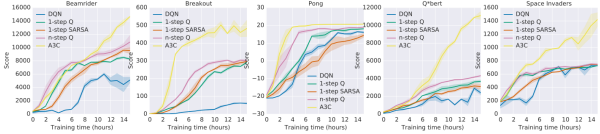
의도된 비대칭

Critic은 **부트스트랩**으로 배우는(분산 작음) 학습자, Actor는 **에피소드 리턴**(분산 큼) 신호를 쓰는 학습자 — **Critic이 Actor의 노이즈를 잡아주는 구조**. 두 출력은 앞부분 shared 층을 **공유**하고 마지막 출력층만 다름.

- **A2C** 이름의 유래: **A**dvantage **A**ctor- **C**ritic (DeepMind, 2016) — "A"가 바로 오늘 배운 **어드밴티지**. (위 코드는 에피소드당 한 번 갱신하는 간소화 버전. 원판 A2C/A3C는 매 스텝마다 갱신)

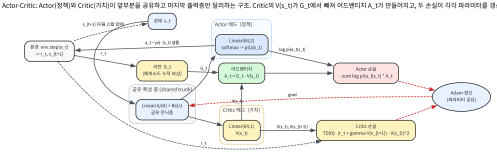
A3C: 비동기 병렬이 붙은 원판

- **A3C** (Mnih et al., 2016): A2C 구조에 **비동기** 워커 여러 개가 **병렬**로 경험을 수집·갱신.
- A2C의 "A" = **A**dvantage, A3C의 "A" = **A**sync (비동기) — 겹치지만 다른 글자.
- Atari 57종목에서 **사람 평균**을 상회하는 학습 곡선 — 비동기 병렬이 분산 감소를 **실무 속도**로 바꿔준 예.



A3C를 포함한 여러 비동기 RL 방법들의 Atari 게임별 학습 곡선 비교 (원 논문 Figure 3).

Actor-Critic 구조도 (순환)



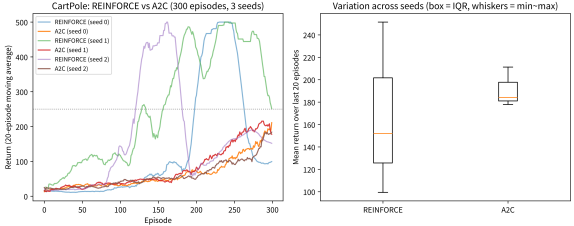
$s_t \rightarrow$ 공유 특성 층 $\rightarrow$ Actor 헤드(softmax 정책) + Critic 헤드($V(s_t)$).

- $s_t \rightarrow$ **공유 층(shared)** $\rightarrow$ **Actor 헤드**(softmax 정책) + **Critic 헤드**($V(s_t)$).
- Actor에서 a_t 샘플링 $\rightarrow$ 환경 $\rightarrow (r_t, s_{t+1})$.
- 에피소드 종료 후 리턴 G_t 계산, $V(s_t)$ 와 만나 $A_t = G_t - V(s_t)$ 생성.
- Actor 손실 $-\sum_t \log \pi \cdot A_t$ 와 Critic 손실(TD(0) MSE)이 각각 **Adam**으로 갱신.
- 갱신된 파라미터가 **공유 층으로 돌아오는 순환** — 매 에피소드마다 반복.

실습: CartPole에서 REINFORCE vs A2C (결과)

두 알고리즘 **300 에피소드씩, 세 시드**(0, 1, 2):

알고리즘 (시드)	처음 20 평균	마지막 20 평균	최고	250 첫 도달
REINFORCE (0)	14.1	99.5	500	194
REINFORCE (1)	42.5	251.4	500	150
REINFORCE (2)	17.5	151.9	500	98
A2C (0)	20.6	211.3	500	299
A2C (1)	21.6	177.9	500	277
A2C (2)	20.4	184.2	476	— (미도달)



REINFORCE 곡선은 시드마다 100∼250 사이로 **크게 갈라짐**. A2C 곡선은 세 시드 모두 **180∼210 대**에서 비슷한 높이로 수렴. 박스플롯: A2C의 박스가 REINFORCE보다 **좁음** (시드 간 변동이 작음).

좌: 리턴 학습 곡선(20 에피소드 이동평균). 우: 마지막 20 에피소드 평균의 시드 간 박스플롯.

세 가지로 읽기: 균일한 시작, 좁은 끝, “속도”

1. **시작점은 A2C가 균일하다** — 처음 20 에피소드 평균이 REINFORCE는 $14.1 \sim 42.5$ 로 **흩어진** 반면, A2C는 $20.4 \sim 21.6$ 로 **모임** — “시드 불운”의 영향이 기준값을 빼면서 줄었음.
2. **마지막 20 에피소드도 A2C가 좁다** — A2C는 $178 \sim 211$ 의 좁은 밴드, REINFORCE는 $99.5 \sim 251.4$ 로 **150 넘게 벌어짐** — 분산 감소가 시드 간 **일관성**으로 나타남.
3. **도달 “속도”는 이야기가 다름** — 이 실험(300 에피소드, 시드 0∼2)에서는 REINFORCE가 오히려 250 돌파가 빠른 시드가 **있었음**.

“REINFORCE가 더 좋다”는 뜻이 아님

분산이 크면 **위쪽으로도** 많이 튀기 때문. 분산 감소의 실제 이득 — **안정성을 유지하면서** 학습을 **훨씬 오래, 훨씬 큰 환경**에서 돌릴 수 있게 된 것 — 은 Week 11에서 PPO가 어드밴티지를 **클리핑된 목적함수**에 재사용하면서 비로소 온전히 수확됨.

자주 하는 실수 1: .detach()를 빼는 것

- `adv = rets - vs.detach()` — vs는 net의 **Critic 헤드 출력**.
- `.detach()`를 빼면 `actor_loss.backward()` 의 그래디언트가 vs를 타고 **Critic 헤드 파라미터까지** 흘러가, **Actor 갱신 과정에서 Critic도 함께** 갱신됨.
- "두 손실이 각자 역할을 할 것"이라는 **구조가 무너짐**.

왜 .detach()가 필요한가

어드밴티지는 Actor 손실 안에서는 **상수**(미분 대상이 아닌 곱수)로 취급해야 하므로.
이 버그는 "Critic이 이상하게 빨리/느리게 학습하는" 형태로만 나타나서 **찾기 어렵다**.

자주 하는 실수 2·3: Critic에 MC 리턴, 속도 변화 를 버그로 판단

2. Critic 목표값에 G_t(MC 리턴) 사용

- Critic 손실을 $(G_t - V(s_t))^2$ 로 쓰면 Critic도 **MC 학습자**가 됨 — 안 **틀리지만**, **부트스트랩이 사라져 Critic의 분산이 커짐**.
- Critic은 "Actor의 노이즈를 **잡아줄 사람**"인데 자기 자신이 노이즈가 많으면 기준값 $V(s_t)$ 가 **흔들리고**, 그 흔들림이 **그대로** Actor의 어드밴티지에 전이.
- **의도된 설계**: Critic은 **TD(0)**(Week 6 부트스트랩, 분산 작음), Actor는 **MC 리턴** — 이 **비대칭**.

3. "베이스라인 넣었더니 학습 속도가 달라졌다"를 버그로 판단

- 베이스라인은 **기댓값**(진짜 기울기 방향)은 **바꾸지 않**지만 **분산은** 바꿈 $\rightarrow$ 신호 **크기**가 달라져 **실효 스텝 크기**가 달라지고, **학습 속도**가 바뀌는 것은 **정상**.
- 속도 변화 $\neq$ 기댓값(방향) 깨짐 — 실제로는 **변하지 않음** (앞 밴딧 예의 $b = 1.9$ 행이 증거).

역사적 일화: 뇌의 도파민이 바로 TD 오차 (Schultz, Dayan, Montague, 1997)

- "TD 오차"가 단순한 **수학적 편의**가 아니라는 증거가 **1997년**에 나옴.
- 원숭이 뇌에서 **도파민 신경세포**가 보상을 받을 때마다:
  - **예측보다 좋으면** 발화량 **증가**,
  - **예측보다 나쁘면 감소**,
  - **예측이 정확히 서 있으면** 보상이 오기 **전**의 신호(큐) 시점에 발화가 **앞당겨짐**.

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t) \quad \text{— 정확히 TD 오차}$$

의미

"예측하지 못했던 좋은 소식"을 보내는 **뇌의 신호**와, 강화학습의 "예측 오차" 신호가 **수학적으로 일치**. 대응: "Critic"(값 예측) $\leftrightarrow$ **도파민 회로**, "Actor"(신호를 행동 선택에) $\leftrightarrow$ **기저핵 회로**. 강화학습 이론이 **생물학 신호를 설명**에 성공한, 이 분야에서 가장 유명한 일화 중 하나. (11.3절의 GAE도 이 TD 오차 δ_t 를 **여러 개 가중평균**한 것 — 같은 뿌리)

자주 묻는 질문 (10.3)

- **Q: Actor와 Critic은 왜 따로 학습하나? 하나로 합칠 수는 없나?** 서로 **다른 것을 예측** — Actor: "어떤 행동을 할 것인가"(정책), Critic: "지금 상태가 얼마나 좋은가" (가치함수). 실제 구현은 **앞부분(특징 추출 층)을 공유**하고 마지막 출력층만 다르게 — 10.2 `PolicyNet`에 가치 예측 출력 하나만 추가하면 간단한 Actor-Critic.
- **Q: $G_t - V(s_t)$ 를 빼도 기댓값이 그대로라는 게 왜 참인가?** $V(s_t)$ 는 **행동** a_t **와 무관하게 상태** s_t **만으로** 결정 — "어떤 행동을 고르든 똑같이 빼지는 상수". 기댓값 관점에서 편향 없음. 샘플 하나하나로는 G_t 의 큰 변동폭이 $V(s_t)$ 만큼 **상쇄** $\rightarrow$ 분산은 확실히 감소.
- **Q: on-policy인가, off-policy인가?** 이 절의 구현은 **on-policy** — Actor와 Critic이 모두 **현재 정책**이 만든 경험에서만 학습, 경험 재생 버퍼 **없음**. (off-policy Actor-Critic — DQN + 정책 결합, Week 9 경험 재생 변형 — 도 존재) 이번 학기 표준 흐름 **A2C** $\rightarrow$ **Week 11 PPO**는 **on-policy** 패밀리 안에서 "분산을 줄이는" 방향으로 발전.
- **Q: 이산 공간인데 굳이 Actor-Critic? DQN이면 됐지.** 맞는 말에 가깝다 — 이산이면 DQN이 더 데이터 효율적일 때가 많음. Actor-Critic이 **필수**인 순간: (1) **연속 행동공간**(Week 13–14 로봇)에서 $\max_a Q(s,a)$ 를 계산할 수 없을 때, (2) **탐색 정책** 자체를 확률적으로 학습하고 싶을 때. 게다가 A_t 는 **PPO의 입력**이므로 PPO까지 이 구조를 실무적으로 익숙해져 있어야 함.

10.3 마무리: “절대 보상”이 아니라 “평균 대비 향상”

핵심 정리

REINFORCE의 신호 G_t 에는 **“운”**이 섞여 있다. **베이스라인** $b(s_t)$ — **행동에 무관한 값** — 을 빼도 그래디언트의 **기댓값은 그대로**(행동의 확률 합이 1에서), **분산만 줄어듦**.

분산을 최소화하는 베이스라인은 $V(s_t)$ 자체 — 따라서 **가치함수를 Critic**이라 부르고, $G_t - V(s_t)$ 를 **어드밴티지**라 부르며, Actor는 이 어드밴티지로, Critic은 **TD(0)**으로, **동시에** 학습.

“절대 보상”이 아니라 “평균 대비 향상”으로 배우는 이 한 가지 아이디어가 Week 11의 PPO로 이어진다.

이번 주차 정리

1. **10.1 정리를 세웠다** — Q를 거치지 않고 정책을 직접 파라미터화(softmax / 조건부 정규). 로그미분 트릭이 "적분의 미분"과 "단절된 샘플"이라는 벽을 **동시에** 해산시켜 $\nabla_\theta J = \mathbb{E}_\tau[\sum_t \nabla_\theta \log \pi_\theta(a_t|s_t)\, G_t]$ 에 도달. one-vs-rest 모양과 $\mathbb{E}[\nabla \log \pi] = 0$ 이 베이스라인 논리의 씨앗.
2. **10.2 정리를 알고리즘으로** — REINFORCE: 경사 상승 + 단일 샘플 G_t (on-policy, model-free, MC 기반, 정책기반). 2행동 밴딧에서 "좋은 행동 확률 $0.5 \to 0.98$", CartPole 300 에피소드 $14 \to 100$. 리턴을 정규화하지 않으면 "덜 좋았을 뿐 양수" 행동을 계속 올리려는 함정.
3. **10.3 거침을 고쳤다** — 행동에 무관한 베이스라인 $b(s_t)$ 를 빼도 **기댓값 불변, 분산만 감소**. 최적 베이스라인 $= V^\pi(s_t) \to$ **Actor-Critic**: Actor는 어드밴티지 $G_t - V(s_t)$ 로, Critic은 TD(0)으로 동시에 학습. A2C가 시드 간 **일관성**에서 REINFORCE를 이김.

다음 주차 — Week 11. 정책이 한 업데이트 만에 무너지지 않게: PPO

이번 주에 손에 쥐게 된 두 네트워크(Actor, Critic)와 어드밴티지 A_t 가 PPO의 **재사용되는 구성 요소**. PPO는 **클리핑**(한 업데이트의 크기를 제한) + **경험 재사용**으로 REINFORCE의 거친 업데이트를 안정화 — Week 13∼14 로봇 시뮬레이션(Pendulum)의 출발점.