

## **Block B 캡스톤: 팀 프로젝트와 학기 총정리**

**16.1 팀 프로젝트: 발표 · 16.2 Peer-Review · 16.3 ML2 총정리와 학기를 넘어서**

Machine Learning 2 · 16주차

한국과학영재학교 (KSA)

Week 16

# 이번 주차 개요

## 이 주차를 마치면

- ① 연속제어 환경에서 4주 파이프라인(환경 고르기 → 구현 → 평가 → 발표)으로 팀 프로젝트를 설계·실행하고, “시드  $\geq 3$  · 무작위 정책 베이스라인 · 학습/평가 분리” 프로토콜을 실제로 수행할 수 있다.
  - ② “학습 곡선이 올랐다”와 “배운 정책이 무작위보다 낫다”가 서로 다른 문장임을 구분하고, 학습 도중(탐험 포함) 성과와 학습 후 결정적( $a = \mu$ ) 평가의 격차를 11.2절의 분산 원리로 해석할 수 있다.
  - ③ 5항목 체크리스트와 1점(감상평) → 3점(반박 가능한 질문) 기준으로 다른 팀의 발표를 심사하는 peer-review를 작성할 수 있다.
  - ④ 학기 전체를 “모델 정의 → 틀린 정도를 수치화 → 개선” 3단계로 정리하고, 학기 이후 방향(오프라인 RL · 범용 로봇 정책 · sim-to-real)을 자기 언어로 말할 수 있다.
- **16.1** 팀 프로젝트: 발표 — Pendulum 실습, 시드 3개, 결정적 평가, 4주 파이프라인
  - **16.2** Peer-Review — 이번엔 네가 심사위원. “우연히 좋은” 패턴 5가지
  - **16.3** ML2 총정리 — 하나의 MDP를 네 경로로, 20문항 자가진단, 최신 동향

**Week 9-15로 새 도구(신경망·시뮬레이션·트리 탐색)를 다 갖췄다. 이 장부터는 배울 개념이 남지 않는다**  
— 도구를 로봇 시뮬레이션에 직접 적용해, 그 결과를 정직하게 보고하는 것으로 학기를 마무리한다.

---

## **16.1 팀 프로젝트: 발표**

---

## 왜 지금 프로젝트를 하는가 — Week 8의 쌍(pair)

- 8.1 Block A 캡스톤: “코드가 동작한다” vs. “내가 문제를 설계하고 평가할 수 있다”의 차이에 대한 첫 답.
- Week 9-15가 두 번째 절반의 도구를 전부 줬다: 표 대신 **신경망(DQN)**, 정책을 직접 학습(REINFORCE·PPO), 시연·선호로부터 배우기(모방학습), 물리 시뮬레이션(MuJoCo·Isaac Sim), 트리 탐색(MCTS).
- 16.1 = Week 8과 쌍인 절** — 같은 절차(환경 고르기 → 구현 → 시드 프로토콜 → 수식적 정당화 → 정직한 발표)를 **완전히 다른 무대**(연속제어 + 신경망)에서 다시 집행.

|                     | Block A (8.1)                | Block B (이 절)                                  |
|---------------------|------------------------------|------------------------------------------------|
| 환경                  | 표 기반(이산 상태·행동)               | 연속제어(연속 상태·행동)                                 |
| 알고리즘                | 2개 이상(Q-learning vs SARSA)   | 1개 이상(DQN/PPO/모방/MCTS)                         |
| 평가 프로토콜             | $\epsilon = 0$ (greedy) 에피소드 | 결정적 실행 $a = \mu$ 에피소드                          |
| 1시드 예산              | 초~분 단위                       | Pendulum 12만 스텝 $\approx 20\sim 30$ 초 ~ MuJoCo |
| 시드 $\geq 3$ · 베이스라인 | 동일                           | 동일                                             |

## 왜 알고리즘은 “1개 이상”인가

- Block A: 두 번째 알고리즘은 **갱신 규칙 한 줄의 차이**(6.3) — Q-learning vs SARSA.
- Block B: 각 알고리즘이 **별개의 신경망 학습 파이프라인**.
  - ▶ DQN: 리플레이 버퍼 + 타깃 네트워크가 따라온다.
  - ▶ PPO: GAE + 클리핑이 따라온다.
  - ▶ 모방학습: 시연 데이터셋이 따라온다.
- 팀 단위 현실적 예산: “한 파이프라인을 제대로 돌리고, 여유가 있으면 비교”.

### 변하지 않는 것이 핵심

시드  $\geq 3 \cdot$  베이스라인(무작위 정책)  $\cdot$  학습/평가 분리는 알고리즘과 무관한 **강화학습 실험의 골격**이라 Block A와 동일하다.

## 역사: 왜 Pendulum인가

- OpenAI 생태계(baselines → stable-baselines) 시대부터 연속 제어의 “hello world” — 라이브러리 PPO 튜토리얼의 표준 예제.
- PPO 논문(Schulman et al., 2017)은 같은 계열의 MuJoCo 연속 제어 고전 과제(Swimmer, Hopper 등)에서 검증.
- Pendulum은 그중 **가장 작은** 구성원: 3차원 상태, 1차원 행동, 에피소드 종료도 목표 상태도 없음 — “매 스텝 균형을 해야 하는” 보상이 연속 제어의 본질적 어려움을 최소 분량에 담는다.

**첫 과제로 고르는 이유는 “쉬워서”가 아니라, 그 보상 구조가 학습 곡선 위에서 “정책이 지금 무엇을 하고 있는지”를 가장 선명하게 보여주기 때문이다.**

## 프로젝트 구조 — 환경 · 적용 · 필수 요구사항

- **환경:** PyBullet 또는 Gymnasium의 연속제어 환경 (Pendulum, MuJoCo 기반 로봇 등) 중 하나.
- **적용:** Week 9-15 중 **최소 하나의 방법**(DQN, PPO, 모방학습, MCTS)으로 정책을 학습.
- **필수 — 수식적 정당화 최소 1개**, 예:
  - ▶ PPO: Ch11.3의 클리핑이 학습 안정성에 미친 영향(있음/없음 비교)
  - ▶ 모방학습: Ch12.1의 복합 오차 관찰(전문가 데이터 분포 밖 성능 저하)
  - ▶ 도메인 무작위화: Ch13.1의 현실 격차 논의와 연결해 효과 설명
- **학습 곡선(에피소드별 누적 보상)은 반드시 제시** — 지도학습의 손실 곡선에 해당하는, “학습이 실제로 되고 있는가”의 기본 증거.

# 환경 고르는 실전 가이드 — 후보에 점수를 매기자

- ① **상태·행동 공간의 차원** — 차원이 높으면 학습 예산이 급격히 커짐(예: HumanoidStandup은  $348 \times 17$ ).
- ② **보상 구조** — “항상 음수(0이 목표)”형(Pendulum)과 “희소(목표 도달 시에만)”형(13.1 Reacher)은 **좋은 정책의 모습** 자체가 달라 평가 지표의 의미가 달라진다.
- ③ **시뮬레이션 격차가 보일 만큼 물리적으로 풍부한가** — 13.1 도메인 무작위화를 제시하려면 Pendulum은 격차가 안 나와 MuJoCo 로봇이 적합.
- ④ **코드 재사용성** — Ch11.2의 PPO 코드가 거의 그대로 적용되는가.

## 왜 점수 매기기를 하는가

기준을 먼저 정해두면 **팀 회의가 쉬워진다**(8.1절의 방식 그대로). 환경은 “임의로 고르는” 것이 아니라 기준에 대해 점수를 받는 것.

## 환경 후보 비교 — Block B 대표 4종

| 환경                        | 상태×행동       | 보상 구조                                                        | 에피소드 |
|---------------------------|-------------|--------------------------------------------------------------|------|
| <b>Pendulum-v1</b>        | 3×1 (연속)    | $r = -\theta^2 - 0.1\dot{\theta}^2 - 0.001a^2$ , 항상 음수(0=완벽) | 200  |
| <b>CartPole-v1</b>        | 4×2 (이산)    | 생존 시 스텝당 -1, 쓰러지면 종료                                         | 500  |
| <b>MountainCar-v0</b>     | 2×3 (이산)    | 스텝당 -1 (희소)                                                  | 200  |
| <b>HumanoidStandup-v5</b> | 348×17 (연속) | 포텐셜 기반 shaping(Ch14)                                         | 1000 |

보상 구조의 “형”이 다르면 좋은 정책의 **모습** 자체가 달라 — 평가 지표의 의미가 바뀐다.

## 환경-알고리즘 “페어링” 논리

- “잘 어울리는” 열의 논리가 핵심 — **환경과 알고리즘은 “검증하고 싶은 개념이 돋보이는 무대”가 무엇인가를 기준으로 짝을 이루어 골라야 한다.**
- 11.3의 클리핑(있음/없음)을 발표하고 싶으면 → 연속 행동 공간에서 클리핑이 실제로 발동하는 **Pendulum**.
- 13.1의 도메인 무작위화를 발표하고 싶으면 → 격차가 생길 만큼 물리적으로 풍부한 **MuJoCo** 환경.
- 12.1의 복합 오차를 발표하고 싶으면 → **전문가 시연 데이터셋**이 있는 모방학습 과제.

**“PPO를 쓰고 싶은데 환경을 뭐로 하지?”는 순서가 틀린 질문.  
“개념 X를 테스트하고 싶은데 무대는 어디인가?”가 올바른 질문이다.**

## 베이스라인: 무작위 정책의 리턴을 먼저 재자

- M1 제출물의 핵심 숫자 — “배운 정책이 실제로 **무작위보다 나은가**”를 판정할 **제로점**이 없으면 “개선됐다”고 말할 수 없다.
- Pendulum-v1 매 스텝 무작위 토크 정책(100 에피소드)의 평균 리턴:  $-1274.1$  (**sd 300.0**), 대략  $[-1800, -760]$  구간에 분포.
- **읽기 1** — “0”과 “좋은”의 거리가 표 기반보다 훨씬 크다. CliffWalking은 무작위  $-5000 \rightarrow$  학습 후  $-13$  (400배 격차)였는데, 여기서 “좋은”이 0이고 무작위가 이미  $-1274$  — **0까지의 거리 자체가 지표.**
- **읽기 2** — 아무것도 하지 않는 정책이 생각보다 나쁘지 않다. 토크 0 고정(zero-torque)이 약  $-1230$ 으로 무작위와 같은 등급.
- “학습 곡선이  $-1200$  부근에서 시작한다”는 사실은 **학습의 증거가 전혀 안 된다** — 이 두 숫자(무작위  $-1274$ , zero-torque  $-1230$ )를 먼저 재야 “PPO가  $-673$ (무작위의 절반)”이라는 판단이 성립한다.

## 비교 프로토콜: 연속제어 버전 3개 항목

8.1절 프로토콜(시드  $\geq 3$ , 학습 중/학습 후 분리, 시드별 표)을 연속제어로 번역 — 1·3은 그대로, 두 번째가 번역된다.

- ① **학습 시드  $\geq 3$ 개** — 시드를 바꾸는 것은 “실험을 다시 하는” 것이 아니라 **“우연인지 재검사하는”** 것. PPO는 초기화·샘플링·데이터 분할의 무작위성이 겹쳐 같은 코드도 시드만 바뀌어도 곡선 모양이 달라짐 (11.2: 큰 그림은 시드마다 안정적이거나 마지막 10에피소드 평균은  $\pm 100 \sim 200$  흔들림).
- ② **학습 도중 성과 vs 학습 후 평가** —  $\varepsilon = 0$ 의 “번역 문제” (다음 프레임).
- ③ **알고리즘/시드별 숫자를 표로 제시.**

표 기반  $\varepsilon$ -greedy에는 깔끔한 핸들이 있었음: 평가 때  $\varepsilon = 0$ 으로 하면 “순수 탐욕적”. 연속 정책  $a \sim \mathcal{N}(\mu_\theta(s), \sigma_\theta^2)$ 에는  $\varepsilon$ 이라는 핸들이 없다.

## $\varepsilon = 0$ 의 대응물 — 왜 $a = \mu$ 인가

### 대응 원리

- **학습 도중(샘플) 평가:** 학습 종과 같은  $a = \mu + \sigma z$ 로 실행 — **탐험 노이즈가 섞인** 성과.
- **학습 후(결정적) 평가:**  $a = \mu_{\theta}(s)$ 만 내보내고 샘플링 안 함 — **연속제어의 “greedy 평가” 대응물.**

### 왜 $a = \mu$ 가 $\varepsilon = 0$ 인가?

- $\varepsilon$ -greedy에서  $\varepsilon$ 의 역할 = “확률  $\varepsilon$ 로 아무 행동이나”.
- 정규분포 정책에서 “아무 행동”에 해당하는 것은 **샘플링 노이즈**  $z$  — 빼면 “정책의 최선 추측”  $\mu$ 만 남는다.

### $\sigma$ 를 0으로 만들면 안 되는 이유

$\sigma$ 는 **학습된 파라미터** — 11.2의 엔트로피 보너스가 0으로 쪼그라들지 않게 브레이크 역할.

평가 때  $\sigma = 0$ 으로 “학습”하는 것이 아니라, **파라미터를 그대로 두고 샘플링만 하지 않는 것**이 정직한 “탐험 제거”. (“ $\sigma$ 를 0으로 설정해서 돌려라”는 오답 — 파라미터를 바꾼 다른 정책의 실행이 되기 때문.)

## 실측: 3시드 결과 표와 읽기 1·2

실습 노트북: Ch11.2의 PPO 그대로,  $\gamma = 0.99$ ,  $\lambda = 0.95$ ,  $\epsilon_{\text{clip}} = 0.2$ ,  $\text{lr}=3\text{e-}4$ , 시드당 300반복 $\times$ 400스텝 = 12만 스텝, 시드 0/1/2, 평가 50 에피소드

| 시드      | 학습 도중 마지막10 | 학습 후 결정적 $a = \mu$ | 학습 후 샘플 $a \sim \mathcal{N}$ |
|---------|-------------|--------------------|------------------------------|
| 0       | -673.5      | -1357.9            | -1287.6                      |
| 1       | -732.3      | -1454.2            | -1399.4                      |
| 2       | -668.3      | -1398.2            | -1367.0                      |
| (베이스라인) | —           | —                  | 무작위 -1274.1 (100 에피소드)       |

이 표는 **세 번** 읽어야 하고, 세 번째가 이 절의 핵심이다.



- **읽기 1 — 학습 도중 곡선은 정말 올랐다:** 마지막 10 (-673/ -732/ -668)이 첫 10 (-777/ -866/ -914) 대비 **15~27% 개선**, 무작위 -1274보다 대략 2배 낫다. 이 숫자만 보면 “학습 성공”.
- **읽기 2 — 시드 간 편차가 있지만 방향은 일관:** 마지막 10의 시드 간 격차 약 65 (-668 ~ -732)로 “같은 모양” 범위 — 11.2의 “큰 그림은 시드마다 안정적”이 재현된다.

## 읽기 3 — 결정적 평가가 베이스라인 아래다

- 세 시드의  $a = \mu$  평가 평균  $\approx -1403$ 으로 무작위 정책 ( $-1274$ ) 아래.

“학습 곡선이 올랐다”와 “배운 정책이 무작위보다 낫다”는 서로 다른 두 문장이다.

- 왜? 학습 도중 리턴은 **탐험 노이즈  $\sigma$ 가 섞인 채** 측정한 것 —  $\sigma$  샘플링이 운 좋게 진자를 높이 스윙하게 한 에피소드가 평균에 들어감 (11.2 FAQ: “에피소드 리턴 자체의 분산은 줄일 수 없다”).
- 노이즈를 빼면 12만 스텝으로는  $\mu$ 가 상태별로 아직 정확하지 못해, 결정적 정책은 “대충 그럴듯한 범위로 스윙” 수준 (아무것도 안 함  $\approx -1230$ 과 같은 등급).



좌: 학습 곡선 (검정 점선 = 무작위 베이스라인  $-1274$ , 시드마다 모양이 다르면 정상). 우: 같은 세 정책을 네 가지 측정 방식으로 — 학습 도중(탐험 포함)이 베이스라인을 크게 상회해도 결정적  $a = \mu$ 는 그 아래일 수 있음.

## 하이퍼파라미터 선택의 주의

- “학습 곡선이 예뻐질 때까지  $\gamma/\lambda/\epsilon_{\text{clip}}$ 을 조한다” — 지도학습에서 “val 곡선이 예뻐질 때까지 조정”하는 것과 같은 역할 (ML1 Ch6.2). 그 자체로 **정당한 모델 선택**.
- 단, 두 조건:
  - ① 어떤 곡선(학습 도중 리턴의 이동평균)을 보고 고르기로 정했는지를 보고서에 **기록**할 것.
  - ② 최종 **결정적** 평가는 선택된 파라미터로 **한 번만** 돌려야 한다.
- “결정적 평가가 예뻐질 때까지” 조정하는 것은 **평가에 대한 과적합** — ML1 6.2의 “test는 한 번만” 원칙이 그대로.
- 선택 기준의 **사전 기록**이 “정당한 val 선택”과 “평가 과적합”의 구분선이다 (16.2 체크리스트 “실험 프로토콜의 정직성” 항목에서 바로 감점 대상).

# 전체 그림: 4주 파이프라인

- 8.1절 파이프라인과 **대칭 — 환경 → 알고리즘·구현 → 평가·정당화 → 발표.**
- 각 박스가 Block B 어느 절의 원칙을 집행하는지 함께 적음.
- 붉은 점선**(평가 → 구현·실험)이 핵심: 시드 간 편차가 비정상적으로 크거나 프로토콜 결함이 발견되면 **돌아가서 다시** 돌려야 한다는 뜻.
- “한 번 지나가면 돌아올 수 없는” 것은 **최종 발표** — 그 외 모든 단계는 되돌아갈 수 있다.



1주: 환경 고르기·문제 정의·베이스라인 / 2~3주: 알고리즘 구현·시드  $\geq 3$ ·하이퍼파라미터 / 3~4주: 시드 비교 표·학습 곡선·보고서 / 4주: 발표·peer-review.

## 일정과 마일스톤 — M1~M4가 제출물

| 주 / 해야 할 일                                                                                                                         | 마일스톤(제출)                                |
|------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------|
| <b>1주:</b> 환경 후보 2~3개 조사, <b>문제 정의 문서</b> (MDP 5요소, 주 지표와 리턴의 이론적 범위), <b>베이스라인(무작위) 리턴 측정</b>                                     | <b>M1</b> 문제 정의 + 환경 선택 + 베이스라인 숫자 (1p) |
| <b>2주:</b> Ch9~15 코드 재사용으로 알고리즘 $\geq 1$ 개 구현, <b>시드 1개에서 엔드투엔드 동작 확인</b> (Pendulum 12만 스텝 $\approx 20\sim 30$ 초), <b>학습 예산 추정</b> | <b>M2</b> 중간코드 리뷰(코드 + 베이스라인 + e2e 숫자)  |
| <b>3주:</b> 나머지 시드 실행, 하이퍼파라미터 조정(모두 동일 프로토콜), <b>학습 후 결정적 <math>a = \mu</math> 평가</b> (시드마다 동일 에피소드 수), 학습 곡선·시드 비교 표 도출           | <b>M3</b> 학습 곡선 1장 + 시드 비교 표            |
| <b>4주:</b> 수식적 정당화, 보고서·슬라이드 완성, <b>발표</b>                                                                                         | <b>M4</b> 보고서 + 발표 + 리뷰 2건              |
| <b>5~7분</b> , peer-review 2팀                                                                                                       |                                         |

### 왜 M2에 “학습 예산 추정”이 들어가는가

Block A(표 기반)에서는 1에피소드 1초라 예산이 문제가 안 됐지만, Block B에서는 Pendulum 12만 스텝이 CPU 22초인 반면 MuJoCo 대형과제의 100만 스텝은 수 시간 — **계산 전에 “얼마나 걸리는가”를 계획하는 것 자체가 방법론의 정직성에 포함.** (Pendulum 12만 스텝  $\approx 22$ 초가 “정상 기준선”.)

# 수식적 정당화: 좋은 예와 나쁜 예

**설정:** 어떤 팀이 Pendulum에 PPO를 적용해 “학습이 잘 됐다”고 발표. 11.2 스크래치패드로 실행 검증한 실제 결과:

처음

10 에피소드평균리턴 : -1551.7

10 에피소드평균리턴 : -1092.2

**나쁜 설명:** “학습 곡선이 올라갔다. PPO가 잘 작동했다.”

**좋은 설명:** “12만 스텝(300 iteration) 동안 평균 리턴이  $-1551.7 \rightarrow -1092.2$ 로 약 30% 개선 — **다만 완전히 수렴한 수준은 아니고** 여전히 개선 여지. 이 개선은 보상을  $1/8$  스케일링하고  $\gamma = 0.95$ ,  $\lambda = 0.9$ 로 조정된 뒤에야 나타남 — Ch11.3의 GAE  $\lambda$ (편향-분산 트레이드오프)가 “왜 그렇게 골랐는지”의 답. 처음 시도(스케일링 없음,  $\gamma = 0.99$ )는 오히려 나빠짐 — Ch11.1대로 어드밴티지 추정의 **분산이 너무 커서** 클리핑이 그 노이즈를 충분히 걸러내지 못했기 때문으로 추정.”

두 설명은 같은 방향(개선됨)을 말하지만, 좋은 설명만 (1) 정확한 수치, (2) “완전 수렴 아님”의 정직함, (3) 하이퍼파라미터의 이론적 근거를 담는다 — 이것이 “수식적 정당화”의 실제 의미.

## 보고서 구조 (M4) — 발표 슬라이드 = 보고서의 절 제목

- 1 **문제 정의** (0.5p): MDP 5요소(Ch3.1), 상태·행동 차원과 범위, 전이·보상(이론적 리턴 범위 포함), 할인율, **주 지표** (학습 후 결정적 평가의 평균 리턴), **베이스라인**.
- 2 **알고리즘 선택과 이유** (1p): **왜 이 환경을 이 알고리즘에 골랐는가**(  $S$  페어링의 “무대” 논리), 하이퍼파라미터 ( $\gamma, \lambda, \epsilon_{\text{clip}}$ , 보상 스케일)와 선택 근거(Ch10~13 개념).
- 3 **실험 프로토콜** (1p): 시드 목록, 학습 예산, **평가 프로토콜(결정적  $a = \mu$ , 에피소드 수, 모든 시드에 동일) 명시**, 하이퍼파라미터 선택 절차. **이 절이 없으면 16.2 체크리스트에서 바로 감점.**
- 4 **결과** (1p): 시드 비교 표, 학습 곡선 1장(여러 시드를 얹은 선으로), **“같은 정책 여러 측정” 패널**(학습 도중/결정적/베이스라인).
- 5 **수식적 정당화** (1p): Ch9~15 개념  $\geq 1$ 개로 “왜 이 결과가 나왔는지” — “좋은 예” 문체로.
- 6 **잘 안 된 부분과 원인 진단** (0.5p): **필수** — 안 된 부분이 없었으면 “무엇을 시도했다가 안 됐는가”를 쓴다. “모두 잘 됐다”는 보고서는 이 절이 비어 있다는 뜻.

## 채점 기준 (rubric)

| 항목                  | 비중         | 좋은 답                                                                    |
|---------------------|------------|-------------------------------------------------------------------------|
| 문제 정의와 환경           | 15%        | MDP 5요소·차원·지표·베이스라인·리턴 이론 범위가 명확, 환경 선택이 “개념 X가 돋보이는 무대” 논리로 근거됨        |
| 방법론 적절성             | 20%        | Ch9~15 알고리즘이 환경 특성(연속/이산, 보상 희소성)에 맞았고, 하이퍼파라미터 근거가 배운 개념으로 설명됨         |
| <b>실험 프로토콜의 정직성</b> | <b>25%</b> | 시드 $\geq 3$ , 동일 평가 프로토콜(결정적, 동일 에피소드 수), 베이스라인, 예산과 선택 절차가 보고서에서 추적 가능 |
| 수식적 정당화             | 20%        | 배운 개념 $\geq 1$ 개로 “왜”를 설명했고, 그 설명이 <b>실제로 관측한 숫자와 일치</b>                |
| <b>결과의 정직성과 반성</b>  | <b>20%</b> | 불안정했던 시드·구간, 베이스라인 이하의 평가치를 숨기지 않고 Ch9~15 개념으로 진단                       |

### 정직성 항목이 **합계 45%**인 이유

이 프로젝트의 목적은 “좋은 정책을 만든 것”이 아니라 **그 성능 숫자를 정직하게 얻는 절차를 실제로 수행한 것**을 증명, 격정적 평가가 베이스라인을 못 넘겨도 프로토콜이 정직하며 높은 점수 반대로 숫자가 예뻐도

## 자주 하는 실수 5가지 — 16.2 리뷰의 “반박 가능한 질문”이 된다

- 1 **시드 1개 실험으로 결론** — 같은 PPO라도 시드만 바뀌도 마지막 10 평균이  $\pm 100 \sim 200$  흔들림(실습표:  $-668 \sim -732$ ). 알고리즘 간 차이가 시드 간 sd보다 작으면 결론은 “유의미한 차이 관측 불가”. 리뷰 질문: “시드 간 sd가 방법 간 차이보다 커요?”
- 2 **학습 도중 리턴을 “최종 정책 성과”로 보고** — 학습 도중 마지막 10( $-673 \sim -732$ )은  $\sigma$  샘플링 노이즈가 섞인 “탐험 포함 성과”. “곡선이 올랐다”를 “잘 학습됐다”로 번역하는 순간 읽기 3의 격차(결정적  $-1403$  vs 베이스라인  $-1274$ )가 사라진다.
- 3 **결정적 평가가 예뻐질 때까지 하이퍼파라미터 조정** — 학습 곡선으로 조정하는 것은 정당한 val 선택이지만, **최종 평가치를 보며 조정하면 평가에 과적합**(ML1 6.2 “test는 한 번만”). 구분선 = 선택 기준의 **사전 기록**.
- 4 **베이스라인 없이 “잘 배웠다”** — 무작위 리턴( $-1274$ )을 재지 않고 “ $-1400$ , 꽤 좋다”라고 발표 = 그 숫자가 무작위보다 나쁜지도 모름. zero-torque( $\approx -1230$ )까지 함께 재면 기준선 두 개가 생긴다.
- 5 **“결정적  $\ll$  샘플 평가는 버그”로 오해** —  $a = \mu$ 가  $a \sim \mathcal{N}$ 보다 낮은 것은 **정상**. 격차의 크기는 “정책이 탐험 운에 얼마나 의존하는가”의 측정값 — **작을수록** 정책이 자기  $\mu$ 만으로 선다.

## 발표 — 5~7분, 마지막 1분이 가장 평가받는다

- 구성: 문제 정의(1분) → 알고리즘과 이유(2분) → 학습 곡선 + 수식적 정당화(2~3분) → **잘 안 됐던 부분과 원인 진단(1분)**.
- “최종 결정적 리턴이 얼마였는가”보다 **“왜 이 알고리즘을 이 환경에 골랐고, 왜 이 결과가 나왔는가”**에 더 높은 점수.
- 마지막 1분 = rubric의 **“결과의 정직성과 반성”** 항목이 정확히 보는 곳.

**예**(실습 숫자를 그대로 발표): “PPO를 시드 3개로 12만 스텝 학습. 학습 도중 마지막 10은  $-673 / -732 / -668$ 으로 무작위 ( $-1274$ )보다 2배 정도 낮다. **다만** 학습 후 결정적( $a = \mu$ ) 평가는  $-1358 / -1454 / -1398$ 으로 베이스라인 아래였다 — 11.2 FAQ의 “에피소드 리턴 자체의 분산은 줄일 수 없다”대로, 학습 도중 숫자에는  $\sigma$  샘플링의 운이 섞여 있었고, 노이즈를 빼면 12만 스텝으로는  $\mu$ 가 아직 정확하지 않다는 진단. 13~14절의 수백만 스텝 원리로 **예산 10배 실행**을 계획하고 있다.”

“실패에 가까운 실험”까지 **배운 개념으로 해석한** 발표가 더 높은 점수를 받는다 — “모든 것이 잘 됐다”는 발표는 이 항목에서 **스스로 감점**을 받는 것.

## 실습: 캡스톤 프로토콜 6단계를 코드로

- ① **(M1) 문제 정의** — Pendulum-v1의 MDP: 관찰 3차원  $[\cos \theta, \sin \theta, \dot{\theta}]$ , 행동 1차원 토크  $[-2, +2]$  Nm, 200스텝, 보상  $r = -\theta^2 - 0.1\dot{\theta}^2 - 0.001a^2$ (상한 0).
- ② **베이스라인** — 무작위 정책 100 에피소드 ( $-1274.1$ , sd 300).
- ③ **(M2) 구현** — Ch11.2의 ActorCritic + GAE 코드를 **재사용**(8.1 FAQ “코드를 처음부터 써야 하나요?”의 답과 같은 이유).
- ④ **(M3) 시드 0/1/2** — 같은 파라미터( $\gamma = 0.99$ ,  $\lambda = 0.95$ ,  $\epsilon_{\text{clip}} = 0.2$ )로 12만 스텝씩 (시드당 20~30초), 학습 도중 리턴 비교.
- ⑤ **학습 후 평가** — 세 정책을 (a) 결정적  $a = \mu$ , (b) 샘플  $a \sim \mathcal{N}(\mu, \sigma)$ 로 각각 50 에피소드 평가 후 베이스라인과 비교.
- ⑥ **발표 자료용 한 장** — 좌: 시드별 학습 곡선, 우: “같은 정책, 측정 방식 네 가지” 막대.

### 이 6단계의 의미

곧 § 보고서 구조의 6개 절, 다시 16.2절의 체크리스트로 매핑된다 — **같은 절차를 세 가지 언어(코드, 보고서, 리뷰)로 말할 수 있어야** 이 프로젝트가 끝난 것이다.

## 확인 문제 (1)-(2)

- 1. 시드 0의 학습 도중 마지막 10이  $-673.5$ (베이스라인  $-1274$ 의 2배)인데, 결정적 평가는  $-1357.9$ (베이스라인 아래)다. 어느 쪽이 “배운 정책의 진짜 성능”이고, **주 지표**는 무엇이어야 하는가?

→ **결정적**( $a = \mu$ ) **평가**가 탐험을 뺀 본래 실력(8.1의  $\varepsilon = 0$  greedy 평가에 해당). 학습 도중 리턴은 “탐험 포함 성과”. 주 지표는 **결정적 평가** — 평가의 목표가 “정책의 안정적인 성능”이지 “학습 과정이 잘 봤는가”가 아니기 때문. 학습 곡선은 “학습이 실제로 되고 있었는가”의 증거로, **역할을 구분해 함께** 보고.

- 2. “연속 정책에는  $\varepsilon$ 이 없으니, 평가할 때  $\sigma$  파라미터를 0으로 설정해서 돌리면 되지 않나요?” — 왜 오답인가?

→  $\sigma$ 는 **학습된 파라미터**(엔트로피 보너스와 함께 학습 대상) —  $\sigma = 0$ 로 바꾸면 “원래 정책에서 탐험을 제거한 실행”이 아니라 **파라미터를 바꾼 다른 정책**의 실행. 정답: 파라미터를 그대로 두고  $a = \mu_\theta(s)$  (**평균**)만 **내보내는 것** — “같은 정책을 샘플링 없이 실행”하는 것이  $\varepsilon = 0$ 과 동일한 역할.

## 확인 문제 (3)-(4) + 자주 묻는 질문

- **3.** “PPO 결정적 평가가 -900으로 30% 개선됐다”는 발표에 던질 **3점 질문 2개**: (a) 프로토콜의 정직성: “시드를 몇 개로 확인했어요? 시드별 숫자는요?” (b) 결과의 정직성: “결정적 평가는 몇 에피소드로 잰가요? 베이스라인은 몇 에피소드로?” — 50 에피소드 결정적 평가의 시드당 sd가 186~239로 커서 평가 에피소드 수가 적으면 측정 오차와 구별 불가. (추가: “학습 예산(스텝 수)은 같았나요?” — 12만 vs 100만 스텝 비교는 알고리즘이 아니라 **예산 비교**.)
- **4.** 12만 스텝  $\approx$  22초(1시드)일 때, 100만 스텝 (8.3배)을 시드 3개로 돌리면  **$\approx$  10분 내외. M2에서** 해야 하는 이유: M3의 “남은 시드 실행”이 **예산 계획 없이는 시작할 수 없기** 때문 — Humanoid(수백배)에 적용하면 수 시간이 되고, 그제서야 “새벽에 돌리자/시드를 줄이자”의 결정. “얼마나 걸리는가”는 실험 **설계의 일부**이지 행정 절차가 아니다.

**FAQ** — 수렴하지 않았어도 발표하는가? **된다** — “완전 수렴 아님”을 정직하게 보고하고 원인 진단하는 것이 부풀린 성공보다 낫다. / 알고리즘 2개가 비슷한가? **비슷함 자체가 관찰** — 학습 도중/학습 후를 나눠 비교하면 다른 트레이드오프가 드러남. / 시드 몇 개가 정석인가? Pendulum은 1시드 20~30초라 **3~5개가 현실적 하한**, MuJoCo 대형은 3개 + GPU 배분 고려. / PPO가 12만 스텝으로 베이스라인 못 넘기면? **예외가 아니라 일반** — Pendulum은 완전 수렴에 100만 스텝 이상. 성공 기준 = 정직한 절차 + 정당화. / 라이브러리 (stable-baselines3)를 써도 되나? **된다** — 다만 “그대로 쓴 부분”(기본값)과 “팀이 바꾼 부분”(환경 인터페이스, 예산,  $\gamma/\lambda$ , 평가 프로토콜)을 **구분**해야 하고, (b)가 실질적 산출물.

---

## **16.2 Peer-Review**

---

## 왜 이번 주가 “역전”의 주인가

- 16.1에서 각 팀은 **발표팀**으로서 자신의 프로젝트를 5~7분 안에 설명했다. 이번 블록(16.2)에서는 역할이 역전된다 — **이번에는 네가 심사위원이다.**
- 다른 두 팀의 발표를 듣고, 체크리스트를 적용해 **리뷰 두 통**을 작성하고, 그 리뷰의 질로 채점받는다.
- “왜 반박 가능한 질문이 좋은 리뷰인가”의 근거(Popper의 반증주의, Amgen 재현 실험: 53편 중 6편만 재현 성공, 2011)는 ML1 8.2 / ML2 8.2에서 다뤘다 — 여기서는 **신경망 강화학습**이라는 새 대상에 무엇을 추가하는가만 다룬다.

# 심사 대상이 8.2에서 달라진 두 가지

## 첫째 — 알고리즘이 신경망에 올랐다

- DQN(Ch09) · REINFORCE · Actor-Critic(Ch10) · PPO(Ch11) · 모방학습(Ch12) · 시뮬레이션(Ch13~14) · MCTS(Ch15).
- 8.2: “CliffWalking에 SARSA vs Q-learning이 맞는가” — **한 장의 개념**으로 판단 가능.
- 16.2: “Pendulum(연속 행동)에 DQN을 쓴 팀” — **왜** DQN이 부적합한지(행동 공간의 **이산성 전제**, Ch09)까지 짚어야 한다.

## 둘째 — 시드 질문이 “신경망 특유의 새 얼굴”로

- (a) **초기화** 자체가 매번 다르다(무작위 가중치).
  - (b) 학습이 **수만~수백만 스텝**이라 “12만 스텝이면 충분히 수렴했는가”를 판정하기 어렵다.
  - (c) 하이퍼파라미터( $\gamma$ ,  $\lambda$ , 클리핑  $\epsilon$ , 보상 스케일)가 결과에 **지대하게** 영향.
- ⇒ 같은 “반박 가능한 질문”이 **수치 민감성** 질문으로 번역된다: “시드 2개를 더 돌리면 이동평균의 편차가?”(Ch11.2), “보상을 1/8로 스케일링한 게 결과의 방향을 바꿨나요?”(Ch11.3).

# 이번 주는 어떻게 진행되는가

| 순서 | 내용                                                                | 시간 배분   |
|----|-------------------------------------------------------------------|---------|
| 1  | 다른 두 팀의 발표 청취(팀당 5~7분, 16.1 형식) + 보고서·코드시트 열람                     | 약 30분   |
| 2  | <b>작성 리뷰 2통</b> — 팀당 체크리스트 5항목 + 반박 가능한 질문 $\geq 1$ 개(개념의 장·절 명시) | 발표 직후(각 |
| 3  | 질의·토론 — 리뷰어가 쓴 질문에 발표팀이 그 자리에서 답변                                 | 나머지 시간  |

## 핵심 = 2번의 작성 리뷰

3번 토론은 “발표팀이 그 질문에 실제로 답할 수 있는가”를 가르는 자리 — **새로운 계산·실험**(시드 재실행, 평가 프로토콜 변경, 베이스라인 실측, 하이퍼파라미터 민감성 실험)을 꺼내야 답하는 질문이 **3점**이고, “네, 알겠습니다”로 넘겨질 질문은 2점에 머문다. 16.1에서 “수식적 정당화”가 발표팀의 의무였다면, 이번 주 그 타당성을 리뷰어가 심사하는 것.

# Peer-Review 체크리스트 — 5항목

| 항목              | 확인할 것                                     |
|-----------------|-------------------------------------------|
| <b>환경 설명</b>    | 상태·행동·보상이 명확히 정의됐는가                       |
| <b>알고리즘 선택</b>  | 환경의 특성(이산/연속 행동, 보상의 희소성 등)에 알고리즘이 맞았는가   |
| <b>수식적 정당화</b>  | 요구사항을 충족했고, 실제로 관찰한 결과와 일치하는가             |
| <b>결과의 정직성</b>  | 수렴하지 않은 부분·학습이 불안정했던 구간을 숨기지 않고 원인을 분석했는가 |
| <b>탐험-활용 균형</b> | Week 2에서 배운 딜레마가 실제 학습 곡선에서 어떻게 드러났는가     |

5항목은 16.1 채점 기준의 **축 그대로** — 리뷰어와 발표팀이 **같은 기준표**를 공유해야 “감점”과 “좋은 지적”이 **같은 언어**로 이야기될 수 있다.

## 5항목의 구체적 의미 (1) 환경 설명 · (2) 알고리즘 선택

- **(1) 환경 설명** — MDP 5요소(Ch03.1) 중 **상태·행동·보상**이 보고서에서 추적 가능한지.  
“Pendulum을 썼다” 한 줄만 있고 주 지표가 무엇인지(학습 도중 리턴? 이동평균? 평가 리턴?), 리턴의 부호 규약(항상 음수, 0에 가까울수록 좋음)이 없으면 뒤의 모든 숫자가 “무엇의 평균”인지 모른다. 학습 곡선이 에피소드 단위인지 스텝 단위 평균인지도 여기서.
- **(2) 알고리즘 선택** — “PPO를 골랐다”가 아니라, **이 환경의 어떤 특성**이 그 선택을 정당화하는지.
  - ▶ **연속 vs 이산** 행동 공간이 **가장 먼저** 봐야 하는 분기: DQN(Ch09)은 이산 행동을 전제로  $Q(s, a)$ 를 표처럼 출력 — 연속(Pendulum, Reacher)에 그대로 쓰면 “행동을 어떻게 이산화했는가”의 추가 전제가 붙는다.
  - ▶ **희소 보상**(Ch15.2의 보너스 구조)도 근거: 희소 보상에 DQN은 Q값의 희소성 문제(대부분 스텝이 0이라 학습 신호 약함)를 겪는다.

## 5항목의 구체적 의미 (3)-(5) 정당화 · 정직성 · 탐험-활용

- **(3) 수식적 정당화** — “최소 1개”를 채웠는지는 형식 문제, 이 항목은 내용: 깊은 개념(예: Ch11.3 GAE  $\lambda$ )이 **실제로 관찰한 숫자와 일치**하는가. “ $\lambda$ 가 편향-분산을 조절한다”는 문장만 있고  $\lambda$ 를 바꿔 어드밴티지 분산이 어떻게 변했는지 실측이 없으면, 그 문장은 어디에나 붙을 설명일 뿐.
- **(4) 결과의 정직성** — 신경망 **초기화 시드**를 몇 개 돌렸는지, 시드별 이동평균이 사라지지 않고 보고에 들어갔는지, “완전 수렴 아님”을 숨기지 않는지. “결과가 좋았는가”가 아니라 “결과가 **정직한 절차**로 얻어졌는가”를 본다.
- **(5) 탐험-활용 균형** — Ch02 멀티암 밴딧의 딜레마가 **실제 학습 곡선**에서 어떻게 드러나는지. 신경망 RL에서는 탐험이  $\epsilon$ -greedy(DQN, Ch09.2)나 가우시안 정책의  $\sigma$  (Ch10.2, Ch11.2)로 구현 — “탐험을 줄여가는데 줄이는 시점이 학습 곡선의 어떤 지점이었나? 일찍 줄이면 고착, 늦으면 노이즈”(Ch02 직관의 신경망 버전 검증).

## 채점 기준: “채웠는가”가 아니라 “구체적인가”

| 리뷰 품질                 | 특징                                      | 예시 (Pencil)                                    |
|-----------------------|-----------------------------------------|------------------------------------------------|
| <b>1점 — 감상평</b>       | 구체적 지적 없음. 듣기만 하고 느낌만 적음                | “학습 곡선(learning curve)이 높아서<br>작동한 것 같지는 않아요.” |
| <b>2점 — 일반 지적</b>     | 문제를 제기하지만 근거(개념)가 약함. 발표팀이 “네”로 넘길 수 있음 | “시드를 하더라도<br>시드만으로는 부족<br>것 같습니다.”             |
| <b>3점 — 반박 가능한 질문</b> | 이 학기 개념(장·절)을 명시하고, 답이 나쁘면 결과가 흔들리는 질문  | “시드 2개만<br>표준편차가<br>차이가 그 편<br>우연일 가능<br>하나요?” |

1점 → 3점의 공통 패턴 (ML1 8.2와 똑같다)

추상적 평가어(“잘됐다”, “확인해보라”)를 (a) 구체적 관찰 + (b) 이 학기 개념(Ch NN) + (c) 그것이 왜 문제인지(숫자)로 교체. “시드를 하나 더 돌려라”(2점)에는 관찰도 개념도 없지만, 3점 질문에는 관찰(시드 수) + 개념(Ch11.2 초기화 민감성) + 왜 문제인지(숫자 비교)가 모두 들어 있다.

## 손으로 한 번: 가상 발표 (팀 “진자돌림”)

실습 노트북과 동일한 설정 — 모든 숫자는 실제로 그렇게 실행하면 나오는 것. 문제인 곳은 숫자가 아니라 프로토콜.

### 발표 요약

“Pendulum-v1에 PPO. 300 반복  $\times$  400 스텝(총 12만 스텝),  $\gamma = 0.99$ ,  $\lambda = 0.95$ , 클리핑  $\epsilon = 0.2$ , 보상 스케일링 없음, **시드 42** 하나로 학습. 처음 10 에피소드 평균 리턴  $-805.3 \rightarrow$  마지막 10 에피소드 평균  $-742.0$ 으로 개선. 학습 곡선이 완만하게 올라가서 PPO가 잘 작동했다. Week 11에서 배운 클리핑 덕분에 안정적인 학습이 됐다.”

체크리스트 5항목을 하나씩 적용해 본다 — 문제는 모두 **숫자가 아니라 보고의 구조**에 있다.

## 가상 발표를 체크리스트로 — (1)(2) 환경 · 알고리즘

- **환경 설명** — 환경 자체는 명확하다(Pendulum-v1, 연속 행동 1차원 토크, 항상 음수 리턴). 그러나 **주 지표가 모호하다** — “마지막 10 에피소드 평균”이 학습 도중 에피소드 리턴인지, 학습 후(탐험 없이) 재평가한 리턴인지 문장에 없다. 8.1/16.1의 “비교 프로토콜”이 둘을 **반드시 나눠서** 보고하게 한 이유가 바로 이 모호함.
- **알고리즘 선택** — PPO는 연속 행동 환경(Pendulum)에 맞는 선택(Ch10~11). **이 항목은 통과.**

## 가상 발표를 체크리스트로 — (3)(4)(5)

- **수식적 정당화** — Ch11을 인용했지만, 인용과 관측이 **연결되어 있지 않다**. “클리핑 덕분에 안정적”은 어디에나 붙을 설명 — 클리핑  $\epsilon$ 을 바꿔서 안정성(곡선 변동폭, 발산 여부)이 어떻게 변했는지 실측이 없으면, 그 문장은 이 실험에 붙은 정황이 아니라 책에서 읽은 문장일 뿐.
- **결과의 정직성** — 세 가지가 **사라져 있다**: (1) **시드 1개**(신경망 초기화가 무작위라 학습 과정의 우연), (2) **베이스라인 부재**(무작위 정책 리턴 = “잘 배웠다”의 기준점), (3) **완전 수렴 여부 미명시**(12만 스텝은 이 과제에 “절반도 안” 왔을 수 있음, 11.2).
- **탐험-활용 균형** — PPO의 탐험은 가우시안  $\sigma$ (11.2) 인데,  $\sigma$ 가 학습 중 어떻게 변했는지(초기  $\approx 0.61$ 에서 어디로) **한 마디도 없음** — Ch02 딜레마가 학습 곡선에 어떻게 반영됐는지 확인 불가.

## 이 발표에 대한 3점 질문

### 반박 가능한 질문

“시드 42 하나로 “마지막 10에피소드 평균  $-742.0$ ”이라고 했는데, **시드 2개를 더 돌리면** 그 평균의 **표준편차**가 얼마나 되나요? 그리고 “잘 배웠다”의 기준점인 **무작위 정책의 평균 리턴**(약  $-1239$ ) 대비 얼마나 개선됐나요? 12만 스텝이면 11.2에서 본 대로 “절반도 안” 온 수 있는데, 더 오래(예: 24만 스텝) 돌리면 이동평균이 계속 올라가나요, 아니면 이미 **포화**인가요?”

**이 질문이 3점인 이유:** 발표팀이 답하려면 **새로운 실험**(시드 2개 추가 + 무작위 베이스라인 실측 + 학습 스텝 확장)을 돌려야만 하고, 그 실험을 돌리면 “PPO가 잘 작동했다”는 결론이 **흔들릴 수도** 있다 — 3점 조건(개념 명시 + 답이 나쁘면 결과가 흔들림)을 정확히 만족.

## “우연히 좋은” 패턴 5가지 — 신경망 RL 버전

ML1 8.2의 “우연히 좋은 결과” 원천 = 테스트셋 유출 · 정확도의 함정 · 과적합. RL에는 검증/테스트셋 자체가 없음 — 대신 학습 과정의 무작위성이 같은 역할. 8.2의 5가지(표 기반)를 신경망 RL에 맞게 다시 쓴 것. 발표 슬라이드에서 이 패턴을 보면 그 행의 “반박 가능한 질문”을 바로 던져야 한다.

| 패턴                    | 겉보기                    | 실제로는 / 반박 가능한 질문                                                                                                            |
|-----------------------|------------------------|-----------------------------------------------------------------------------------------------------------------------------|
| 1. 시드 1개 학습 곡선        | “곡선이 완만하게 올라가네”        | 신경망 <b>초기화</b> 의 우연 — 같은 코드로 학습한 곡선. “시드 2개를 더 돌리면 이동 평균이 좀 더 매끄러워질 거야. 알고리즘 간 차이가 그 편차보다 큰 것 아니냐 (초기화 민감성)”                |
| 2. 학습 도중 리턴으로 “수렴” 결론 | “마지막 10이 -742.0까지 올랐네” | 학습 도중 리턴은 탐험 ( $\sigma \cdot \epsilon$ 포함) 때문. 12만 스텝은 완전 수렴이 아닐 수 있음. “학습 후 탐험 0으로 재평가한 값은 얼마일까요? (11.2) 돌리면 포화인가요?”(11.2) |

## “우연히 좋은” 패턴 3~5

| 패턴                  | 겉보기                                     | 실제로는 / 반박 가능한 질문                                                                                                                            |
|---------------------|-----------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------|
| 3. 하이퍼파라미터 “적당히” 하나 | “ $\gamma = 0.99, \lambda = 0.95$ 로 학습” | 민감성 미검증 — Ch11.3 GAE 분산)· $\gamma$ (장기 리턴 비중)· <b>보상 1/8</b> 자체가 결과 방향을 바꿀 수 있음. “ $\lambda =$ 어드밴티지 분산이? 스케일링이 결론에 바꿨나요?”(Ch11.3, 16.1 예시) |
| 4. 이산용 알고리즘을 연속 환경에 | “DQN으로 학습했다”                            | DQN(Ch09)은 이산 행동을 전제 — 연속 환경에 적용하려면 행동 이산화 추가 <b>보고에 없으면</b> 선택 부적합. “행동을 이산화했나요? 정말도 손실(Ch09) 확인 연속 정책(Ch10~11)이 자연스러운 이산화?”               |
| 5. 베이스라인 없이 “잘 배웠다” | “-742.0가 나왔다”                           | 기준점 없이 “나다”를 말할 수 없다 — Ch11.3 M2의 무작위 평균(약 -1239)을 <b>재야</b> 판 “무작위 정책의 평균 리턴은 얼마? 그 측정하셨나요?”(16.1 M2)                                      |

**패턴 3이 특히 신경망 특유인 이유:** 8.2의 하이퍼파라미터 ( $\alpha, \epsilon$ )는 일치하는 스케일에서 결과를 바꾸지만, 신경망의  $\gamma \cdot \lambda \cdot$ 보상스케일은 **리턴의 규모 (-1000 안팎)를 직접 바꿔 “좋아진 것”이 알고리즘의 공헌인지** 37/67

## 실습: 가상 발표를 리뷰어의 눈으로 재실행

- 1 **발표팀 재현** — Pendulum-v1, PPO(Ch11.2 코드), 시드 42,  $\gamma = 0.99$ ,  $\lambda = 0.95$ ,  $300 \times 400$ (12만 스텝) → 처음 10: -805.3, 마지막 10: -742.0. 발표팀의 숫자 재현.
- 2 **패턴 1 검증 — 시드 2개 추가** — 시드 123, 7로 재실행 → 시드별 마지막 10 이동평균 표. 편차를 보고 “알고리즘의 차이”인가 “시드의 우연”인가를 판정.
- 3 **패턴 2 검증 — 학습 스텝 확장** — 12만 → 24만 스텝, 이동평균이 포화되는지 → “절반도 안 왔다”(11.2)를 숫자로 확인.
- 4 **패턴 3 검증 — 보상 스케일링 민감성** —  $1/8$  스케일링 +  $\gamma = 0.95$ 로 재실행 → 스케일링이 결론의 방향을 바꾸는지.
- 5 **패턴 5 검증 — 베이스라인 실측** — 무작위 정책 300 에피소드 → 평균 약 -1239.
- 6 **리뷰 작성** — 실습에서 나온 숫자를 근거로 3점 리뷰를 실제 템플릿(나중)으로 완성.

이 6단계 = “리뷰어는 발표팀의 실험을 **자기 손으로** 재실행할 수 있는 사람”이라는 이 절의 핵심 태도를 코드 레벨에서 보여줌. “이 학습 곡선, 시드를 바꿔도 같은 모양이 나올까요?” 라는 질문은 **리뷰어가 실제로 다시 돌려본 적이 있을 때** 가장 날카롭다.


## 실제로 확인해본 것 — 같은 정책, 다른 프로토콜

- 발표팀의 “마지막 10 평균  $-742.0$ ”은 **학습 도중** 에피소드 리턴의 이동평균. 같은 학습 결과를 **학습 후**에 재평가하면: 탐험( $\sigma \approx 0.61$ )이 섞인 채 20 에피소드  $\rightarrow -1413$ , 탐험 0(결정론적  $\mu$ 만)  $\rightarrow -1491$ .  $-742.0$ 은 둘 다보다 훨씬 좋아 보인다.
- **왜?** 학습 도중 에피소드는 학습 초반의 에피소드(탐험이 크고 운 좋게 수직 근처를 스치는 것 포함)까지 10개 평균에 들어가는 반면, 재평가는 마지막 시점의 정책을 순수하게 재기 때문. **같은 정책을 다른 프로토콜로 잰 값** ( $-742$  vs  $-1413 / -1491$ )이 8.2 패턴 2(평가  $\varepsilon$ )의 **신경망 버전**  $-\varepsilon$  대신 가우시안  $\sigma$ 가 탐험의 차원이 됐다.
- **베이스라인**까지: 무작위 300 에피소드 평균 **약**  $-1239$  — 발표팀 정책의 순수 재평가 ( $-1413 / -1491$ )는 **무작위보다 오히려 나쁘다**(12만 스텝의 PPO가 아직 무작위 수준, 11.2 “절반도 안 왔다”가 숫자로 확인).
- **시드**: 42/123/7의 마지막 10 평균  $-742 / -658 / -568$  — 시드 간 sd(약 **70**)가 주장한 “개선폭”( $-805 \rightarrow -742$ , 약 63)보다 **크다**. “개선됐다”의 **방향성조차** 시드의 우연과 구별 불가 — 이 숫자들이 3점 질문이 왜 3점인지를 보여준다(답하려면 실제 실험을 돌려야 하고, 돌리면 결론이 “아직 무작위 수준”으로 뒤집힌다).

# 리뷰 쓰는 과정 — 체크리스트 → 반박 가능한 질문

- (1) 다른 팀 발표 + 보고서 읽고 **주장 파악**  
(알고리즘·하이퍼파라미터·숫자·결론)
- (2) **체크리스트 5항목** 적용
- (3) 각 항목에서 **질문 초안** — 답이 새 계산·실험이어야 함
- (4) **분기**: “Ch9~15 개념(장·절)을 근거로 들고, 답하려면 **새 실험**(시드 재실행·평가 프로토콜 변경·베이스라인 실측·스케일 비교)이 필요한가?”
  - ▶ 예 → **반박 가능한 질문 채택**(초록)
  - ▶ 아니오 → “곡선이 올라가네요” 같은 **감상평** (빨강)으로 떨어짐 — Ch09.2( $\epsilon$ -greedy)·Ch11.3 (GAE  $\lambda$ )·Ch12.1(복합 오차) 개념으로 **다시 쓰기**(점선으로 (3) 회귀)
- (5) 3단계 기준(1/2/3점)으로 **자기 채점**

16.2 Peer-Review — ‘반박 가능한’ 리뷰를 쓰는 과정 (신경망 RL 버전)



# 리뷰 템플릿 — ML1 8.2에서 5번을 두 칸으로

ML1 8.2 템플릿에서 5번을 두 칸으로 늘린 것 (“근거가 되는 개념” + “반박하려면 어떤 새 실험이 필요한지”)이 강화학습 버전의 특징 — 답이 새 실험이어야 질문이 3점이 되기 때문. 5번 두 칸이 모두 채워져야 3점 도달; 비어 있으면 반박 불가능한 리뷰.

팀이름

: \_\_\_\_\_ 리뷰어 : \_\_\_\_\_

1. 환경설명—상태행동 · 이산연속 (/) 보상·부호 ( 규약, 희소여부 ) · 주지표학습중  
( 리턴? 이동평균? 평가리턴 ? )가 추적가능한가 ? 베이스라인무작위  
( ) 리턴은 명시됐는가 ?
2. 알고리즘선택—이환경의 어떤 특성행동 ( 이산연속 / , 보상구조 ) 이 알고리즘  
( Ch9~15 ) 선택을 정당화하는가 ? 개념으로 설명되는가 ?
3. 수식적정당화— ” $\geq$ 개1” (16.1) 를 채웠는가? 깊은 개념이 실제로 관측한 숫자와 일치하는가 단순  
( 인용이 아닌가 )?
4. 결과의정직성—시드초기화 ( ) 수, 시드별 이동평균 , ”완전 수렴이 아니다  
”가 정직하게 보고됐는가 ? 불안정한 시드구간이 · 있는가?
5. 반박가능한 질문필수 ( , 개1 이상 ) — 근거가 되는 개념  
: Week \_\_ 절 \_\_ 개념 ( : \_\_\_\_\_ ) 발표팀이 답하려면 필요한 새 실험 계산  
/: \_\_\_\_\_ 질문  
: \_\_\_\_\_ 발표팀이  
( 이 질문에 답이 나쁘면 결과가 흔들리는 것이어야 한다 )

## 자주 하는 실수: 학습 곡선 한 번만 보고 결론 내리기

- RL 프로젝트에서 특히 빈번한 부실한 리뷰: “학습 곡선이 잘 올라갔으니 성공”로만 판단 — 그 곡선이 **무작위 시드 하나**인지, **반복해서 일관된 경향**인지, **완전 수렴**인지 “개선됐지만 갈 길이 남은” 상태인지를 **먼저** 물어야 한다.
- 신경망 RL에서 구조적으로 더 위험한 이유: 곡선의 “오르다/안 오르다”가 **학습의 진전과 분리될 수 있기** 때문 — 11.2에서 PPO 곡선은 “완만한 상승”이었으나 개별 에피소드 리턴은  $-1800$ (쓰러짐)  $\sim 0$ (수직)까지 넓게 퍼져 있음. 이동평균이 올라간다고 **에피소드 리턴의 분산**이 줄어든 것은 아니다.

### 학습 곡선 3문 — 리뷰어가 던지는 질문

- ① **시드(초기화)**: 시드 몇 개의 평균(또는 범위) 인가? 1개라면 “일관된 경향”을 말할 수 없다.
- ② **평가 프로토콜**: “학습 도중 리턴”(탐험 포함)인지 “학습 후 탐험 0 재평가 리턴”인지? **다른 대상**의 측정값이다.
- ③ **수렴 여부**: 이 스텝 수(예: 12만)가 완전 수렴인가? 더 오래 돌리면 포화인가요, 계속 오르나요(11.2)?

## 우리 팀 발표를 리뷰하기 — 발표 전 셀프-리뷰

- ML1 8.2의 결론을 그대로: **네가 심사할 때 던질 수 있는 가장 날카로운 질문을, 네 발표 전에 스스로 던져보고 답을 준비해두는 것**이 최선의 전략.
- § 5가지 패턴의 5개 질문을 **자기 팀의 보고서**에 적용:
  - ① 시드 3개의 이동평균 표가 **보고서에** 있는가
  - ② 평가 프로토콜 문장(탐험 0? 에피소드 수? 모든 시드에 동일)이 있는가
  - ③ 무작위 정책의 리턴이 **실측 숫자**로 적혀 있는가
  - ④  $\lambda$ -보상스케일 민감성을 한 줄이라도 검증했는가
  - ⑤ 불안정한 시드·구간이 “잘 안 된 부분” 절에 사라지지 않고 있는가
- 이 5가지에 답이 없다면, **발표 전에** 해결해두는 것이 발표 중에 3점 리뷰를 받는 것보다 **항상 낫다**.

## 확인 문제 (1)-(2)

- 1. “시드 3개 이동평균  $-742/ -658/ -568$ 이 나왔으므로 PPO는 안정적이다” — 이 세 숫자는 **무엇의** 편차이고, **무엇의** 편차가 아니인가?

→ **학습 과정의** 무작위성(초기화 시드)이 만든 **세 개의 서로 다른 정책**의 이동평균 — “어떤 정책이 학습됐는가”의 편차이지 “그 정책을 재는 측정 오차”가 아님. 윈도우를 키워도 시드 간 편차( $sd \approx 70$ )는 안 사라짐.

“안정적이다”라 말하려면 **두 층의 불확실성**을 구분해서 (“시드 간  $\pm 70$ , 시드 내 에피소드 분산  $\pm \dots$ ”) 나눠 적어야. 참고: 시드 간 편차(약 70)는 한 시드의 개선폭(약 63)보다 크므로 방향성조차 우연과 구별 불가.

- 2. “학습된 정책으로 마지막 10 에피소드 평균  $-742$ ” 에는 어떤 **모순**이 숨어 있는가?

→ “학습된 정책”이  $\sigma$ 가 포함된 정책이라면 “마지막 10 에피소드”는 **탐험이 섞인** 측정 — PPO는  $\sigma$ 가 학습 중 변하므로(11.2), “마지막” 에피소드의  $\sigma$ 가 얼마 였는지 명시해야 “정책의 성과”. 질문: “ $\sigma$ 는 얼마?

$\sigma = 0$ (결정론적)으로 재평가하면? 더 오래(30만 스텝) 하면 포화되나요(11.2)?”

## 확인 문제 (3)-(5)

- **3.** “GAE의  $\lambda = 0.95$ 가 편향-분산을 조절해서 학습이 안정됐다(Ch11.3)”로 끝난 정당화는 **2점에 가깝다** — 개념은 인용했지만 관측 숫자가 없음. 3점 전환: “ $\lambda$ 를 0.8/1.0으로 바꿔 어드밴티지 추정치의 분산을 실측했습니다 — 실측 표가 보고에 있습니까?”(관찰+개념+ 숫자).
- **4.** “왜 DQN이 아니라 PPO인가요?” — 이대로면 **2점**(“연속이라서” 한 줄이면 반박이 어려움). 3점 버전: “Pendulum의 행동은 연속인데 DQN(Ch09)은 이산 전제로  $Q(s, a)$ 를 출력 — 이산화의 정밀도 손실을 확인했나요? 아니면 연속 정책인 PPO(Ch10~11)가 자연스러운 이유가 무엇인가요?”(체크리스트 2번에 Ch09 vs Ch10 개념 연결).
- **5.** “PPO가 항상 좋은가요? “잘 학습했다”가 무작위(약 -1239)보다 나은 걸 어떻게 아나요?” — **정직한 범위:** “이 환경·이 설정( $\gamma, \lambda$ , 12만 스텝)에서 시드 3개 한도에서 학습 도중 이동평균이 무작위보다 높다”(단, 순수 재평가 -1413/ -1491로는 오히려 나쁨; 외부 일반화는 이 실험이 지지하지 않음). **말하면 안 될** 추론: “PPO가 더 좋은 알고리즘이다” — 이 비교는 이 환경·이 스텝 수의 답이지 **알고리즘 우열**의 답이 아니다.

## 자주 묻는 질문

- **하이퍼파라미터 선택 근거까지 물어봐야 하나? 그렇다면** — “적당히” 고른 값( $\gamma, \lambda, \epsilon$ , 보상 스케일)이 결과에 얼마나 큰 영향을 주는지 확인 했는지가 **방법론 적절성** 평가의 핵심.
- **모방학습/MCTS 팀은 체크리스트를 어떻게?** “학습 곡선” 대신 다른 증거로 — 모방학습: Ch12.1 **복합 오차**(전문가 분포 밖 성능 저하) 관찰됐는가 / MCTS: Ch15.2처럼 **시뮬레이션 횟수 증가** 시 선택되는 수가 더 정확해지는가.
- **문제가 없는 팀에 3점 질문을 어디서?** “문제가 보이지 않는 것”과 “확인되지 않은 것”은 다르다 — 3점 질문은 항상 **확인되지 않은 영역**에서 나옴(시드 5개 확장,  $\lambda$  민감성, 더 긴 학습 스텝, 다른 평가 프로토콜). “이 실험의 다음 단계로 무엇이 가장 정보가 많을까요?”가 3점이 될 수 있다 — 발표팀이 답할 수 있다면 발표는 **더 단단해** 짐(리뷰어가 목표 달성).
- **“더 오래 돌려보세요”를 쉽게 요구할 수 없는데?** 리뷰어가 직접 300만 스텝을 돌릴 필요는 **없다** — 3점 질문은 발표팀이 돌려야 할 실험을 지적하는 것. “12만 스텝으로 포화가 안 보이는데, 이 과제는 완전 수렴에 수십만 스텝이 필요하다고(11.2) 했죠? 그걸 인지하고 “아직 안 끝났다”고 보고했나요?” — “몰랐습니다”면 **수렴 여부 미인식** 자체가 “결과의 정직성” 감점 요인.

---

## 16.3 ML2 총정리와 학기를 넘어서

---

# 이 절은 새로운 개념이 하나도 없다 — 하는 일 네 가지

- ① 16.1 발표 · 16.2 Peer-Review가 수렴해 온 **채점 기준(rubric)** 을 확정.
- ② **같은 작은 MDP를 네 가지 경로로 풀어** “모두가 같은 방정식을 푸는 구조”를 **숫자**로 확인.
- ③ 준비도를 스스로 재는 **자가진단**(20문항).
- ④ 학기 이후로 이어지는 지도(§ 학기를 넘어서)를 그림.

## 복습의 원칙

이 절의 모든 문장은 **이번 학기 13개 장의 요약** — 한 문장이라도 막히면 **그 장·절 번호로 돌아가는 것**이 복습이 아니라 정확한 복습이다.

## 프로젝트 채점 기준 — Block B 3주가 수렴하는 곳

8.1 rubric이 그대로 이어져 오면서 “Ch4~7 개념”이 “Ch9~15 개념”으로 교체된 것이 전부:

| 항목           | 비중  | 좋은 답이란                                                                                                                                       |
|--------------|-----|----------------------------------------------------------------------------------------------------------------------------------------------|
| 문제 정의와 환경    | 15% | 상태·행동·보상이 명확(물리적 단위까지, Ch13), 환경 선택이 Ch9~15의 개념 검증 목적에 근거                                                                                    |
| 알고리즘 적절성     | 20% | 환경 특성(이산/연속, 희소성, 모델 유무)에 알고리즘이 맞고, 근거가 Ch9~15 개념으로 설명                                                                                       |
| 실험 프로토콜의 정직성 | 25% | 시드 $\geq 3$ , 학습 곡선과 최종 평가(탐험 끄) 분리, 베이스라인(무작위 또는 사람이 설계한 PD 제어 등), $\epsilon \cdot \gamma \cdot \lambda$ -클립 $\epsilon$ 감수성 실험이 보고서에서 추적 가능 |
| 수식적 정당화      | 20% | 배운 개념 $\geq 1$ 개로 “왜”를 설명(11.3 클리핑, 12.1 복합 오차, 13.1 도메인 무작위화 ...)했고, 관측 숫자와 일치                                                              |
| 결과의 정직성과 반성  | 20% | 불안정했던 시드·구간을 숨기지 않고 원인을 Ch9~15 개념으로 진단(16.1 좋은/나쁜 예 기준)                                                                                      |

## 손으로 한 번: Peer-Review rubric을 직접 써보기

- 관점을 한 단계 더 뒤집어 “너가 채점자라면 무엇을 봐야 하는지” rubric을 직접 쓰는 연습.
- 5개 항목을 그대로 두고, 각 항목에 대해 **두 칸**을 채운다: (1) **나쁠 때는 어떤 모습인가**(구체적 나쁜 패턴), (2) **그걸 시험하는 질문은 무엇인가**(16.2의 반박 가능한 질문).

### 나쁠 때 (구체적 패턴)

보고서에 **최고 점수 시드 하나만** 실려 있음. 학습 곡선이 매끄럽고 불안정 구간 설명이 없는데, 학습 로그(코드 출력)를 보면 300 iteration 중 **150~200 구간에서 리턴이 갑자기 내려간** 기록이 있음

### 시험하는 질문 (반박 가능)

“로그의 150~200 iteration 리턴 추락을 보고서의

이 연습의 채점 기준 = 16.2 “구체적인가” 3단계 그대로: “나쁨 = 불성실”은 **1점**(감상평), 그날 발표실에서 실제로 낚일 수 있는 패턴을 쓴 것은 **3점**. “나쁠 때의 모습”을 쓸 수 있으려면 “좋은 답이란”을 이미 정확히 이해해야 하므로, 이 30분 연습(나머지 4행 = 팀 회의 과제)은 **학기 전체를 가장 빨리 재검증하는 방법**.

# “달리거나 쉬거나” MDP — 숫자로 보는 학기 중간고사

같은 작은 MDP를 Week 4~6의 네 경로로 풀어, 네 경로가 “같은 답, 또는 설명 가능한 다른 답”에 도달하는 것을 확인. 실습 노트북이 네 경로의 학습 곡선을 코드로 재현.

MDP(8.3 템플릿 ②): 3-state,  $\gamma = 0.9$

- **S**(시작): run — 0.7 확률로 G, 0.3 확률로 S로 **미끄러짐**, 보상 0. rest — S에 남음, 보상 -1.
- **G**(골): collect — T로 전이, 보상 +3.
- **T**: 터미널.

## 경로 ① — 동적계획법(Ch4): 벨만방정식을 손으로 푼다

+3을 받는 유일한 길은 G에서 collect  $\Rightarrow V^*(G) = 3$ . S에서 run이 최선(후보 추측)이면:

$$V^*(S) = 0.9(0.7 \times 3 + 0.3 V^*(S)) = 1.89 + 0.27 V^*(S) \Rightarrow V^*(S) = \frac{1.89}{0.73} \approx 2.589$$

검증(후보+검증 Step 3):

$$Q^*(S, \text{run}) = 2.589 > Q^*(S, \text{rest}) = -1 + 0.9 \times 2.589 = 1.330 \checkmark$$

## 경로 ② 몬테카를로(Ch5) · 경로 ③ SARSA(Ch6 on-policy)

- **경로 ② 몬테카를로** — greedy 정책(run@S, collect@G)으로 에피소드를 끝까지 roll-out하고, 실제 리턴  $G_t$ 를 그대로 목표값으로 (첫방문 MC). 4000 에피소드로  $V(S) \approx 2.594$  — 참값과 **0.2% 차이**. MC는 **편향이 없다**(실제 실현된 리턴의 기댓값이 정확히  $V^\pi$ ) — “충분히 많이 돌리면” 약속이 이 예에선 정말로 지켜진다.
- **경로 ③ SARSA** — TD 오차로 갱신하되, 다음 행동  $a'$ 도 **실제 행동 정책( $\epsilon$ -greedy)**이 고른 것을 쓴다.

### 이번 학기의 핵심 드라마

**SARSA는 최적값이 아니라 “탐험하는 행동 정책의 값”을 배운다.**  $\epsilon = 0.3$  고정 시  $\pi$ 의 값  $V^\pi(S) \approx 2.29$ 로 수렴 — 해석적으로 정확히 **2.292. 2.589가 아니라 2.29.**

(참고: 이때  $Q(S, \text{run})$  자체는  $\approx 2.53$  —  $\pi$ 가 15% 확률로 rest를 실제로 고르기 때문에  $V^\pi(S) = 0.85 Q^\pi(S, \text{run}) + 0.15 Q^\pi(S, \text{rest})$  가 실제 선택 분포까지 반영해 더 낮아짐.)

## 경로 ③ SARSA — 0.297의 간극은 버그가 아니라 기능

- **2.589 — 2.292 = 0.297**의 간극은 **버그가 아니라 기능** — “ $\epsilon$ -greedy가 30%의 시간을 미끄러지며 낭비한다”는 사실이 가치에 반영된 것 (6.3 CliffWalking 에서 “학습 도중 리턴이 오히려 나쁜” SARSA의 근원이 바로 여기).
- $\epsilon$ 을 **감쇠**시키면(매 에피소드 0.995배 스케줄)  $V^\pi$ 는  $V^*$ 에 가까워진다 —  $\epsilon \rightarrow 0$ 이면 행동정책이 greedy로 수렴하므로, 실습에서  **$\epsilon$  감쇠 SARSA는 2.589로 끝난다.**

on/off-policy의 차이는 **취향이 아니라 “무엇을 묻느냐”**의 차이 — ③은 “지금 탐험하는 정책의 값”, ④는 “최적 값”.  
(확인 문제 3의 “왜 PPO는 데이터를 재사용할 수 없는가”의 표 버전이다.)

## 경로 ④ Q-learning(Ch6 off-policy) — max 한 줄

- 갱신식에 max을 써서, 행동 정책이 실제로 무엇을 했든 “다음에서는 **최선을 고른다면**”을 목표값으로 삼는다.
- 그래서 행동 정책과 무관하게 **최적 Q에 직접 수렴** — 시뮬레이션(2000 에피소드,  $\epsilon$ 을 0.05까지 감쇠)  
결과  $Q(S, \text{run}) \approx 2.64$ ,  $Q(S, \text{rest}) \approx 1.34$ ,  $Q(G, \text{collect}) = 3.0$  — 참값(2.589, 1.330, 3.0)에 근접.

| 경로            | 장   | 무엇을 쓰는지                | $V(S)$ 추정/수렴값                         | 수렴 대상     |
|---------------|-----|------------------------|---------------------------------------|-----------|
| ① 동적계획법 (손계산) | Ch4 | 전이 모델 $P$              | 2.589                                 | 최적값 $V^*$ |
| ② 몬테카를로       | Ch5 | 에피소드 전체 리턴             | 2.594 (4000 에피소드)                     | greedy    |
| ③ SARSA       | Ch6 | 1스텝 TD 오차 (on-policy)  | <b>2.29</b> ( $\epsilon = 0.3$ 고정)    | 행동 정책     |
| ④ Q-learning  | Ch6 | 1스텝 TD 오차 (off-policy) | 2.64 (2000 에피소드, $Q(S, \text{run})$ ) | 최적값 $Q^*$ |

③과 ④의 갱신식은 **한 줄 차이**다 — 6.3에서 “SARSA vs Q-learning의 차이는 max 한 줄”이라 했지만, 그 한 줄이 **수렴하는 대상 자체를 바꾼다**:

# 한 줄 차이 — SARSA vs Q-learning

```
# SARSA (on-policy): 다음행동은 a_next ε-greedy 실제로고른것
Q[s, a] += alpha * (r + gamma * Q[ns, a_next] - Q[s, a])
# Q-learning (off-policy): 실제로무엇을했든최선을 "" 목표로
Q[s, a] += alpha * (r + gamma * np.max(Q[ns]) - Q[s, a])
```

## 왜 1개 MDP를 네 번 푸는가가 가치 있는가

단일 장에서는 보이지 않는 **세 가지**가 숫자로 드러난다. **(1) 목표가 다르면 답이 다르다** — ③④는 갱신식이 한 줄 ( $Q[ns, a']$  vs  $\max Q[ns]$ ) 다른 구조인데  $V(S)$ 가 2.29와 2.589에 각각 수렴 — 간극이 정확히  $V^* - V^\pi = 0.297$ , “탐험의 가격” 그 자체. **(2) 네 경로 모두 같은 방정식을 쓴다** — ①이 벨만방정식을 직접 풀고, ②는 미래 항을 실제 실현으로, ③④는 한 스텝 예측 + 자기 추정으로 대체한 것뿐. **(3) 탐험의 비용이 측정된다** — ③의 0.297 간극은 “ $\epsilon = 0.3$ 의 탐험이 리턴 기준으로 이만큼 값어치가 한다”는 **숫자** — Ch2에서 직관으로 시작한 탐험-활용 딜레마가 여기서는 측정 대상.

## ML2 개념 지도 — 13개 장

| 장    | 배운 것             | 핵심 질문                              |
|------|------------------|------------------------------------|
| Ch02 | 멀티암 밴딧           | 상태 없이도 탐험-활용 딜레마를 어떻게 다루는가         |
| Ch03 | MDP              | 강화학습 문제를 어떻게 수학적으로 정식화하는가          |
| Ch04 | 동적계획법            | 모델을 알 때 최적 정책을 어떻게 계산하는가           |
| Ch05 | 몬테카를로            | 모델 없이, 에피소드 결과만으로 어떻게 배우는가         |
| Ch06 | 시간차 학습           | 에피소드가 끝나길 기다리지 않고 어떻게 배우는가         |
| Ch07 | n-step/적격흔적/Dyna | MC와 TD 사이, 경험 재사용은 어떻게 하는가         |
| Ch09 | DQN              | 표 대신 신경망으로 어떻게 Q-함수를 근사하는가         |
| Ch10 | 정책기반 RL          | Q를 거치지 않고 정책을 직접, 연속공간에서 어떻게 학습하는가 |
| Ch11 | PPO              | 정책이 한 번에 너무 멀리 움직이지 않게 어떻게 제한하는가   |
| Ch12 | 모방학습/RLHF        | 시행착오 대신 시연이나 선호로부터 어떻게 배우는가        |
| Ch13 | 로봇 시뮬레이션         | 물리 법칙이 지배하는 연속 제어 문제를 어떻게 다루는가     |
| Ch14 | MuJoCo/Isaac Sim | 시뮬레이션의 정밀도와 속도를 어떻게 절충하는가          |
| Ch15 | MCTS             | 완벽한 모델이 있을 때 미리 수를 어떻게 읽어보는가       |

## 두 과목을 관통하는 구조 — 3단계

- ① **모델을 정의한다**: 상태를 행동(또는 그 확률분포)으로 매핑하는 함수의 형태를 정한다 (Q-테이블, 신경망 Q-함수, 정책 신경망, 게임 트리, ...).
- ② **틀린 정도(또는 목표와의 격차)를 수치화한다**: TD 오차, 정책 그래디언트의 목적함수, PPO의 클리핑된 목적함수, MCTS의 승률 통계, ... — **형태는 매번 다르지만** “지금 얼마나 좋은가/나쁜가를 수치 하나로 요약한다”는 **역할은 항상 같다**.
- ③ **그 수치를 개선하는 방향으로 파라미터(또는 탐색 방향)를 조정한다**: 경사하강법, 또는 트리 탐색의 반복 — **이 학기 배운 모든 알고리즘의 마지막 단계는 결국 이것**.

### “네 경로” 예가 3단계의 축소판

앞의 4경로 예는 이 3단계가 같은 방정식 위에서 어떻게 변주되는지, 이 지도는 그 변주들이 어떤 축을 따라 정렬되는지를 그려준다.

# Block B 개념 지도 읽는 법 — 박스와 축의 교차점

지도의 읽기는 8.3 Block A 지도와 같은 두 기법:


## ● (1) 질문은 박스가 아니라 박스와 축의 교차점

— “DQN의 리플레이 버퍼가 왜 PPO에는 없는가” = DQN 박스와 on/off-policy 축이 만나는 **엇지**; “GAE의  $\lambda$ 를 0.95로 올리면 어떻게 되나” = PPO 박스와 편향-분산 축의 **엇지**.

## ● (2) 엇지가 곧 “왜” — 박스 자체를 묻는 질문은 드물다. 발표·면접에서 반복적으로 나오는 것은:

- ▶ **신경망으로 바꾼 이유**(Ch9, 표가 불가능해진 상태공간)
- ▶ **클립을 하는 이유**(Ch11, 한 번의 업데이트가 정책을 망가뜨리는 방어)
- ▶ **모방학습이 나빠지는 이유**(Ch12, 분포 이동의 복합 오차)
- ▶ **sim-to-real이 필요한 이유**(Ch13, 현실 격차가 커지기 때문)

Block B(Ch9~15) 개념 지도 — 한 질문: ‘정답 없이, 내가 만든 경험만으로, 로봇 스캐일까지 배우는가?’



## 확인 문제: 장을 넘나드는 복습 4개 (1)-(2)

- 1. Ch2.2의 **UCB**와 Ch15.2의 **UCT**는 수식이 거의 똑같다. 무엇이 같고, 다른가?

→ 둘 다 “지금까지의 평균 성과 + 덜 시도해본 정도에 대한 불확실성 보너스”라는 같은 형태 ( $\bar{X} + c\sqrt{\ln N/n}$ ).

**다른 것은 적용 대상** — UCB는 **밴딧의 팔**(상태 없는 단일 선택) 하나하나에, UCT는 **게임 트리의 매 노드마다** 독립적으로 적용되어 “각 국면에서 다음 수를 고르는” 문제를 반복해서 푼다.

- 2. Ch6.1의 **TD 오차**와 Ch10.3의 **Actor-Critic**은 어떤 관계인가?

→ Actor-Critic의 **critic**이 학습하는 신호가 바로 **TD 오차** — REINFORCE(10.2)가 에피소드 전체 리턴으로 그래디언트 분산이 컸다면, AC는 그 리턴을 **TD 오차**(한 스텝만 보고 계산한 어드밴티지 추정치)로 대체해 **분산을 줄인다**. Ch11.3의 **GAE**는 이 TD 오차를 여러 스텝에 걸쳐 지수가중평균한 **일반화**.

## 확인 문제: 장을 넘나드는 복습 4개 (3)-(4)

- **3.** DQN(off-policy)이 리플레이 버퍼의 오래된 경험을 재사용할 수 있는데, REINFORCE·PPO는 왜( PPO는 부분적으로만) 그럴 수 없는가?

→ DQN은 **Q-함수**(정답이 정해진 값)를 배우는 것이라 “누가 그 경험을 만들었는지”와 무관하게 벨만 방정식이 성립 — **off-policy**. REINFORCE는 정책 그래디언트가 “지금 정책이 그 행동을 선택할 확률”에 의존 — 정책이 바뀌면 그 확률도 바뀌어 **옛 데이터의 그래디언트가 더 이상 정확하지 않다(on-policy)**. PPO는 확률비  $r_t(\theta)$ 로 이 차이를 **보정**하고 클리핑으로 오차를 억제해서 몇 에폭 정도는 재사용 가능하지만, DQN처럼 완전히 오래된 경험까지는 재사용 못 함.

- **4.** Ch12.1 **모방학습**(BC/DAGger)과 Ch15.2 **MCTS**는 둘 다 “에이전트가 직접 시행착오를 겪는 것의 대안”. 각각 무엇을 대신 활용하는가?

→ 모방학습은 **사람의 시연**(전문가가 실제로 어떻게 행동했는지)을 **정답** 삼아 지도학습으로 정책을 배움. MCTS는 **완벽한 모델(규칙)로 만든 가상의 시뮬레이션**을 반복해서, 실제로 행동하기 전에 결과를 미리 들여다봄. 둘 다 표준 RL보다 **안전하거나 효율적**이지만, 전자는 **사람의 시연 데이터**가, 후자는 **정확한 모델(규칙)**이 있어야 한다는 **전제**가 필요.

## 복습 자가진단 — 20문항

8.3의 20문항과 같은 형식 — 각 문항에 대해 10초 안에 한 문장으로 답을 말할 수 있으면 O, 막히면 ×. 18개 이상 = 준비 완료 / 15~17 = ×가 모인 장의 “자주 하는 실수”+확인 문제 다시 / 12~14 = § 네 경로의 수식(TD 오차, 클리핑된 목적함수)을 손으로 다시 유도 / 12 미만 = § 자주 하는 실수(총정리판)를 건너뛰지 않는다.

| #  | 한 문장 질문 (장)                                      |
|----|--------------------------------------------------|
| 1  | DQN의 타겟 네트워크는 왜 매 스텝 갱신하면 안 되는가 (Ch09)           |
| 2  | 리플레이 버퍼가 해결하는 문제와, DQN에서만 가능한 이유 (Ch09/06)       |
| 3  | TD 오차를 $Q$ 로 표기하시오 (Ch06/09)                     |
| 4  | REINFORCE와 TD 갱신의 차이를 한 문장으로 (Ch10)              |
| 5  | baseline 차분이 왜 편향을 만들지 않는가 (Ch10)                |
| 6  | PPO의 클리핑이 막는 “나쁜 일”은 무엇인가 (Ch11)                 |
| 7  | 정책 그래디언트가 왜 on-policy여야 하는가 (Ch10/11)            |
| 8  | GAE의 $\lambda$ 가 0이면 / 1에 가까우면 각각 무엇이 되는가 (Ch11) |
| 9  | 행동복제가 “복합 오차”로 나빠지는 메커니즘 (Ch12)                  |
| 10 | DAGger가 복합 오차를 피하는 방식 (Ch12)                     |
| 11 | RLHF에서 “정답”이 아니라 무엇으로 레이블을 얻는가 (Ch12)            |
| 12 | 로봇 정책을 시뮬레이션에서 학습하는 이유 두 가지 (Ch13)               |
| 13 | 현실 격차가 “잡음”이 아니라 “편이”라는 말의 뜻 (Ch13)              |
| 14 | 도메인 무작위화 범위가 넓은 것이 항상 좋은 것이 아닌 이유 (Ch13)         |
| 15 | MuJoCo와 Isaac Sim의 트레이드오프를 한 문장으로 (Ch14)         |
| 16 | AlphaZero가 정책망과 가치망을 둘 다 쓴 이유 (Ch15)             |
| 17 | UCT의 탐색 항이 “시도 횟수”로 무엇을 쓰는지 (Ch15/02)            |
| 18 | MCTS가 DP와 다른 점 — “모델”을 어떻게 쓰는지 (Ch15/04)         |
| 19 | 이번 학기 모든 알고리즘의 공통 3단계를 쓰시오 (전체)                  |

# 자가진단 답 (한 줄) — 핵심 10문항

- 1 — 목표와 추정치가 서로를 따라다니며 발산하기 때문(9.2절 보스팅 불안정의 방치 버전).
- 2  $3 - \delta = r + \gamma Q(s', a') - Q(s, a)$  — 최적을 추구하면  $a'$  자리에 max.
- 3  $5 -$  baseline  $b(s)$ 가  $a$ 에 무관하므로  $\mathbb{E}_a[\nabla \log \pi(a|s) b(s)] = b(s) \nabla \sum_a \pi(a|s) = 0$  — **분산만 줄고 편향은 0.**
- 4  $6 - r_t(\theta)$ 가 1에서 크게 벗어나 한 업데이트에 정책이 “멀리 점프”해 좋은 정책을 **망가뜨리는 것** — 클리핑은 점프 반경을 제한.
- 5  $8 - \lambda = 0$ 이면 TD(0)(편향 있음, 분산 작음),  $\lambda \rightarrow 1$ 이면 (유한 에피소드에서) MC 리턴(편향 없음, 분산 큼) — 7.2의 U자 스펙트럼.
- 6  $9 -$  전문가 데이터 **분포 밖** 상태에 들면 그 행동이 신뢰 불가 → 다음 상태가 더 벗어난 분포로 → 오차가 **스텝마다 곱해짐**(covariate shift).
- 7  $11 -$  사람의 **선호**(두 응답 중 어느 것이 나은지) — 선호 데이터로 **보상 모델**을 먼저 학습하고, 그 보상으로 PPO.
- 8  $13 -$  **systematic**한 차이이므로 시뮬레이션 데이터를 늘려도 **사라지지 않음** — ML1 Ch04 bias-variance에서 “편이는 데이터로 안 줄고”의 RL 버전.
- 9  $15 -$  MuJoCo: 접촉·마찰 **정밀도**, Isaac: GPU **병렬화**(수천 환경 동시) — 정밀도 대 규모.
- 10  $20 -$  ML1은 다른이(데이터 수집자)가 만든 데이터와 정답을 줘 맞추게 하고, ML2는 에이전트가 행동해서 데이터를 스스로 만들고 정답 없이 보상만으로 배운다 — “**무엇을 데이터로 갖고, 무엇을 최적화하는가**”의 답이 바뀌는 것.

## 자주 하는 실수 — 총정리판

- “**곡선이 올라갔다**”로 “**왜 올라갔는지**”를 대체하기 — 16.1 좋은/나쁜 예의 학기 전체 버전. “PPO로 학습 했는데 리턴이 좋아졌다”는 문장은 Ch11의 어떤 개념도 사용 하지 않은 문장. “보상 스케일링 1/8로 어드밴티지 분산이 줄었고 (11.1),  $\lambda = 0.9$ 로 편향-분산 트레이드오프를 조정한(11.3) 결과”까지가 한 문장이면, 그 팀은 이 학기를 **통과**한 것.
- “**시뮬레이션에서 검증했다**”로 “**완료**” 선언하기 — 시뮬레이션 점수는 **시뮬레이션 환경의 점수**일 뿐, 시뮬 상위권 정책이 **실물에서 꼴찌**로 뒤집힐 수 있음. 물리 파라미터(감쇠, 마찰)를 넣었다면 그 파라미터를 바꿔 “순위 유지”가 성립하는지 확인한/안 한 팀의 점수가 rubric “방법론 적절성”에서 갈림.
- “**PPO가 더 좋았다**”를 조건 없이 쓰기 — 알고리즘 비교 결론에 **환경(연속/이산, 보상 구조), 시드 수, 하이퍼파라미터**가 붙지 않으면 그 문장은 **무효**. 유효한 버전: “Pendulum, 시드 3개, 같은 총 스텝 수에서, PPO( $\lambda = 0.9$ )가 REINFORCE 대비 에피소드당 리턴이 평균 12% 높고 시드 간 표준편차는 40% 작았다”.
- “**수렴했다**”와 “**좋다**”를 혼동하기 — 탐험이 부족한 상태의 Q값은 틀린 값으로 정확히 수렴할 수 있고, 곡선의 “평탄화”는 수렴일 수도 **고착(stuck)**일 수도 있음. 16.1 Pendulum 예(−1092, 이론 최적과는 멀다) = “개선됐지만 수렴한 것은 아니다”의 정직한 보고 예.
- **자기 프로젝트의 실패를 복습 자료로 안 쓰기** — “이 실험의 이상한 결과를 원인으로 진단하라”형 질문(발표 질의응답, 면접)에 답할 자료는 **바로 16.1의 “잘 안 됐던 부분과 원인 진단” 절**. 자기 실험의 실패 한 것을 개념으로 해석한 능력은 어떤 참고서로도 대체 불가.

# 마지막 체크리스트 — 학기 이후에 가져갈 세 가지

공식 목록은 13개 장이지만, 졸업하고 몇 년 뒤에 실제로 남는 것은 세 가지:

- ❶ **“무엇을 데이터(경험)으로 갖고, 무엇을 최적화하고 싶은가”라는 질문의 습관.** 새로운 문제(운영 전략, A/B 테스트, 물리 설계, LLM 후학습)를 마주했을 때 “어떤 에이전트·어떤 보상·어떤 경험인가”로 **번역하는 연습**을 13번 한 것이 이 학기. 알고리즘 이름은 잊어져도 **이 번역은 남는다** — ML1의 “행의 단위, 정답의 유무”와 쌍을 이루는, 문제 정식화 기술의 절반이 완성된 것.
- ❷ **정직한 숫자에 대한 기준.** 시드  $\geq 3$  · 학습/평가 분리 · 베이스라인 · “완전히 수렴하지 않았다”는 문장 — 8.1 에서 시작해 16.1에서 반복된 프로토콜의 정직성은, 강화학습만이 아니라 **모든 실험 과학**(ML1 val/test 정직성과 같은 뿌리)의 기본 문법.
- ❸ **“같은 방정식, 다른 형태”의 지도.** 이 학기의 알고리즘 13개는 **3단계 구조의 13가지 변주**에 불과 — 그래서 새 알고리즘 논문을 만나도 “이것은 ②번(수치화)을 바꾼 변주구나” 에서부터 읽을 수 있다. 지도의 **엣지**를 말할 수 있는 한, 지도는 **확장 가능한 자산**이고, **박스만** 외운 한으로는 **재고**에 불과하다.

# 최신 동향 — 이 학기가 이어지는 세 방향

이번 학기에서 다루기엔 이르지만 지금 활발히 연구되는 방향 — “지금 배운 것이 이런 곳으로 이어질 수 있다”는 지도를 그리는 것이 목적.

- **오프라인 강화학습 (Offline RL)** — 환경과 직접 상호작용하지 않고, **이미 모아둔 방대한 로그 데이터만으로** 정책을 학습. 실물 로봇으로 탐험하는 것 자체가 위험하거나 비싼 상황(자율주행, 의료)에서 특히 중요. Ch12 모방학습과 문제의 식이 비슷하지만, 시연이 아니라 (**좋은 것과 나쁜 것이 섞인**) **임의의 로그**로부터 배운다는 점이 다름.
- **범용 로봇 정책 (Generalist Robot Policies)** — 하나의 작업에 특화된 정책 대신, **다양한 로봇·작업에 걸쳐 일반화되는 하나의 큰 정책**(RT-2, OpenVLA 등) — ML1의 **LLM 사전학습** 아이디어를 로봇 제어에 적용한 것에 가까움: 방대한 로봇 시연·상호작용 데이터로 폭넓게 학습한 뒤 특정 작업에 맞게 다듬음.
- **Sim-to-Real의 발전** — Ch13.1 도메인 무작위화를 넘어, **시뮬레이션과 실제 환경의 차이 자체를 학습으로 메우려는** 연구 — Ch14 GPU 가속 시뮬레이션(Isaac Sim 등)이 “훨씬 많은 다양한 시뮬레이션 조건을 빠르게 경험시킨다”는 방향으로 기여.

**더 깊이** 파고들고 싶다면: 각 장에서 “이 학기 범위를 넘는다”고 언급됐던 부분 — TRPO의 상세 수학, DAgger의 수렴 증명, 멀티에이전트 RL의 내쉬 균형, AlphaZero의 자기대국 학습 세부사항 등.

## 자주 묻는 질문 — 산출물·Block A/B 차이·다음 방향

- **16.3의 산출물? 두 개:** (1) § 손으로 한 번의 rubric 표 4행(“나뉘는 모습” + “시험하는 질문”), (2) 20문항 자가진단에서 본인이  $\times$ 를 표한 것 중 **3개**를 골라, 각각 “말했어야 할 한 줄”을 **자기 언어**로 쓰는 것.  $\times$  개수 자체는 점수가 **아니다** —  $\times$ 를 자기 언어로 메운 문장이 점수화. 16.1 = “프로젝트를 정직하게 수행했는가”, 16.2 = “남의 프로젝트를 구체적으로 심사를 했는가”, 16.3 = “**학기 전체를 자기 것으로 만들었는가**”를 묻는 블록.
- **Block A vs Block B 복습은 어디에 시간을?** 요구사항의 **형태**가 바뀌었다 — Block A: “알고리즘 최소 2개 비교” + 개념 연결 / Block B: **알고리즘 1개 + 수식적 정당화 1개**. “어떤 알고리즘을 썼는가”보다 “**왜**” 그 하이퍼파라미터(보상 스케일,  $\gamma$ ,  $\lambda$ , 클립  $\epsilon$ )를 그렇게 골랐는가가 점수의 대부분을 결정 — 복습의 무게중심도 “개념 나열”에서 “**개념 → 내 실험의 숫자**”를 잇는 연습으로 이동.
- **졸업 후 자연스러운 다음은?** § 최신 동향의 **세 방향**이 현재 주류 — 오프라인 RL(로그 데이터만 있는 실서비스), 범용 로봇 정책(LLM 사전학습이 로봇으로 건너간 지점), Sim-to-Real(13~14장의 정면 돌파). 공통 지름줄은 **하나**: 3단계 구조(모델 정의 → 수치화 → 개선)로 그 연구를 **자신만의 언어로 다시 정식화**할 수 있는가.

## 마지막 한 문장

ML1이 “**정답이 있는 데이터**로부터 배운다”는 세계였다면,  
ML2는 “**스스로 행동해서 얻은 경험**만으로 배운다”는 **완전히 다른 세계**.

- **밴딧**의 탐험-활용 딜레마에서 시작해 **MDP · 동적계획법 · 몬테카를로 · 시간차 학습**으로 이론을 다졌고, **신경망**과 결합해 그 이론을 **로봇 시뮬레이션**이라는 현실적인 무대까지 끌고 왔다.
- 이제 이 두 세계 모두에서, “**무엇을 데이터(또는 경험)로 갖고 있고, 무엇을 최적화하고 싶은가**”라는 **같은 질문**을 던질 수 있을 것이다.

# 이번 주차 정리

- **16.1 팀 프로젝트: 발표** — 환경은 “개념 X가 돋보이는 무대” 기준으로, 알고리즘과 **페어링**.  
베이스라인(무작위 -1274, zero-torque -1230)을 **먼저** 재야 “개선”의 방향을 말할 수 있다.  $\epsilon = 0$ 의 대응물 =  $a = \mu$  **결정적 평가** ( $\sigma$ 는 학습된 파라미터라 0으로 바꾸지 않고, 샘플링만 안 함). 12만 스텝 Pendulum 실습: 학습 도중 마지막 10(-673/ -732/ -668)이 베이스라인 2배여도, **결정적 평가**( $\approx -1403$ )가 **베이스라인**(-1274) **아래** — “곡선이 올랐다”  $\neq$  “무작위보다 낫다”. M2에 **학습 예산 추정**(22초 기준선). **수식적 정당화** = 수치 + “완전 수렴 아님”의 정직함 + 하이퍼파라미터 근거. **채점** = **정직성 45%** — 프로토콜 정직성이 정책의 질보다 중요.
- **16.2 Peer-Review** — **역전**의 주: 네가 심사위원. 5항목(환경/알고리즘 선택/정당화/정직성/탐험-활용) + **1점(감상평)** → **2점(일반 지적)** → **3점(반박 가능한 질문 = 개념 명시 + 답이 나쁘면 결과가 흔들림)**. 신경망 특유의 “**우연히 좋은**” 패턴 **5가지**: 시드 1개 학습 곡선, 학습 도중 리턴으로 수렴 결론, 하이퍼파라미터 “적당히”, 이산용 (DQN)을 연속에, 베이스라인 없이 “잘 배웠다”. 실습: 가상 발표(시드 42, -742.0)를 재실행 — 같은 정책, 다른 프로토콜로 -742 vs -1413/ -1491(결정론적), 무작위 -1239 **아래**로 뒤집힘. 시드 간 sd(약 70) > 개선폭(약 63). **발표 전 셀프-리뷰**가 최선의 전략.
- **16.3 ML2 총정리** — **새로운 개념 없음**. 하나의 MDP(달리거나 쉬거나,  $\gamma = 0.9$ )를 네 경로로: ① DP  $V^*(S) = 2.589$ (정확) / ② MC 2.594(편향 없음) / ③ SARSA **2.29**(행동 정책  $V^\pi$ , 간극 0.297 = “탐험의 가격”) / ④ Q-learning 2.64(max 한 줄이 **수렴 대상 자체**를 변경). 두 과목을 관통하는 **3단계**: 모델 정의 → 틀린 정도 수치화 → 개선. 개념 지도 읽기: **질문은 박스와 축의 교차점(엣지)**, 67/67 엣지가 곧 “왜” 30분할 자기질문: “학기 이후에 가져갈 네 가지?”(변역의 순간, 정직함 수치의 기준)