Machine Learning and Deep Learning 샘플

프로젝트 1 · 보고서 샘플 (6주차 제출, 축약본)

Spring 2027

아래는 **가상의 팀**이 쓴 샘플입니다. 수치는 형식을 보이기 위한 예시이며 실제 실험 결과가 아닙니다. 형식과 분량의 기준으로만 참고하세요.

1. 문제 정의. 고객 한 명을 행으로, 다음 달 연체 여부를 라벨로 한다. 주 지표는 PR-AUC이다 (연체 22%의 불균형 때문). 베이스라인은 항상 "연체 아님" (PR-AUC 0.22).

2. 데이터와 전처리. 30,000행을 60/20/20으로 stratified 분할했다. 표준화의 평균과 표준편차는 **train에서만** 구해 validation과 test에 적용했다. 범주형(학력, 결혼 상태)은 원-핫 인코딩.

3. 모델 선택과 이유. 로지스틱회귀는 해석이 쉽고, 특성이 많이 연관되어 있어 L2 정규화 효과를 보이기 좋다. GBDT는 표 데이터에서 강한 비교 대상이다. 거리 기반이 아니므로 GBDT에는 표준화를 쓰지 않았다.

모델 (validation)	PR-AUC	비고
베이스라인(항상 0)	0.22	
로지스틱회귀, 정규화 없음	0.46	
로지스틱회귀, L2 ($C = 0.1$)	0.48	validation으로 선택
GBDT (트리 150개)	0.55	validation으로 선택

4. 결과. 최종 test는 **한 번만** 측정했다: GBDT PR-AUC 0.54, 로지스틱회귀(L2) 0.47. 학습 곡선(그림 1)에서 트리 개수가 150을 넘으면 train은 계속 오르지만 validation은 멈춰 150에서 멈췄다.

5. 수식적 정당화. L2 정규화가 계수의 크기를 줄여 분산을 낮춘 결과 validation PR-AUC가 0.46에서 0.48로 올랐다(편향은 약간 증가). SHAP으로 한 고객의 예측을 분해하면 최근 두 달의 연체 여부가 가장 크게 기여했다.

6. 재현 방법. 데이터는 UCI 저장소의 원본 CSV, 시드 42, 분할 60/20/20(stratified), L2 세기 $C = 0.1$, 트리 150개. 저장소의 `run.sh` 한 줄로 표의 숫자가 다시 나온다.

7. 한계와 잘 안 된 부분. 불균형을 줄이려고 연체 쪽 가중치를 키웠더니 PR-AUC가 오히려 0.02 내려갔다. 가중치가 확률을 왜곡해 순위 지표에는 도움이 안 된다고 진단했다.