기말 프로젝트 공지

딥러닝으로 실제 데이터 문제 풀기 (9∼17주차)

Machine Learning and Deep Learning

KSA 2027-Spring
Sumin Han (suminhan@ksa.hs.kr)

프로젝트 한눈에 보기

무엇을	실제 데이터 하나에 **딥러닝 기법**을 적용하는 **팀 프로젝트**. 이미지 · 텍스트 · 시퀀스 같은 비정형 데이터도 됩니다
어떤 기법	CNN, RNN · LSTM · 트랜스포머, 그래프 신경망, 표현 학습 · 임베딩, VAE · GAN 같은 생성 모델 (9∼15주차)
핵심 질문	**왜 고전 머신러닝이 아니라 딥러닝인가?** 이 질문에 숫자로 답해야 합니다
목표	중간 프로젝트와 같습니다. “이 숫자를 믿어도 되는가”를 스스로 따져 보는 힘

데이터 선정 → Abstract → 구현 · 검증 → 보고서 + 영상 → 동료평가

일정과 마감

주차	할 일	제출
9∼10주 (4/12–23)	팀 구성, 데이터 후보 2∼3개 조사, 정형 / 비정형 판정	
11주 (4/26–30)	행 · 라벨 · 지표 · 베이스라인, “왜 딥러닝인가” 초안, 신경망 계획	**Abstract** (1쪽)
12∼13주	3분할, train으로만 맞춘 전처리, **GBDT 베이스라인**, 신경망 학습, validation 튜닝, **test는 한 번만**	
14주 (5/17–21)	보고서 완성, 영상 만들기	**보고서 + 코드 + 영상**
15주	배정된 다른 팀 보고서 읽기	
17주 (6/7–11)	배정된 두 팀 심사 (기말고사 기간)	**리뷰 2건**

16주차는 보강주간입니다. 12 · 13주차에는 공휴일이 있으니 구현 일정을 미리 잡으세요. 마감 시각과 제출 방법은 따로 안내합니다.

꼭 지켜야 할 다섯 가지

1. **데이터**: Kaggle · UCI · Hugging Face Datasets · 데이터샵 (비정형 데이터 가능)
2. **딥러닝 기법 하나 이상**을 실제 데이터에 적용
   CNN, RNN · 트랜스포머, 그래프 신경망, VAE · GAN 계열 등
3. **GBDT 비교 (필수)**: 같은 데이터에 GBDT(또는 랜덤 포레스트)를 베이스라인으로 돌려 신경망이 정말 나은지 확인합니다. “왜 딥러닝인가”의 출발점입니다
4. **수식적 정당화 하나 이상**
   CNN이면 파라미터 수 · 연산량으로 설계 정당화, 드롭아웃 등 정규화의 효과, 생성 모델이면 ELBO나 min-max 목적함수
5. **검증 원칙**: 3분할, 전처리는 train으로만, **test는 딱 한 번**, **에포크 단위 학습 곡선**

정형인가, 비정형인가: 데이터 고르기에 하나 더

중간 프로젝트의 다섯 가지 기준(행의 단위 · 같은 대상의 여러 행 · 시간 · 클래스 비율 · 크기)은 그대로입니다

경우	예	판정
수치 · 범주 열로만 된 표	매출표, 센서 로그	**정형**: GBDT와의 비교가 더 중요해집니다
픽셀 · 음파 · 토큰의 원시 배열	이미지, 오디오, 문장	**비정형**: 손으로 특징을 만들기 어려워 신경망이 특징을 뽑습니다
애매한 경우	이미 벡터로 바뀐 텍스트	원시 토큰으로 직접 다룰 수도 있습니다. **그 이유를 Abstract에**

데이터는 어디서 찾나

데이터샵

`smhanlab.com/book-ml/datashop`

- 품질 검사 영상, 한국어 리뷰, 음성, 위성 영상, 링크 예측, 차량 궤적 …
- 행의 단위 · 라벨 · 크기 · 함정을 먼저 점검합니다
- 후보가 많으면 **데이터 월드컵**으로 2~3개로 좁힙니다

그 밖에

Kaggle · UCI · Hugging Face Datasets

- 같은 기준으로 직접 검사합니다
- 학습 시간도 확인합니다: **Colab에서 한 번 학습이 몇 분인가**
- 너무 크면 일부만 써도 됩니다. 어떻게 줄였는지 보고서에 적습니다

11주차 Abstract (1쪽)에 들어갈 것

- **문제 정의**: 행의 단위, 라벨, 주 지표, **정형 / 비정형 판정과 그 근거**
- **"왜 딥러닝인가" 초안**: 어떤 구조를 신경망이 쓸 것이라고 보는가 (가설)
- **베이스라인 두 층**: 무작위 · 다수 클래스, 그리고 **GBDT**
- **계획**: 적용할 신경망 구조, 에포크를 정할 방법, 수식적 정당화 후보
- **예상되는 위험**: 학습 시간, 데이터 크기, 과대적합

익명 심사입니다. **팀원 이름은 적지 않습니다.** 형식은 기말 프로젝트 샘플을 보세요.

14주차 보고서의 구조

	절	분량	쓸 것
1	문제 정의	0.5쪽	행 · 라벨 · 지표, **베이스라인 두 층(무작위 · GBDT)**, 정형 / 비정형 판정
2	데이터와 전처리	1쪽	원본 통계, train으로만 맞춘 전처리(스케일링 · 토크나이저 · 패딩), 분할 비율
3	모델 선택과 이유	1~2쪽	신경망 구조(층 · 크기)를 **파라미터 수**로 정당화, 왜 GBDT가 아니라 이것인가
4	결과	1쪽	최종 test(한 번), **에포크 학습 곡선**, GBDT · 무작위와의 비교표
5	수식적 정당화	1쪽	파라미터 수 · 정규화 효과 · ELBO 중 하나 이상
6	재현 방법	0.5쪽	데이터 출처 · 분할 · 시드 · 하이퍼파라미터 · **Colab 링크**
7	한계와 잘 안 된 부분	0.5쪽	**필수**. 학습이 안 되거나 과대적합된 부분을 배운 개념으로 진단

부록: AI 사용 내역 · 인용 근거 표 (쪽수 제외). 결론에서 **"왜 딥러닝인가"**에 숫자로 답합니다.

14주차 영상

보고서와 함께 **영상 1편**을 냅니다

담을 것	**문제 · 방법 · 결과 · 한계**
길이 · 형식	따로 안내합니다
익명	얼굴 · 이름이 나오지 않게 (화면 녹화 + 목소리 또는 자막)

영상은 보고서를 읽기 전에 심사하는 사람이 전체 흐름을 잡는 데 씁니다.

채점 기준: 다섯 항목 각 20%

항목	좋은 보고서
주장의 명확성	첫 문단에서 주장이 한 문장으로 보이고, 행의 단위 · 라벨 · 지표가 분명하고, 결과가 주장과 이어진다
비교 대상	**GBDT 베이스라인**과 신경망을 같은 분할 · 같은 지표로 비교하고, “왜 딥러닝인가”에 숫자로 답한다
확장성	다른 데이터 하나(또는 데이터를 줄인 실험)에서도 결론이 유지되는지, 구성 요소를 빼 보는 실험으로 어디까지 통하는지 보인다
재현성	다른 사람이 같은 숫자를 다시 얻을 수 있다. test를 한 번만 썼고 어디서 썼는지 보인다
한계의 솔직함	잘 안 된 부분을 숨기지 않고 원인을 진단한다. **성능이 낮아도 한계가 정직하면 높은 점수**

성능이 좋아 보여도 test를 두 번 썼거나, GBDT 비교가 없거나, 재현이 안 되면 크게 감점합니다.

17주차 동료평가 · 제출 · 함께 볼 자료

- **동료평가**: 배정된 다른 팀 보고서 2편을 KSA Review에서 심사 (기말고사 기간)
  필수 확인 두 가지(인용 하나 · 숫자 하나 재현)는 같습니다. 이번에는 GBDT 비교가 있는지도 꼭 봅니다
- **제출**: Abstract(11주) · 보고서 · 코드 · 영상(14주) · 리뷰 2건(17주). 팀 구성, 제출 방법, 마감 시각은 따로 안내합니다

함께 볼 자료	무엇이 있나
보고서 작성 가이드	첫 문단 쓰는 법, AI 사용 규칙, 인용 근거 표, 점검표
리뷰(동료평가) 가이드	리뷰 양식, 필수 확인 두 가지, 좋은 리뷰와 나쁜 리뷰
기말 프로젝트 샘플	Abstract · 보고서 · 리뷰의 실제 형식