중간 프로젝트 공지

고전 머신러닝으로 실제 표 데이터 문제 풀기 (1∼8주차)

Machine Learning and Deep Learning

KSA 2027-Spring
Sumin Han (suminhan@ksa.hs.kr)

프로젝트 한눈에 보기

무엇을	실제 **정형(표) 데이터** 하나에 고전 머신러닝 모델을 적용하고 비교하는 **팀 프로젝트**
어떤 기법	회귀(선형 · 로지스틱), 분류(나이브 베이즈 · kNN · SVM · 결정 트리 · 랜덤 포레스트 · GBDT), 군집(k-means), 차원 축소(PCA)
도구	`scikit-learn` 안에서 (MLP도 `MLPClassifier` · `MLPRegressor`까지는 가능)
목표	높은 성능이 아니라 **"이 숫자를 믿어도 되는가"**를 스스로 따져 보는 힘

데이터 선정 → Abstract → 구현 · 검증 → 보고서 → 동료평가

일정과 마감

주차	할 일	제출
1∼2주 (2/15–26)	팀 구성, **KSA Review 회원가입**, 데이터 후보 2∼3개 조사	회원가입
3주 (3/1–5)	문제 정의(행의 단위 · 라벨 · 지표), 데이터, 베이스라인과 모델 계획	**Abstract** (1쪽)
4∼5주	3분할, train으로만 맞춘 전처리, 베이스라인, 모델 적용, validation 튜닝, **test는 한 번만**	
6주 (3/22–26)	보고서 완성	**보고서 + 코드**
7주	배정된 다른 팀 보고서 읽기	
8주 (4/5–9)	배정된 두 팀 심사 (중간고사 기간)	**리뷰 2건**

마감 시각과 제출 방법은 따로 안내합니다.

꼭 지켜야 할 다섯 가지

1. **데이터**: Kaggle · UCI · 데이터샵의 **정형(행/열) 데이터** 하나 (이미지 · 텍스트 제외)
2. **모델 두 가지 이상**을 따로 학습시켜 **같은 데이터 · 같은 분할 · 같은 지표**로 비교
   예: 로지스틱회귀와 GBDT. 모델을 합치거나 섞는 것이 아닙니다
3. **수식적 정당화 하나 이상**
   정규화를 썼다면 편향-분산으로 왜 바뀌었는지 · GBDT라면 SHAP으로 예측 하나 분해 · 불균형이면 PR-AUC
4. **검증 원칙**: train / validation / test 3분할, 전처리는 train으로만, **test는 딱 한 번**
5. **학습 곡선**: validation 곡선으로 하이퍼파라미터를 골랐다는 것이 그림에서 보여야 합니다

데이터 고르기: 다섯 가지 기준

확인할 것	왜
행 하나가 무엇인가	환자? 거래? 주문? 한 문장으로 말할 수 없으면 무엇을 예측하는지도 말할 수 없습니다
같은 대상이 **여러 행**인가	한 사람의 행이 train과 test에 나뉘면 누수. 그룹 단위로 나눕니다
시간 순서가 있는가	시계열이면 시간 순서로 나눕니다
클래스 비율은?	99:1처럼 치우쳤으면 정확도 대신 PR-AUC · 재현율
크기는?	100행 미만이면 숫자가 심하게 흔들립니다. 500~10,000행이 다루기 편합니다

데이터는 어디서 찾나: 데이터샵과 데이터 월드컵

데이터샵

`smhanlab.com/book-ml/datashop`

- 신용카드 연체, 통신사 이탈, 호텔 예약, 부동산, 전력, 택시 수요, 공정 불량 …
- 데이터마다 **행의 단위 · 라벨 · 크기 · 클래스 비율 · 알려진 함정**이 적혀 있습니다
- 노트북(.ipynb)을 받아 직접 열어 봅니다

데이터 월드컵

`.../datashop/worldcup/`

- 32개 데이터를 이상형 월드컵으로 비교
- 우승 데이터와 4강을 **팀 회의 후보 2∼3개**로
- 데이터샵에 없는 데이터(Kaggle · UCI)도 같은 다섯 가지 기준으로 검사합니다

3주차 Abstract (1쪽)에 들어갈 것

- **문제 정의**: 행의 단위, 라벨, 주 지표 (그 지표를 고른 이유 한 문장)
- **데이터**: 출처, 크기, 누수 위험, 분할 방식
- **베이스라인**: 항상 다수 클래스로 답하는 모델 등
  이 숫자가 있어야 “모델을 만들었다”고 말할 수 있는지 판정할 수 있습니다
- **계획**: 비교할 모델 두 가지, 하이퍼파라미터를 고를 방법, 수식적 정당화 후보
- **예상되는 위험**: 무엇이 잘 안 될 수 있는가

익명 심사입니다. **팀원 이름은 적지 않습니다.** 형식은 중간 프로젝트 샘플 1쪽을 보세요.

6주차 보고서의 구조

	절	분량	쓸 것
1	문제 정의	0.5쪽	행의 단위 · 라벨 · 주 지표 · 베이스라인, 지표를 고른 이유
2	데이터와 전처리	1쪽	원본 통계(크기 · 결측 · 이상치), train으로만 맞춘 전처리, 분할 비율
3	모델 선택과 이유	1∼2쪽	후보 두 개 이상과 그 이유, validation 비교표
4	결과	1쪽	최종 test 숫자(한 번), 학습 곡선, 비교표
5	수식적 정당화	1쪽	편향-분산 · 정규화 · SHAP · PR-AUC 중 하나 이상
6	재현 방법	0.5쪽	데이터 출처 · 분할 · 시드 · 하이퍼파라미터 · **Colab 링크**
7	한계와 잘 안 된 부분	0.5쪽	**필수**. 안 된 것이 없었다면 시도했다가 안 된 것
부록	AI 사용 내역 · 인용 근거 표	–	쪽수에 넣지 않음 (보고서 작성 가이드 참고)

채점 기준: 다섯 항목 각 20%

항목	좋은 보고서
주장의 명확성	첫 문단에서 주장이 한 문장으로 보이고, 행의 단위 · 라벨 · 지표가 분명하고, 결과가 주장과 이어진다. 같은 내용을 되풀이하거나 기호를 불필요하게 늘리지 않는다
비교 대상	베이스라인(다수 클래스, 정규화 없는 모델)과 모델 두 개 이상을 같은 분할 · 같은 지표로 비교한다
확장성	다른 분할(그룹 · 시간 순서)이나 다른 데이터 하나에서도 같은 절차가 통하는지 확인하고, 안 통하는 조건을 적는다
재현성	다른 사람이 같은 숫자를 다시 얻을 수 있다. test를 한 번만 썼고 어디서 썼는지 보인다
한계의 솔직함	잘 안 된 부분과 약한 가정을 숨기지 않고 원인을 진단한다. **성능이 낮아도 한계가 정직하면 높은 점수**

성능이 좋아 보여도 test를 두 번 썼거나, 비교 대상이 없거나, 재현이 안 되면 크게 감점합니다.

8주차 동료평가

- 각자 배정된 **다른 팀 보고서 2편**을 KSA Review에서 심사합니다
- 양식: 요약 · 장점 · 약점 · 질문 · 점수 · 확신도, 그리고 **필수 확인 두 가지**
  핵심 인용 하나를 원문에서 확인하고, Colab을 실행해 숫자 하나를 재현합니다
- 근거를 대야만 답할 수 있는 **질문을 하나 이상** 넣습니다
- 리뷰 점수는 저자가 매기는 **도움 점수**, 필수 확인, 수업 중 무작위 확인으로 정합니다

자세한 방법은 **리뷰(동료평가) 가이드**를 보세요

팀 구성 · 제출 방법 · 함께 볼 자료

- **팀 구성**: 팀당 인원과 편성 방식은 따로 안내합니다
- **제출**: Abstract(3주) · 보고서 PDF와 코드(6주) · 리뷰 2건(8주). 제출 방법과 마감 시각은 따로 안내합니다

함께 볼 자료	무엇이 있나
보고서 작성 가이드	첫 문단 쓰는 법, AI 사용 규칙, 인용 근거 표, 제출 전 점검표
리뷰(동료평가) 가이드	리뷰 양식, 필수 확인 두 가지, 좋은 리뷰와 나쁜 리뷰
중간 프로젝트 샘플	Abstract · 보고서 · 리뷰의 실제 형식