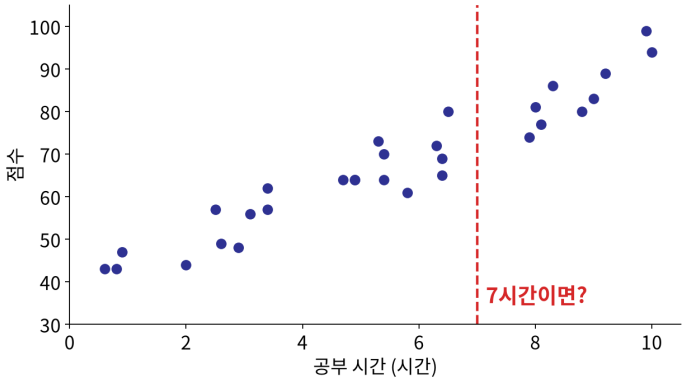
선형회귀 (Linear Regression)

직선 하나로 예측하기, 그리고 곡선까지

Machine Learning and Deep Learning

KSA 2027-Spring
Sumin Han (suminhan@ksa.hs.kr)

오늘의 질문



학생 30명의 공부 시간과 점수. **7시간 공부하면 몇 점일까?**

머신러닝이 “학습한다”는 것은

작업 T 에서, 성능 척도 P 로 쟀을 때,

경험 E 가 쌓일수록 성능이 나아지면

“학습한다”라고 정의한다

“A computer program is said to learn from experience E with respect to some class of tasks T and performance measure P, if its performance at tasks in T, as measured by P, improves with experience E.”

T. Mitchell, Machine Learning (1997)

오늘 문제에 대 보면: T • P • E

T	작업 (task)	공부 시간으로 시험 점수 맞히기
P	성능 척도 (performance)	예측이 평균 몇 점 틀렸나 (작을수록 좋다)
E	경험 (experience)	학생 30명의 (공부 시간, 점수)

데이터를 보고 틀리는 정도를 **줄여 가는 것**이 학습

풀기 전에 정할 것: 다섯 칸

		오늘 문제	
①	**한 행**은 무엇?	학생 한 명	← E 는 이 행들의 모음
②	**입력** X	공부 시간	예측하는 순간 알 수 있는 것만
③	**출력** y	시험 점수	숫자면 **회귀**, 범주면 **분류**
④	**평가지표**	평균 몇 점 틀렸나	$= P$
⑤	**베이스라인**	모두에게 평균 점수 67점 → 평균 **15점** 틀린다	

모델 점수는 **베이스라인과 비교**해서 읽는다

프로젝트 1 Abstract (3주차)에 쓸 것이 바로 이 다섯 칸

학습의 뼈대: 네 가지만 정하면 된다

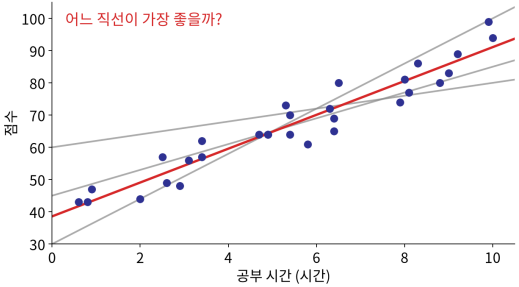


거의 모든 머신러닝 알고리즘은 이 **네 가지의 조합**이다

오늘은 **모델 = 직선**, **손실 = 오차 제곱 평균**, **최적화 = 경사하강법**

Goodfellow, Bengio & Courville, Deep Learning (2016), § 5.10

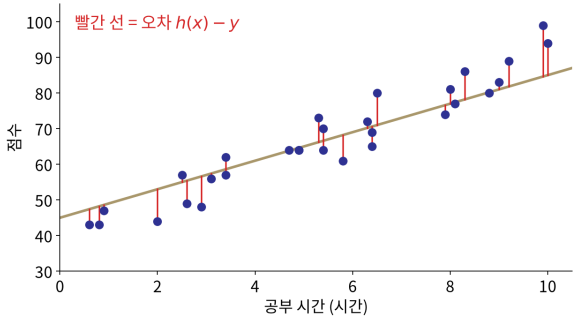
직선을 긋는다



$$h_{\boldsymbol{w}}(x) = w_0 + w_1 x$$

w_0: 절편 w_1: 기울기 (1시간 더 하면 몇 점 오르나)

오차를 제곱해서 평균: 비용 J



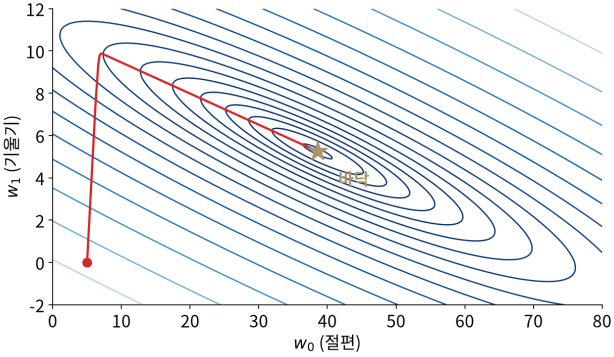
$$J(\boldsymbol{w}) = \frac{1}{2m} \sum_{i=1}^{m} \left(h_{\boldsymbol{w}}(x^{(i)}) - y^{(i)} \right)^2$$

m: 데이터 수 (30명) 빨간 선: 오차

제곱: 음수 오차와 양수 오차가 상쇄되지 않게

$\frac{1}{2}$: 미분할 때 2와 약분되라고 붙인 것

J 는 그릇 모양



w_0, w_1 를 바꿀 때마다 J 가 달라진다. 등고선의 중심 = 가장 좋은 직선. 빨간 선: 경사하강법이 걸어간 길

경사하강법: 기울기 반대로 한 걸음

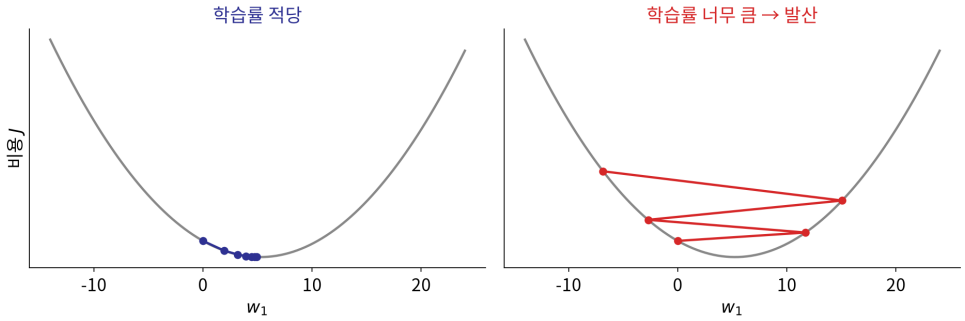
$$w_j \leftarrow w_j - \alpha \frac{\partial J}{\partial w_j}$$

$$\frac{\partial J}{\partial w_0} = \frac{1}{m} \sum_{i=1}^{m} \left(h(x^{(i)}) - y^{(i)} \right) \qquad \frac{\partial J}{\partial w_1} = \frac{1}{m} \sum_{i=1}^{m} \left(h(x^{(i)}) - y^{(i)} \right) x^{(i)}$$

α: 학습률 (한 걸음의 크기)

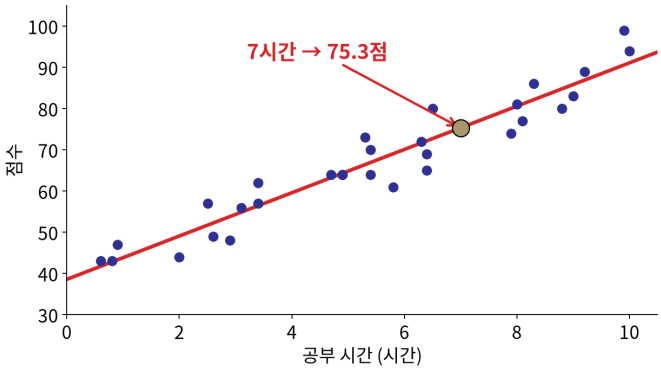
오차 $\times$ 입력의 평균만큼 고친다

학습률은 적당히



너무 작으면 느리고, **너무 크면 바닥을 건너뛰며 튕겨 나간다**

바닥에 도착하면



$$h(x) = 38.6 + 5.25\,x$$

7시간 → 75.3점

한 문제, 두 가지 풀이

점 $(1,2),\ (2,4),\ (3,5)$ 에 직선 $h(x) = w_0 + w_1 x$ 를 맞춘다

x	1	2	3
y	2	4	5

J 가 가장 작은 $w_0,\ w_1$ 은?

풀이 A: 경사하강법으로 걸어서　　풀이 B: 식을 풀어서 바로

풀이 A: 경사하강법 ($\alpha = 0.1$, $w_0 = w_1 = 0$ 에서 출발)

첫 걸음: 오차 $h - y = -2,\ -4,\ -5$ $\quad \dfrac{\partial J}{\partial w_0} = \dfrac{-11}{3} \approx -3.67$ $\quad \dfrac{\partial J}{\partial w_1} = \dfrac{-2-8-15}{3} \approx -8.33$

$$w_0 \leftarrow 0 + 0.1 \times 3.67 = 0.37 \qquad w_1 \leftarrow 0 + 0.1 \times 8.33 = 0.83$$

걸음	w_0	w_1	J
0	0	0	7.50
1	0.37	0.83	1.51
2	0.53	1.20	0.32
3	0.60	1.37	0.09
10	0.66	1.50	0.028
400	0.667	1.500	0.0278

수백 걸음 뒤 $w_0 \approx 0.667,\ w_1 \approx 1.5$

풀이 B: 기울기를 0 으로 놓고 바로 풀기

바닥에서는 기울기가 0 이다: $\dfrac{\partial J}{\partial w_0} = 0, \;\; \dfrac{\partial J}{\partial w_1} = 0$

$$3\,w_0 + 6\,w_1 = 11 \quad \leftarrow \sum x = 6,\ \sum y = 11$$
$$6\,w_0 + 14\,w_1 = 25 \quad \leftarrow \sum x^2 = 14,\ \sum xy = 25$$

첫 식 $\times 2$ 를 빼면 $2\,w_1 = 3 \;\Rightarrow\; w_1 = 1.5, \quad w_0 = (11 - 9)/3 = 2/3$

$$\mathbf{w} = (X^\top X)^{-1} X^\top \mathbf{y}$$

한 번에 $w_0 = 0.667,\ w_1 = 1.5$

두 풀이는 같은 답, 무엇이 다른가

	A. 경사하강법	B. 바로 풀기 (정규방정식)
답	$w_0 \approx 0.667,\ w_1 \approx 1.5$ (반복 후)	$w_0 = 2/3,\ w_1 = 3/2$ (정확)
준비	학습률 α, 출발점, 걸음 수	없음
비용	한 걸음이 싸다, 걸음을 반복	$d \times d$ 역행렬, 특징 d 개면 약 d^3
쓸 수 있는 곳	로지스틱회귀, 신경망까지 그대로	선형회귀처럼 닫힌 해가 있을 때만

특징이 적은 선형회귀는 B, 데이터와 특징이 크거나 다른 모델은 A

얼마나 잘 맞나: RMSE와 R^2

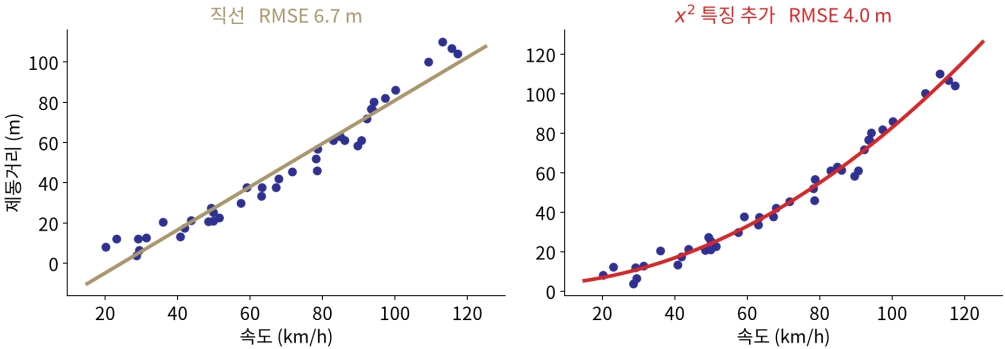
RMSE $\sqrt{\frac{1}{m}\sum(h-y)^2}$ **4.36점**: 평균적으로 이만큼 틀린다 (점수와 같은 단위)

$\boldsymbol{R^2}$ $1-\frac{\sum(h-y)^2}{\sum(\bar{y}-y)^2}$ **0.916**: 평균으로만 찍을 때보다 오차가 91.6% 줄었다

베이스라인 (평균 67점) RMSE **15.05점** $\rightarrow$ 직선 **4.36점** (p.4)

평가할 때는 $\frac{1}{2}$ 없이 그냥 평균 (비용 J 의 $\frac{1}{2}$ 은 미분 편의용 (p.7))

데이터가 곡선이면?



속도 $\rightarrow$ 제동거리: x^2 을 **특징으로 하나 더** 넣으면 **RMSE 6.7 m $\rightarrow$ 4.0 m**

“선형”은 w 에 대해 선형이라는 뜻

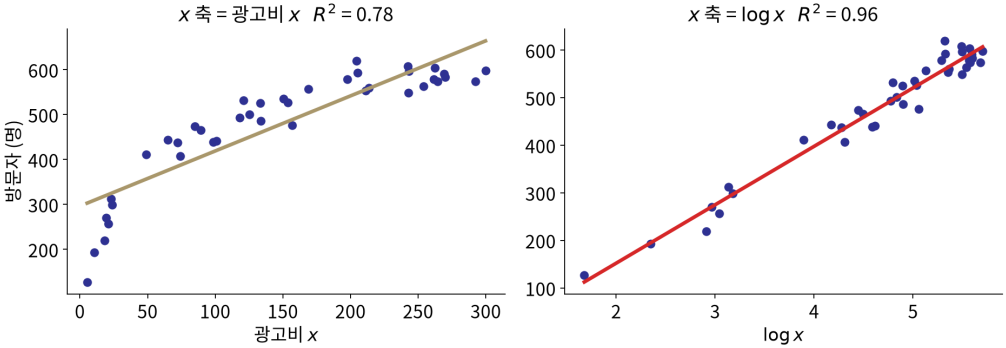
$$h(x) = w_0 + w_1 \underbrace{x}_{\text{feature 1}} + w_2 \underbrace{x^2}_{\text{feature 2}}$$

x^2 을 새 열로 미리 계산해 두면, w 에 대해서는 여전히 **곱하고 더하기**뿐

비용 J 도 여전히 그릇 모양 $\rightarrow$ 경사하강법 그대로 (p.9)

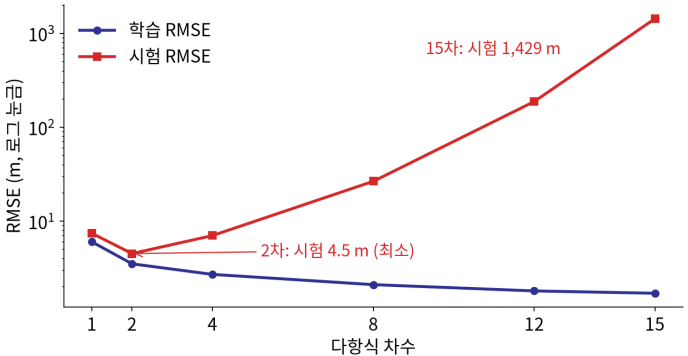
$h = w_0 + \sin(w_1 x)$ **는?** $\rightarrow w$ **에 대해 선형이 아니다**

점점 덜 늘어나면: 로그 변환



광고비 $\rightarrow$ 방문자: x 대신 $\log x$ 를 넣으면 R^2 **0.78** $\rightarrow$ **0.96**

차수를 계속 올리면: 과적합



학습 오차는 계속 줄지만, **처음 보는 데이터(시험) 오차는 폭발**한다

문제풀이

1. 데이터 $(1,3),(2,5),(3,7)$, 모델 $h = w_0 + w_1 x$, 지금 $w_0 = 0,\ w_1 = 2$.
   (a) 세 오차 $h - y$ 는? (b) J 는? (c) $\partial J/\partial w_0$, $\partial J/\partial w_1$ 는? (d) $\alpha = 0.1$ 로 한 걸음 가면?
2. 다음 중 선형회귀로 풀 수 있는 모델은? (a) $w_0 + w_1 x + w_2 x^3$ (b) $w_0 + w_1 \log x$ (c) $w_0 + e^{w_1 x}$
3. 학습 RMSE 는 계속 줄고 시험 RMSE 는 늘어난다. 무슨 일이 일어나고 있나?

실습

1. 경사하강법 직접 구현: 기울기 두 줄 채우기 $\rightarrow$ 7시간 75.3점 재현, 학습률 바꿔 발산 보기
2. 실제 자동차 데이터: 마력 $\rightarrow$ 연비, 직선 vs x^2 vs $\log x$ 의 R^2 비교
3. 같은 데이터로 차수 올리기: 학습 / 시험 오차로 과적합 찾기

Auto MPG (자동차 398대, UCI)

▶ Colab에서 실습 노트북 열기

정리

풀기 전에 **다섯 칸**: 한 행 · 입력 · 출력 · 평가지표 · 베이스라인

모델 $h = w_0 + w_1 x$ 비용 오차 제곱의 평균 J

경사하강법 기울기 반대로 한 걸음, 학습률은 적당히

곡선도 선형회귀 x^2, $\log x$ 를 특징으로 (w 에 대해 선형)

차수를 너무 올리면 과적합 시험 오차로 확인