# 문제 정형화와 평가지표

## Problem Formulation · Metrics · Baselines

Machine Learning and Deep Learning

KSA 2027-Spring
Sumin Han (suminhan@ksa.hs.kr)

# 오늘의 질문




타석마다 **홈런일까?**를 맞히는
**AI**를 만들었다.

2024 MLB 모든 타석 182,449개에서

**정확도 97.01%**

좋은 모델일까?

2024 MLB 정규시즌 (MLB 공식 기록)

## 머신러닝 문제 = 다섯 칸 채우기

| | | |
|---|---|---|
| ① | **한 행은 무엇?** | 예시 하나의 단위: 와인 한 병, 거래 한 건, 계좌 하나 |
| ② | **입력** $X$ | 예측할 때 **알 수 있는** 것만 |
| ③ | **출력** $y$ | 맞히려는 것: 품종? 도수? 세탁 여부? 3D 구조? |
| ④ | **평가지표** | 무엇으로 채점하나: 정확도, MAE, 정밀도 · 재현율 … |
| ⑤ | **기준선** | 머리 안 쓰는 답의 점수: 가장 흔한 답, 평균, 지난달 그대로 |

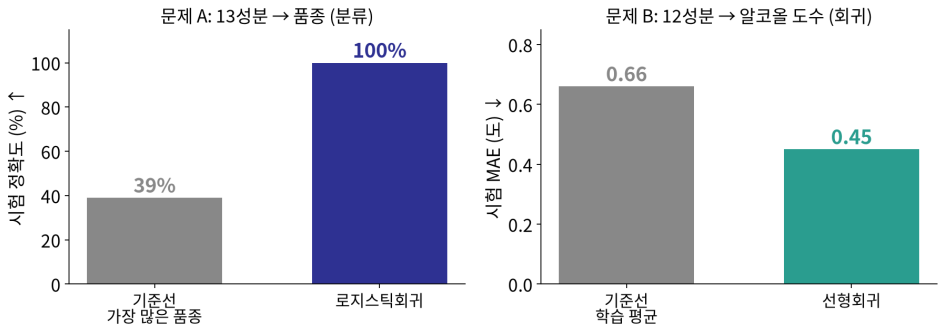
다섯 칸이 정해져야 **"잘했다"를 말할 수 있다**

## 출력 $y$ 의 모양이 문제의 종류를 정한다

| 출력 $y$ | 문제 종류 | 예 |
|---|---|---|
| 범주 하나 | **분류** (classification) | 와인 품종 (3개 중 하나), 세탁인가 (예/아니오) |
| 숫자 하나 | **회귀** (regression) | 알코올 도수, 다음 달 항공 승객 수 |
| 숫자 여러 개 | 물체 찾기 (detection) | 사진에서 고양이를 감싼 상자 (좌표 4개) |
| 글 · 그림 | 생성 | 다음 단어, 그림 (14주차 이후) |

같은 데이터라도 $y$ **를 무엇으로 정하느냐**에 따라 다른 문제가 된다

# 같은 와인 178병, 두 문제




문제 A: $y$ = 품종 → **정확도**　　문제 B: $y$ = 알코올 도수 (11.03 ∼ 14.83도) → **MAE**

학습 70% · 시험 30% (54병), 표준화 + 로지스틱회귀 / 선형회귀. 문제 B 의 입력에는 알코올을 넣지 않는다 (답을 입력에 넣으면 안 된다)

# 회귀의 채점: MAE 와 RMSE

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n} |\, y_i - \hat{y}_i \,| \qquad \text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

$y_i$ = 정답, $\hat{y}_i$ = 예측, 둘 다 $y$ **와 같은 단위** (도, 명, cm)

오차 [1, 1, 1, 9]: $\text{MAE} = \frac{1+1+1+9}{4} = \mathbf{3}$ RMSE $= \sqrt{\frac{1+1+1+81}{4}} = \sqrt{21} = \mathbf{4.58}$

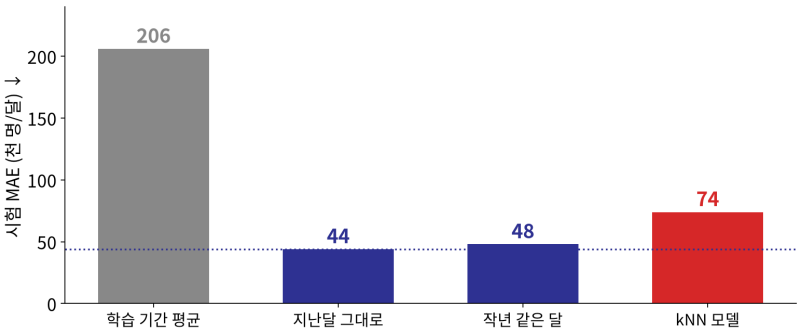
RMSE 는 제곱하니까 **크게 틀린 하나**에 더 큰 벌을 준다. 무엇이 더 나쁜지에 따라 고른다

# 기준선: 머리를 안 쓴 답은 몇 점인가

| 문제 | 기준선 | 점수 |
|---|---|---|
| 와인 품종 (분류) | 늘 가장 많은 품종 (71병짜리) 이라고 답 | 정확도 **39%** |
| 알코올 도수 (회귀) | 늘 학습 데이터의 평균 도수라고 답 | MAE **0.66도** |
| 항공 승객 (시계열) | 늘 지난달 승객 수라고 답 | MAE **44천 명** |
| 자금세탁 (분류) | 늘 “정상”이라고 답 | 정확도 **99.90%** |

모델 점수는 **기준선과 비교**해서 읽는다

# 모델이 기준선보다 못할 수도 있다




## 지난 12달을 보고 고른 kNN 모델 **74**, “지난달 그대로” **44**천 명

국제선 항공 승객 1949∼1960, 앞 10년 학습 · 뒤 2년 (24달) 시험, MAE (천 명/달). kNN: $k = 3$, 학습 기간 평균 · 표준편차로 표준화

## 시험 데이터 = 모델이 "실제로 만날" 데이터

| 데이터 | 어떻게 나누나 |
|---|---|
| 와인 178병 | 무작위로 70% 학습 · 30% 시험 (품종 비율은 맞춰서) |
| 항공 승객 | **시간 순서대로**: 1949∼1958 학습, 1959∼1960 시험 |
| 은행 거래 | **시간 순서대로**: 앞 기간으로 학습, 뒤 기간으로 시험 |
| 영화 별점 | 가장 최근 별점을 **숨겨서** 시험 (넷플릭스 프라이즈) |

미래를 섞어 학습하면 **시험 점수가 거짓말**을 한다

# 자금세탁 데이터 열어 보기: 한 행 = 거래 한 건

| Timestamp | From (은행, 계좌) | To (은행, 계좌) | Amount Paid | Currency | Format | Is Laundering |
|---|---|---|---|---|---|---|
| 2022/09/01 00:20 | 10, 8000EBD30 | 10, 8000EBD30 | 3,697.34 | US Dollar | Reinvestment | 0 |
| 2022/09/01 00:20 | 3208, 8000F4580 | 1, 8000F5340 | 0.01 | US Dollar | Cheque | 0 |

⋮

거래 5,078,345건, 그중 세탁 **5,177건 (0.10%)**

입력 $X$: 시각 · 보낸 쪽 · 받는 쪽 · 금액 · 통화 · 결제 형식 출력 $y$: `Is Laundering` (0/1)

IBM 이 가상 세계(사람 · 회사 · 은행)를 시뮬레이션해 만든 합성 데이터 (Altman et al., NeurIPS 2023). 실제 은행 거래는 공개할 수 없어서 이렇게 만든다

# 정확도의 함정: 드문 것을 찾는 문제

| | 전부 “정상” | 규칙: 결제 형식이 ACH (자동 이체)면 “세탁” |
|---|---|---|
| 정확도 | **99.90%** | 88.24% |
| 잡아낸 세탁 거래 | **0 건** | **4,483건** |

세탁을 **하나도 못 잡는** 쪽이 정확도는 더 높다

세탁이 드물어서, “정상”을 맞힌 수가 점수를 거의 다 차지한다

## 그래서 세는 법을 바꾼다: 정밀도와 재현율

| | 실제 세탁 | 실제 정상 |
|---|---|---|
| **"세탁"이라고 함** | **4,483** (잡았다) | **596,314** (헛짚었다) |
| **"정상"이라고 함** | **694** (놓쳤다) | (나머지) |

$$\text{재현율 (recall)} = \frac{\text{잡았다}}{\text{실제 세탁 전부}} = \frac{4{,}483}{4{,}483 + 694} = \mathbf{86.6\%}$$

$$\text{정밀도 (precision)} = \frac{\text{잡았다}}{\text{"세탁"이라고 한 것 전부}} = \frac{4{,}483}{4{,}483 + 596{,}314} = \mathbf{0.75\%}$$

전부 "정상"은 재현율 0%. 자세한 계산과 둘 사이의 줄다리기는 3주차 (정밀도와 재현율)

## 한 행을 무엇으로 정하나: 거래 vs 계좌

| | 한 행 = 거래 한 건 | 한 행 = 보낸 계좌 하나 |
|---|---|---|
| 행 수 | 5,078,345 | 496,999 |
| $y = 1$ 인 행 | 5,177 | 3,376 |
| 세탁 비율 | **0.10%** | **0.68%** |
| 현실의 질문 | 이 송금을 막을까? | 이 계좌를 조사할까? |

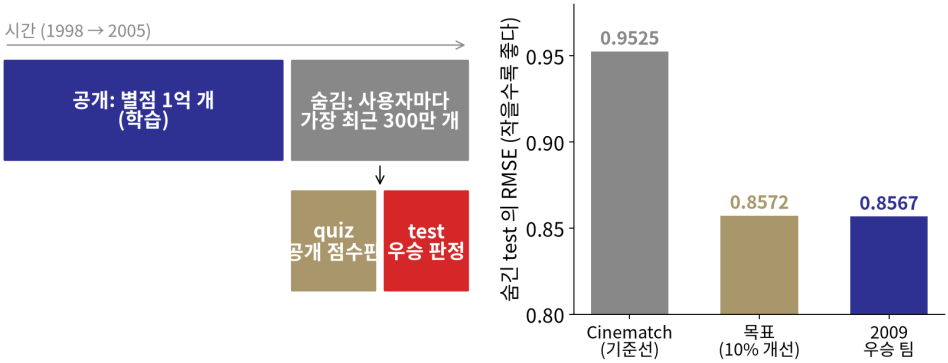
같은 파일, 다른 문제. 논문마다 “세탁 비율”이 다르게 적힌 이유

## 문제를 먼저 공개한 대회: 넷플릭스 프라이즈 (2006)

| | |
|---|---|
| **한 행** | (사용자, 영화, 날짜) 하나 |
| **입력** $X$ | 사용자 번호 · 영화 번호 · 날짜 |
| **출력** $y$ | 별점 $1 \sim 5$ |
| **평가지표** | **RMSE** (별 몇 개만큼 틀리나) |
| **기준선** | 넷플릭스의 추천 시스템 Cinematch: RMSE **0.95** |
| **목표** | 그보다 **10%** 나은 팀에게 상금 **100만 달러** |

공개한 데이터: 사용자 48만 명 이상 · 영화 약 1만 8천 편 · 별점 1억 개 이상 ($1998 \sim 2005$)

# 시험 데이터를 숨겼다: 가장 최근 별점 300만 개




공개 점수판은 숨긴 별점의 **절반 (quiz)** 으로만. 우승은 **나머지 절반 (test)** 으로 판정

점수판에 맞춰 계속 고치면 점수판에만 잘 맞는 모델이 된다 (과대적합, 2주차)

## 우승한 모델, 그런데 그대로 쓰지는 않았다

**2009** 우승 팀: 100개가 넘는 모델을 섞은 앙상블, RMSE **0.8567**

**그 뒤** 넷플릭스는 대회 중간 (2007) 에 나온 방법 두 가지만 가져다 썼다
최종 앙상블은 **들일 품에 비해 좋아지는 게 작았다**

**그 사이** DVD 대여 $\rightarrow$ 스트리밍: '별점' 보다 '무엇을 끝까지 보나' 가 중요해졌다

지표 (RMSE) 를 이기는 것과 **사업이 좋아지는 것**은 다르다

## 지표를 정하면, 모델은 그 지표만 쫓는다

| 지표 | 이 점수를 최대로 만드는 가장 쉬운 방법 |
|---|---|
| 정확도 | 전부 “정상” $\rightarrow$ 99.90% |
| 재현율 | 전부 “세탁” $\rightarrow$ 100% (그런데 은행이 멈춘다) |
| 정밀도 | 가장 확실한 한 건만 “세탁” $\rightarrow$ 100% (나머지는 다 놓친다) |

지표는 **현실에서 무엇이 손해인지**에서 거꾸로 정한다

놓친 세탁 한 건의 손해 vs 헛짚어 정상 고객을 막은 한 건의 손해

# 문제풀이

1. 다섯 칸을 채워 보자: (a) 스팸 문자 거르기 (b) 내일 서울 최고 기온 (c) 사진 속 고양이 위치 찾기
2. 예측 `[10, 20, 30, 40]`, 정답 `[12, 18, 30, 50]`. MAE 와 RMSE 는?
3. 환자 1,000명 중 20명이 병에 걸렸다. “전부 건강”의 정확도는? 재현율은?
4. 내일 주가를 맞히는 모델의 입력에 “내일 거래량”을 넣었더니 성능이 크게 올랐다. 무엇이 잘못됐나?
5. 학생 성적 데이터에서 시험 데이터를 무작위로 뽑았는데, 같은 학생의 다른 학기 기록이 학습 데이터에 있다. 무엇이 문제일까?

# 실습: 문제를 직접 정해 보기

1. 와인: 같은 데이터로 분류 · 회귀 두 문제 만들기, 정확도 · MAE · 기준선 직접 구현
2. 항공 승객: 지난달 그대로 · 작년 같은 달 vs kNN (**74** vs **44**)
3. IBM AML: 거래 5,078,345건 열기, 전부 "정상" 99.90%, 규칙 하나의 정밀도 · 재현율, 한 행을 계좌로 바꾸면 (0.10% → 0.68%)
4. 넷플릭스 프라이즈 축소판: MovieLens 별점, 사람마다 최근 별점을 숨겨 RMSE · 10% 개선 목

AML 은 Hugging Face 사본에서 받는다 (로그인 없이, 압축 약 90MB)

▶ Colab에서 실습 노트북 열기

# 정리

문제 = **다섯 칸**: 한 행 · 입력 $X$ · 출력 $y$ · 평가지표 · 기준선

같은 데이터라도 $y$ 와 **한 행**을 다르게 정하면 다른 문제 (와인, 거래 vs 계좌)

점수는 **기준선과 비교**해서 읽는다 (모델이 "지난달 그대로"에 질 수도)

시험 데이터는 실제로 만날 데이터처럼: 시간 순서, 사람 · 지역 단위

지표는 현실의 손해에서 거꾸로 정한다. 시험 데이터는 **숨긴다** (넷플릭스 프라이즈)

# 이미지 · 데이터 출처

- 홈런 (p.1): MLB Stats API (`statsapi.mlb.com`), 2024 정규시즌 30개 팀 타석 · 홈런 합계와 오타니 쇼헤이 개인 기록
- 자금세탁 거래: IBM Transactions for Anti Money Laundering (HI-Small), Kaggle `ealtman2019` (실습은 Hugging Face 사본); Altman et al., “Realistic Synthetic Financial Transactions for Anti-Money Laundering Models” (NeurIPS 2023 Datasets and Benchmarks)
- 넷플릭스 프라이즈: Bennett & Lanning (2007) “The Netflix Prize”, KDD Cup and Workshop; 우승 결과 (2009) 와 이후 사용은 넷플릭스 기술 블로그 (2012)
- 와인: UCI Wine (Aeberhard & Forina, 1991)  항공 승객: Box & Jenkins, Time Series Analysis (1976)