문제 정형화와 평가지표

Problem Formulation · Metrics · Baselines

Machine Learning and Deep Learning

KSA 2027-Spring
Sumin Han (suminhan@ksa.hs.kr)

오늘의 질문



투수가 **공을 던지기 전에**,
이번 공이 **홈런일까?**를 맞히는 **AI**를
만들었다.

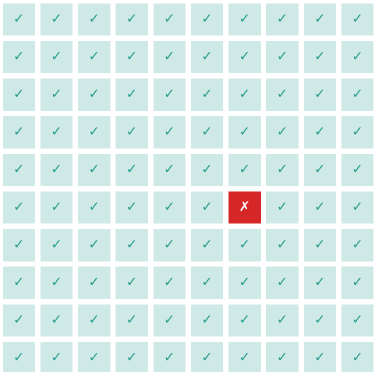
2024년 6월 MLB 투구 116,355개에서

정확도 99.21%

좋은 모델일까?

2024 MLB 정규시즌 6월 (Baseball Savant)

답: 이 AI는 모든 공에 “홈런 아님”이라고만 했다



공 100개 중 **홈런 1개** 꼴 (0.79%)

2024년 6월 MLB 투구	116,355
그중 홈런	921 (0.79%)
홈런 아님	115,434
맞힌 공 (전부 “아님”)	115,434
정확도	$\frac{115{,}434}{116{,}355} = \mathbf{99.21\%}$
잡아낸 홈런	**0 개**

홈런이 드물어서 **아무것도 안 해도** 99%

6월 오타니가 받은 공 498개 중 홈런 12개, 하나도 못 맞힌다

머신러닝 문제 = 다섯 칸 채우기

①	**한 행은 무엇?**	예시 하나의 단위: 공 하나 (투구), 타석 하나, 타자 한 명
②	**입력** X	**던지기 전** 정보만: 볼카운트 · 타자 · 투수 **O**, 구종 · 비거리 **X**
③	**출력** y	맞히려는 것: 이 공이 홈런? 스윙할까? 구속은?
④	**평가지표**	무엇으로 채점하나: 정확도, MAE, 정밀도 · 재현율 …
⑤	**기준선**	머리 안 쓰는 답의 점수: 가장 흔한 답 (“홈런 아님”), 평균

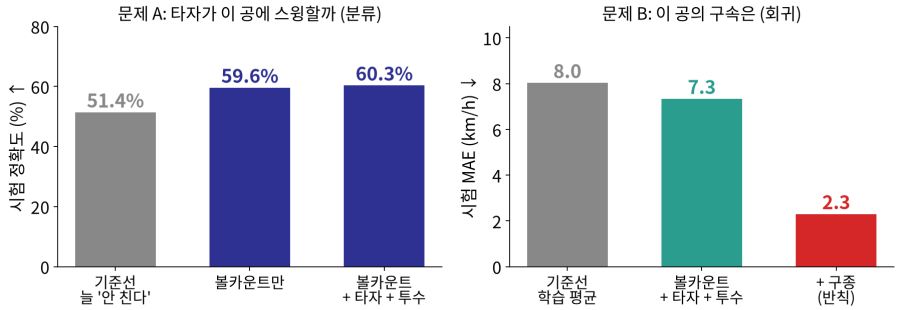
다섯 칸이 정해져야 **“잘했다”를 말할 수 있다**

출력 y 의 모양이 문제의 종류를 정한다

출력 y	문제 종류	예
범주 하나	**분류** (classification)	이 공이 홈런인가, 스윙할까 (예/아니오)
숫자 하나	**회귀** (regression)	공의 구속, 타구 비거리

같은 데이터라도 y **를 무엇으로 정하느냐**에 따라 다른 문제가 된다

같은 공, 두 문제: 스윙할까? 구속은?



문제 A: y = 스윙할까 $\rightarrow$ **정확도** 문제 B: y = 구속 (km/h) $\rightarrow$ **MAE**

구종은 던진 뒤에야 안다. 넣으면 MAE 2.3로 확 줄지만 **반칙**

2024년 6월 MLB 투구 115,940개, 입력 = 던지기 직전 볼카운트 · 타자 · 투수, 6/1∼23 학습 · 6/24∼30 시험, 로지스틱회귀 / 선형회귀

기준선: 머리를 안 쓴 답은 몇 점인가

문제	기준선	점수
스윙할까 (분류)	늘 “안 친다”라고 답	정확도 **51.4%**
구속 (회귀)	늘 학습 데이터의 평균 구속 (143.6km/h)	MAE **8.0km/h**
모든 공 (분류)	늘 “홈런 아님”이라고 답	정확도 **99.21%**

모델 점수는 **기준선과 비교**해서 읽는다

시험 데이터 = 모델이 “실제로 만날” 데이터

나누는 법	결과
무작위로 섞기	**X**: 같은 경기 · 같은 타석의 앞뒤 공이 학습과 시험에 나뉜다
날짜 순서대로	**O**: 6월 1∼23일로 학습, 24∼30일로 시험 (오늘 쓰는 두 문제 모두)

미래를 섞어 학습하면 **시험 점수가 거짓말**을 한다

한 행을 무엇으로 정하나: 공 vs 타석 vs 타자

	한 행 = 공 하나	타석 하나	타자 한 명
행 수	116,355	30,060	480
$y = 1$ 인 행	921	921	310
홈런 비율	**0.79%**	3.06%	**64.6%**
현실의 질문	이 공이 홈런?	이 타석이 홈런?	이 타자가 이번 달 홈런?

같은 기록, 다른 문제. “홈런 비율”이 숫자마다 다른 이유

2024년 6월 MLB. 타석은 홈런으로 끝났으면 1, 타자는 6월에 홈런을 한 번이라도 쳤으면 1

지표를 정하면, 모델은 그 지표만 쫓는다

지표	이 점수를 최대로 만드는 가장 쉬운 방법
정확도	전부 “홈런 아님” $\rightarrow$ 99.21%
잡은 홈런 수 (재현율)	전부 “홈런” $\rightarrow$ 하나도 안 놓침 (그런데 아무 정보가 없다)

지표는 **현실에서 무엇이 손해인지**에서 거꾸로 정한다

예: 홈런 예측으로 하이라이트 카메라를 미리 돌린다면, 놓친 홈런 장면 하나 vs 헛돌린 카메라 한 번

문제풀이

1. 다섯 칸을 채워 보자: (a) 스팸 문자 거르기 (b) 내일 서울 최고 기온
2. 어떤 타자가 공 1,000개를 받아 홈런 8개를 쳤다. 매번 “홈런 아님”이라고 하면 정확도는? 잡은 홈런은?
3. 이 공에 스윙할지 맞히는 모델의 입력에 “구종”을 넣었더니 정확도가 크게 올랐다. 무엇이 잘못됐나?
4. 학생 성적 데이터에서 시험 데이터를 무작위로 뽑았는데, 같은 학생의 다른 학기 기록이 학습 데이터에 있다. 무엇이 문제일까?

정리

문제 = **다섯 칸**: 한 행 · 입력 X · 출력 y · 평가지표 · 기준선

같은 데이터라도 y 와 **한 행**을 다르게 정하면 다른 문제 (공 vs 타석 vs 타자)

점수는 **기준선과 비교**해서 읽는다 (99.21% 도 “아무것도 안 함”일 수 있다)

시험 데이터는 실제로 만날 데이터처럼: 시간 순서, 사람 · 지역 단위

지표는 **현실의 손해**에서 거꾸로 정한다 (놓친 홈런 vs 헛돌린 카메라)

프로젝트 1 **Abstract**(3주차)에 쓸 것이 바로 이 **다섯 칸**

이미지 · 데이터 출처

- 투구 (p.1, p.5): Baseball Savant (MLB Statcast), 2024-06 정규시즌 모든 투구 CSV; 게임 화면: 컴투스프로야구2021 (컴투스) 캡처, 아래 자막만 덧그림