문제 정형화와 평가지표

Problem Formulation · Metrics · Baselines

Machine Learning and Deep Learning

KSA 2027-Spring
Sumin Han (suminhan@ksa.hs.kr)

오늘의 질문



공을 치기 전에, 이번 타석이
홈런일까?를 맞히는 **AI**를 만들었다.

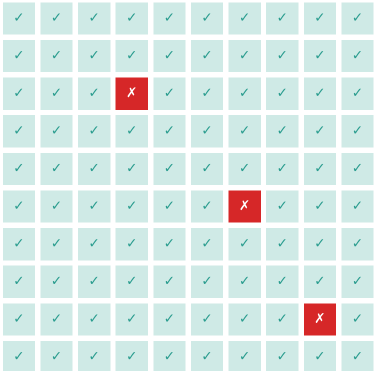
2024 MLB 모든 타석 182,449개에서

정확도 97.01%

좋은 모델일까?

2024 MLB 정규시즌 (MLB 공식 기록)

답: 이 AI는 모든 타석에 “홈런 아님”이라고만 했다



타석 100개 중 **홈런은 3개**뿐

AI의 답: 모든 타석에 “홈런 아님”

✓ **맞음**	홈런 아닌 타석	176,996개
× **틀림**	홈런 타석	5,453개
	전체 타석	182,449개

$$\text{정확도} = \frac{\text{맞음}}{\text{전체}} = \frac{176{,}996}{182{,}449} = \mathbf{97.01\%}$$

홈런은 **하나도 못 잡았는데** 97%

머신러닝 문제 = 다섯 칸 채우기

①	**한 행은 무엇?**	예시 하나의 단위: 타석 하나, 타구 하나, 선수 한 시즌
②	**입력** X	**알 수 있는** 것만: 타자 · 투수 · 지난 기록 **O**, 타구 비거리 **X**
③	**출력** y	맞히려는 것: 홈런인가? 비거리? 다음 시즌 홈런 수?
④	**평가지표**	무엇으로 채점하나: 정확도, MAE, 정밀도 · 재현율 …
⑤	**기준선**	머리 안 쓰는 답의 점수: 가장 흔한 답, 평균, 작년 그대로

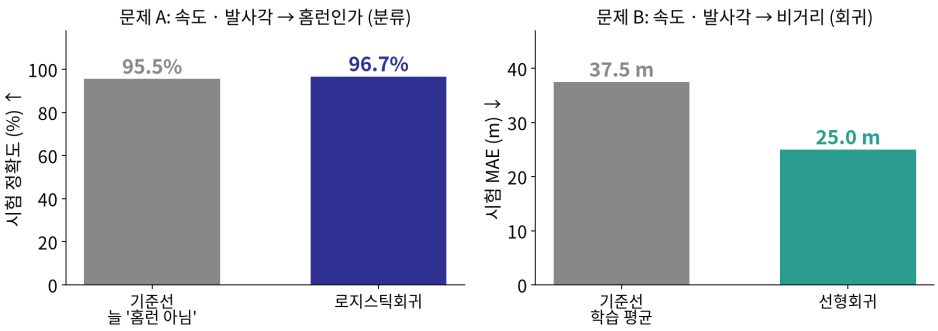
다섯 칸이 정해져야 **"잘했다"를 말할 수 있다**

출력 y 의 모양이 문제의 종류를 정한다

출력 y	문제 종류	예
범주 하나	**분류** (classification)	홈런인가 (예/아니오), 구종 (직구? 변화구?)
숫자 하나	**회귀** (regression)	타구 비거리, 다음 시즌 홈런 수
숫자 여러 개	물체 찾기 (detection)	중계 화면에서 공을 감싼 상자 (좌표 4개)
글 · 그림	생성	다음 단어, 그림 (14주차 이후)

같은 데이터라도 y **를 무엇으로 정하느냐**에 따라 다른 문제가 된다

같은 타구 20,506개, 두 문제



문제 A: y = 홈런인가 $\rightarrow$ **정확도** 문제 B: y = 비거리 (m) $\rightarrow$ **MAE**

2024년 6월 MLB 인플레이 타구 (홈런 915개), 학습 70% · 시험 30% (6,152개), 입력 = 타구 속도 · 발사각 (+ 발사각^2), 표준화 + 로지스틱회귀 / 선형회귀.

입력에 비거리를 넣으면 안 된다 (A 에서는 답과 거의 같고, B 에서는 답 그 자체)

회귀의 채점: MAE 와 RMSE

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n} |\, y_i - \hat{y}_i \,| \qquad \text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

y_i = 정답, $\hat{y}_i$ = 예측, 둘 다 y **와 같은 단위** (m, 개)

오차 [1, 1, 1, 9]: $\text{MAE} = \frac{1+1+1+9}{4} = \mathbf{3}$ RMSE $= \sqrt{\frac{1+1+1+81}{4}} = \sqrt{21} = \mathbf{4.58}$

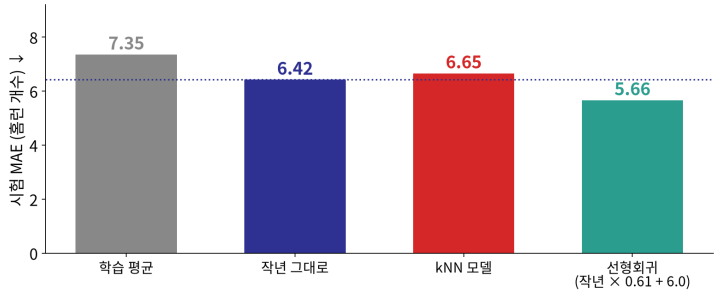
RMSE 는 제곱하니까 **크게 틀린 하나**에 더 큰 벌을 준다. 무엇이 더 나쁜지에 따라 고른다

기준선: 머리를 안 쓴 답은 몇 점인가

문제	기준선	점수
홈런인가 (분류)	늘 “홈런 아님”이라고 답	정확도 **95.5%**
타구 비거리 (회귀)	늘 학습 데이터의 평균 비거리 (50.4m)	MAE **37.5m**
다음 시즌 홈런 수	늘 작년 홈런 수 그대로라고 답	MAE **6.42개**
모든 타석 (분류)	늘 “홈런 아님”이라고 답	정확도 **97.01%**

모델 점수는 **기준선과 비교**해서 읽는다

모델이 기준선보다 못할 수도 있다



이번엔 **한 행 = 타자의 한 시즌**: 올해 기록으로 **내년 홈런 수** 맞히기

kNN 모델 **6.65** 개, “작년 그대로” **6.42** 개 틀린다

MLB 타자, 두 해 모두 300타석 이상. 학습 2021→2022 · 2022→2023 (394명), 시험 2023→2024 (207명), MAE (홈런 개수). kNN: $k = 3$, 작년 타석 · 타수 · 안타 · 홈런 · 볼넷 · 삼진을 표준화

시험 데이터 = 모델이 "실제로 만날" 데이터

데이터	어떻게 나누나
타구 20,506개	무작위로 70% 학습 · 30% 시험 (홈런 비율은 맞춰서)
선수 시즌	**시간 순서대로**: 2023 시즌까지로 학습, 2024 시즌으로 시험

미래를 섞어 학습하면 **시험 점수가 거짓말**을 한다

타석 데이터 열어 보기: 한 행 = 타석 하나

2024 타자	타석	홈런	홈런 비율
Aaron Judge	704	58	8.2%
Shohei Ohtani	731	54	7.4%
Anthony Santander	665	44	6.6%
⋮			
MLB 전체	182,449	5,453	**2.99%**

입력 X: 타자 · 투수 · 지난 기록 …(타석에 서기 전에 알 수 있는 것)　　출력 y: 홈런인가 (0/1)

볼카운트 (2볼 2스트라이크 …) 는? 타석 전에 예측하면 아직 0-0 이라 못 쓴다. **투구 하나를 한 행**으로 바꾸면 입력이 된다

MLB 공식 기록 (MLB Stats API), 2024 정규시즌 타자 기록

정확도의 함정: 드문 것을 찾는 문제

	전부 “홈런 아님”	규칙: 작년 30홈런 이상 타자면 “홈런”
정확도	**97.01%**	88.68%
잡아낸 홈런	**0 개**	**800개**

홈런을 **하나도 못 잡는** 쪽이 정확도는 더 높다

홈런이 드물어서, “아님”을 맞힌 수가 점수를 거의 다 차지한다

그래서 세는 법을 바꾼다: 정밀도와 재현율

	실제 홈런	실제 아님
"홈런"이라고 함	**800** (잡았다)	**15,992** (헛짚었다)
"아님"이라고 함	**4,653** (놓쳤다)	(나머지)

$$\text{재현율 (recall)} = \frac{\text{잡았다}}{\text{실제 홈런 전부}} = \frac{800}{800 + 4{,}653} = \mathbf{14.7\%}$$

$$\text{정밀도 (precision)} = \frac{\text{잡았다}}{\text{"홈런"이라고 한 것 전부}} = \frac{800}{800 + 15{,}992} = \mathbf{4.76\%}$$

전부 "홈런 아님"은 재현율 0%. 자세한 계산과 둘 사이의 줄다리기는 3주차 (정밀도와 재현율)

한 행을 무엇으로 정하나: 타석 vs 선수

	한 행 = 타석 하나	한 행 = 타자 한 명 (한 시즌)
행 수	182,449	651
$y = 1$ 인 행	5,453	522
홈런 비율	**2.99%**	**80.2%**
현실의 질문	이번 타석에 홈런이 나올까?	이 타자가 올해 홈런을 칠까?

같은 기록, 다른 문제. “홈런 비율”이 숫자마다 다른 이유

지표를 정하면, 모델은 그 지표만 쫓는다

지표	이 점수를 최대로 만드는 가장 쉬운 방법
정확도	전부 “홈런 아님” $\rightarrow$ 97.01%
재현율	전부 “홈런” $\rightarrow$ 100% (그런데 아무 정보가 없다)
정밀도	가장 확실한 한 타석만 “홈런” $\rightarrow$ 100% (나머지는 다 놓친다)

지표는 **현실에서 무엇이 손해인지**에서 거꾸로 정한다

예: 홈런 예측으로 하이라이트 카메라를 미리 돌린다면, 놓친 홈런 장면 하나 vs 헛돌린 카메라 한 번

문제풀이

1. 다섯 칸을 채워 보자: (a) 스팸 문자 거르기 (b) 내일 서울 최고 기온 (c) 사진 속 고양이 위치 찾기
2. 예측 $[10, 20, 30, 40]$, 정답 $[12, 18, 30, 50]$. MAE 와 RMSE 는?
3. 어떤 타자가 1,000타석에서 홈런 20개를 쳤다. 매 타석 “홈런 아님”의 정확도는? 재현율은?
4. 타석마다 홈런을 맞히는 모델의 입력에 “타구 비거리”를 넣었더니 정확도가 크게 올랐다. 무엇이 잘못됐나?
5. 학생 성적 데이터에서 시험 데이터를 무작위로 뽑았는데, 같은 학생의 다른 학기 기록이 학습 데이터에 있다. 무엇이 문제일까?

실습: 문제를 직접 정해 보기

1. 타구 20,506개: 같은 데이터로 분류 (홈런인가) · 회귀 (비거리) 두 문제, 정확도 · MAE · 기준선
2. 다음 시즌 홈런 수: 작년 그대로 vs kNN vs 선형회귀 (**6.42** vs **6.65** vs 5.66), 시간 순서로 나누
3. 2024 모든 타석: 전부 "홈런 아님" 97.01%, 규칙 하나의 정밀도 · 재현율,
   한 행을 타자로 바꾸면 (2.99% → 80.2%)

타구는 Baseball Savant, 선수 기록은 MLB Stats API 에서 받는다 (로그인 없이, 처음엔 1분쯤)

▶ Colab에서 실습 노트북 열기

정리

문제 = **다섯 칸**: 한 행 · 입력 X · 출력 y · 평가지표 · 기준선

같은 데이터라도 y 와 **한 행**을 다르게 정하면 다른 문제 (홈런 vs 비거리, 타석 vs 타자)

점수는 **기준선과 비교**해서 읽는다 (모델이 "작년 그대로"에 질 수도)

시험 데이터는 실제로 만날 데이터처럼: 시간 순서, 사람 · 지역 단위

지표는 **현실의 손해**에서 거꾸로 정한다 (놓친 홈런 vs 헛돌린 카메라)

이미지 · 데이터 출처

- 홈런 (p.1): MLB Stats API (`statsapi.mlb.com`), 2024 정규시즌 30개 팀 타석 · 홈런 합계와 오타니 쇼헤이 개인 기록; 게임 화면: 컴투스프로야구2021 (컴투스) 캡처, 아래 자막만 덧그림
- 타구 (p.5): Baseball Savant (MLB Statcast), 2024-06 정규시즌 인플레이 타구 CSV
- 선수 · 타석 기록: MLB Stats API (`statsapi.mlb.com`), 2021∼2024 정규시즌 타자 기록