ROC-AUC와 PR-AUC

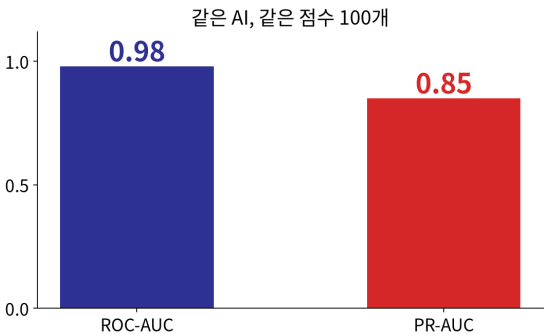
기준선 하나가 아니라, 기준선 전체로 평가하기

Sumin Han (suminhan@ksa.hs.kr)

Machine Learning and Deep Learning · 한국과학영재학교 (KSA)

2027학년도 1학기 · 3주차 (3/1–3/5)

오늘의 질문



지난 시간의 독감 AI (100명 중 독감 10명).

같은 AI 인데 왜 0.98 과 0.85 로 다를까?

기준선 하나로는 부족하다

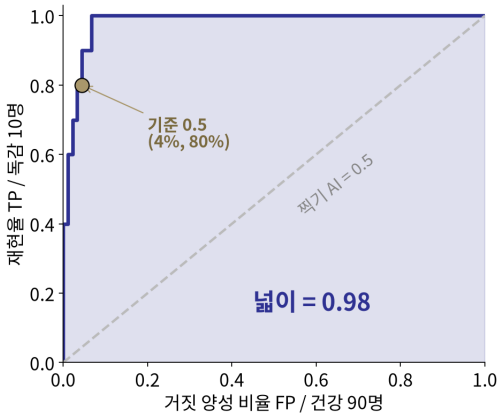
기준 0.5 $\rightarrow$ 정밀도 67% · 재현율 80%

기준 0.7 $\rightarrow$ 정밀도 86% · 재현율 60%

기준을 바꿀 때마다 성적이 달라진다 $\rightarrow$ **모든 기준을 한꺼번에** 평가하고 싶다

기준을 1 에서 0 까지 내리며 찍은 점들을 이으면 곡선, 그 아래 넓이가 **AUC** (area under the curve)

ROC 곡선: 헛짚음 비율 vs 재현율



가로 $\text{FPR} = \dfrac{FP}{FP + TN}$

건강한 90명 중 “독감”이라고 헛짚은 비율

세로 $\text{TPR} = \dfrac{TP}{TP + FN}$

독감 10명 중 찾아낸 비율 = 재현율

기준 0.5: $\left(\frac{4}{90},\ \frac{8}{10}\right) = (4\%,\ 80\%)$

ROC-AUC = 짝 비교에서 이긴 비율

$$\text{ROC-AUC} = \frac{\text{독감 점수} > \text{건강 점수 인 짝}}{\text{독감 10} \times \text{건강 90}} = \frac{883}{900} = 0.98$$

독감 학생 하나, 건강 학생 하나를 뽑으면 **독감 학생의 점수가 더 높을 확률**

찍기 AI (점수가 무작위) $\rightarrow$ 반반 $\rightarrow$ 0.5 완벽한 AI $\rightarrow$ 1

같은 헛짚음 4명, 무엇으로 나누나

$$\underbrace{\frac{4}{90} = 4\%}$$

ROC: 건강 90명으로

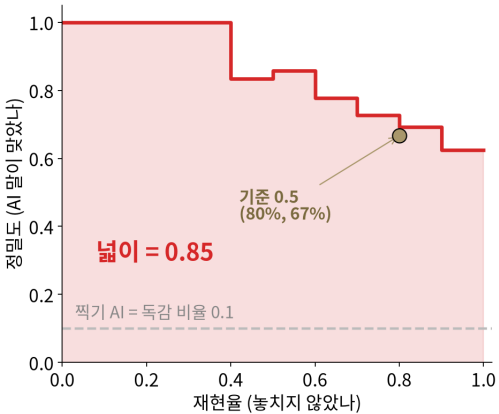
$$\underbrace{\frac{4}{12} = 33\%}\ \text{틀림}$$

PR: AI 가 고른 12명으로

ROC 는 건강한 학생이 많을수록 헛짚음이 **작아 보인다**

하지만 “독감”이라는 AI 말은 3번 중 1번 틀렸다 (정밀도 67%)

PR 곡선: 재현율 vs 정밀도



가로 재현율 $\frac{TP}{TP+FN}$

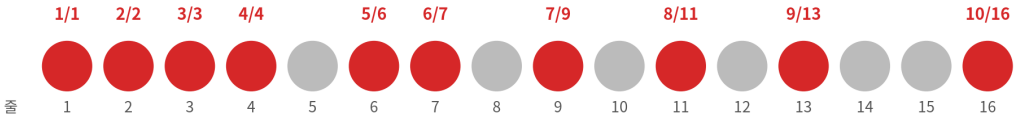
놓치지 않았나?

세로 정밀도 $\frac{TP}{TP+FP}$

AI 말이 맞았나?

기준 0.5: $(80\%,\ 67\%)$

PR-AUC 를 직접 세기: 점수 순으로 줄 세우기



독감 학생(빨강)을 찾을 때마다 그때까지의 정밀도를 적는다

$$\frac{1}{1}, \frac{2}{2}, \frac{3}{3}, \frac{4}{4}, \frac{5}{6}, \frac{6}{7}, \frac{7}{9}, \frac{8}{11}, \frac{9}{13}, \frac{10}{16}$$

PR-AUC = 그 정밀도들의 평균

$$\text{PR-AUC} = \frac{1}{10}\left(1+1+1+1+\frac{5}{6}+\frac{6}{7}+\frac{7}{9}+\frac{8}{11}+\frac{9}{13}+\frac{10}{16}\right) = 0.85$$

독감 학생을 찾을 때마다의 정밀도를 평균 = **Average Precision (AP)**

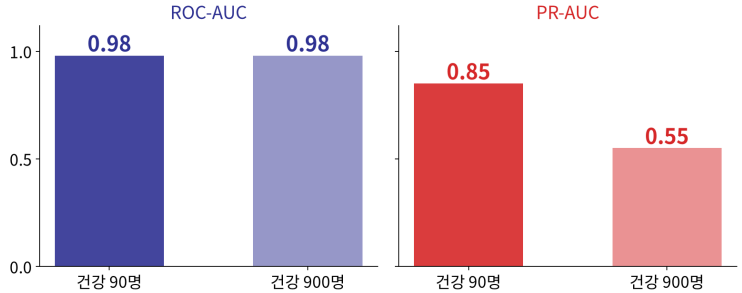
재현율이 0.1 씩 오를 때마다 그때의 정밀도를 높이로 하는 막대 10개의 넓이 = PR 곡선 아래 넓이 (p.6)

찍기 AI 의 점수도 다르다

	ROC-AUC	PR-AUC
찍기 AI (무작위 점수)	0.5	**0.1 (독감 비율)**
우리 AI	0.98	0.85
완벽한 AI	1	1

바닥이 다르다: ROC-AUC 는 0.5 부터, PR-AUC 는 0.1 부터

건강한 학생이 10배가 되면



같은 점수의 건강 학생을 10배로 ROC-AUC **0.98 그대로** PR-AUC **0.85 → 0.55**

헛짚는 학생 수도 10배 → AI 의 “독감” 판정은 훨씬 자주 틀린다. ROC 는 비율이라 못 느낀다

언제 무엇을 볼까

ROC-AUC	두 쪽이 비슷하게 많을 때	쏠림에 둔하다 (너그러움)
PR-AUC	찾을 것이 드물 때 (사기 · 희귀병)	쏠림을 반영 (엄격함)

쏠린 데이터라면 **둘 다** 적고, PR-AUC 는 **바닥(양성 비율)과 함께** 적는다

문제풀이

1. 양성 2명(점수 0.9, 0.4), 음성 3명(0.8, 0.3, 0.2). (a) 짝 6개 중 양성이 이긴 짝은? ROC-AUC 는? (b) 줄 세워 AP 를 구하면?
2. 양성 비율이 5% 인 데이터에서 어떤 모델의 PR-AUC 가 0.30 이다. 좋은 모델인가?
3. 음성 데이터만 100배로 늘렸다 (모델은 그대로). ROC-AUC 와 PR-AUC 는 각각 어떻게 되나?

실습

1. 슬라이드의 점수 100개로 ROC-AUC (짝 세기) · AP (줄 세우기) 구현 → 0.98 · 0.85
2. 건강 학생을 10배 · 100배로 늘리며 두 점수 비교
3. 실제 데이터: 오존 경보 (양성 6%), 두 모델을 ROC-AUC 와 PR-AUC 로 비교

Ozone Level Detection (UCI; OpenML)

▶ Colab에서 실습 노트북 열기

정리

기준을 $1 \to 0$ 으로 내리며 찍은 곡선의 넓이 = **AUC**

ROC-AUC 독감 학생이 건강 학생보다 점수가 높을 확률 (찍기 = 0.5)

PR-AUC (AP) 독감 학생을 찾을 때마다의 정밀도 평균 (찍기 = 양성 비율)

쏠린 데이터: ROC 는 너그럽고 PR 은 엄격하다 $\to$ 둘 다 본다