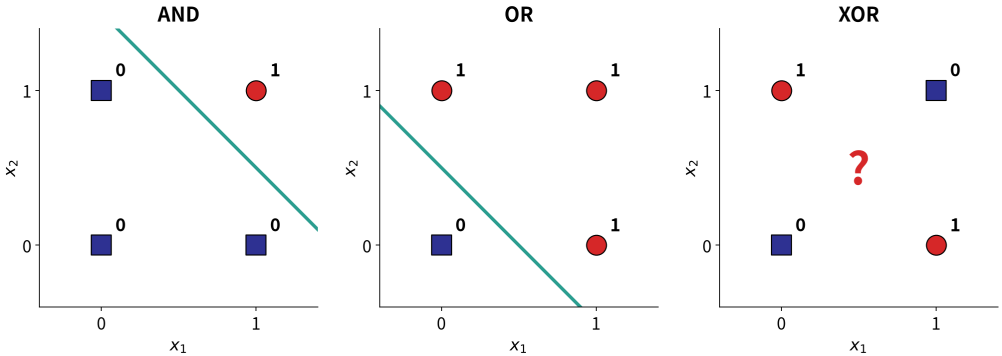
XOR 과 역전파 (Backpropagation)

AI 를 얼어붙게 한 문제, 그리고 숨은 층을 학습하는 방법

Sumin Han (suminhan@ksa.hs.kr)
Machine Learning and Deep Learning · 한국과학영재학교 (KSA)
2027학년도 1학기 · 7주차 (3/29–4/2)

오늘의 질문: 직선 하나로 가를 수 있을까?



AND, OR 는 직선 하나로 가른다 **XOR (두 입력이 다를 때만 1) 은?**

퍼셉트론 (1958): 직선 하나로 분류하는 기계

$$y = \begin{cases} 1 & w_1 x_1 + w_2 x_2 + b > 0 \\ 0 & \text{otherwise} \end{cases}$$

F. Rosenblatt 가 만든 첫 학습하는 신경망 경계 $w_1 x_1 + w_2 x_2 + b = 0$ 은 **직선**

OR: $w = (1, 1), b = -0.5$ AND: $w = (1, 1), b = -1.5$

지금 신경망의 뉴런 하나와 같다 (계단 대신 시그모이드 · ReLU 를 쓸 뿐)

XOR 은 왜 직선 하나로 안 되나

직선 하나로 된다고 해 보자: $w_1 x_1 + w_2 x_2 + b$

$$
\begin{aligned}
(0,0) &\to 0 \quad b \leq 0 \\
(0,1) &\to 1 \quad w_2 + b > 0 \\
(1,0) &\to 1 \quad w_1 + b > 0 \\
(1,1) &\to 0 \quad w_1 + w_2 + b \leq 0
\end{aligned}
$$

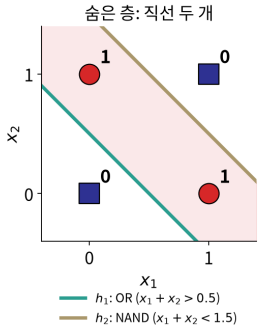
가운데 두 줄의 합 $w_1 + w_2 + 2b > 0$ 에 $-b \geq 0$ 을 더하면 $w_1 + w_2 + b > 0$ **넷째 줄과 모순**

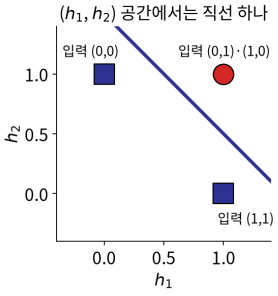
1969년, 신경망의 겨울

1958	로젠블랫의 퍼셉트론, 큰 기대
1969	민스키 & 페퍼트 《Perceptrons》: 한 층의 한계 (XOR 등)
1970 ∼ 80년대 중반	연구비 · 관심이 크게 준다 (약 15년의 **겨울**)
1986	루멜하트 · 힌턴 · 윌리엄스: **역전파** (Nature)

층을 쌓으면 XOR 이 풀린다는 건 알려져 있었다. 문제는 숨은 층을 **학습**하는 방법이었다

층을 쌓으면: 직선 두 개를 조합한다





$h_1 = \text{OR}, \quad h_2 = \text{NAND}, \quad y = \text{AND}(h_1, h_2)$

숨은 층이 **직선 하나로 갈리게** 만든다

2-2-1 신경망

$$\mathbf{h} = \sigma(\mathbf{x}W_1 + \mathbf{b}_1) \qquad y = \sigma(\mathbf{h} \cdot \mathbf{w}_2 + b_2)$$

x	입력 2개 $\rightarrow$ W_1 (2×2), $\mathbf{b}_1$: 숨은 층
h	숨은 뉴런 2개 $\rightarrow$ $\mathbf{w}_2$ (2개), b_2: 출력층
σ	시그모이드 (계단 대신 미분할 수 있게)
$L = \frac{1}{2}(y-t)^2$	정답 t 와의 오차

손으로 고른 가중치 대신, 가중치 **9개**를 데이터로 학습하고 싶다

문제: 숨은 층의 가중치는 어떻게 고치나?

출력층 $\mathbf{w}_2$: 오차가 바로 보인다 (선형회귀 · 로지스틱회귀처럼)

숨은 층 W_1: 정답이 없다. h_1 **이 얼마여야 했는지** 아무도 모른다

$$\frac{\partial L}{\partial W_1} = ?$$

답: $W_1 \to \mathbf{h} \to y \to L$ 로 이어진 **연쇄법칙**을 거꾸로 따라간다 = **역전파**

역전파 1: 출력층

$$\frac{\partial L}{\partial \mathbf{W}_2} = \underbrace{(y-t)}_{\partial L/\partial y}\ \underbrace{y(1-y)}_{\partial y/\partial z_2}\ \underbrace{\mathbf{h}}_{\partial z_2/\partial \mathbf{W}_2} = \delta_2\,\mathbf{h}$$

$\delta_2 = (y-t)\,y(1-y)$: 출력의 **오차 신호**

시그모이드의 미분: $\sigma'(z) = \sigma(z)(1-\sigma(z))$ $\quad z_2 = \mathbf{h}\cdot\mathbf{W}_2 + b_2$

역전파 2: 숨은 층으로 거꾸로

$$\delta_1 = \delta_2 \, \mathbf{w}_2 \odot \mathbf{h}(1 - \mathbf{h}) \qquad \frac{\partial L}{\partial W_1} = \mathbf{x}^\top \delta_1$$

출력의 오차 신호 δ_2 를 **그 길의 가중치 $\mathbf{w}_2$ 만큼 나눠** 숨은 뉴런에 돌려보낸다

숨은 뉴런마다 자기 시그모이드의 기울기를 곱하면 δ_1 그다음은 출력층과 같은 모양

$\odot$: 칸별 곱 층이 더 있어도 같은 일을 반복한다

손으로 한 번

입력 $(1,1)$, 정답 $t=0$ $\quad W_1=\begin{bmatrix}1 & -1\\ 1 & -1\end{bmatrix}$, $\mathbf{w}_2=(1,1)$, 편향 0

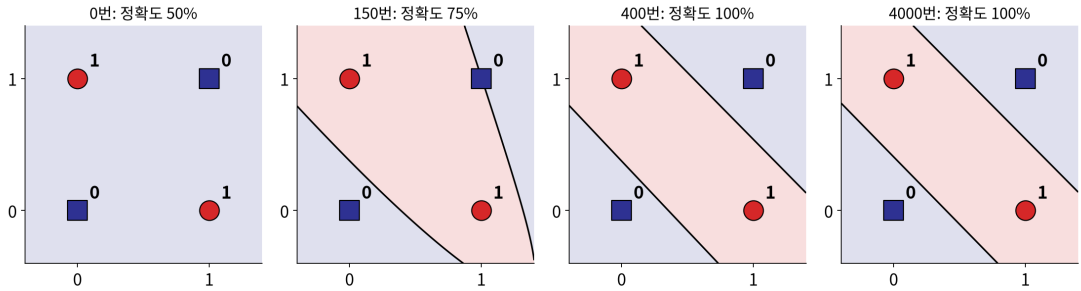
순전파 $\mathbf{z}_1=(2,-2)$, $\mathbf{h}=(0.881,0.119)$ $\quad y=0.731$, $L=0.267$

출력층 $\delta_2=0.731\cdot 0.731\cdot 0.269=\mathbf{0.144}$ $\quad \partial L/\partial \mathbf{w}_2=(0.127,0.017)$

숨은 층 $\delta_1=0.144\cdot 1\cdot 0.105=\mathbf{0.015}$ $\quad \partial L/\partial W_1$: 모든 칸 0.015

경사하강: 가중치를 기울기 반대로 $\quad\rightarrow y$ 가 정답 0 쪽으로 내려간다

XOR 학습: 정확도 50% → 100%



학습률 2.0 150번 75% 400번 **100%** 4,000번: 0.012 · 0.986 · 0.986 · 0.013

역전파가 연 길

1986	여러 층 신경망을 학습할 수 있게 됐다
오늘	층 수백 개, 가중치 수십억 개도 **같은 원리**
PyTorch	`loss.backward()` 한 줄이 역전파 (계산 그래프를 거꾸로)

그런데 층을 깊게 쌓자 새로운 문제가 나타났다 → 다음 주: **기울기 소실**

문제풀이

1. NAND (둘 다 1 일 때만 0) 를 퍼셉트론 하나로 만드는 w_1, w_2, b 를 하나 찾아라.
2. 손 계산 예 (p.10) 에서 정답이 $t = 1$ 이었다면 δ_2 의 부호는? 가중치는 어느 쪽으로 움직이나?
3. 숨은 뉴런의 시그모이드 출력이 $h = 0.99$ 이면 $h(1 - h)$ 는? 이 뉴런으로 가는 오차 신호는 어떻게 되나?
4. 2-2-1 신경망의 가중치 · 편향은 모두 몇 개인가? 2-3-1 이면?

실습

1. numpy 로 2-2-1 신경망 + 역전파 직접 구현 → XOR 100%
2. 기울기 확인: 역전파 기울기 vs 숫자로 조금 움직여 본 기울기
3. PyTorch `loss.backward()` 로 같은 계산 + 실제 손글씨 숫자 분류

Optical Recognition of Handwritten Digits (UCI; scikit-learn `load_digits`)

▶ Colab에서 실습 노트북 열기

정리

퍼셉트론 = 직선 하나 XOR 은 직선 하나로 못 가른다 $\rightarrow$ 신경망의 겨울 (1969)

숨은 층이 공간을 바꿔 직선으로 갈리게 만든다 (OR · NAND $\rightarrow$ AND)

역전파: 오차 신호 δ 를 연쇄법칙으로 출력 $\rightarrow$ 입력 쪽으로 돌려보낸다

$\partial L/\partial W =$ (들어온 입력) $\times$ (오차 신호) XOR 50% $\rightarrow$ 100%