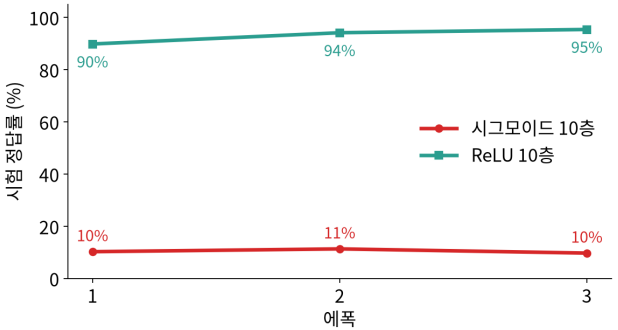
기울기 소실 (Vanishing Gradient)

층을 쌓을수록 학습이 멈춘다? 활성 함수와 초기화

Machine Learning and Deep Learning

KSA 2027-Spring
Sumin Han (suminhan@ksa.hs.kr)

오늘의 질문



MNIST, 은닉층 **10개**, 활성 함수만 다르다: **시그모이드 10% vs ReLU 95%**

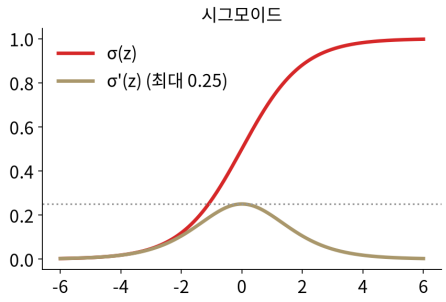
역전파는 층을 지날 때마다 곱한다

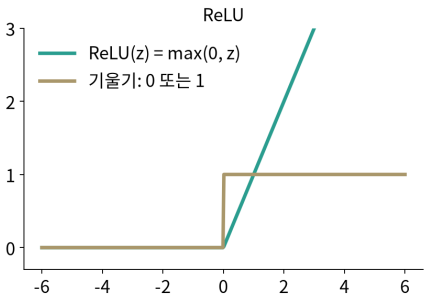
역전파 시간 $\delta_1 = \delta_2 \, w_2 \, \sigma'(z_1)$ (숨은 층 하나)

$$\delta_{\text{1층}} = \delta_{\text{출구}} \times w_{10} \, \sigma'(z_9) \times w_9 \, \sigma'(z_8) \times \cdots \times w_2 \, \sigma'(z_1)$$

층이 10개면 **곱하기 10번** 곱하는 수가 1 보다 작으면 **0 으로**, 크면 **폭발**

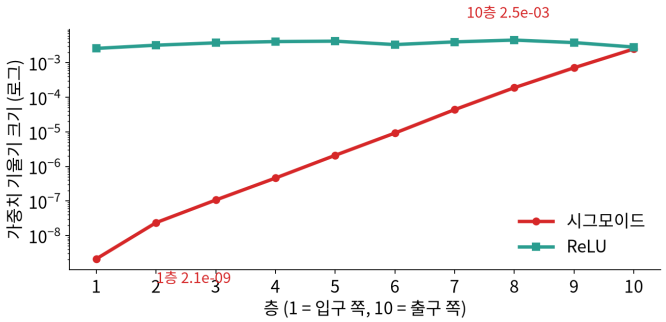
시그모이드의 기울기는 아무리 커도 0.25





$$\sigma'(z) = \sigma(z)\big(1 - \sigma(z)\big) \leq 0.25 \qquad 0.25^{10} \approx \mathbf{0.00000095}$$

실제로 재 보면: 입구는 출구의 119만분의 1



시그모이드: 10층 2.5×10^{-3} → 1층 2.1×10^{-9} ReLU: 비슷

학습 전, 배치 512장의 가중치 기울기 평균 절댓값 (Xavier · He 초기화)

해결 1: ReLU

$$\mathrm{ReLU}(z) = \max(0, z) \qquad \mathrm{ReLU}'(z) = \begin{cases} 1 & z > 0 \\ 0 & z \leq 0 \end{cases}$$

켜진 뉴런은 기울기를 **그대로 (× 1)** 통과시킨다 계산도 빠르다 (지수 함수 없음)

같은 10층: 시그모이드 **10%** → ReLU **95%**

2010년 무렵부터 깊은 신경망의 기본 활성 함수 (AlexNet, 2012)

반대로: 기울기 폭발

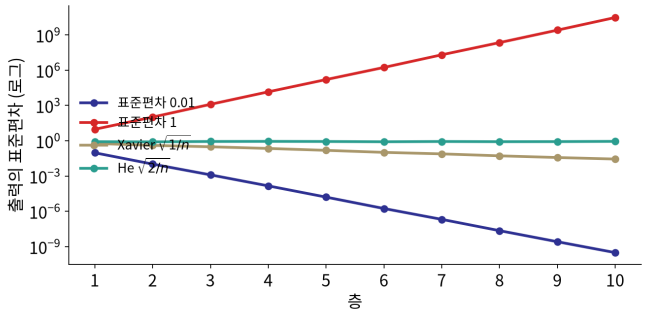
층마다 1.5 를 곱하면 $1.5^{10} \approx$ **58** 2 를 곱하면 $2^{10} =$ **1,024**

기울기가 층마다 커져서 **한 걸음에 멀리 튀고** 학습이 망가진다 (손실 NaN)

대책: **기울기 자르기** (gradient clipping) 크기가 정한 값을 넘으면 줄인다

순환 신경망 (11주차) 에서 특히 잘 생긴다

해결 2: 가중치 초기화



ReLU 10층, 시작 표준편차만 바꿈: 0.01 $\to 3 \times 10^{-10}$ 1 $\to 3 \times 10^{10}$ He $\to$ **0.88**

크기를 층마다 유지하는 초기화

입력 n 개를 받는 뉴런: 가중치 n 개의 곱의 합 $\rightarrow$ 분산이 $n \times \mathrm{Var}(w)$ 배로

Xavier (Glorot, 2010) $\mathrm{Var}(w) = \dfrac{1}{n}$ 시그모이드 · tanh

He (2015) $\mathrm{Var}(w) = \dfrac{2}{n}$ **ReLU** (절반을 0 으로 버리니 2배)

PyTorch `nn.Linear` 의 기본값도 이런 크기 조정을 한다 폭 256 이면 He 의 표준편차 $\sqrt{2/256} \approx 0.088$

ReLU 의 약점과 친척들

죽은 ReLU 늘 음수만 받는 뉴런은 기울기가 항상 0 $\rightarrow$ 영영 안 배운다

Leaky ReLU 음수 쪽에 작은 기울기 ($0.01z$) 를 남긴다

GELU 매끄러운 ReLU 트랜스포머 (GPT · BERT) 의 기본

그 밖에: **배치 정규화** (다음 시간), **잔차 연결** (9주차), **LSTM** (11주차)

문제풀이

1. 시그모이드 신경망 20층에서, 가장 운이 좋아도 입구의 오차 신호는 출구의 몇 배인가? ($0.25^{10} \approx 10^{-6}$)
2. ReLU 뉴런의 입력 z 가 $-3, 0.5, 2$ 일 때 출력과 기울기는?
3. 입력이 512 개인 ReLU 층의 He 초기화 표준편차는?
4. 학습 중 손실이 갑자기 NaN 이 됐다. 의심할 것과 대책 두 가지는?

실습

1 층마다 곱하기: 시그모이드 기울기 0.25 를 10번, 20번 초기화별 층 출력 크기

2 PyTorch 10층 신경망 (MNIST): 시그모이드 vs ReLU 의 층별 기울기 재기

3 같은 신경망을 1에폭 학습해 정답률 비교 + Leaky ReLU · GELU

MNIST (LeCun, Cortes, Burges; torchvision)

▶ Colab에서 실습 노트북 열기

정리

역전파는 층마다 곱한다 1 보다 작으면 **소실**, 크면 **폭발**

시그모이드 기울기 $\leq 0.25 \rightarrow$ 10층에서 입구 기울기 119만분의 1, 정답률 10%

ReLU: 켜진 뉴런은 기울기 1 $\rightarrow$ 95% (죽은 ReLU $\rightarrow$ Leaky ReLU, GELU)

초기화: Xavier $1/n$, He $2/n$ 로 층마다 크기 유지 폭발엔 기울기 자르기