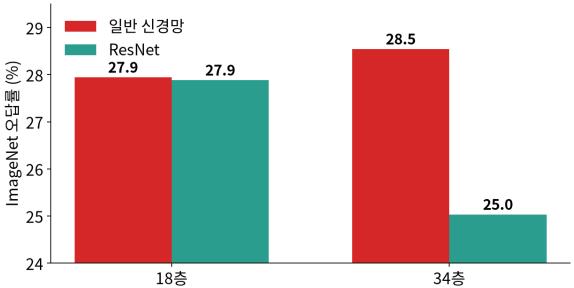
ResNet 잔차 신경망 (Residual Network)

입력을 건너뛰어 더하는 지름길 하나

Machine Learning and Deep Learning

한국과학영재학교 (KSA)

오늘의 질문: 두 배 깊게 쌓으면 더 좋아질까?



일반 신경망 18 → 34층: 27.9% → **28.5%, 오히려 증가** (학습 데이터에서도)

He, Zhang, Ren, Sun (2015), ImageNet 검증 top-1 오답률

이상하다: 깊은 쪽이 최소한 같아야 한다

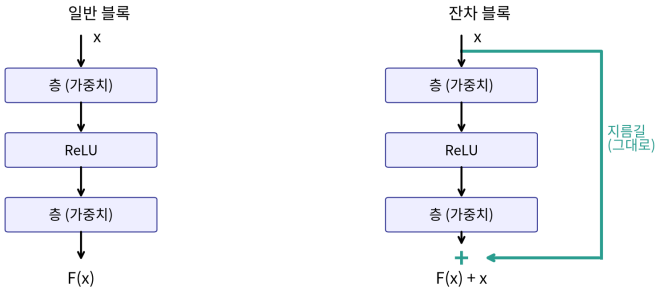
18층 신경망에 층 16개를 더 붙이는데, 그 16개가 **입력을 그대로 내보내기만** 하면

34층 = 18층과 **정확히 같은** 성능

34층이 더 나쁠 이유가 없다 그런데 "그대로 내보내기" 조차 **학습하기 어렵다**

여러 층을 거쳐 $\mathbf{h} = \mathbf{x}$ 를 만들기는 까다롭다 (기울기 소실과도 얽힘)

해결: 입력을 건너뛰어 더한다



$$\mathbf{y} = F(\mathbf{x}) + \mathbf{x}$$

지름길 (skip connection, shortcut) 가중치가 없다, 그냥 더하기

층은 바뀔 부분 (잔차) 만 배운다

원하는 출력이 $H(\mathbf{x})$ 라면 층이 배울 것은 $F(\mathbf{x}) = H(\mathbf{x}) - \mathbf{x}$

할 일이 없으면	$F = 0 \to$ 입력이 **그대로** 통과
조금 고칠 일이면	작은 수정만 배운다
역전파	$\partial \mathbf{y}/\partial \mathbf{x} = \partial F/\partial \mathbf{x} + 1 \to$ 기울기가 **줄지 않고** 전달

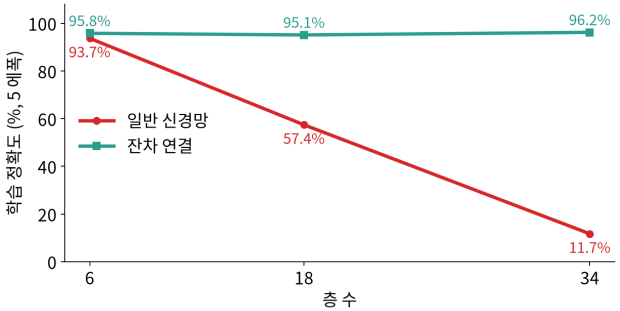
결과

ImageNet top-1 오답률	18층	34층
일반 신경망	27.9%	**28.5%**
ResNet	27.9%	**25.0%**

152층까지 쌓아 ILSVRC 2015 1위 (상위 5개 오답률 **3.57%**, 앙상블)

He, Zhang, Ren, Sun (2015) arXiv:1512.03385, Table 2 인용 수가 가장 많은 논문 중 하나

우리 실험: 손글씨 1만 장, 깊이만 바꿨다



34층: 일반 **11.7%** (못 배움) 잔차 **96.2%** (학습 정확도, 5 에폭)

블록 = 층 2개 (폭 64) 블록 2 · 8 · 16개 = 층 6 · 18 · 34개 Adam, 같은 조건

더하려면 크기가 같아야 한다

CNN 에서는 중간에 채널 수가 늘고 (64 → 128) 크기가 줄어든다 (보폭 2)

$$\mathbf{y} = F(\mathbf{x}) + W_s\,\mathbf{x}$$

그때만 지름길에 **1 × 1 합성곱** W_s 를 넣어 크기를 맞춘다 나머지 지름길은 그냥 더하기

ResNet 블록 = 합성곱 → BatchNorm → ReLU → 합성곱 → BatchNorm → (+ 지름길) → ReLU

지름길은 지금 어디에나 있다

이미지	ResNet-50 은 지금도 이미지 모델의 기준선
트랜스포머 (12주차)	모든 층이 $\mathbf{x} + \mathrm{Attention}(\mathbf{x})$, $\mathbf{x} + \mathrm{FFN}(\mathbf{x})$
GPT · BERT	수십 $\sim$ 백 층 이상을 쌓을 수 있는 이유 중 하나

"바꿀 부분만 배우고, 나머지는 그대로 흘려보낸다"

문제풀이

1. 잔차 블록에서 $\mathbf{x} = (1, 2)$, $F(\mathbf{x}) = (0.1, -0.3)$ 이면 출력은? 블록이 아무것도 안 바꾸려면 F는?
2. 일반 신경망 50층의 학습 정확도가 20층보다 낮다. 과대적합인가? 이유는?
3. $y = F(x) + x$ 에서 $\partial F/\partial x = 0.01$ 이면 $\partial y/\partial x$ 는? 지름길이 없으면?
4. 입력 채널 64, 출력 채널 128 인 블록의 지름길에 쓰는 1×1 합성곱의 가중치 수는? (편향 없음)

실습

1. 잔차 블록 직접 만들기 (`nn.Module`, `F(x) + x`)
2. 손글씨 1만 장: 일반 vs 잔차, 6 · 18 · 34층 → 11.7% vs 96.2% 재현
3. 층별 기울기 크기 비교 + torchvision `resnet18` 구조 들여다보기

MNIST (torchvision)

▶ Colab에서 실습 노트북 열기

정리

깊게 쌓은 일반 신경망은 **학습 데이터에서도** 더 못한다 (18 $\rightarrow$ 34층: 27.9 $\rightarrow$ 28.5%)

잔차 블록 $\mathbf{y} = F(\mathbf{x}) + \mathbf{x}$ 층은 바뀔 부분만, 할 일 없으면 0

기울기가 지름길로 그대로 전달 $(+1)$ 34층 25.0%, 152층으로 2015 대회 1위

우리 실험 34층: 일반 11.7% vs 잔차 96.2% 트랜스포머의 모든 층에도