KL 발산 (Kullback–Leibler Divergence)

믿은 확률과 실제 확률 사이의 거리 아닌 거리

Sumin Han (suminhan@ksa.hs.kr)
Machine Learning and Deep Learning · 한국과학영재학교 (KSA)
2027학년도 1학기 · 14주차 (5/17–5/21)

오늘의 질문: 공지 확률이 틀렸다면 얼마나 손해일까?

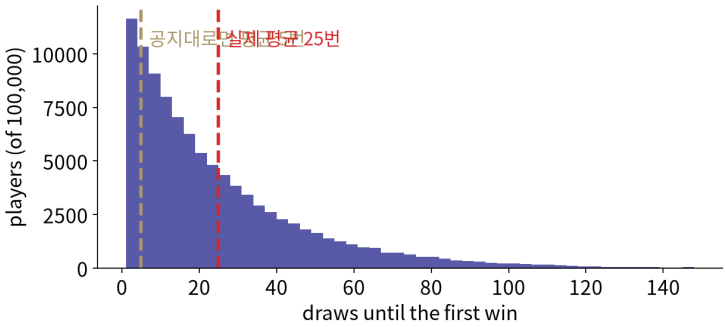
	당첨	꽝
공지 Q	20%	80%
실제 P	**4%**	96%

당첨까지 평균 **5**번 (공지) vs **25**번 (실제): 돈이 5배

두 확률 분포가 “얼마나 다른지” 를 숫자 하나로 잴 수 있을까?

게임 뽑기는 설명용 예시 (실제 게임 아님)

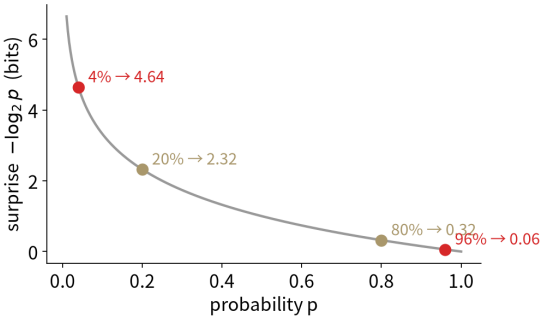
흉내 내 보기: 10만 명이 뽑으면



실제 4%: 평균 **24.9**번, 중앙값 17번 50번 넘게 **13%**, 100번 넘게 1.7%

공지 20% 로 흉내 내면 평균 5.0번 평균 횟수 = 1 / 당첨 확률

놀라움 (정보량): $I = -\log_2 p$



드문 일일수록 놀랍다

	실제로 재면	공지로 재면
당첨	**4.64**	2.32
꽝	0.06	0.32

단위: 비트 ($\log_2$) 확률 1/2 = 1비트

동전 한 번 결과를 적는 데 필요한 0 · 1 의 개수

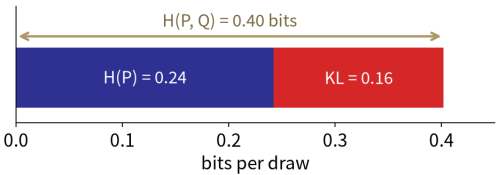
엔트로피 · 교차 엔트로피

	놀라움은	평균은 실제 비율로
엔트로피 $H(P)$	실제 확률로	$4.64 \times 0.04 + 0.06 \times 0.96 = \mathbf{0.24}$
교차 엔트로피 $H(P,Q)$	**공지** 확률로	$2.32 \times 0.04 + 0.32 \times 0.96 = \mathbf{0.40}$

$$H(P) = -\sum_x P(x) \log_2 P(x), \qquad H(P,Q) = -\sum_x P(x) \log_2 Q(x)$$

뜻: 결과를 하나 적을 때 드는 평균 비트 틀린 확률로 부호를 만들면 더 든다

KL 발산 = 교차 엔트로피 − 엔트로피



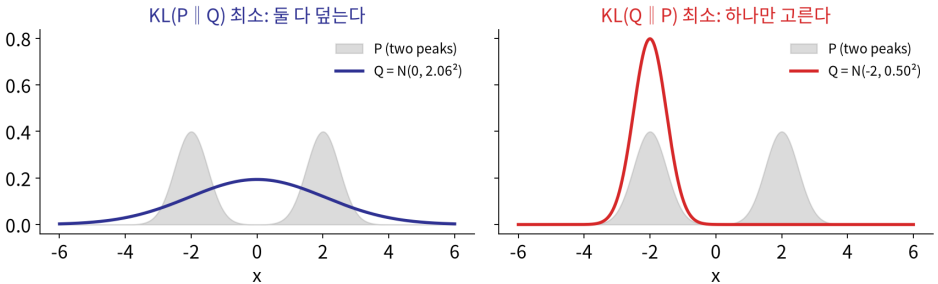
$$\mathrm{KL}(P \,\|\, Q) = \sum_x P(x) \log_2 \frac{P(x)}{Q(x)} = 0.40 - 0.24 = \mathbf{0.16}\ \text{비트}$$

틀린 확률을 믿어서 **한 번에 더 드는** 비트 뽑기 1,000번이면 160비트 낭비

항상 ≥ 0, $P = Q$ 일 때만 0 (Kullback & Leibler, 1951)

거리처럼 보이지만 대칭이 아니다

$$\mathrm{KL}(P\|Q) = \mathbf{0.16} \qquad \mathrm{KL}(Q\|P) = 0.2\log_2\frac{0.2}{0.04} + 0.8\log_2\frac{0.8}{0.96} = \mathbf{0.25}$$



봉우리 둘인 P 를 정규분포 Q 로: $\mathrm{KL}(P\|Q)$ 는 다 덮고, $\mathrm{KL}(Q\|P)$ 는 하나만

머신러닝 속 KL

분류 손실 (2주차)	정답이 원-핫이면 교차 엔트로피 = KL
VAE (14주차)	구름을 $N(0,1)$ 쪽으로: KL$(N(\mu,\sigma^2)\|\|N(0,1))$
t-SNE (10주차)	고차원 이웃 P 와 지도 이웃 Q: KL$(P\|\|Q)$
지식 증류	작은 모델이 큰 모델의 확률을 따라 하게: KL
ChatGPT 의 RLHF	원래 모델에서 멀어지지 않게 KL 벌점

분류: 고양이 정답에 70% $\to$ 0.51 비트, 95% $\to$ **0.07** 비트

문제풀이

1. 공정한 동전 $P = (0.5, 0.5)$ 을 $Q = (0.9, 0.1)$ 로 믿으면 KL$(P\|Q)$ 는? ($\log_2 \frac{0.5}{0.9} \approx -0.848$, $\log_2 5 \approx 2.32$)
2. 정답 (1, 0) 에 모델이 (0.5, 0.5) 를 주면 손실 (비트) 은?
3. 당첨 확률이 2% 라면 당첨까지 평균 몇 번? 놀라움은 몇 비트? ($\log_2 50 \approx 5.64$)
4. 데이터 P 를 흉내 내는 생성 모델이 KL$(Q\|P)$ 만 줄이면 어떤 문제가 생길까?

실습

1. 놀라움 · 엔트로피 · 교차 엔트로피 · KL 함수 $\rightarrow$ 0.24 · 0.40 · 0.16
2. 뽑기 횽내: 당첨까지 횟수, 기록 1,000번의 비트 수
3. 봉우리 둘을 정규분포로 맞추기: 앞 방향 vs 뒤 방향 KL

▶ Colab에서 실습 노트북 열기

정리

놀라움 $-\log_2 p$ 엔트로피 = 평균 놀라움 (뽑기 0.24 비트)

교차 엔트로피 = 틀린 확률로 잰 평균 놀라움 (0.40) **KL** = 그 차이 **0.16**

KL ≥ 0, 같을 때만 0 대칭 아님 (0.16 vs 0.25): 다 덮기 vs 하나 고르기

분류 손실 · VAE · t-SNE · 지식 증류 · RLHF 의 공통 언어