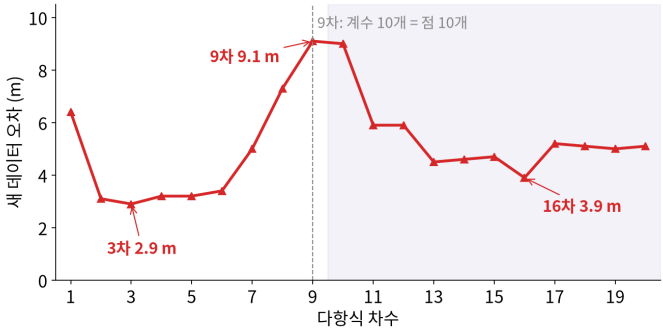
이중 하강 (Double Descent)

외울 수 있을 만큼 큰 모델이 왜 다시 좋아지나

Machine Learning and Deep Learning

KSA 2027-Spring
Sumin Han (suminhan@ksa.hs.kr)

3주차 마지막 쪽: 9차를 넘어 계속 키웠더니



3차 **2.9 m** → 9차 **9.1 m** → 16차 **3.9 m**

10차부터는 측정 오차가 모두 0 m

오늘의 질문

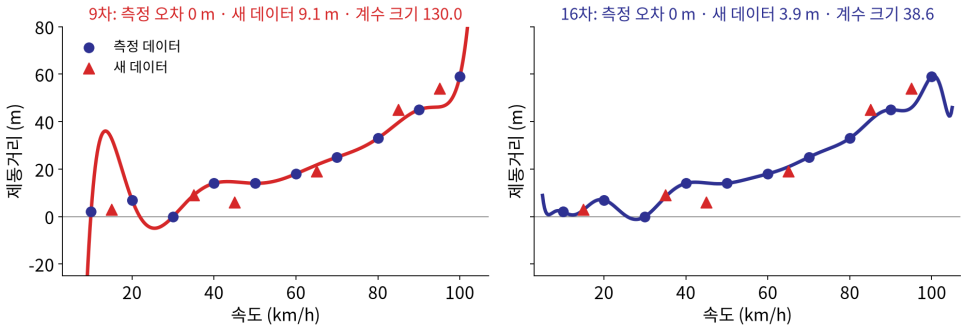
데이터를 **완벽히 외우는** 모델이 왜 새 데이터도 잘 맞힐까?

큰 신경망은 계수가 데이터보다 훨씬 많다 $\rightarrow$ 학습 데이터를 다 외울 수 있다

3주차의 결론대로라면 **과대적합**이어야 하는데, 실제로는 잘 된다

오늘의 순서: 작은 예 (제동거리 점 10개) $\rightarrow$ 큰 예 (손글씨 숫자 200장) $\rightarrow$ 무엇이 피크를 만들고 무엇이 없애나 $\rightarrow$ 아직 논쟁 중인 것

둘 다 점 10개를 외웠다: 9차와 16차



9차는 점 사이에서 크게 출렁이고, 16차는 **얌전하다**

9차가 최악인 이유: 해가 하나뿐이다

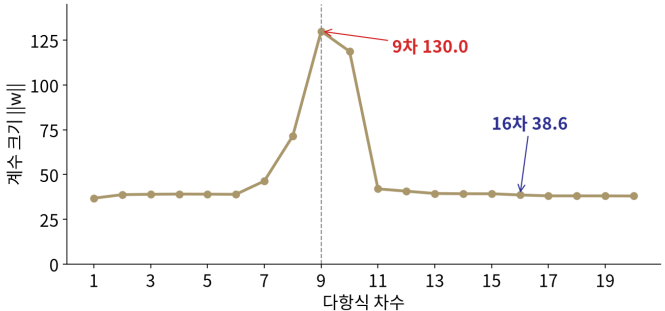
계수 10개 = 점 10개 (방정식 10개)

$\rightarrow$ 모든 점을 지나는 곡선이 **딱 하나**. 고를 여지가 없다

그 하나가 잡음까지 지나려면 $\rightarrow$ 계수를 **크게** 써서 억지로 휜다

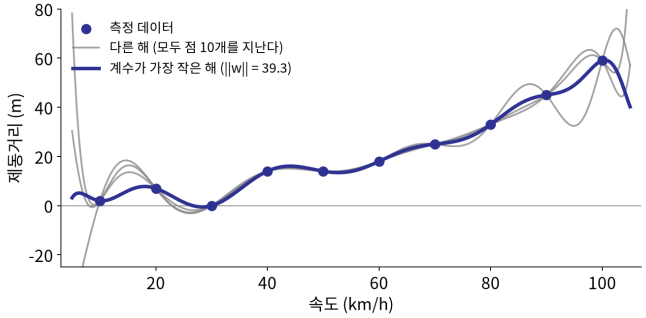
30 km/h 에서 0 m 같은 잡음 점을 지나느라 계수 크기 $\|w\| = \sqrt{w_0^2 + w_1^2 + \cdots}$ 가 130

계수 크기를 차수별로 재 보면



계수 크기도 9차에서 **130** 으로 솟았다가 **38 근처**로 돌아온다 (오차 곡선과 같은 모양)

10차부터: 모든 점을 지나는 곡선이 무수히 많다



계수 16개, 방정식 10개 $\rightarrow$ 남는 자유 6개만큼 **무수히 많은** 해 (15차)

그중 **계수 크기가 가장 작은 해**를 고른다 = **최소 노름 해 (minimum-norm solution)**

최소 노름 해: 식과 코드

$$\min_{w} \|w\|^2 \quad \text{subject to} \quad Xw = y$$

$$w^* = X^\top (XX^\top)^{-1} y$$

X: 점 10개 $\times$ 계수 16개 (행 = 점, 열 = 기저 함수) y: 측정한 제동거리 10개

코드 한 줄: `np.linalg.lstsq(X, y)` 또는 `np.linalg.pinv(X) @ y`

계수가 점보다 적으면 같은 함수가 보통의 최소제곱 해를 준다 (3주차의 1 9차)

경사하강법은 0 에서 출발하면 저절로 최소 노름 해로 간다

$$w \leftarrow w - \alpha\, X^\top (Xw - y) \qquad \text{GD update}$$

$$w = X^\top v \;\; \text{꼴을 유지한다} \qquad \text{start } w = 0, \text{ every step adds } X^\top(\cdot)$$

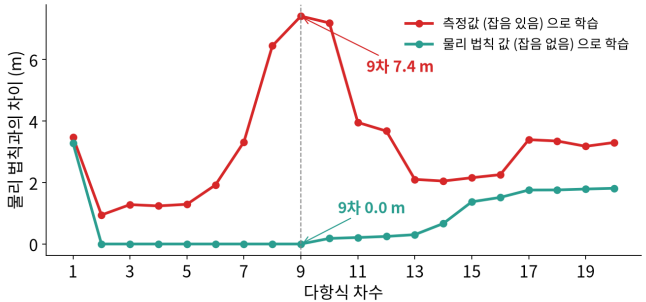
$$Xw = y,\; w = X^\top v \;\Rightarrow\; w = w^* \;\text{(하나뿐)} \qquad \text{others } = w^* + u,\; Xu = 0$$

$$\|w^* + u\|^2 = \|w^*\|^2 + \|u\|^2 \;\geq\; \|w^*\|^2 \qquad u \perp X^\top v$$

16차 · 1000번: 0 에서 출발 $\rightarrow$ 최소 노름 해와 거리 **0.0** 모든 계수 3 에서 $\rightarrow$ **11.6**

둘 다 점 10개를 정확히 지나지만, **출발점**이 어떤 해에 도착할지를 정한다

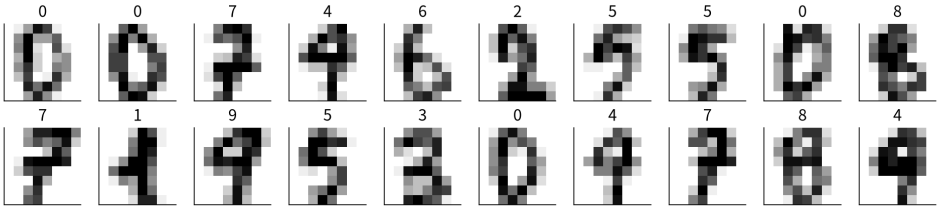
잡음이 없으면 피크도 없다



물리 법칙 값으로 학습하면 9차도 법칙과의 차이 **0.0 m** 측정값으로 학습하면 **7.4 m**

피크 = 해가 하나뿐인 자리에서 **잡음**까지 억지로 외운 대가 (새 속도 6곳에서 법칙 값과의 평균 차이)

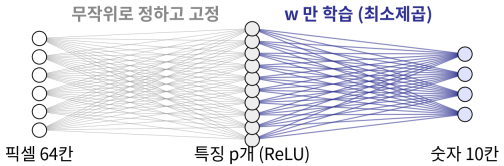
큰 예: 손글씨 숫자 (UCI optdigits)



$8 \times 8 = 64$칸, 밝기 $0 \sim 16$ 학습 **200장** (앞에서부터) 시험 **1797장**

Alpaydin & Kaynak (1998), UCI Machine Learning Repository

모델: 무작위 특징 (random features)

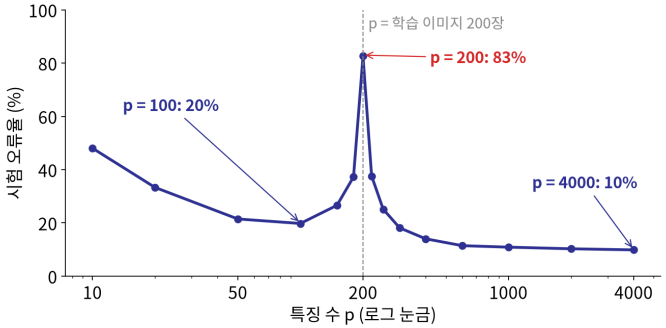


$$h(x) = \sum_{j=1}^{p} w_j \,\mathsf{ReLU}(a_j^\top x)$$

a_j: 무작위로 정하고 **고정** w_j: 학습 (최소 노름 최소제곱) 특징 수 p 를 10 에서 4000 까지

첫 층을 학습하지 않는 신경망. 학습이 최소제곱 한 번이라 정확히 재현된다. 무작위 seed 5개 평균

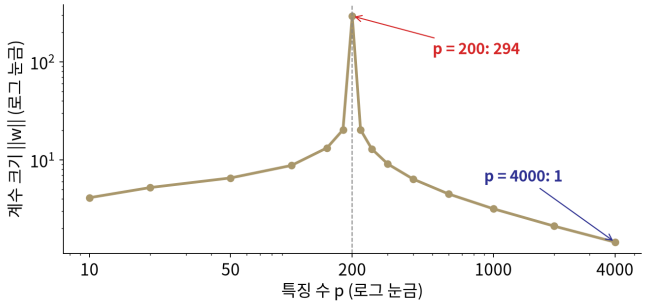
결과: 이중 하강



$p = 100$: **20%** $\rightarrow$ $p = 200$: **83%** $\rightarrow$ $p = 4000$: **10%**

피크: 특징 수 = 학습 이미지 수 (해가 딱 하나, interpolation threshold) 두 번째 바닥이 첫 바닥보다 낮다

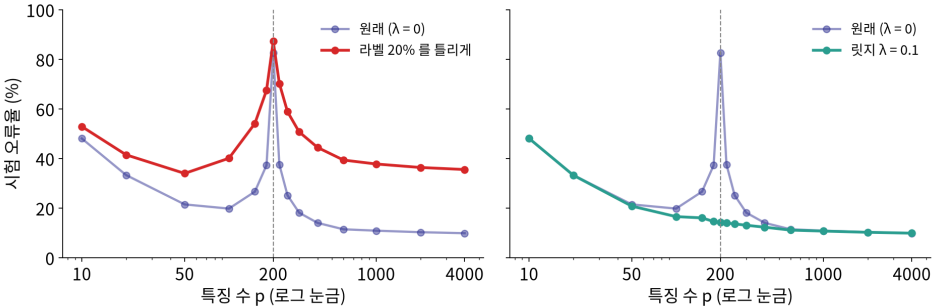
여기서도 피크 = 계수 크기의 폭발



$\|w\|$: $p = 100$ 에서 9 $\rightarrow$ $p = 200$ 에서 **294** $\rightarrow$ $p = 4000$ 에서 **1**

특징이 많을수록 같은 데이터를 맞추는 방법이 많아져서, 가장 작은 계수로 맞출 수 있다

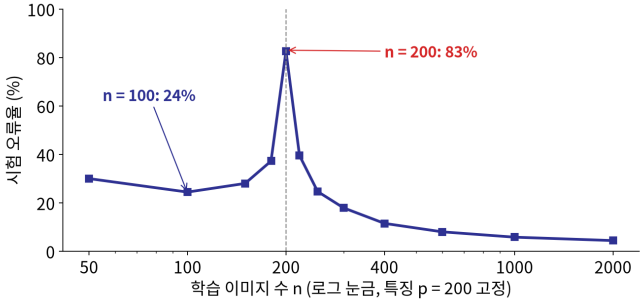
라벨 잡음은 키우고, 릿지는 없앤다



라벨 20% 틀리게: 끝도 **36%** 릿지 $\lambda = 0.1$: 피크가 **사라진다** ($p = 200$ 에서 14%)

잡음 = 다섯 장마다 한 장의 라벨을 다음 숫자로 바꿈 릿지 = 손실 + $\lambda\|w\|^2$ (5주차 정규화)

데이터를 늘렸는데 나빠진다?



특징 200개 고정: 학습 100장 **24%** → 200장 **83%** → 2000장 **4%**

데이터 수가 특징 수에 다가가면 다시 해가 딱 하나인 자리가 된다 (sample-wise double descent)

이름과 역사

1990년 전후 통계물리의 학습 곡선 연구에서 이미 비슷한 피크 (Opper 등 · Krogh & Hertz 1992)

2019 Belkin 등 (PNAS): **double descent** 라는 이름, 고전 U자와 큰 모델을 한 그림에

2019 Nakkiran 등 (OpenAI, Deep Double Descent): 딥러닝에서 세 가지 모양

모델 크기 (오늘 p) · 데이터 수 (오늘 n) · 학습 횟수 (epoch-wise)

2023 Curth 등 (NeurIPS): “파라미터 수로 그린 탓” 이라는 반론 (다음 쪽)

반론: 자를 잘못 고른 것일 수도 있다

Curth 등 (2023): 가로축의 **파라미터 수**가 모델의 실제 복잡도를 제대로 재지 못한다

최소 노름 해는 파라미터가 많아질수록 계수를 **더 작게** 쓴다 (p.12) → 실제로 쓰는 복잡도는 오히려 줄 수 있다

"유효 파라미터 수"로 다시 그리면 **고전적인 U자**와 크게 어긋나지 않는다는 주장

확실한 것: 이런 곡선이 **관찰된다**, 피크는 잡음과 정규화에 크게 좌우된다

아직 열린 것: "근본적으로 새로운 현상인가", 큰 신경망의 성공을 이것으로 설명할 수 있나

큰 신경망과의 연결: 후보 설명들

암묵적 정규화 SGD 가 수많은 해 중 “작은” 해를 고르는 경향 (p.8) (선형은 증명됨)

benign overfitting 잡음까지 외워도 어떤 조건에서는 새 데이터 오차가 작다 (Bartlett 등, 2020)

grokking 다 외운 한참 뒤에야 일반화가 일어나는 현상 (Power 등, 2022)

scaling law 데이터를 한 번 남짓만 보는 큰 언어모델은 주로 이쪽으로 논의

공통 질문: “**외웠는데 왜 잘 되나**”는 아직 **완전히 풀리지 않았다**

문제풀이

1. 점 6개에 다항식을 맞춘다. 5차면 모든 점을 지나는 해는 몇 개인가? 8차면?
2. 방정식 $w_1 + w_2 = 3$ 의 해 $(3, 0)$, $(0, 3)$, $(1.5, 1.5)$ 의 크기 $\|w\|$ 를 각각 구하라. 최소 노름 해는?
3. 2번에서 $X = [1 \;\; 1]$ 이다. 경사하강법을 $(0, 0)$ 에서 출발하면 w 는 늘 어떤 방향 위에 있나? 어디에 도착하나?
4. 학습 이미지 500장으로 무작위 특징 모델을 만든다. 피크는 특징 수 몇 개 근처에서 생길까? 피크를 없애는 방법 두 가지는?

실습

1. 최소 노름 해 구현 → 9차 9.1 m · 16차 3.9 m 재현 + 경사하강법도 같은 해로? (p.8)
2. 손글씨 숫자: 무작위 ReLU 특징 만들기 → 이중 하강 곡선 그리기 (p.12)
3. 라벨 잡음 · 릿지 λ · 데이터 수로 피크를 키우고 없애기

UCI optdigits (Alpaydin & Kaynak, 1998)

▶ Colab에서 실습 노트북 열기

정리

피크: 계수 수 = 데이터 수 $\rightarrow$ 해가 딱 하나 $\rightarrow$ 잡음까지 외우느라 계수가 폭발

두 번째 하강: 해가 무수히 많아지고, 그중 **가장 작은 해**를 고르면 다시 좋아진다

경사하강법은 0 에서 출발하면 그 작은 해를 **저절로** 고른다 (암묵적 정규화)

잡음은 피크를 키우고, 릿지는 없앤다 데이터를 늘려도 피크를 지날 수 있다

관찰은 확실, **해석은 논쟁 중** (파라미터 수가 맞는 자인가?)