Machine Learning 1: 머신러닝 첫걸음 샘플

중간 프로젝트 샘플 (Abstract · 보고서 · 동료평가)

Spring 2027

아래는 **가상의 팀**이 쓴 샘플입니다. 수치는 형식을 보이기 위한 예시이며 실제 실험 결과가 아닙니다. 형식과 분량의 기준으로만 참고하세요.

① Abstract 샘플 (3주차 제출, 1쪽)

제목: 신용카드 연체 예측에서 정규화 로지스틱회귀와 GBDT의 비교
팀: 김OO, 이OO, 박OO

문제 정의. 행 하나는 **카드 고객 한 명**이고, 라벨은 다음 달 연체 여부(1=연체)이다. 연체 비율이 약 22%로 한쪽에 치우쳐 있어 정확도 대신 **PR-AUC**를 주 지표로 쓴다.

데이터. UCI "Default of Credit Card Clients" (30,000행, 특성 23개). 같은 고객이 한 행씩만 있어 그룹 누수 위험은 없고, 시간 정보가 없어 무작위 stratified 분할(60/20/20)을 쓴다.

베이스라인. (a) 항상 "연체 아님"을 내놓는 모델(정확도 78%, PR-AUC 0.22), (b) 정규화 없는 로지스틱회귀.

계획. L2 정규화 로지스틱회귀와 GBDT를 비교한다. 정규화 세기와 트리 개수는 validation 곡선으로 고르고, test는 마지막에 한 번만 측정한다. 수식적 정당화로는 정규화에 따른 편향-분산 변화와 GBDT의 SHAP 분해 한 건을 쓴다.

예상되는 위험. 청구 금액 특성들이 서로 강하게 연관되어 로지스틱회귀 계수가 불안정할 수 있다. 정규화로 계수가 어떻게 변하는지 함께 기록한다.

② 보고서 샘플 (6주차 제출, 축약본)

1. 문제 정의. 고객 한 명을 행으로, 다음 달 연체 여부를 라벨로 한다. 주 지표는 PR-AUC이다 (연체 22%의 불균형 때문). 베이스라인은 항상 "연체 아님" (PR-AUC 0.22).

2. 데이터와 전처리. 30,000행을 60/20/20으로 stratified 분할했다. 표준화의 평균과 표준편차는 **train에서만** 구해 validation과 test에 적용했다. 범주형(학력, 결혼 상태)은 원-핫 인코딩.

3. 모델 선택과 이유. 로지스틱회귀는 해석이 쉽고, 특성이 많이 연관되어 있어 L2 정규화 효과를 보이기 좋다. GBDT는 표 데이터에서 강한 비교 대상이다. 거리 기반이 아니므로 GBDT에는 표준화를 쓰지 않았다.

모델 (validation)	PR-AUC	비고
베이스라인(항상 0)	0.22	
로지스틱회귀, 정규화 없음	0.46	
로지스틱회귀, L2 ($C = 0.1$)	0.48	validation으로 선택
GBDT (트리 150개)	0.55	validation으로 선택

4. 결과. 최종 test는 **한 번만** 측정했다: GBDT PR-AUC 0.54, 로지스틱회귀(L2) 0.47. 학습 곡선(그림 1)에서 트리 개수가 150을 넘으면 train은 계속 오르지만 validation은 멈춰 150에서 멈췄다.

5. 수식적 정당화. L2 정규화가 계수의 크기를 줄여 분산을 낮춘 결과 validation PR-AUC가 0.46에서 0.48로 올랐다(편향은 약간 증가). SHAP으로 한 고객의 예측을 분해하면 최근 두 달의 연체 여부가 가장 크게 기여했다.

6. 재현 방법. 데이터는 UCI 저장소의 원본 CSV, 시드 42, 분할 60/20/20(stratified), L2 세기 $C = 0.1$, 트리 150개. 저장소의 `run.sh` 한 줄로 표의 숫자가 다시 나온다.

7. 한계와 잘 안 된 부분. 불균형을 줄이려고 연체 쪽 가중치를 키웠더니 PR-AUC가 오히려 0.02 내려갔다. 가중치가 확률을 왜곡해 순위 지표에는 도움이 안 된다고 진단했다.

③ 동료평가 샘플 (8주차 제출)

평가 대상: 다른 팀의 "당뇨 재입원 예측" 보고서 **작성자**: 이OO

항목	평가
주장의 명확성	첫 문단에서 입원 한 건의 30일 내 재입원을 예측한다가 분명하다. 라벨과 지표도 명확하다.
비교 대상	항상 재입원 없음을 내놓는 베이스라인과 로지스틱회귀, GBDT를 같은 분할로 비교했다. 좋다.
확장성	한 병원의 데이터만 썼다. 다른 병원이나 다른 연도에서도 통하는지 확인이 없다.
재현성	시드와 하이퍼파라미터는 있으나, 한 환자의 여러 입원을 어떻게 나눴는지와 코드 실행 방법이 적혀 있지 않아 다시 해 볼 수 없다.
한계	실패한 시도와 클래스 불균형의 영향을 솔직하게 적었다. 좋다.

반박 가능한 질문. 같은 환자의 입원이 train과 test에 함께 들어갔다면 test 숫자는 부풀려진 것이 아닐까요? 환자 단위로 나눠서 다시 측정한 결과가 있나요?