Block A 캡스톤: 팀 프로젝트와 총정리

팀 프로젝트 4주 파이프라인 · Peer-Review · 중간고사 대비 총정리

Machine Learning 1 · 8주차

한국과학영재학교 (KSA)

Week 8

이번 주차 개요

- **8.1 팀 프로젝트** — 4주 파이프라인, **정직하게 얻은 성능**
- **8.2 Peer-Review** — 체크리스트로 두 팀 심사, 반박 가능한 질문
- **8.3 중간고사 총정리** — 유도 템플릿 3가지, 장별 자가진단

이번 장을 마치면

모델·지표·전처리·분할을 스스로 골라 근거지을 수 있고, 3분할·베이스라인·“test 한 번” 절차를 실제로 수행해 보고서·발표로 제시할 수 있다.

같은 절차를 세 가지 언어(코드, 보고서, 리뷰)로 말할 수 있어야 이 프로젝트가 끝난 것이다.

8.1 팀 프로젝트: 데이터 선정부터 발표까지

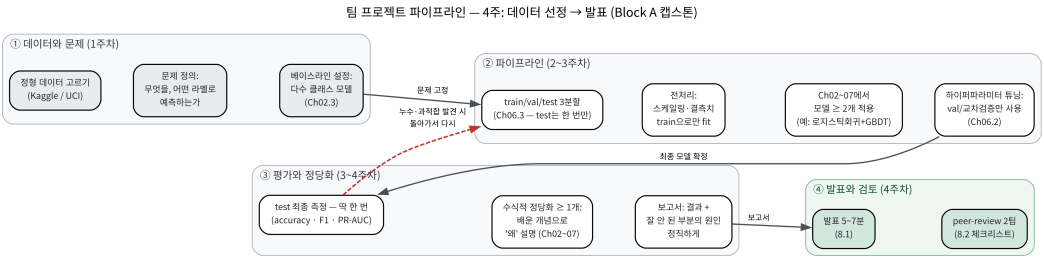
왜 지금 프로젝트를 하는가

- 트리 기반 모델(Week 7)까지 끝내면 정형 데이터의 대표 도구를 **거의 다** 손에 쥔다 — Block B 신경망 없이도 실전 데이터셋 상당수를 다룰 수 있다.
- 지금이 “각 장의 코드가 **실제 데이터** 앞에서도 작동하는가”를 확인할 가장 좋은 시점.

검증의 성격이 달라진다

- Week 2–7 실습: 교재가 고른 데이터, 교재가 고른 모델.
- 이번엔 데이터 고르기, 모델 고르기, **나빠지면 원인을 찾아 다시 고르기**까지가 우리 몫.
- “코드가 동작한다”의 증거와 “내가 풀 수 있다”의 증거는 다르다.

전체 그림: 4주 파이프라인



데이터·문제 정의(1주) → 3분할·전처리·모델·val 튜닝(2–3주) → test 한 번·수식적 정당화(3–4주) → 발표·peer-review(4주)

전체 그림: 어떻게 읽는가

- 왼쪽→오른쪽으로 **데이터** → **파이프라인** → **평가** → **발표** 로 흐름.
- **붉은 점선**이 핵심: test에서 **누수** (Week 6.3)나 **과적합**(Week 4.1)이 보이면 돌아가서 다시.
- “한 번 지나가면 돌아올 수 없는 것”은 **test 한 번의 측정**뿐 — 그 외 모든 단계는 되돌아갈 수 있다.

일정과 마일스톤 M1–M4 I

주	해야 할 일
1	데이터 후보 2∼3개 조사(크기·결측치·클래스 비율), 팀 회의, **문제 정의 문서**(행이 무엇인지, 라벨, 주 지표
2	3분할(Week 6.3)로 코드 스캐폴드, train으로만 fit하는 전처리, 1개 모델 엔드투엔드, 베이스라인 측정
3	나머지 모델 적용, val/교차검증(Week 6.2)으로 튜닝, **test 최종 측정(한 번만)**, 학습 곡선 도출
4	수식적 정당화 작성, 보고서·슬라이드 완성, **발표(5∼7분)**, **peer-review 2팀**

왜 마일스톤이 이 모양인가

M2가 **베이스라인 숫자 한 줄**을 요하는 이유: 이 숫자를 봐야 “모델을 만들었다”고 말할 수 있는지 판정 가능.
M3가 **학습 곡선 한 장**을 요하는 이유: 최종 숫자만 제출하면 하이퍼파라미터를 어떻게 정했는지 검증 못 함 — 곡선이 있으면 val 곡선이 실제로 선택에 쓰였는지가 그림에서 드러남.

프로젝트 구조

- 정형 데이터 하나
- 두 가지 모델 비교
- 필수: 수식적 정당화 $\geq$1개 —
- 3분할 준수, 테스트 1회

데이터 고르기 실전 가이드 5개

1. **행의 물리적 단위**를 한 문장으로 설명할 수 있는가 (환자? 거래? 주문?) — 설명이 안 되면 "예측 대상 단위를 일반화하는가"를 물을 수 없다.
2. **레이아웃의 함정**이 있는가 — 같은 환자의 여러 검사 결과가 여러 행이면 무작위 분할이 누수 → `GroupKFold` 필요.
3. **클래스 비율을 먼저 보고 지표를 정한다** — 99:1이면 정확도가 아니라 PR-AUC/재현율(Week 2.3 정확도의 함정).
4. **크기** — 100행 미만이면 CV 폴드가 너무 작아 숫자가 극도로 흔들림 → 500∼10,000행이 편함.

후보 데이터셋 한 줄 점검표

데이터셋	크기	문제 정의	주의할 함정
breast cancer (UCI)	569×30, 약 4:6	조직이 악성인가	비교적 깨끗함 — “기본 코스”
Heart Failure (UCI)	1,000×14, 약 7:3	28일 내 사망	약간 불균형 — F1 · PR-AUC 함께
Poker Hand (UCI)	1,025×13, 10클래스	패 손 등급	다중 클래스 — 베이스라인 10%(무작위)
Space Guests (Kaggle)	4,500×14, 균형	목적지 성좌	결측치 다수 — 대체를 **train으로만**
Credit Card (Kaggle)	28만×31, 99.8:0.2	사기 탐지	극단 불균형 — 정확도 금지, PR-AUC 필수

권장 순서

“기본 코스” breast_cancer를 먼저 끝내고, 시간이 남으면 Credit Card 같은 극단 데이터로 **지표 선택의 중요성**을 재확인한다 — 8.2절에서 “정확도의 함정”을 근거로 리뷰할 실력이 된다.

베이스라인: “모델보다 먼저 봐야 할 숫자”

다수 클래스(majority-class) 모델

모델을 **아예 안 만들고도** 성능을 만드는 유일한 방법: train에서 가장 많이 나온 클래스를 전부 예측.

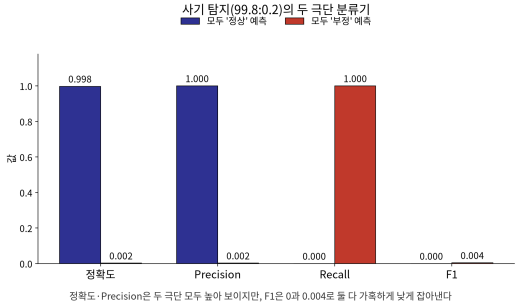
- 클래스 비율 50:50 → 베이스라인 정확도 50%.
- 90:10 → 90%, 99.8:0.2 → 99.8%.
- 비율을 보면 베이스라인이 **자동으로 정해진다**.

“우리 test 정확도가 99.8%”라는 발표는, 베이스라인을 보지 않은 한 아무것도 말하지 않은 발표다.

Week 2.3 “정확도의 함정”을 숫자로 강제하는 체크 — 보고서는 모델 성능 숫자와 함께 **항상 베이스라인 숫자도 함께** 제시.

손으로 한 번: 베이스라인의 F1

- 부정(fraud)에 대한 정확도는 $P = 1.0$ 이지만 **재현율** $R = 0$ — 부정 건을 하나도 못 잡음.
- $$F_1 = \frac{2PR}{P + R} = 0$$
- 재현율은 $R = 1.0$ 이지만 정확도는 0.2% 수준으로 희석.
- $$F_1 \approx 0.004$$



정확도·Precision은 두 극단 모두 높아 보이지만, F1은 0과 0.004로 둘 다 가혹하게 낮게 잡아낸다

교훈

F1은 정확도보다 이런 **극단적 모델을 더 가혹하게 (= 정확하게)** 다뤄준다 — 바로 이것이 지표를 고르는 이유다.

모델 비교의 기준: val에서 정하고, test는 한 번만

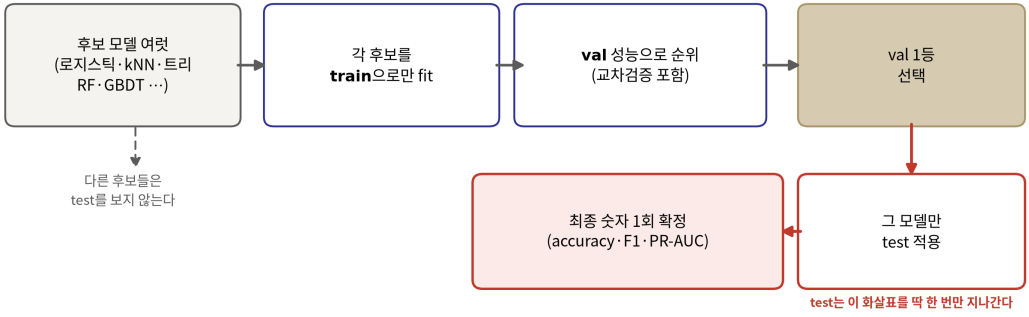
1. 모든 후보 모델을 **train으로만** fit하고, **val 성능으로 순위** 매기기 (하이퍼파라미터 포함이면 val 안에 Week 6.2 교차검증 사용).
2. **val 순위 1등**을 최종 모델로 결정.
3. 그 모델 **만** test에 적용해 최종 숫자를 **한 번** 얻는다.

왜 "한 번"인가

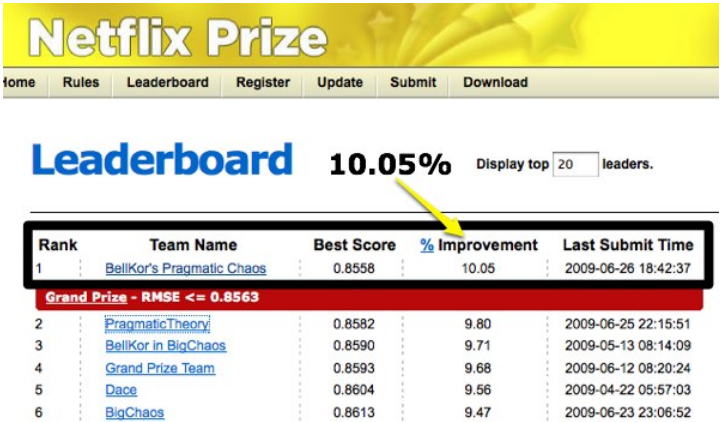
test로 후보 m개를 돌려봐서 가장 좋은 것을 고르면, 잡음 σ 기준으로 $\mathbb{E}[\max]$만큼 성능이 **부풀어 오른다**(Week 6.3 선택 편향 시뮬레이션). 형식적 원칙이 아니라 **정량적** 이유다.

그림으로: 모델 비교 절차

모델 비교의 기준: val로 고르고, test는 한 번만



후보들은 **val**만 보고 순위가 매겨지고, 순위 1등만 **test**를 향해 딱 한 번 나아간다 — 나머지 후보는 test라는 화살표를 아예 지나가지 않는다.



Netflix Prize 공개 리더보드 (2009년 6월)

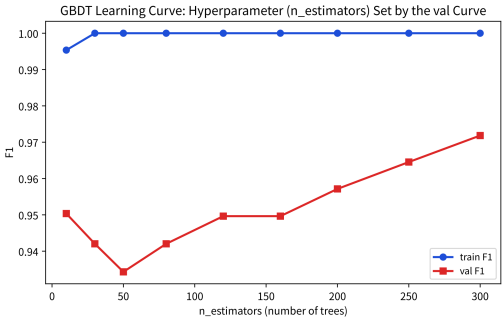
BellKor's Pragmatic Chaos — 10.05% 개선, 공개 순위를 보며 여러 팀이 반복 제출

선택 편향의 크기: 후보 50개면?

본 프로젝트 규모: 모델 5개 $\times$ 하이퍼파라미터 후보 10개 $=$ **후보 50개**. 잡음 $\sigma = 0.02$ (F1 스케일)로 가정하면 부풀림 약 **0.045**.

"test F1 0.97"이 실제로는 0.925일 수 있다는 뜻이다.

- val로 고르면 **val이** 이 편향을 먹고, test는 한 번만 쓰이므로 부풀림이 test에 **전이 되지 않는다**.
- 3분할 원칙은 "정직한 test 숫자"를 사기 위한 **구조**.



GBDT 학습 곡선 — train F1은 10개 트리부터 거의 1.0(341건을 몇 그루면 외우기 쉬움), val F1은 0.93∼0.97 사이로 느리게 이동. $n_{\text{estimators}}$는 **val 곡선으로만** 정한다.

6.3절 원칙이 그림에서 바로 보인다: **train 곡선은 "배운 것을" 재고, val 곡선만 "재는 것을" 한다.**

실습: breast_cancer 한 흐름 9단계

단계	내용(실측)
1	문제 정의 — 행=환자, 라벨=양성/악성, 주 지표 F1
2	3분할: train 341 / val 114 / test 114 (stratify, unique id로 pairwise disjoint 기계 점검)
3	전처리: `StandardScaler`를 **train으로만 fit**
4	모델 5개 후보(로지스틱·kNN·트리·RF·GBDT) val F1 비교 $\rightarrow$ **kNN(k=5)가 0.973로 1위**
5	베이스라인: 다수 클래스의 val F1 0.774 — kNN이 0.198 상회해야 "모델을 만들었다"고 말할 수 있음
6	test 한 번: accuracy 0.939, F1 0.950, PR-AUC 0.979
7	선택 편향 시뮬레이션: test로 5개 후보 고르면 $+0.023$, 50개면 $+0.045$ 부풀림
8	학습 곡선: GBDT $n_{\text{estimators}}$ vs train/val F1
9	SHAP 가산성 2-특징 장난감 손계산: $0.50 + 0.08 + 0.20 = 0.78 = f(\{A, B\})$

이 9단계가 곧 **보고서 6절** $\rightarrow$ **8.2 체크리스트 4항목**으로 매핑된다 — 같은 절차를 코드·보고서·리뷰 **세 가지 언어**로 말할 수 있어야 프로젝트가 끝난다.

보고서 구조 (M4) — 발표 슬라이드 = 보고서의 각 절 제목

절	분량	내용
1. 문제 정의	0.5p	행의 단위·라벨·주 지표·베이스라인 + “왜 이 지표를 골랐는가” 한 문장
2. 데이터와 전처리	1p	원본 통계(크기·결측치·이상치), **train으로만 fit한 전처리** 명시, 3분할 비율 + stratify 여부
3. 모델 선택과 이유	1∼2p	후보 ≥2개, **왜 이 후보들인가** (데이터 특성과 연결: 거리 기반이면 스케일링, 트리 기반이면 불필요), val 비교 표
4. 결과	1p	최종 test 숫자(한 번), 학습 곡선 1장, val 표
5. 수식적 정당화	1p	편향-분산·정규화·SHAP·PR-AUC 중 ≥1개로 “왜 이 결과가 나왔는지”
6. 잘 안 된 부분과 원인 진단	0.5p	**필수** — 없었으면 “무엇을 시도했다가 안 됐는가”. 이 절이 비어 있으면 “결과의 정직성” 항목을 의심받음

채점 기준 (rubric)

항목	비중	좋은 답
문제 정의와 데이터	15%	행의 단위·라벨·지표·베이스라인 명확, 지표 선택이 데이터 특성에 근거
방법론 적절성	25%	데이터 특성(불균형·차원·시계열·그룹)에 맞는 모델·전처리·분할, Week 2-
검증의 정직성	25%	3분할·train-fit·test 한 번·베이스라인 ·학습 곡선·val 튜닝이 **추적 가능**할
수식적 정당화	20%	개념 $\geq$1개로 “왜” 설명 + 설명이 관측(숫자)과 일치
결과의 정직성과 반성	15%	잘 안 된 부분을 숨기지 않고 Week 2–7 개념으로 원인 진단

50%가 절차인 이유

목적이 “높은 성능”이 아니라 **“성능 숫자를 정직하게 얻는 절차”를 수행한 것을 증명**하는 것이기 때문. 성능 0.60 이어도 절차가 정직하면 높은 점수, 0.99여도 test를 두 번 썼거나 베이스라인이 없으면 크게 감점.

수식적 정당화: 나쁜 설명 vs 좋은 설명

같은 결과("정규화 적용 → test 정확도 0.89→0.93")를 설명하는 두 문장:

나쁜 설명

"정규화를 넣으니까 성능이 좋아졌다.
정규화가 좋은 방법인 것 같다."

관찰만 있고 **왜**가 없다.

좋은 설명

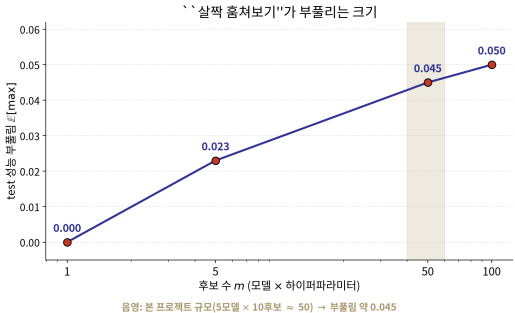
정규화 없이 train 0.99 / test 0.89 — 큰 격차(Week 4.1 의 분산 큰 과적합). L2 추가 + Week 6.2 교차검증으로 λ 튜닝 → train 0.95로 약간 하락, test 0.93 으로 상승 — **train/test 격차가 줄어든 것**이 정규화가 실제로 분산을 줄인 증거.

"성능이 올랐다"는 관찰과 "왜 올랐는지 설명할 수 있다"는 이해는 다른 수준의 성취다.

“살짝 훔쳐보기”가 얼마나 성능을 부풀리는가

최고 점 선택은 낙관 편향

후보 수 m	$\mathbb{E}[\max]$
1 (val로만)	≈ 0
5 (모델 5개)	≈ 0.023
50 (모델$\times$HP 10)	≈ 0.045
100	≈ 0.050



음영: 본 프로젝트 규모(5모델 × 10후보 ≈ 50) → 부풀림 약 0.045

읽는 법

“5개 모델을 test로 돌려보고 제일 좋은 것을 골랐다”는 행위는 F1 0.97의 결과에 **실제로 0.947일 수 있다**는 불확실성을 안고 있다. 후보가 **모델 수** $\times$ **하이퍼파라미터 수**의 곱으로 커지는 것이 이 편향이 4.5%p가 되는 이유.

자주 하는 실수 5가지

1. 테스트로 모델 고르기
2. 정규화 통계량 누수
3. 베이스라인 없이 성능 보고
4. 시계열 무작위 분할
5. 학습 곡선 없이 하이퍼파라미터 보고

발표: 5∼7분의 설계도

순서	내용	시간
1	문제 정의	1분
2	데이터와 전처리	1분
3	적용한 모델과 이유	2분
4	결과와 수식적 정당화	2분
5	잘 안 됐던 부분과 원인 진단	1분

- **왜 이 모델을 골랐고 왜 이 결과가 나왔는지**
- **마지막 1분이 가장 평가받는 부분**

발표의 마지막 1분: 실패를 개념으로 해석하라

“모든 것이 잘 됐다”

“결과의 정직성과 반성” 항목에서 **스스로 감점**을 받는 발표 — 이 절이 비어 있다는 뜻.

점수받는 발표

“트리 깊이를 5로 늘리자 val F1이 0.97에서 0.95로 떨어졌다 — Week 7.3대로 GBDT가 잔차를 계속 쫓다 노이즈까지 학습하기 시작한 것으로 진단하고, 깊이를 3으로 고정했다.”

- 실패한 시도를 **배운 개념으로 해석한** 증거라서 더 높은 점수.

확인 문제 (1)

- **1.** 팀이 train 70% / test 30%만 쓰고 하이퍼파라미터를 **test로** 고르겠다고 한다. 후보 10개, 잡음 $\sigma = 0.01$일 때 test 성능이 평균적으로 얼마나 부풀어 오르는가?

  답: Week 6.3 $\mathbb{E}[\max]$ 계산 ($\sigma = 1$일 때 ≈ 1.53)에 $\sigma = 0.01$을 곱하면 ≈ 0.015 — test F1이 실제로 0.985인데 1.00으로 보고될 수 있다. 질문 예: "시드 5개로 val/test 순위의 불일치율을 재볼 수 있나요?"

- **2.** breast_cancer(악성 62.7%)에서 다수 클래스 베이스라인의 val F1은 0.774였다. **정확도** 지표의 베이스라인은? 왜 정확도가 F1보다 "인정하기 쉬운" 숫자인가?

  답: 정확도 베이스라인 $\approx$ 62.7%. 정확도는 소수 클래스 몇 건을 잡았는지를 **희석**한다 — 50:50이 아니면 모델과 베이스라인의 차이를 과소/과대 평가. F1은 희석 효과를 없애므로 적합.

확인 문제 (2)

- **3.** 같은 데이터를 (a) 무작위 분할, (b) 환자(그룹) 분할로 나눠 kNN을 학습하면 (a)의 test RMSE가 비현실적으로 낮아진다. (a)가 왜 좋은 성적을 내는가?

  답: (a)에서는 같은 환자의 여러 행이 train/test에 흩어져, kNN이 test 행의 k-이웃을 **같은 환자의 train 행**으로 찾아 "환자를 인식"한다 — 관계를 배운 것이 아니라 환자를 **외운** 것. 질문: "그룹 키 (환자 ID)가 있는가? `GroupKFold`로 재분할하면?"

- **4.** "GBDT $n_{\text{estimators}}$=300을 val 곡선으로 정했다"는데, val F1이 300에서 **계속 상승 중**이다. 한계는?

  답: 상승 중이면 "300이 최적"이 아니라 "관찰 범위 내 최선". val이 $n \approx 150$에서 정점 후 하락했다면 300은 train F1=1.0 포화 상태에서 **잔차 (노이즈)를 쫓다 overfit한** 구간 — 150 부근(early stopping)을 골랐어야 함. 기준은 언제나 **val 정점**.

자주 묻는 질문

- **Q. 두 모델 성능이 거의 같으면?** 오히려 좋은 소재 — Week 6.3: 차이가 검증셋 표본 크기에 비해 작다면 "우연"일 수도 있다는 것 자체가 **통계적으로 중요한 관찰**. 예측이 어떤 포인트에서 갈리는지, 어느 쪽이 해석하기 쉬운지(로지스틱의 계수 vs GBDT의 SHAP)로 채운다.
- **Q. 결측치·이상치가 많은 데이터는 감점?** 아니다 — 오히려 전처리 결정(어떻게 채웠는지, 이상치를 제거·유지 했는지)과 **그 근거**가 좋은 평가 포인트. "지저분한 데이터를 다룬 판단 과정"이 실전에 훨씬 가깝다.
- **Q. 역할 분담은?** 데이터·코드·보고서·발표를 **팀 전체가 함께 결정**하되 작성은 나눠도 된다. "코드는 A, 보고서는 B"로 완전히 분리하면 B가 A의 코드를 모르는 채 정당화를 쓰게 됨(="나쁜 설명") — M2 중간코드 리뷰가 이를 강제.
- **Q. 4주 안에 안 끝날 것 같은데?** 성공 기준은 "높은 성능"이 아니라 **"정직한 절차"** — 모델을 2개로 줄이고(최소선은 2개) "시간 부족으로 3번째 모델을 못 돌렸다"를 정직하게 쓰는 것이 부풀리기보다 낫다.

8.2 Peer-Review

역전: 이번엔 네가 심사위원이다

- ML 결과는 **잘못된 것이 아니라 우연히 좋은 것처럼 보이는 것**이 너무나 쉽다:
  - test를 하이퍼파라미터 튜닝에 써서 (Week 6.3 선택 편향),
  - 클래스가 99.8:0.2로 기울어 있어서 (Week 2.3 정확도 의 함정),
  - train에 과적합해서 (Week 6.1).

그러므로

"좋은 결과"는 **스스로를 증명하지 못한다** — 다른 누군가가 그 결과를 **뒤집을 수 있는 구체적인 방법**을 찾아내는지로 판단해야 한다.

Popper의 반증주의: 왜 “반박 가능”인가

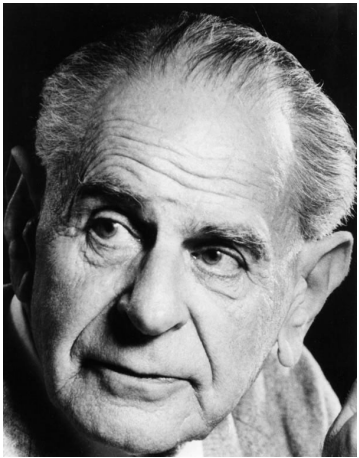
Karl Popper, 1934년 The Logic of Scientific Discovery:

반증주의 (falsifiability)

한 주장은 “그것이 틀렸음을 보여주는 관측이 **원칙적으로** 상상이 가능한가”로 판별된다. **반박될 수 없는 주장은 과학이 아니다.**

peer-review의 적용 좋은 질문이란 **발표팀이 제대로 답하지 못하면 결과 자체가 흔들리는** 질문:

- “더 잘 설명해 주세요” = **요청**.
- “Week 6 교차검증 없이 λ를 정했는데, 그 검증 성능이 우연일 가능성은 없는가?” = **반박**.



Karl Popper — LSE 교수, 1980년경

Amgen 재현 실험 (2011)

- 생물제약 회사 Amgen이 1999∼2005년 발표된 "주요(landmark)" 생물학 논문 **53편**을 직접 재현하려 했다.
- **6편밖에** 재현되지 못했다.
- 47편은 "잘못되었다기보다 재현이 안 된다" — 이후 **재현성 위기** 논쟁의 상징이 되었다.

peer-review의 정체

"남의 발표를 까탈스럽게 까는 절차"가 **아니다** — Amgen이 스스로 했던 것과 동일한 행위: **내 결과도 남이 재현·반박할 수 있도록 미리 방어하는 것**.

네 발표 전에, 네가 심사할 때 던질 가장 날카로운 질문을 스스로 던져 답을 준비해 두는 것이 최선.



John Ioannidis (Stanford)

“Why Most Published Research Findings Are False”(2005) 저자 — 재현성 위기 논의의 학술적 배경

이번 주 진행: 세 단계 + 체크리스트

순서	내용	시간
1	다른 두 팀 발표 청취(각 5~7분, 8.1 형식)	50분 중 약 30분
2	체크리스트 기반 **작성 리뷰 두 통** — 팀당 4개 항목 + **반박 가능한 질문 1개 이상**	발표 직후
3	질의·토론: 리뷰어가 쓴 질문에 발표팀이 답변	나머지 시간

체크리스트 4항목	확인할 것
문제 정의	무엇을 예측/분류하려 했는지 명확한가
방법론 적절성	데이터 특성(불균형, 차원 수 등)에 맞는 모델을 골랐는가
수식적 정당화	요구사항을 충족했고, 그 설명이 실제로 타당한가
결과의 정직성	잘 안 된 부분을 숨기지 않고 원인을 분석했는가

8.1에서 “수식적 정당화”가 발표팀의 의무였다면, 이번 주는 그 정당화가 타당한지를 **리뷰어가 심사**한다.

채점 기준: “채웠는가”가 아니라 “구체적인가”

품질	특징	예시
1점 — 감상평	구체적 지적이 없음, 느낌만	“발표 잘 들었
2점 — 일반 지적	문제를 제기하지만 **근거(개념)가 약함** — 발표팀이 “네”로 넘길 수 있음	“모델 선정 이 봐주세요.”
3점 — 반박 가능	**장·절을 명시**하고, 답이 나쁘면 결과가 흔들리는 질문	“불균형(99. Precision·R 모델일 수 있

1점 → 3점: 공통 패턴

- **추상적 평가어를 구체적 관찰과 개념으로 교체**
- “99.8:0.2 불균형에서 정확도만 비교했다(Ch02.3의 정확도의 함정)”(3점):

3점 질문의 구조

관찰 + 개념(장·절) + “왜 문제인지” — 세 칸 모두 채워져야 반박 가능.

손으로 한 번: 가상 발표에 체크리스트를 적용

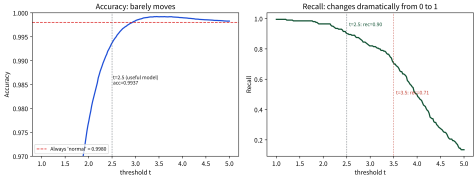
가상 발표 요약

항목	판정
문제 정의	✓명확 — 이상거래 탐지, 이진 분류
방법론 적절성	× 99.8:0.2 극단 불균형에 **정확도**를 썼다 — “정확도의 함정”(We
수식적 정당화	× 형식적으로만 충족 — 불균형에 맞는 지표(PR-AUC, 재현율)를
결과의 정직성	× “GBDT가 더 좋다”는 결론의 근거가 위 문제 때문에 약함

실습: “정확도 99.8%”를 코드로 검증 (1)

- 노트북은 발표의 설정(거래 10만 건, 사기 200건 = 0.2%)을 1차원 장난감 데이터로 재현하고, 임계값 분류자로 정확도·재현율·PR-AUC를 직접 계산.
- **(1) “쓸모있는 모델”의 정확도는 “무조건 정상”보다 낮다**: 사기를 약 90% 잡는 분류자(임계값 $t = 2.5$)의 정확도는 **99.37%** — 아무 모델 없이 전부 “정상”을 찍으면 **99.8%**(사기 1건도 못 잡는데도 정확도만으로는 더 낫다).

정확도 99.8%가 “모델이 좋다”는 증거가 아님을 보여주는 가장 직접적인 숫자.



왼쪽: 임계값 t 1.0→5.0을 올리면 정확도는 99.8%(무조건 정상, 붉은 점선) 부근에서 거의 움직임이 없음. 오른쪽: 같은 범위에서 재현율은 0에서 0.99까지 크게 변한다 — 정확도로 “동점”인 동안, 사기를 잡는 능력은 완전히 다름.

실습: 정확도 순위와 사기 잡기 순위 (2)

같은 분류자에서 **임계값만** 바꿔도 정반대의 줄 서기:

임계값 t	정확도	Precision	재현율	F1
3.5	**99.92%**	86.1%	71.0%	77.8%
2.5	99.37%	22.8%	90.0%	36.3%
2.0	97.72%	7.8%	**96.5%**	14.5%

- 정확도로 줄 세우면 $t = 3.5$가 최고, $t = 2.0$이 최하.
- 사기를 실제로 잡는 능력(재현율)으로는 **순서가 완전히 뒤집힌다** ($t = 2.0$이 최고).

교훈

"정확도가 높을수록 좋은 모델"이라는 직관이 불균형 데이터에서는 **모든 것을 더 놓치는 방식을 최고로 뽑는** 잘못된 기준이 된다.

실습: 동점의 함정 (3) — 의미를 가진 지표는 PR-AUC

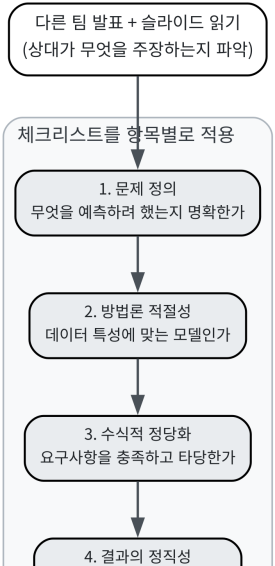
- 발표 설정(로지스틱회귀 vs GBDT)을 실제 2차원 불균형 데이터로 재현하면: test 정확도는 **99.86% vs 99.80%** — 0.06%p 차이, **검증셋 잡음보다 작거나 같은** 크기.
- 그런데 PR-AUC는 **0.636 vs 0.071**로 확연히 달라진다 — 정확도 하나만 보면 "둘이 같다", PR-AUC를 보자니 차이는 컸다.
- 참고: 이 장난감 실행에서 GBDT는 50개 트리·학습률 0.1로 양성 200개에 **과소적합**해 오히려 PR-AUC가 낮게 — "트리 수·학습률이 양성 개수에 비해 충분한가" 라는 리뷰 질문의 좋은 예시.

반박 가능성

"정확도만 보면 동점인데 PR-AUC를 보자니 다르다"는 리뷰어가 한 말이 실험에서 실제로 일어난 일이므로 **반박 가능** — 발표팀이 반박하려면 **숫자**(PR-AUC/재현율 + "0.1%p 차이가 이 크기보다 크다")를 꺼내야 한다.

좋은 리뷰를 쓰는 과정

8.2 Peer-Review — '반박 가능한' 리뷰를 쓰는 과정



형식으로 고정한 흐름

1. 발표 듣고
2. 체크리스트 4항목 적용
3. 각 항목에 **구체적 관찰** 기록
4. 그것이 **이 학기 개념(장·절)**에 뿌리 박은 질문인지 검사
5. 아니면 다시 쓰기

리뷰 템플릿 — 빈칸이 채워지지 않으면 3점 미만

```
팀이름
 :  _________ 리뷰어   :  _________
1. 문제정의   -- 무엇을예측분류하려 / 했는지한문장   . 명확했는가?
2. 방법론적절성   -- 데이터의어떤특성불균형   (, 차원, 결측치)에어떤모델이맞았는가
     ? 그선택에동의하는가   , 근거와함께 .
3. 수식적정당화   -- "최소 개1"(8.1)를 채웠는가? 어떤장의개념을썼고
   , 그설명이실제로   ** 타당한가?
4. 결과의정직성   -- 잘안된부분과그원인을분석했는가        ?
5. 반박가능한질문필수    (, 개1 이상)근거개념
    : Ch__ 절__ 개념(: _______)질문
   : _________ 답이( 나쁘면결과가흔들려야한다    )
```

빈칸 미채우면 3점 미만

자주 하는 실수: 리뷰가 감상평에 머무는 것

- **구체적인 주차·개념을 근거로 든 질문**만이 “반박 가능”하다 — 발표팀이 답하려면 실제로 자신의 결과를 다시 들여다봐야 하기 때문.

채점의 축

peer-review 점수가 체크리스트를 “채웠는가”가 아니라 **“그 안의 질문이 얼마나 구체적인가”**로 매겨지는 이유가 여기에 있다.

확인 문제 (1)

- **1.** “5%만 양성인 데이터에 신경망을 써서 정확도 95%를 냈다”는 발표. 가장 약한 부분은? Week 2.3 개념으로 반박 가능한 질문 하나를 쓰시오.

  답: 정확도의 함정(Ch02.3) — **모두 음성**으로만 찍어도 95%. 질문: “Precision과 Recall(또는 PR-AUC)이 각각 얼마인가요? 무조건 음성 모델과 같은 수인데, 실제로 양성을 얼마나 더 잡는지 보여주세요.”

- **2.** “**테스트셋**으로 여러 λ 중 가장 좋은 것을 골랐다”고 인정한 팀. Week 6.3의 어떤 원칙이 깨졌고, 왜 그 숫자가 낙관적인가?

  답: “test를 하이퍼파라미터 선택에 쓰지 말고 딱 한 번만” 원칙 위반. 후보 중 **가장 잘 나온 것**을 고르면 잡음의 max를 고르는 것 — 후보가 많을수록 낙관적으로 읽힘(선택 편향). 올바르게: val로 λ 선택 후 test **한 번**.

확인 문제 (2)

- **3.** “왜 반박 가능한(falsifiable) 질문이 좋은 리뷰의 기준인가?” 한 단락으로.

  답: Popper의 반증주의처럼, 과학적 주장은 “틀렸음을 보이는 관측이 상상이 가능한가”로 판별된다. 좋은 리뷰 질문도 발표팀이 **제대로 답하지 못하면 결과가 무너지는** 질문이어야 한다. 감상평은 답이 아무리 나빠도 결과를 흔들지 못함. peer-review는 Amgen처럼 “내 결과도 남이 재현·반박할 수 있는가”를 **미리 방어**하는 과학적 행위.

- **4.** “모델 선정이 적절해 보이지 않습니다”는 3단 채점 중 어디인가? 3점으로 **어떻게** 바꿀 수 있는가?

  답: 근거(개념, 데이터 특성)가 없으므로 **2점**. 3점이려면 **관찰+개념+왜**를 채운다: “99:1 불균형에서 정확도로 비교했는데(관찰), Ch02.3 함정으로 ’둘 다 항상 다수 클래스’ 모델일 수 있어(개념) Precision·Recall 또는 PR-AUC로 다시 비교해야 합니다(왜).”

확인 문제 (3) — 어떤 숫자를 신뢰하는가

- **5.** 95% 불균형 데이터에서 “test 정확도 93%”를 헤드라인으로, 그 뒤에 “PR-AUC 0.55”도 함께 보고한 팀. “모델이 쓸모있는가”를 판단할 때 **어떤** 숫자를 신뢰해야 하는가?

  답: **PR-AUC 0.55** 쪽. 95% 불균형에서는 정확도 93%가 **무조건 다수 클래스** 모델(95%)보다도 **낮다** — 정확도는 이 모델이 “무조건 다수”보다 못하다는 뜻일 뿐, 유용성의 **크기**를 말해주지 않는다. PR-AUC 0.55는 베이스레이트(0.05)보다 훨씬 높아 “우연보다 더 잘 잡고 있다”는 신호. **유용성**을 논할 때는 PR-AUC/재현율 기준.

판정 기준

정확도는 **순위를 정하는 데는**, PR-AUC/재현율은 **유용성을 논하는 데는** 사용할 수 있다 — 두 숫자를 **둘 다** 보고, 불균형이 심할수록 후자에 무게를 둔다.

자주 묻는 질문

- **Q. 우리 팀 발표에 대한 리뷰가 너무 비판적이면?** 비판적인 리뷰일수록 체크리스트의 목적에 가깝다 — 발표팀이 못 보고 지나친 문제를 찾아주는 것이지 인신공격 이 아니다. 다만 리뷰어도 "왜 그 지적이 타당한지"를 **이 학기 개념으로 뒷받침**해야 한다.
- **Q. 시간이 부족하면 무엇을 우선? "방법론 적절성"**을 가장 먼저 — 문제 정의가 아무리 명확해도 데이터 특성에 안 맞는 모델(예: 불균형에 정확도)을 골랐다면 뒤의 **결과 해석 전체**가 흔들리기 때문.
- **Q. 발표팀이 "좋은 지적입니다"만 하면?** 그건 발표팀이 **아직 답하지 못했다는** 증거. 좋은 리뷰는 "좋은 지적"으로 넘길 수 **없는** 질문 — 답하려면 **새로운 계산·실험·그래프**를 꺼내야 하는 질문. "Precision·Recall을 보여주세요"는 그 자리에서 혼동행렬을 다시 써야 답 $\rightarrow$ **반박 가능**. "모델을 더 생각해보세요"는 어떤 답도 가능 $\rightarrow$ 반박 불가능. "좋은 지적"으로 끝나면 그 질문은 2점에 머문 것 — **구체적 산출물(어떤 그래프/계산)을 요구**하는 쪽으로 재작성.

8.3 중간고사 대비 총정리

새 개념이 없다 — “재현 가능한가”를 점검한다

- **Block A 마지막: 재현 가능성 점검**

이 절의 구조

시험에서 가장 자주 나오는 질문 유형 **4개**를 뽑고, 그중 **“손으로 써야 하는” 3가지(유도 템플릿 ①②③)**를 실제로 종이에 풀고, 나머지는 자가진단 플로우와 확인 문제 9개로 채운다. 실습 노트북은 세 템플릿의 숫자를 코드로 검증.

장별 핵심 질문 — 자가진단 도구

장	핵심 질문	다시 봐야 할 개념
Ch02	같은 선형모델로 회귀와 분류를 어떻게 모두 푸는가	경사하강법, 정규방정식, 교차 엔트로피
Ch03	생성적 접근과 판별적 접근의 차이는 무엇인가	베이즈 정리, GDA/로지스틱회귀의 관계
Ch04	“가깝다”만으로 예측하는 것의 한계는 무엇인가	편향-분산, 차원의 저주
Ch05	확률이 아니라 마진으로 경계를 정하면 무엇이 달라지는가	서포트 벡터, 커널 트릭
Ch06	과적합을 손실함수로 어떻게 통제하는가	L1/L2 정규화, 교차검증
Ch07	트리를 어떻게 앙상블하고 예측을 어떻게 설명하는가	정보이득, RF vs GBDT, SHAP

- **목록으로 읽지 말고** “핵심 질문”에 한 문장으로 답할 수 있는가의 **자가진단 도구**로.

시험에서 반복되는 질문 유형 4가지

유형	예
① **유도(빈칸 완성)**	“경사하강 1스텝 빈칸 채우시오”, “KKT에서 해를 구하시오”
② **“X를 키우면?” 정성 추론**	“C를 크게 하면?”, “λ를 0으로 하면?”, “트리 깊이를 늘리면?”
③ **모델 비교(장 넘나들기)**	“kNN과 SVM은 왜 둘 다 스케일링이 필요한가?”, “RF와 GBDT의 차이는?”
④ **실전 코드·절차 판정**	“이 파이프라인의 누수 지점은?”, “이 발표의 약점과 질문 하나”

시험 준비가 끝나는 구조

①②를 실제로 종이에 써보고, ③④는 기존 섹션(확인 문제, “자주 하는 실수”)을 훑으면 된다.

유도 템플릿 ①: 로지스틱회귀 경사하강 1스텝 I

문제

1차원 입력, $n = 3$ 샘플, $x = (1, 2, 3)$, $y = (0, 1, 1)$, 현재 $w = 0.1$, $b = 0$, 학습률 $\eta = 0.5$. 교차엔트로피 손실

$$\ell = -\frac{1}{n}\sum_{i}\left[y_i \log \hat{p}_i + (1 - y_i)\log(1 - \hat{p}_i)\right] \qquad (\hat{p}_i = \sigma(wx_i + b))$$

에서 **경사하강 1스텝**을 손으로 수행하라. 4단계가 **예측 대입** → **손실 계산** → **경사** → **업데이트** — 손실이 무엇이든 이 순서만 지키면 같은 모양.

1단계 — 예측 대입. $z_i = wx_i + b = (0.1, 0.2, 0.3)$:

샘플	x_i, y_i	z_i	$\hat{p}_i = \sigma(z_i)$	$\hat{p}_i - y_i$
1	(1, 0)	0.1	0.524979	$+0.524979$
2	(2, 1)	0.2	0.549834	-0.450166
3	(3, 1)	0.3	0.574443	-0.425557

유도 템플릿 ①: 로지스틱회귀 경사하강 1스텝 II

$$\ell = -\frac{1}{3}\big[\log(0.475021)+\log(0.549834)+\log(0.574443)\big] = \frac{0.744436+0.597797+0.554336}{3} \approx 0.6322$$

3단계 — 경사. $\frac{\partial \ell}{\partial w} = \frac{1}{n}\sum_i(\hat{p}_i - y_i)x_i$ 에 대입:

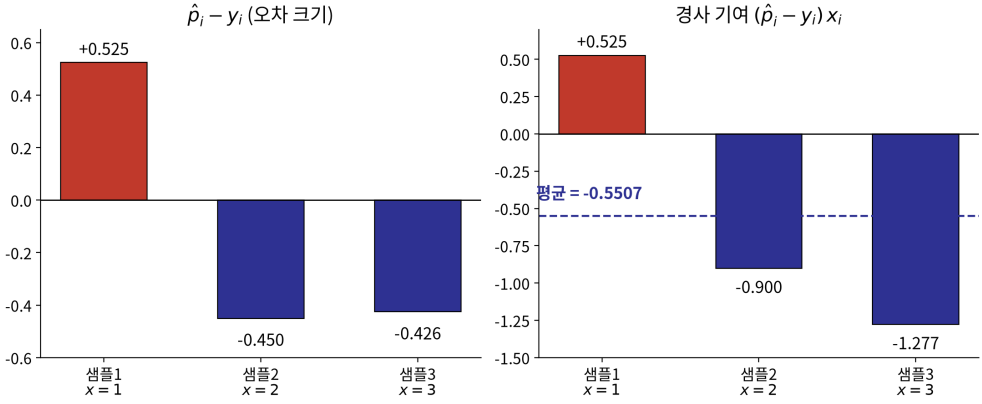
$$\frac{1}{3}\big[(+0.524979)(1)+(-0.450166)(2)+(-0.425557)(3)\big] = \frac{0.524979-0.900332-1.276671}{3} = -0.550675$$

$\frac{\partial \ell}{\partial b} = \frac{1}{3}\sum_i(\hat{p}_i - y_i) = -0.116915$ 도 함께. **4단계 — 업데이트.**

$$w \leftarrow 0.1 - 0.5 \times (-0.550675) = 0.375338, \qquad b \leftarrow 0 - 0.5 \times (-0.116915) = +0.058457$$

템플릿 ① “왜?”: 부호 읽기와 $(\hat{p} - y)x$

샘플 3($x = 3$)의 기여가 샘플 1($x = 1$)보다 2.4배 큰 이유



부호가 실제-예측 오차의 **방향**을, x_i가 그 오차의 **가중치**를 정한다 — 샘플 3의 기여가 샘플 1의 2.4배인 것은 “더 틀려서”가 아니라 “큰 x로 틀려서”다.

유도 템플릿 ②: SVM KKT — "C가 실제로 바꾸는 것" I

문제 — 1차원 4개 점:

점	x	y	역할
A	-1	$+1$	
B	-1	$+1$	A와 같은 위치(다중점)
C	$+2$	-1	
E	-0.2	-1	**이상치** — -1인데 $+1$ 쪽에 붙어 있음

목적함수

$$\min_{w,b} \ \tfrac{1}{2}w^2 + C\sum_i \xi_i \qquad (\text{약분 } y_i(wx_i+b) \geq 1-\xi_i,\ \xi_i \geq 0)$$

KKT 세 조건 + 정합성:

1. $0 \leq \alpha_i \leq C$ — α는 "점 i에게 쓰인 위반 예산". C가 전체 예산이면 α는 각 점에 배정된 몫.
2. $\alpha_i \xi_i = 0$ — 마진 위반($\xi_i > 0$)을 하는 점은 α가 상한 C에 **꽉 차 있다**.
3. $\alpha_i(y_i f(x_i) - 1 + \xi_i) = 0$
   - $\alpha_i = 0$: 마진 바깥($y_i f(x_i) \geq 1$), 해에 영향 없음.

유도 템플릿 ②: SVM KKT — “C가 실제로 바꾸는 것” II

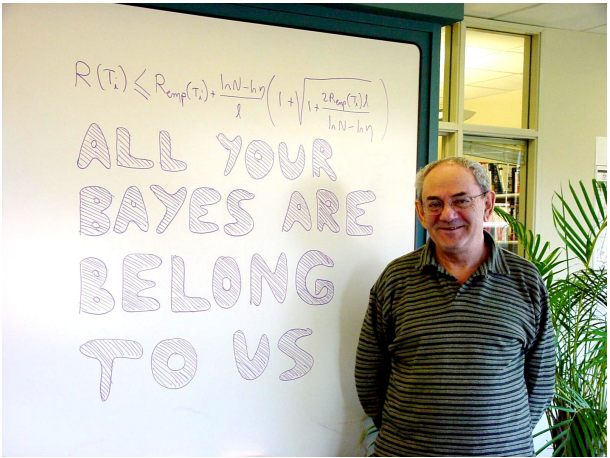
- $0 < \alpha_i < C$: **마진 위에 정확히** ($y_i f(x_i) = 1$).
- $\alpha_i = C$: 마진 안 또는 오분류 ($y_i f(x_i) \le 1$).

정합성 (stationarity)

$$w = \sum_i \alpha_i y_i x_i, \qquad \sum_i \alpha_i y_i = 0$$

이 문제에선 클래스 2:2라 $\alpha_A + \alpha_B = \alpha_C + \alpha_E$. 이제 C를 0에서부터 올리며 각 구간의 해를 구한다. **이 4구간 풀이(구간 경계 = “어떤 α가 상한/0에 닿는가”)가 템플릿**.

구간	C 범위	α	w, b	$\|w\|^2$, 마진 $2/\|w\|$
I	$C \le \frac{10}{57} \approx 0.175$	전부 $= C$	$(-3.8C,\ 1.9C)$	$14.44\,C^2$; 마진 $\frac{2}{3.8C}$ (52.6→3.0)
II	$\frac{10}{57} < C < \frac{5}{6}$	$\alpha_E = C, a = \frac{1}{9} + \frac{11}{30}C, \alpha_C = \frac{2}{9} - \frac{4}{15}C$	$(-\frac{2}{3},\ \frac{1}{3})$ **고정**	**4/9 고정**; 마진 **3.0 고정**
III	$\frac{5}{6} < C < \frac{25}{8}$	$\alpha_E = C, a = C/2, \alpha_C = 0$	$(-0.8C,\ 1 - 0.8C)$	$0.64\,C^2$; 마진 $\frac{2.5}{C}$ (3.0→0.8)
IV	$C \ge \frac{25}{8} = 3.125$	$a = \frac{25}{16}, \alpha_E = \frac{25}{8}, \alpha_C = 0$	$(-\frac{5}{2},\ -\frac{3}{2})$ **고정**	**6.25 고정**; 마진 **0.8 고정**



Vladimir Vapnik — 통계적 학습 이론의 일반화 오차 상한 공식 앞에서 (2001년 워크숍)

4구간 읽는 법 (1): I·II — 직감이 유일한 맞는 구간

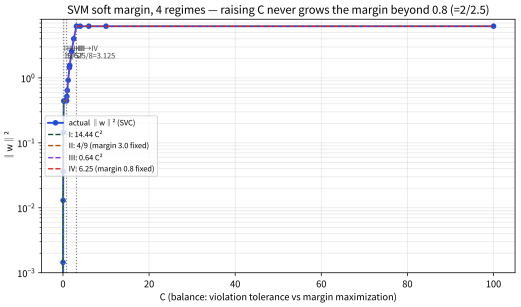
- **구간 I:** C **증가 시 마진 비례 팽창**

핵심

C가 바꾸는 것은 마진의 **크기**가 아니라 **"이상치 E의 위반을 얼마까지 사들이는가"**.

4구간 읽는 법 (2): III·IV + 실측

- **III**: E의 위반 비용이 커지자 ($C \geq 5/6$) C($+2$)가 마진에서 빠짐($\alpha_C = 0$), 경계가 **왼쪽으로 미끄러지며** E를 감싸기 시작 ($w = -0.8C$). 마진은 $\frac{2.5}{C}$로 **줄어든다** (C를 올리면 마진이 줄어드는 구간!). $C = 25/16$에서 E가 올바르게 분류.
- **IV** ($C \geq 3.125$): E도 마진 위에 닿으면 해는 $w = -\frac{5}{2},\ b = -\frac{3}{2}$ 로 **다시 정지** — 경계는 A($-1, +1$)과 **이상치 E**($-0.2, -1$)가 정한다(중점 -0.6, 반갭 0.4, 마진 0.8).



C를 0.0001~100으로 올리며 실제 $\|w\|^2$(파랑)을 그린 것. 실선이 **두 번 꺾여 수평** (I: $14.44C^2 \to$ II: 4/9 $\to$ III: $0.64C^2 \to$ IV: 6.25). 세 수직 점선($10/57,\ 5/6,\ 25/8$)이 구간 경계. C를 아무리 올려도 $\|w\|^2$는 6.25를 넘지 않음.

C를 100으로 올려도 $\|w\|^2 = 6.25$, 마진 0.8, 경계 $x = -0.6$은 변하지 않는다.

템플릿 ②의 답안 뼈대

- $C \geq C^*$ **이후 해는** C**에 무관**

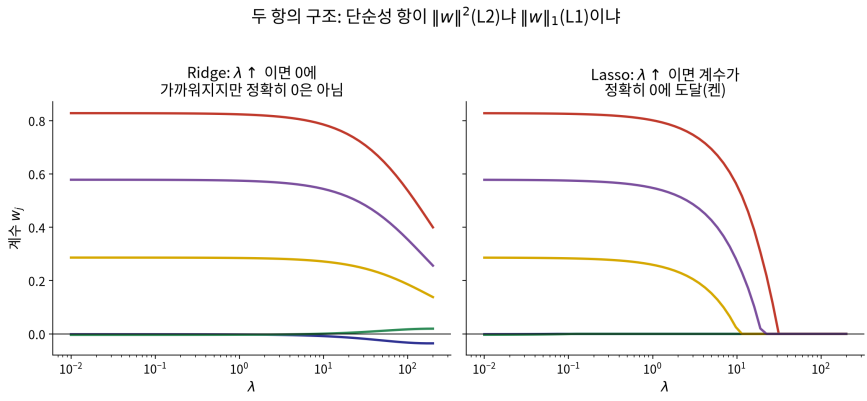
유도 템플릿 ③: “두 항의 구조” (적합도 + 단순성)

모델	목적함수	적합도 / 단순성 항	노브(트리
Ridge (Ch06)	$\ell_{\text{MSE}} + \frac{\lambda}{2}\|w\|^2$	ℓ_{MSE}: 데이터에 맞추기 / $\|w\|^2$: 가중치 축소(분산↓)	λ (0→무
Lasso (Ch06)	$\ell_{\text{MSE}} + \lambda\|w\|_1$	위와 같음 / $\|w\|_1$: **정확히 0** 만드는 켄(kink)	λ
소프트 마진 SVM (Ch05.2)	$\frac{1}{2}\|w\|^2 + C\sum_i \xi_i$	$C\sum \xi_i$: 위반 사들이기 / $\frac{1}{2}\|w\|^2$: 마진 최대화	C (0→
GBDT (Ch07.3)	(반복) 잔차에 트리 적합 + η로 축소	트리: 잔차 설명 / η(학습률), n(트리 수)	η, n
kNN (Ch04)	(파라미터 없음 — 전량 memorize)	“적합” = 전량 암기 / k: 이웃 평균으로 매끄럽게	k (1→임

패턴 한 줄

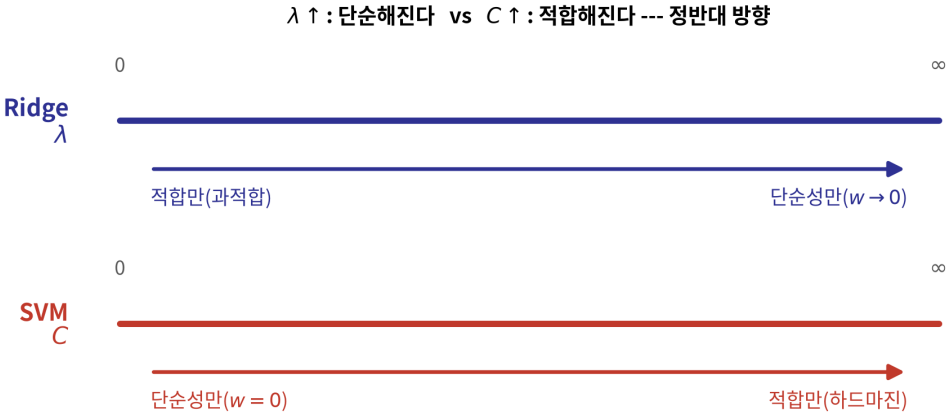
적합도 항은 “데이터에 잘 맞추는 것”, 단순성 항은 “모델을 단순하게 유지하는 것”을 재고, 노브 하나가 둘의 비중을 조절한다.

그림으로: Ridge vs Lasso — 계수가 0에 도달하는가



합성 데이터(5특징) 실제 적합 경로 — L2는 $\lambda\uparrow$에도 0에 **가까워질 뿐**, L1은 일부 계수가 **정확히 0**에 도달.

템플릿 ③ 주의: 노브의 방향은 모델마다 반대



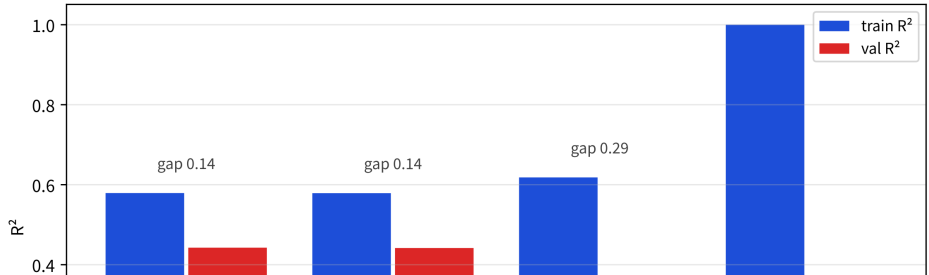
Ridge λ와 SVM C는 역방향 — “노브를 크게 하면?” 문항에서 가장 흔한 0점은 이 방향을 헷갈리는 것.

편향-분산 스펙트럼: 같은 데이터, 네 모델

diabetes 데이터로 4개 모델 실측

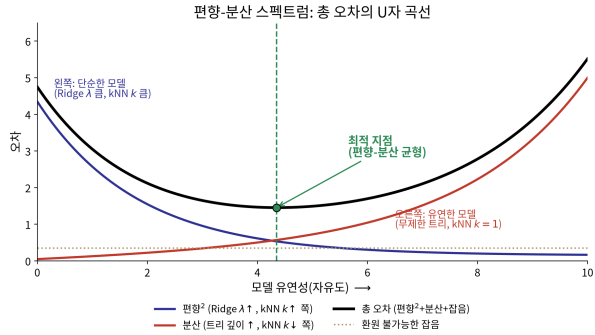
모델	train R^2	val R^2	격차 (train − val)
Ridge(λ=10^{-4}) [Ch02,06]	0.579	0.443	0.137
Ridge(λ=1) [Ch06]	0.579	0.442	0.137
kNN(k=5) [Ch04]	0.618	0.329	0.290
Tree(무제한 깊이) [Ch07.1]	1.000	-0.014	**1.014**

Flexibility spectrum: Ridge → kNN → Tree. Moving right, train keeps rising while val falls behind



스펙트럼 읽는 법 — 시험 답안 구조

- **모델 유연성 스펙트럼**
- 격차가 큰 모델(오른쪽)은 **분산**이 크다 (Week 4.1: “모델 추정량이 train 데이터의 선택에 따라 크게 흔들린다”). 격차가 작은 모델(왼쪽)은 **편향** 이 크다 (Week 6: “평균적으로 진실을 향한 systematic한 오차”).

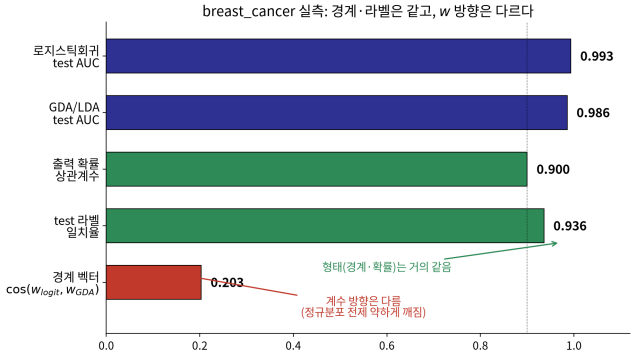


트리의 val R^2가 **0 아래**(음수)

train에서 1.000을 찍고도 검증 데이터에서는 **평균만 예측하는 모델보다 나쁘다**는 뜻 — Week 6.2 U자 곡선의 “$\lambda \to 0$ 쪽 끝”이 실제로 이렇게 처져 있음을 보여주는 숫자. **“train R^2=1.000이니까 좋은 모델”이라는 답안은 이 한 줄로 반박된다.**

장을 넘나드는 동치성: GDA vs 로지스틱회귀

측정	값
로지스틱 test AUC	0.9934
GDA/LDA test AUC	0.9855
출력 확률 상관계수	0.900
$\cos(w_{\text{logit}}, w_{\text{GDA}})$	0.203
test 라벨 일치율	93.6%



결정 경계는 같고, 경계 벡터 방향은 다르다 — 정규분포 전제에 따라 동치성 범위가 달라진다

누수 원칙, 숫자로: 스케일러 fit의 위치

스케일러 fit 범위	val R^2
전체(train+val+test) — **원칙 위반**	0.4417
train만 — 원칙 준수	0.4417

차이는 3×10^{-5} — "거의 없다"가 정답

diabetes는 "행 하나 = 독립 관측"이어서 train의 평균/표준편차와 전체의 것이 거의 같다. 누수가 **크게** 벌어지는 것은 Week 6.3의 환자 예처럼 **동일 실체 (환자, 계좌, 사용자)가 train과 val/test에 동시에 들어와 정보를 공유할 때**다 — 그때는 `fit`의 위치가 아니라 **분할 자체**가 문제를 만든다.

시험 판정 기준: "누수가 커지는 조건(공유된 실체, 시간 순서)을 설명할 수 있는가".

자가진단 5문항 + 40분 모의 문제

1. 장별 핵심 질문 6문항 중 **한 문장도 멈추지 않고** 답할 수 있는 것이 몇 개인가? (5개 이상이면 양호)
2. **템플릿 ① 4단계 빈칸 없이 쓰기**
3. 템플릿 ②에서 "$C \geq 25/8$ 이후 왜 $\|w\|^2 = 6.25$로 고정되는가"를 **KKT 세 조건**으로 쓸 수 있는가?
4. **편향-분산 언어로 2문장 진단**
5. 8.2절 가상 발표(99.8:0.2, 99.7% vs 99.8%)에 대해, **장·절을 명시한** 반박 가능한 질문 하나를 쓸 수 있는가?

자주 하는 실수 6가지

1. **경사 부호/계수 혼동**
2. **C를 키우면 마진이 무한히 커진다**
3. **"train R^2 = 1.000이면 좋은 모델"**(§ 스펙트럼): 무제한 트리는 train 1.000 / val -0.014 — **val(또는 gap)로만 판단**.
4. **Ridge λ와 SVM C를 같은 방향의 노브로 생각**

확인 문제 1∼4: 장 넘나들기 I

- **1.** 로지스틱회귀(Ch02)와 GDA(Ch03)는 둘 다 **어떤 공통된 최종 형태**에 도달하는가?

  답: 둘 다 $P(y{=}1|x) = \sigma(w^\top x + b)$ 라는 **같은 시그모이드-선형 형태**(Ch03.2). 다만 로지스틱회귀는 **판별적으로** 직접 학습하고, GDA는 정규분포를 가정한 **생성적 모델링**에서 베이즈 정리로 유도해내는 **경로**가 다르다.

- **2.** kNN(Ch04)에서 k를 1로 두는 것과 SVM(Ch05) 에서 C를 매우 크게 두는 것은 편향-분산 관점에서 어떤 **공통점**이 있는가?

  답: 둘 다 모델을 데이터에 최대한 정확히 맞추려는 **극단 — 분산이 커지고** (과적합 위험) 편향은 작아지는 쪽. $k = 1$은 노이즈 하나에도 민감하고, C가 매우 크면 이상치 하나까지 완벽히 분류하려 든다(Ch05.2).

- **3.** Ridge(Ch06)와 소프트 마진 SVM(Ch05.2) 목적함수는 둘 다 "두 항의 합". 각각 어떤 두 항인가?

  답: Ridge는 "적합도(원래 손실) + $\lambda\times$가중치 크기", SVM은 "$\frac{1}{2}\|w\|^2$(마진 최대화) + $C\times$위반 정도(힌지 손실)". 둘 다 "데이터에 잘 맞추기"와 "단순하게 유지하기" 사이 트레이드오프를 **하나의 하이퍼파라미터**(λ 또는 C)로 조절.

- **4.** 나이브베이즈(Ch03.3)와 결정 트리(Ch07.1)는 **왜 둘 다** 특징 스케일링이 필요 없는가?

  답: 나이브베이즈는 각 특징의 확률 $P(x_j|y)$를 **독립적으로** 추정한 뒤 값들 사이의 **거리를 재지** 않는다.

확인 문제 5∼7: 장 넘나들기 + 템플릿 ② I

- **5.** RF(Ch07.2)와 GBDT(Ch07.3)의 트리 학습 방식(**독립 병렬** vs **순차적 잔차 학습**) 차이가, **라벨링 오류에 대한 취약성**에 어떤 영향을 주는가?

  답: RF는 트리들이 서로 **독립** 적이라 한 트리가 라벨 오류를 과하게 학습해도 **다수결** 에서 다른 트리에 의해 희석. GBDT는 각 트리가 이전까지의 **잔차를 좇으므로**, 라벨 오류가 만드는 이상한 잔차를 후속 트리들이 계속 따라가며 **과적합할 위험**이 더 크다(Ch07.3 FAQ).

- **6.** Week 6.3의 데이터 누수(leakage) 원칙이 이번 프로젝트에서 **가장 흔히 깨지는 지점**은?

  답: 정규화·표준화 통계량(평균, 표준편차)이나 결측치 대체값을 train/val/test로 나누기 **전에 전체 데이터로** 미리 계산하는 경우(Ch06.3) — `fit`은 반드시 **train에만** 적용하고, val/test에는 `transform`만 적용.

- **7.** 템플릿 ②의 4점 문제에서, $C = 3.125$와 $C = 100$의 해($w^\star, b^\star$, SV 집합)는 **같다**. KKT 조건으로 **왜** 같은지, 그리고 C를 더 키워도 바뀌지 않는 마진의 **상한 값(0.8)**을 두 점의 지오메트리에서 직접 구해보자.

  답: $C \geq 25/8$에서는 A·B$(-1,+1)$ 과 이상치 E$(-0.2,-1)$가 **모두 마진 위에** 있고 $(0 < \alpha_i < C)$, C$(+2)$는 **마진 바깥** $(\alpha_C = 0)$ — 이 세 상태(마진 위/위/바깥)는 C의 **크기에 의존하지 않으므로** KKT의 해도 C에 무관. 마진의 상한은 **가장 가까운 다른 클래스 두 점**이 정한다: A$(-1,+1)$과 E$(-0.2,-1)$

확인 문제 8∼9: 템플릿 ①③ I

- **8.** 템플릿 ①에서 학습률을 $\eta = 0.5$ 대신 $\eta = 2$로 쓰면 1스텝 후의 w, b는? "학습률을 크게 하면 항상 빨리 수렴한다"가 왜 **성급한 결론**인지, 이 숫자만으로 말할 수 있는 한계는?

  답: $w = 0.1 - 2 \times (-0.550675) = 1.201350$, $b = 0 - 2 \times (-0.116915) = 0.233830$ — 스텝이 **정확히 4배**. 한계: 손실면이 볼록(교차 엔트로피는 볼록)이므로 이 방향의 큰 스텝은 손실을 **낮추기는** 한다, 그러나 스텝이 경사 변화율에 비해 너무 크면 다음 스텝에서 반대쪽으로 **오버슈팅**하며 손실이 튀어오를 수 있다 — 1스텝만으로는 "수렴"이 아니라 "더 큰 스텝"만을 볼 수 있다. (Ch09 Block B에서 학습률 스케줄링이 이 주제의 일반화.)

- **9.** Lasso(Ch06.1)의 목적함수 두 항을 쓰고, "왜 L1은 가중치를 **정확히 0**으로 만들지만 L2는 (유한한 λ에서는) 그렇지 않은가"를 한 문장으로 답하자.

  답: $\min_w \ell_{\mathsf{MSE}}(w) + \lambda\|w\|_1$. $\|w\|_1$은 $w_j = 0$에 **켄(kink)**을 만들어, 원래 손실 기울기의 절댓값이 λ 이하이면 정답이 그 켄 에 딱 붙어 $w_j = 0$이 된다(Ch06.1의 소스 스로싱 $\mathcal{T}_\lambda$). 반면 $\|w\|^2$은 0에서 **기울기 가 0인 매끄러운** 볼록함수라 w_j를 0으로 **가까이 당기지만** 유한한 λ로는 정확히 0까지 데려가지 못한다.

확인 문제 8∼9: 템플릿 ①③ II

이번 프로젝트가 남기는 교훈

지금까지 배운 어떤 모델도 “항상 최선”이지 않다 — 실전에서는 데이터의 특성을 보고 어떤 도구를 쓸지 스스로 판단해야 한다.

자주 묻는 질문 + 시험 전날 세 숫자

- **Q. 코딩 문제도?** Week 2, 6, 7에서 반복 연습한 **"핵심 줄이 빈칸으로 남겨진 함수를 완성하라"** 형식이 가장 가까운 연습.
- **Q. 여섯 장을 전부 같은 비중으로?** 아니다 — "핵심 질문"에 스스로 답할 수 있는지가 **가장 빠른 자가 진단**. **손유도 문제**(정규방정식, GDA↔로지스틱회귀 동치성, 마진 공식)는 그대로 다시 나올 가능성이 높아 우선순위 고.
- **Q. "장 넘나들기" 연습법?** 한 문항을 **두 장의 언어로 각 한 문장씩** — 예: 확인 문제 4는 "Ch03.3의 언어: $P(x_j \mid y)$를 독립 추정하므로 거리 계산이 없다" + "Ch07.1의 언어: 순서(>threshold)만 쓰므로 스케일에 불변".

시험 전날 **세 숫자**	의미(장)
-0.5507	템플릿 ①의 1스텝 경사 (Ch02)
$C^* = 3.125$ 이후 $\|w\|^2 = 6.25$ 고정	템플릿 ②의 마진 상한 0.8 (Ch05)
무제한 트리: train 1.000 / val -0.014, 격차 ≈ 1.0	§ 스펙트럼 (Ch04·06·07)

세 숫자를 "어떤 가정에서, 왜" 나오는 수로 설명할 수 있으면 유도 문제의 뼈대는 확보 — 숫자 자체는 실습 노트북에서 언제든 재현.

이번 주차 정리

1. **8.1 팀 프로젝트** — 4주 파이프라인 (문제 정의 $\rightarrow$ 3분할·train-fit·모델 비교 $\rightarrow$ test 한 번 $\rightarrow$ 보고·발표). 산출물은 **성능이 아니라 정직한 절차** — 베이스라인, 학습 곡선, 수식적 정당화(관찰 + 개념 + 왜).
2. **8.2 Peer-Review** — Popper의 반증주의 + Amgen 재현 실험. 좋은 리뷰 = **구체적 관찰 + 장·절 개념 + "왜 문제인지"**. 정확도의 함정(99.8:0.2)은 PR-AUC/재현율로만 판별.
3. **8.3 총정리** — 세 숫자: -0.5507(경사 1스텝), $C \geq 3.125$ 이후 $\|w\|^2 = 6.25$(마진 상한 0.8), 무제한 트리 train 1.000/val -0.014.

다음 주 — Week 9. 신경망 기초

직선 하나로 경계를 그을 수 없는 문제(XOR)를 **은닉층 과 역전파**로 풀기. 이번 장에서 몸에 밴 "성능을 정직하게 재는 절차"와 "결과를 개념으로 설명하는 습관"은 층이 깊어질수록 오히려 더 절실해진다.

이미지 출처

- Karl Popper 사진 (1980년경) — Franz Barta, LSE Library