# 잠재변수 생성모델: VAE에서 GAN, Diffusion까지

## VAE: ELBO와 실습 · GAN, Diffusion, 그리고 세 원리 비교

Machine Learning 1 · 15주차

한국과학영재학교 (KSA)

Week 15

# 이번 주차 개요

- **15.1 VAE** — ELBO 유도, 복원 vs KL 줄다리기, 생성 모드
- **15.2 GAN · Diffusion** — min-max 게임, 노이즈 단계별 제거, 세 원리 비교

**이 주차를 마치면**

**ELBO**를 **복원 항 + KL 정규화 항**으로 분해하고 학습 곡선에서 두 항의 **균형점**을 읽을 수 있고, GAN의 **내쉬 균형** (판별자 정확도 50%가 목표)과 **모드 붕괴**의 원인(다양성 항의 부재)을 설명할 수 있고, 세 원리를 **잠재변수 · 학습 방법 · 안정성 · 생성 속도**로 비교할 수 있다.

# 15.1 VAE: ELBO와 실습

# EM에서 VAE로: 연속적으로, 신경망으로

- **VAE**(Variational Autoencoder, Kingma & Welling, 2013): **정확히 같은 질문** — "관측되지 않은 잠재변수가 데이터를 어떻게 만들어내는가"
- 차이: $z$를 유한한 클러스터 번호가 아니라 **연속적인 벡터**로
- E-step/M-step의 명시적 반복 계산을 **신경망**으로 근사

**한 문장 요약**

**"EM의 E-step을 신경망이 맡는다"** — EM/GMM에서 VAE로의 전환을 가장 짧게 요약하는 문장.

# “variational”이라는 이름의 기원

- 정확한 사후 $p(z|x)$를 계산하는 대신 **함수족 안에서 최적의 근사 $q(z|x)$를 “변분(변화시켜 보며)” 구하는** 것
- “생성형 신경망”은 2013∼14년 한 번에 나온 것이 아니라 **변분 베이즈(오래된 통계 기법) × 심층학습**의 교차 지점에서 태동

**방향적 그래프 모델 (원 논문 Fig. 1)**

데이터 $\boldsymbol{x}$, 잠재 $\boldsymbol{z}$, 파라미터 $\theta$. 생성 모델 $p_\theta(z)$, $p_\theta(x|z)$와 인식 모델 $q_\phi(z|x)$의 구조.

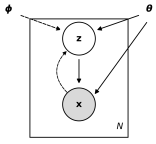



Fig. 1 재구성: 실선=생성 $p_\theta$, 점선=근사 $q_\phi$

# 두 전통의 합류: 오토인코더 × 베이지안

### 오토인코더

- 1980년대, Geoffrey Hinton 그룹의 문자·음성 복원 연구에서 발전
- 입력을 낮은 차원의 "코드"로 **압축**하고 다시 **복원**하는 순환 구조

### 베이지안(잠재변수) 모델

- $x$는 보이지 않는 원인 $z$가 만들어낸 관측값이라는 **생성과정**의 관점
- 15.1절 GMM이 따랐던 전통

**VAE = ?**

"오토인코더의 **압축·복원 구조**"에 "잠재변수 모델의 **확률적 의미**"를 입힌 것.

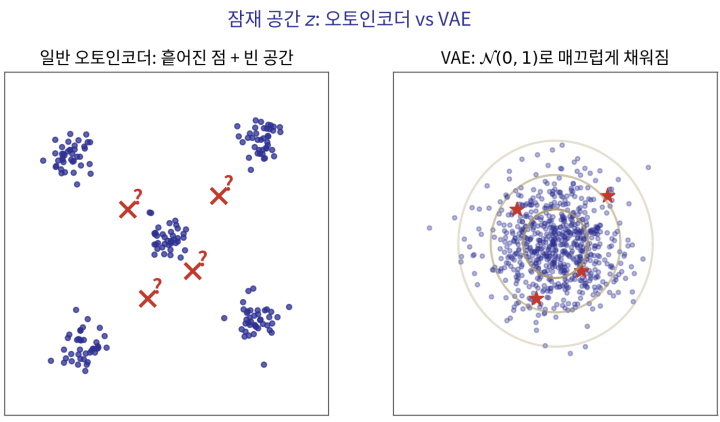
# 왜 분포를 내놓는가: 빈 공간 문제

- **VAE의 해법**: 인코더가 점 $z$ 대신 **확률분포** (보통 정규분포의 평균·분산)를 내놓도록 강제
- 그 분포가 **표준정규분포**(평균 0, 분산 1)에 가깝도록 추가 제약
- **잠재 공간이 매끄럽게 채워진다**

**구조**

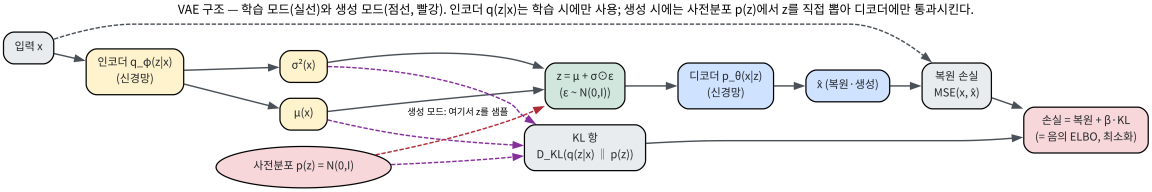
인코더 $q_\phi(z|x)$가 $x$로부터 $z$의 분포(평균·분산)를 내놓고, 그 분포에서 $z$를 샘플링한 뒤 디코더 $p_\theta(x|z)$가 $x$를 복원(생성).

# 그림으로: 오토인코더 vs VAE의 잠재 공간




일반 오토인코더(왼쪽)는 학습점이 여기저기 뭉쳐 있고 그 사이 **빈 공간**(빨간 $\times$)에서 뭐가 나올지 보장이 없다. VAE(오른쪽)는 모든 분포를 $\mathcal{N}(0, 1)$ 쪽으로 당겨 공간이 **매끄럽고 빈틈없이** 채워진다 — 같은 위치(빨간 별)에서도 VAE 쪽만 항상 데이터 근처.

# 구조도: 학습 모드 vs 생성 모드




점선 = 생성 시 흐름(인코더 미사용), 실선 = 학습 시 흐름.

## **학습 모드** (실선)

- $x$가 주어지면 인코더가 $(\mu, \sigma^2)$를 내놓고, 샘플링한 $z$로 디코더가 $x$를 복원
- 인코더 분포는 사전분포 $p(z)$에 가깝도록 KL 항이 “끌어당김”

## **생성 모드** (점선)

- 학습 후 **인코더는 완전히 버려짐**
- 사전분포 $p(z)$에서 $z$를 무작위 추출 $\rightarrow$ 디코더에만 통과시켜 새 샘플

# 우도 기반 접근과 "적분" 문제

- **VAE는 우도 기반:** $P(x)$ **최대화**
- **적분 계산 불가능(intractable)**

**GMM과의 대조 (1)**

- GMM: $p(x) = \sum_k \pi_k \mathcal{N}(x; \mu_k, \sigma_k^2)$
- $z$가 **유한** → 유한 합, 각 항이 정규 밀도로 **닫힘** → 우도 정확히 계산 가능
- VAE: $z$가 **연속** → 적분으로 바뀜, 디코더가 신경망 이라 닫힌 형태 없음

**GMM과의 대조 (2)**

- GMM: 이산이라 사후확률(책임값) 계산 가능 → **EM** 성립
- VAE: 이 적분의 "역방향" $p(z|x)$도 계산 불가능 → **E-step 수행 불가**
- 그래서 E-step을 신경망 $q_\phi(z|x)$로 **대체**(근사)

# ELBO: 계산 가능한 하한으로 우회

$$\log p_\theta(x) \geq \mathbb{E}_{z\sim q_\phi(z|x)}[\log p_\theta(x|z)] - D_{KL}\big(q_\phi(z|x)\,\|\,p(z)\big)$$

우변을 **ELBO**(Evidence Lower BOund)라 부른다. 두 항의 의미:

**첫 항: 복원 항**

$\mathbb{E}[\log p_\theta(x|z)]$ — 인코더가 만든 $z$로 디코더가 원본 $x$를 얼마나 잘 복원하는가 (일반 오토인코더의 복원 오차와 본질적으로 같음).

**둘째 항: 정규화 항**

$D_{KL}(q_\phi(z|x)\|p(z))$ — 인코더 분포가 목표 사전분포 $p(z)$ (보통 표준정규)에서 얼마나 벗어났는가 (KL divergence, Week 2.3 섀넌의 정보이론에서 소개). 이 항이 바로 잠재 공간을 매끄럽게 만드는 힘.

# ELBO 유도: 엔센 부등식 한 번

$$\log p(x) = \log \int q(z)\, \frac{p(x,z)}{q(z)}\, dz = \log \mathbb{E}_{z\sim q}\left[\frac{p(x,z)}{q(z)}\right]$$

log **오목함수 엔센 부등식 적용**

$$\log p(x) \geq \mathbb{E}_q\left[\log \frac{p(x,z)}{q(z)}\right] = \underbrace{\mathbb{E}_q[\log p(x|z)]}_{\text{복원 항}} - \underbrace{D_{KL}(q\|p)}_{\text{정규화 항}}$$

마지막 등호에서 $\mathbb{E}_q[\log p(z)] - \mathbb{E}_q[\log q(z)] = -D_{KL}(q\|p)$를 썼다. **엔센 부등식 한 번이 전부**다.

# 갭의 정체: ELBO 최대화 = 변분 베이즈

- **ELBO 갭은 KL 발산**
- $\Rightarrow$ ELBO를 최대화하는 것은 **사후분포 근사 $q$를 정확히 만드는 것**과 동치

**학습에서의 의미**

$\log p_\theta(x) \geq$ ELBO이므로, **ELBO를 최대화하면 실제 우도의 하한도 함께 올라감** — 직접 계산 못 하는 목표를 계산 가능한 **대리(surrogate)** 목표로 바꿔치기한 것.

# 손으로 한 번: 1차원 장난감에서 ELBO

- **복원 항**: $\mathbb{E}_{z\sim\mathcal{N}(1,1)}[\log \mathcal{N}(x; z, 1)]$
- $\Rightarrow -\frac{1}{2}[(x-1)^2 + 1 + \log 2\pi] \approx -\frac{1}{2}[0 + 1 + 1.838] = \mathbf{-1.419}$
- **정규화 항**: $D_{KL}(\mathcal{N}(1,1)\|\mathcal{N}(0,1))$ — 정규분포 사이 KL은 닫힌 형태: $\frac{1}{2}(\sigma_q^2 + \mu_q^2 - 1 - \log \sigma_q^2) = \frac{1}{2}(1 + 1 - 1 - 0) = \mathbf{0.5}$
- **ELBO** $= -1.419 - 0.5 = \mathbf{-1.919}$

# 진짜 $\log p(x)$와 비교: 부등식이 실제로 성립

- **정규분포 두개의 합(적분)은 정규분포**
- $\log p(1) = -\frac{1}{4} - \frac{1}{2}\log(4\pi) \approx -\mathbf{1.516}$
- **부등식이 실제로 성립:** $-1.516 \geq -1.919$

## $x = 9$로 다시 계산

복원 항 $\approx -33.419$, 정규화 항 0.5 → ELBO $\approx -33.92$. 진짜 $\log p(9) = \log \mathcal{N}(9; 0, 2) \approx -21.52$ — **갭이 12.40으로 벌어짐**. $q = \mathcal{N}(1, 1)$은 $x = 1$ 근처에선 "그럭저럭" 근사(갭 0.4)지만 $x = 9$엔 **완전히 부적합**(갭 12.4).

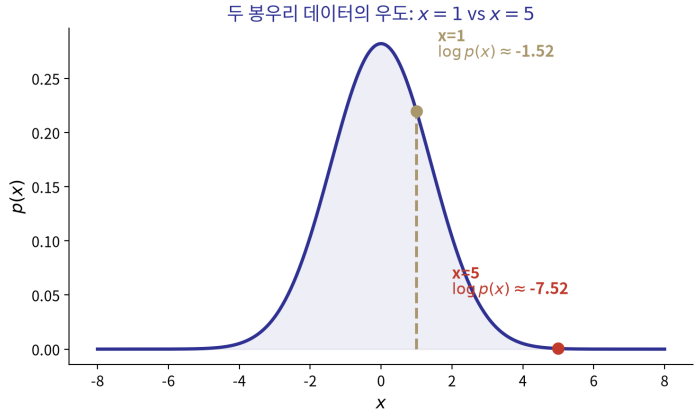
# 숫자가 말하는 것: 입력별 분포가 필요한 이유

- **x=5의 우도는 매우 낮음**
- $\Rightarrow$ 근사분포가 **데이터마다** 얼마나 잘 맞아야 하는지

**ELBO를 최대화하는 것은 “근사분포를 잘 고르는 것”**

실제 학습에서는 $q$를 $x$**마다 다른** (인코더가 만들어내는) $q_\phi(\cdot|x)$로 놓아, **복원 항이 좋아질수록 정규화 항이 나빠지는(또는 그 반대) 균형**이 학습이 끝난 지점에서 결정된다. 그 균형이 실제로 어디에 잡히는지 다음 실습에서 확인.

# 그림으로: $x = 1$과 $x = 5$의 우도 차이




진짜 $p(x) = \mathcal{N}(x; 0, 2)$ 위에서 $x = 1$(두 봉우리 중 하나에 가까움)과 $x = 5$(어느 봉우리에도 속하지 않음)의 높이를 직접 비교 — $x = 5$ 쪽이 **훨씬 낮다**. 근사분포 $q(z|x)$가 이만큼 다른 $x$들을 전부 감당하려면 $x$**마다 다른 분포**가 필요.

# VAE 손실함수: ELBO의 코드

```python
def vae_loss(x, x_reconstructed, mu, log_var):
    # 복원손실여기서는  ( 로MSE 근사)
    recon_loss = sum((x[i] - x_reconstructed[i]) ** 2 for i in range(len(x)))
    # KL divergence: 정규분포 q(mu, sigma^2)와 표준정규 N(0,1)의 닫힌형태
    kl_loss = -0.5 * sum(1 + log_var[i] - mu[i]**2 - math.exp(log_var[i])
                         for i in range(len(mu)))
    return recon_loss + kl_loss  # ELBO 최대화 = 음의 ELBO 최소화
```

정규분포 $\mathcal{N}(\mu, \sigma^2)$와 표준정규 $\mathcal{N}(0,1)$ 사이의 KL은 닫힌 형태:

$$D_{KL}\big(\mathcal{N}(\mu,\sigma^2)\,\|\,\mathcal{N}(0,1)\big) = \frac{1}{2}\left(\sigma^2 + \mu^2 - 1 - \log\sigma^2\right)$$

# Reparameterization Trick

- **Reparameterization Trick** (Rezende et al., 2014):

$$z = \mu + \sigma \odot \epsilon, \qquad \epsilon \sim \mathcal{N}(0, 1)$$

**왜 꼭 필요한가 (Week 9 연결)**

역전파는 연쇄법칙으로 미분 가능한 연산 사슬을 거슬러 올라가는 것 — "확률분포에서 무작위 추출" 연산은 미분이 정의되지 않는다. 이 트릭이 없으면 VAE의 인코더를 학습할 수 없다.

# 실습: 두 봉우리 데이터로 작은 VAE

15.1절 GMM 예제와 같은 모양(1 근처·9 근처 두 봉우리)의 1차원 데이터로 실제 VAE를 학습:

```
import torch, torch.nn as nn

class VAE(nn.Module):
    def __init__(self, latent_dim=2):
        super().__init__()
        self.enc = nn.Sequential(nn.Linear(1, 16), nn.ReLU())
        self.mu = nn.Linear(16, latent_dim)
        self.logvar = nn.Linear(16, latent_dim)
        self.dec = nn.Sequential(nn.Linear(latent_dim, 16), nn.ReLU(), nn.Linear(16, 1))
    def forward(self, x):
        h = self.enc(x)
        mu, logvar = self.mu(h), self.logvar(h)
        z = mu + torch.exp(0.5*logvar) * torch.randn_like(mu)  # reparameterization trick
        return self.dec(z), mu, logvar
```

# 학습 곡선: 두 항의 줄다리기

| 에폭 | loss (복원 손실, KL) |
|---|---|
| 0 | 57.381 (54.392, 2.989) |
| 100 | 3.051 (0.852, 2.199) |
| 499 | 2.063 (0.482, 1.581) |

- **손실 57.4 → 2.06 감소**
- **복원 손실 소폭 상승 구간**

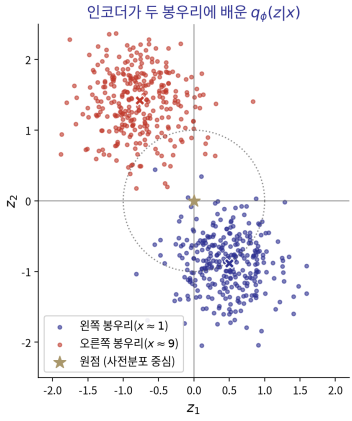
# 인코더가 두 봉우리에 배운 분포

- 왼쪽 봉우리($\approx 1$)의 점들: 평균 $(\mu_1, \mu_2) \approx (0.5, -0.88)$
- 오른쪽($\approx 9$): $(-0.77, 1.42)$ 근처로 **분리**
- 분산은 아주 작음 ($\log \sigma^2 \approx -1.7$ 이하)

**GMM과의 연결**

인코더가 "왼쪽 점"과 "오른쪽 점"을 잠재 공간에서 **다른 위치에, 좁은 분포로** 배치 — GMM의 이산적 클러스터 할당에 해당하는 **연속적(soft) 버전**.

# 그림으로: 인코더가 배운 두 개의 좁은 분포




왼쪽 봉우리($x \approx 1$)와 오른쪽 봉우리($x \approx 9$)가 잠재 공간 $(z_1, z_2)$에서 **서로 다른 위치에, 좁은 분산으로** 분리되고, 원점(사전분포 $\mathcal{N}(0,1)$의 중심)을 사이에 두고 대략 대칭 — GMM의 이산적 클러스터 할당에 해당하는 **연속적(soft) 버전**.

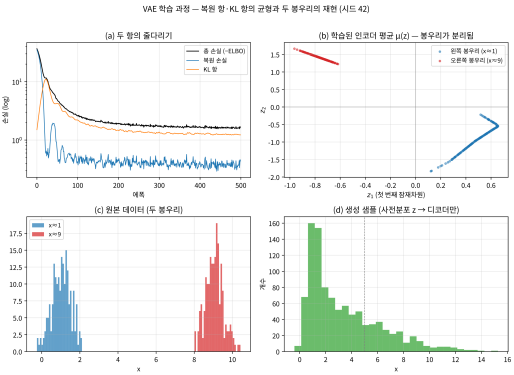
# 생성 모드: 원본을 전혀 보지 않고

**원본 데이터 없이 표준정규 $z$ 추출**

생성된 샘플: 평균 4.83, 표준편차 3.84
1(왼쪽 봉우리) 근처 비율: 59.1%,  9(오른쪽 봉우리) 근처 비율: 40.9%

- 원본이 두 봉우리에 대략 절반씩인데, 디코더가 잠재 공간의 표준정규 $z$만으로 그 두 봉우리를 **대략 6:4로 재현**

# 학습 과정 2×2 시각화




(a) 손실 곡선 (log) (b) 인코더가 매긴 $\mu(z)$ (c) 원본 (d) 생성 샘플

- **(a)**: KL 항이 2.2에서 1.2로 **큰 폭으로 떨어짐**, 복원 손실은 0.43 부근에서 **거의 제자리** — 두 항이 서로 "견제"하며 균형으로 수렴
- **(b)**: GMM의 이산적 클러스터 할당의 **연속적(soft) 버전** — 각 점에 매긴 평균이 "왼쪽 $\approx (0.5, -0.9)$", "오른쪽 $\approx (-0.8, 1.4)$" 근처의 **좁은 군집**으로 모임
- **(c)(d)**: 생성 샘플(1000개)이 두 봉우리를 히스토그램으로 대략 재현

# $\beta$-VAE: 두 항의 균형점을 "학습률처럼"

$\beta$-**VAE:** $\mathcal{L} = \mathbb{E}[\log p(x|z)] - \beta\, D_{KL}$

| $\beta$ | 복원 손실 | KL | 생성 샘플 표준편차 |
|---|---|---|---|
| 0 | 0.016 | 19.1 | 0.58 |
| 0.1 | 0.068 | 5.61 | 0.91 |
| 0.5 | 0.232 | 1.70 | 1.67 |
| 1.0 (기본) | 0.378 | 1.22 | 2.05 |
| 2.0 | 0.546 | 0.90 | 2.42 |

**$\beta$는 복원 품질 vs 잠재 공간 매끄러움의 균형**

# 자주 하는 실수 ①②: KL 항 계산

## ① 복원 항 기대값에 $\sigma^2$ 항을 빼먹는 것

$\mathbb{E}[\log p(x|z)]$를 계산할 때 $(x-\mu)^2$만 쓰고 분산 $\sigma_q^2$ 항을 빼먹으면 복원 항이 $-0.919$로 **과소평가**(정답 $-1.419$). $z = \mu + \sigma\epsilon$일 때 $\mathbb{E}[(x-z)^2] = (x-\mu)^2 + \sigma^2$ — "평균으로 대체"한 것만으로 오차가 사라지지 않음. $\sigma^2$가 큰(인코더가 불확실한) 입력에서 손실값이 실제보다 크게 나타나는(= ELBO 과소평가) 방향으로 오류를 만들어, "정규화 항을 줄이는데 왜 손실이 안 줄지"를 진단할 때 혼란의 원인.

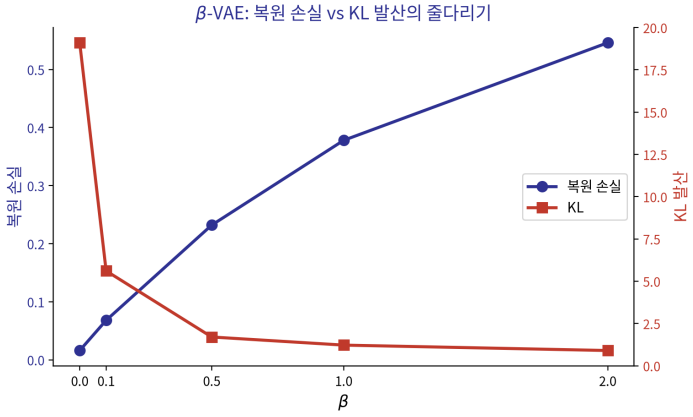
## ② KL 항을 "분산만" 계산하는 것

인코더가 $(\mu, \sigma^2)$를 함께 내놓는데, KL 항에 $\mu^2$(위치) 항을 빼먹고 $\sigma^2 - 1 - \log\sigma^2$만 쓰면, $\mu$**에 대한 그래디언트가 0** — 인코더의 평균 출력 위치에 대해 정규화 항이 아무 작용도 하지 않아 "분산만 조절된다"는, 학습이 이상하게 멈추는 원인. $\frac{1}{2}(\sigma^2 + \mu^2 - 1 - \log\sigma^2)$의 $\mu^2$ 항이 **인코더의 위치($\mu$)를 원점 방향으로 끌어당기는 힘**임을 꼭 기억.

# 자주 하는 실수 ③④⑤

- **③ $\beta$를 너무 크게 올려 "정규화만" 보는 학습** — $\beta$-VAE에서 $\beta$를 극단적으로 올리면 KL이 0에 가까워지고 복원 손실은 커짐 — "인코더가 데이터를 전혀 담지 않고 표준정규분포를 그대로 뱉는" 방향으로 **치팅**할 유인이 강해짐. $\beta = 2$ 이미 복원 손실 0.55(기본 1.0 대비 1.45배). "KL을 많이 줄이면 잠재 공간이 더 매끄러우니 좋다"는 생각은 $\beta$-VAE의 **균형을 무너뜨리는** 것.

# 그림으로: $\beta$가 키우는 트레이드오프




이전 슬라이드 표(0, 0.1, 0.5, 1.0, 2.0)를 그대로 그래프로 — $\beta$가 커질수록 **KL(파랑 → 빨강 곡선)은 떨어지고 복원 손실은 올라간다**. $\beta$를 극단적으로 키우면 KL이 0에 가까워지며 "치팅" 방향(정규화만 보는 학습)으로 무너지는 이유가 이 곡선에 그대로 보인다.

# 확인 문제 (15.1)

1. **ELBO 부등식의 갭.** $\log p(x) - \text{ELBO} = D_{KL}(q \| p(z|x))$임을 유도한 뒤, $q = p(z|x)$일 때만 갭이 0이 된다는 것을 한 문장으로 설명.
2. **정규분포 합 = 정규분포.** $\mathcal{N}(x; z, 1) \cdot \mathcal{N}(z; 0, 1)$에 대해 $z$로 적분 하면 $\mathcal{N}(x; 0, 2)$가 된다는 것을, "두 독립 정규분포의 합은 정규분포"라는 사실로부터 한 문장으로 설명.
3. **손계산 재현.** $x = 9$ 예제에서 복원 항이 $\approx -33.4$가 되는 것을 직접 계산 (힌트: $(x-\mu)^2 = 64$, $\sigma_q^2 = 1$, $\log 2\pi \approx 1.838$ 대입).

**핵심 요약**

ELBO = **복원 항** $-$ **KL 정규화 항**. **ELBO 최대화 = 사후분포 근사 $q$를 정확히 만드는 것 (변분 베이즈)**. $\mu^2$ 항은 **위치를 원점 쪽으로 끌어당기는 힘**, $\sigma^2$ 항은 **너비를 제어**.

# 자주 묻는 질문: 두 항 중 하나만 최적화하면?

- **복원 항만**(KL 없이): 일반 오토인코더와 같아져 잠재 공간이 매끄럽지 않아 샘플링 품질이 나빠짐 — 실습에서 KL 항이 없었다면 생성 샘플이 두 봉우리를 재현하지 못했을 가능성 큼
- **KL 항만**(복원 없이): 인코더가 아무 정보도 담지 않고 그냥 표준정규분포를 그대로 뱉는 방향으로 "치팅" — 복원이 전혀 안 되는 무의미한 모델
- ⇒ **두 항의 균형이 VAE의 핵심**

# 자주 묻는 질문: 리파라미터화 · 흐릿함

## Reparameterization trick이 왜 꼭 필요한가?

Week 9: 역전파는 연쇄법칙으로 미분 가능한 연산 사슬을 거슬러 올라가는 것. “확률분포에서 무작위 추출” 연산은 미분이 정의 안 됨. $z = \mu + \sigma \odot \epsilon$으로 다시 쓰면 무작위성은 $\epsilon$(입력과 무관한 상수)에만, $\mu, \sigma$로 가는 경로는 전부 미분 가능(곱셈·덧셈) → 역전파가 인코더 파라미터까지 정상적으로 흐름.

## KL 항이 “흐릿함”의 원인이라는 말은?

복원 항은 **기대값** $\mathbb{E}_{z\sim q}[\log p(x|z)]$를 최적화 — 인코더 분포의 **모든** $z$로 복원했을 때의 **평균**이 좋아야 함. 분포가 넓을수록($\sigma^2$ 클수록) 복원된 $x$ 후보가 넓게 퍼져 “모든 $z$의 평균”이 흐려짐 → VAE 생성 이미지의 **흐릿함(blurry)** 근원. $\beta$를 크게 하면 더 강해짐 (정보를 더 압축하니까). GAN이 “한 개 $z$ → 한 개 $x$”를 **결정적으로** 학습(흐릿하지 않은 선명함)하는 이유도 결국 “기대값 최적화 vs 결정적 복원”의 차이.

# 자주 묻는 질문: EM/GMM과의 관계 · 차원 선택

## VAE와 15.1절 EM/GMM의 관계?

GMM: $z$가 **이산**(클러스터 번호)이라 E-step(책임값)이 닫혀 계산 가능 → EM 성립. VAE: $z$가 **연속**이라 E-step 자체가 계산 불가능 → **E-step을 신경망 $q_\phi(z|x)$로 대체**(근사), M-step을 **역전파**로 수행. "EM의 E-step을 신경망이 대신한다". M-step도 "잠재변수별 파라미터 가중평균"이 아니라 "전체 파라미터를 ELBO의 그래디언트로 갱신"으로 바뀜.

## `latent_dim` $= 2$가 왜 2차원인가?

**학습 대상이 아니라 하이퍼파라미터**. 두 봉우리 데이터: "두 가지 원인"이 있어 1차원으로 충분, 2차원이면 두 봉우리가 원점 중심의 **대칭** 위치로 자연스럽게 배치. 이미지 데이터: 20∼200 차원이 흔함 — 너무 작으면 복원 품질 떨어짐, 너무 크면 "사용하지 않는 차원"으로 가득 차 KL이 커짐.

# 15.2 GAN, Diffusion, 그리고 세 원리 비교

# 15.1의 다음: 우도 기반과 확연히 다른 두 방식

- 이번 절: 우도 기반과 **확연히 다른** 두 방식
- **GAN**: 두 신경망의 **경쟁 게임**으로 학습
- **Diffusion**: 노이즈를 **한 단계씩 되돌리는 회귀 문제**로 학습

# GAN: 생성자와 판별자의 min-max 게임

- 2014년, **이언 굿펠로우(Ian Goodfellow)**: “진짜 같은 가짜를 만드는 모델 학습” 대신 **두 신경망이 서로 경쟁**하게 하면?
- **위조범**(생성자 $G$): 가짜를 만듦, **감정사**(판별자 $D$): 진짜/가짜를 구별
- VAE의 “우도 최대화”라는 **단일** 목표함수와 달리, GAN은 두 네트워크가 **서로 반대되는** 목표를 갖고 동시에 학습

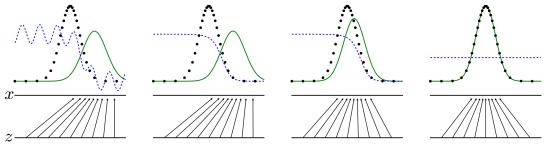



Fig. 1: 1차원 toy 예제 — 검은 점=실제 데이터 분포, 초록 선=생성자 분포, 파랑 점선=판별자 출력. (a)→(d)로 갈수록 생성자가 데이터 분포에 수렴, 판별자는 $D=1/2$로 구별 불가능해짐.

## 역사적 일화

2015년 GAN 논문이 ICLR 워크숍에서 거절, 심사평 “**average quality**”. 2016년 ACM 튜링상 수상 연설에서 굿펠로우가 직접 소개한 아이러니.



Ian Goodfellow — GAN 고안 (2014)



Yoshua Bengio — 지도교수, 2018 ACM 튜링상
(Bengio, Hinton, LeCun 공동 수상)

# 생성자·판별자와 목적함수

- **생성자**(Generator) $G$: 무작위 노이즈 $z \sim p(z)$를 입력받아 가짜 데이터 $G(z)$를 만듦
- **판별자**(Discriminator) $D$: 데이터를 입력받아, 그것이 **진짜일 확률** $D(x) \in [0,1]$을 출력 (Week 2 **로지스틱회귀**와 정확히 같은 형태)

**목적함수** (min-max game):

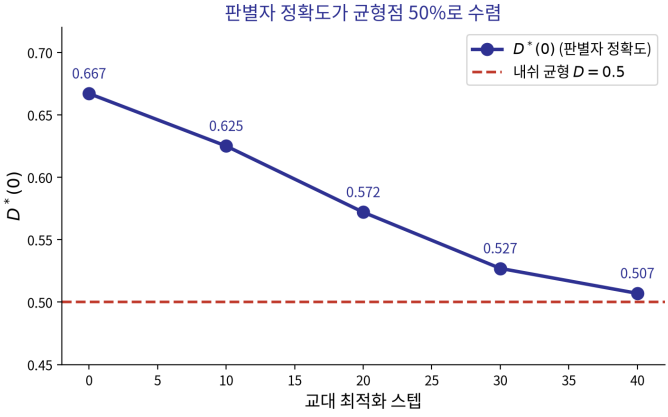
$$\min_G \max_D V(D,G) = \mathbb{E}_{x\sim p_{\text{data}}}[\log D(x)] + \mathbb{E}_{z\sim p(z)}[\log(1 - D(G(z)))]$$

| | |
|---|---|
| 판별자 손실 | $-\big(\mathbb{E}[\log D(x)] + \mathbb{E}[\log(1 - D(G(z)))]\big)$ |
| 생성자 손실 | $-\mathbb{E}[\log D(G(z))]$ (D_fake를 1에 가깝게) |

# 왜 “균형점”을 논해야 하는가

- 게임이론에서 이런 안정 상태 = **내쉬 균형**(Nash equilibrium) — **어느 쪽도 혼자서 전략을 바꿔서 더 나아질 수 없는 상태**
- **내쉬 균형: D(x)=0.5, $G$ 분포=실제 데이터**

# 그림으로: 판별자 정확도가 50%로 수렴




40스텝 교대 최적화 궤적(뒤 슬라이드 표 데이터) — $D^*(0)$이 0.667에서 **0.5(내쉬 균형)로 꾸준히 접근**.
실전 판독의 기준선: 판별자 정확도 50%는 실패가 아니라 **목표 운영점**.

# 1차원 장난감: 파라미터가 딱 1개인 GAN

- 데이터 $x \sim \mathcal{N}(0, 1)$, 생성자 분포 $p_G = \mathcal{N}(0, s^2)$
- **표준편차 $s$ 하나로** 가짜 분포의 "너비"만 바꿀 수 있는 생성자

## 판별자는 로지스틱회귀

$D$는 $x$ 위의 로지스틱회귀(Week 2.3). $G$를 고정하고 $D$를 **완전히** 최적화하면(미니배치가 아니라 전체 데이터에서 MLE로) 해는 **닫힌 형태**:

$$D^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_G(x)}$$

# 놀라운 닫힌 형태: JSD로 게임의 값

$$V(D^*, G) = 2\,\mathrm{JSD}(p_{\text{data}} \| p_G) - \log 4$$

**JSD (Jensen-Shannon Divergence)**

KL 발산의 "**양방향 평균**" 버전: $\mathrm{JSD}(p\|q) = \frac{1}{2}D_{KL}(p\|m) + \frac{1}{2}D_{KL}(q\|m), m = \frac{1}{2}(p+q)$. KL은 $p, q$ 순서가 바뀌면 값이 달라지는 **비대칭** 발산인데, JSD는 두 방향의 평균이라 **대칭**.

- JSD $\geq 0$이고 두 분포가 **정확히 같을 때만** 0 → $V$의 최솟값은 $p_G = p_{\text{data}}$에서의 $-\log 4$
- JSD $\leq \log 2$ → 게임의 값은 항상 $[-\log 4,\ 0)$ 안에

# “게임 값을 낮추라” = “JSD를 줄이라”

**생성자 관점의 명령**

“게임 값을 낮추라”는 것은 **“가짜와 데이터 분포의 JSD를 줄이라”**는 것과 **정확히 같은 명령** — 두 분포를 일치시키는 것, 즉 내쉬 균형 $s^* = 1$으로 수렴.

1. $G$를 고정하고 $D$를 최적화 (장난감에서는 닫힌 형태 $D^*$라 바로 점프)
2. $D^*$를 고정하고 $G$의 파라미터 $s$를 그라디언트 스텝으로 한 스텝 갱신

# EM과의 결정적 차이

**EM**

- E-step이 **정확한** 사후확률을 채워 넣음
- “우도가 매 반복 절대 줄지 않는다”는 보장이 **증명 가능**

**GAN 루프**

- (1)이 일반적으로 **완전 최적화가 아닌 근사**
- 매 $D$ 갱신마다 $G$가 내려다보는 **경사면 자체가 바뀌고**
- 게임 값에 **단조 감소 보장이 없음**

**이 장난감이 운 좋은 이유**

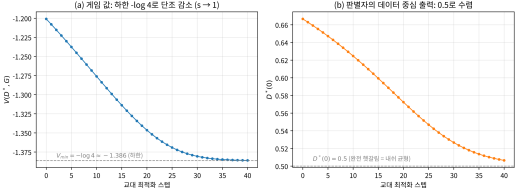
게임 값이 $s$의 매끄러운 함수로 **유일하게** 최소가 $s = 1$ 에 있어 **단조하게** 수렴. 실전 GAN의 “나쁜 소식들”(등락, 발산, 모드 붕괴)이 아직 안 보이는 이유 = 이 장난감에 **국소 균형이 딱 하나**뿐. 여러 개의 국소 균형이 존재하려면, 데이터 분포의 “여러 모드 중 일부만 덮는” 가짜 분포도 균형 후보가 되는 **고차원 세계**가 필요.

# 40스텝 교대 최적화 궤적

$s_0 = 2.0$, 학습률 $\eta = 0.15$로 40스텝 (수반 노트북 2절):

| 스텝 | $s$ | $V(D^*, G)$ | $D^*(0)$ |
|---|---|---|---|
| 0 | 2.000 | $-1.201$ | 0.667 |
| 10 | 1.664 | $-1.276$ | 0.625 |
| 20 | 1.339 | $-1.346$ | 0.572 |
| 30 | 1.113 | $-1.381$ | 0.527 |
| 40 | 1.026 | $-1.386$ | 0.507 |
| $\infty$ | 1.000 | $-\log 4 \approx -1.386$ | 0.500 |

- **(i)** 균형점의 게임 값은 $-\log 4 \approx -1.386$ 인데 **0이 아님** — "생성자 손실이 0에 가까워지면 성공"은 **틀린 읽기**. 성공 신호 = $V$가 더 이상 줄지 않고 $-\log 4$ 근방에서 **안정**
- **(ii)** $D^*(0)$(판별자가 데이터 중심 $x = 0$을 "진짜"로 판정하는 확률)이 0.667에서 0.5로 **점점 구별력을 잃는** 궤적 — "내쉬 균형 = 판별자가 완전히 헷갈리는 점"의 실행
- **(iii)** $V$는 줄지만 **0으로 가지 않음** — 게임 값 하한 $-\log 4$. 양쪽이 완벽히 헷갈려도 손실은 양쪽 로그 항이 $\log 0.5 = -\log 2$씩 기여해 합계 $-\log 4$




왼쪽: $V(D^*, G)$ 궤적, 오른쪽: $D^*(0)$ 수렴

# 장난감의 한계: 평균을 못 움직임

- 장난감 생성자는 평균을 못 움직임

# 실전 학습: 교대 최적화의 함정

- (1) 판별자 갱신: $G$ 고정, $D$만 한 스텝
- (2) 생성자 갱신: $D$ 고정, $G$만 한 스텝 — $G$_loss의 그래디언트가 $D$를 "지나" $G$의 파라미터로 흐름

**EM과의 차이 (다시)**

EM: E-step이 **정확한** 사후확률을 채워넣음 → "우도가 단조증가"가 **증명 가능**. GAN: (1)이 $D$를 완전 최적화하지도, (2)가 $G$를 완전 최적화하지도 못하는 **근사적** 게임 최적화 → 학습 곡선이 "꾸준히 하강하는 우도"처럼 보이지 않고, 오히려 **등락을 거듭**.

# 불안정성의 세 가지 양상

- **학습 속도 밸런스가 중요**

# 실수 1: D 정확도 50%를 “실패”로 읽기

**거꾸다**

이 게임에서 $D$의 정확도 50%는 **가장 이상적인 운영점** (내쉬 균형).

- 학습 중 $D$의 정확도가 **50% 부근**에서 머물면 “양쪽이 서로를 잘 따라가고 있다”는 **신호**
- 반대로 $D$의 정확도가 **90%+**로 치솟으면 $G$**가 이미 학습에서 이탈한 전형적 실패 신호** — “$D$가 잘 learned하고 있다”가 아니라 **“$G$가 $D$를 못 따라가고 있다”**는 뜻

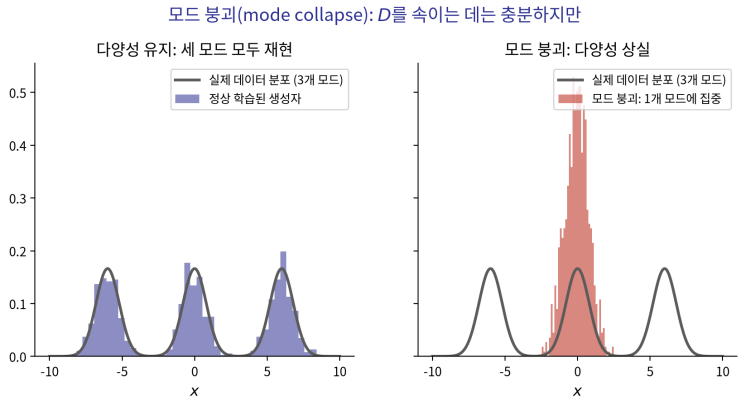
# 모드 붕괴: “성공”이 “실패”가 되는 지점

- **모드 붕괴: 다양성 상실**
- VAE: 이론적으로 **안정적**이지만 생성 품질이 다소 **흐릿**(blurry) 경향
- GAN: **선명한** 결과이지만 **학습이 까다로움**

**1차원 장난감이 이미 메커니즘을 보여줌**

기본 GAN 목적함수에는 **“다양성을 유지하라는 항”이 없음**. 생성자 손실 $-\log D(G(z))$는 오직 “이 가짜가 $D$를 얼마나 속였는가”에 의존. 데이터 분포가 세 개의 모드(예: 세 종류의 동물)를 갖고 있어도, **하나의** 모드만 집중적으로 만들어도 $D$를 잘 속일 수 있다면 — 고차원 공간에서 $D$가 “세 모드 모두를 동시에 감시”할 수 없는 한 — 그 하나에 집중하는 것이 손실을 줄이는 **가장 확실한** 전략.

# 그림으로: 모드 붕괴가 실제로 이렇게 생겼다




실제 데이터가 세 개의 모드를 가질 때, 정상 학습된 생성자(왼쪽)는 세 모드를 **모두** 재현하지만, 모드 붕괴(오른쪽)는 그중 **하나에만 집중** — $D$를 속이는 데는 충분해도 다양성을 잃는다.

# VAE에는 이 항이 있다: 핵심 구조적 차이

## VAE (15.1절)

- KL 항 $D_{KL}(q_\phi(z|x)\|p(z))$이 “인코더 출력 분포가 표준정규분포에 가깝게 유지”를 **목적함수 안에 명시적으로** 요구
- 잠재 공간 **전체**가 쓰이는 구조적 압력
- “잠재 공간의 일부만 쓰는” 퇴화 = **ELBO를 직접적으로 낮추는 행위**

## GAN

- 내쉬 균형 $p_G = p_{\text{data}}$ (모든 모드를 덮는 분포)가 “완전한 균형”
- 실제 학습이 풀고 있는 **근사적** 게임에서는 “일부 모드를 덮고 $D$를 속이는” 분포도 **국소적으로 균형처럼** 작용
- 이 대응 **항이 없음**

**이것이 VAE/GAN 비교에서 반복되는 핵심 구조적 차이.**

# 2014년 이후 GAN 계열: “안정화”가 3년의 주제

- **WGAN: 워터스톤 거리로 안정화**
- **CycleGAN: 레이블 없는 이미지 변환**
- **StyleGAN: 스타일 수준별 제어**
- **BigGAN: 대규모 조건부 생성**



StyleGAN류 생성기가 만든 얼굴 — 실존 인물이 **아님** (This Person Does Not Exist 예시)

# Diffusion: 정방향/역방향 과정

## 정방향 과정 (forward process)

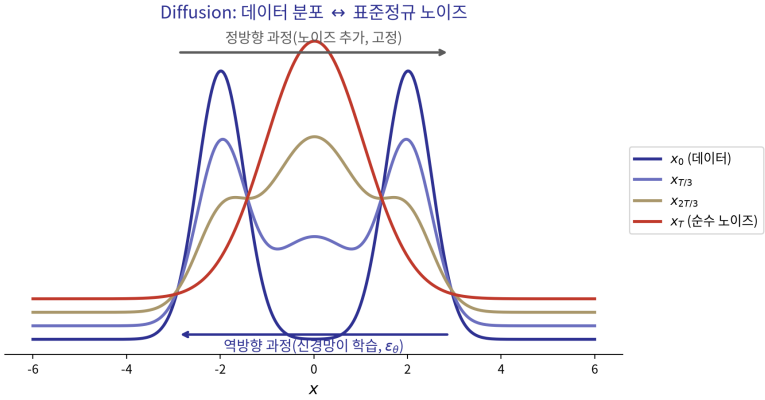
진짜 이미지 $x_0$에 **아주 작은 노이즈를 $T$번 반복**해서 추가해, 결국 $x_T$가 **순수한 무작위 노이즈**가 됨.
이 과정은 **고정된 절차이지 학습 대상이 아님**.

## 역방향 과정 (reverse process)

신경망이 **"한 단계 전 노이즈가 어땠는지"**를 예측하도록 학습. 학습 후, 순수 노이즈 $x_T$에서 시작해 이 역방향 단계를 $T$번 반복 → **새로운 이미지**.

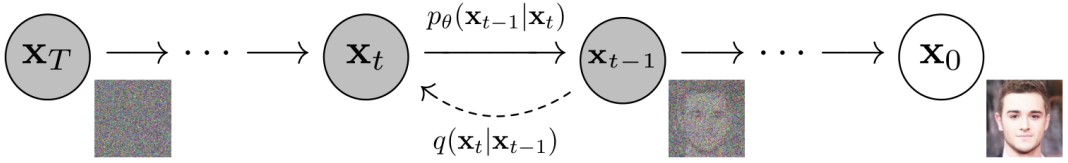
- **Diffusion은 작은 단계 $T$개로 쪼갬**

# 그림으로: 데이터 분포 ↔ 노이즈




정방향(위쪽 화살표, 고정)은 두 봉우리 데이터 분포를 표준정규 $\mathcal{N}(0,1)$까지 점점 뭉갠다. 역방향(아래쪽 화살표, $\epsilon_\theta$가 학습)은 그 과정을 거슬러 **노이즈에서 데이터 분포를 되살린다**.

# 그림으로: Diffusion의 마르코프 체인




$x_T$(순수 노이즈)에서 $x_0$(완성된 이미지)까지 — 실선 화살표 $p_\theta(x_{t-1}|x_t)$가 학습되는 **역방향(생성)** 과정, 점선 화살표 $q(x_t|x_{t-1})$가 고정된 **정방향(노이즈 추가)** 과정.

# 정방향은 왜 “학습 대상”이 아닌가

- 정방향 과정은 **고정된, 알려진** 절차:

$$x_t = \sqrt{1-\beta_t}\, x_{t-1} + \sqrt{\beta_t}\, \epsilon_t, \qquad \epsilon_t \sim \mathcal{N}(0, I)$$

- **역방향 추측이 어려운 이유**

**학습 대상은 하나뿐**

역방향 모델 $p_\theta(x_{t-1} \mid x_t)$.

# “노이즈 예측” 회귀 문제 (DDPM)

**DDPM: 신경망 $\epsilon_\theta(x_t, t)$로 노이즈 $\epsilon_t$ 예측**

$$\mathcal{L}(\theta) = \mathbb{E}_{t, x_0, \epsilon}\left[\|\epsilon - \epsilon_\theta(x_t, t)\|^2\right]$$

**이 식이 MSE 회귀 손실**이라는 점에 주목

이 장에서 본 모든 방식(EM의 M-step, VAE의 ELBO 역전파)과 달리, GAN의 min-max 게임도 아니고, 우도의 적분 근사도 아닌, **가장 보통의 단일 회귀 최적화**. “안정적으로 학습된다”의 **정체**가 바로 이것.

**$\epsilon$ 예측은 스코어 함수 $\nabla_x \log p_t(x)$ 추정과 동치**

# 역방향 단계(DDPM)와 “다시 노이즈 추가”

$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}}\left(x_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}}\,\epsilon_\theta(x_t, t)\right) + \sigma_t\, z, \quad z \sim \mathcal{N}(0, I)$$

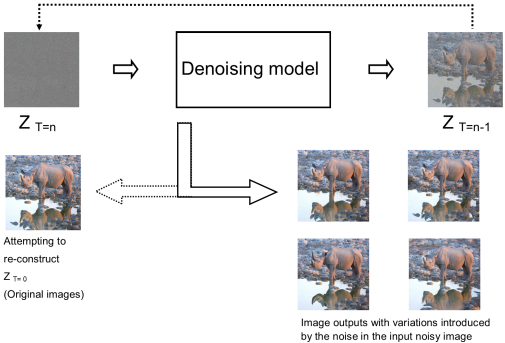
- “$\epsilon_\theta$만큼 **빼고**(조금 깨끗해지고), $\sigma_t z$만큼 **다시 더한다**(다시 노이즈를 조금)”

**자주 하는 실수 3**

“denoise = 계속 깨끗해지는 과정”이라는 직관과 달리, DDPM의 역방향 단계에는 $+\sigma_t z$(**다시 노이즈 추가**)가 있음. 이 항을 빼면 역방향 과정이 더 이상 $p(x_{t-1} \mid x_t)$ 가 아니라 **“점 추정”**으로 바뀌고, 생성 품질이 크게 떨어짐. $x_{t-1} \mid x_t$가 **분포**라는 점을 잊지 말 것.

# 역사: Sohl-Dickstein 2015 $\rightarrow$ DDPM 2020

- **DDPM: 노이즈 예측, MSE 손실, 실용적 스케줄**
- 같은 해 **DDIM** (Song et al.): 역방향 과정을 **거의 결정적으로** 만들어 $T$를 **1000에서 약 50** 단계로 줄임
- **Stable Diffusion: VAE 조합, 잠재 공간 Diffu**




노이즈 → 이미지: 실제 Denoising Diffusion 과정 예시



Stable Diffusion(2022) 생성 결과 예시

# GAN vs Diffusion: “학습할 것” 한 줄

| | GAN | Diffusion |
|---|---|---|
| 학습할 네트워크 | 2개 ($G, D$) | 1개 ($\epsilon_\theta$) |
| 학습 목표 | 게임의 **균형**(닫힌 형태 없음) | $\|\epsilon - \epsilon_\theta\|^2$ (**MSE**) |
| 샘플링 시 순전파 | **1회** | $T$회 (DDIM으로 $\sim$50회) |

# 이미지 밖으로: Waymo SceneDiffuser

- SceneDiffuser: 자연어 지시로 3D 교통 장면 생성 및 시뮬
- 장면 수준 Diffusion 사전분포로 스페이오-템포럴 예측
- 생성 모델이 안전 검증 도구로 쓰이는 대표 사례




Waymo 자율주행차 — SceneDiffuser(2024)를 만든 실제 회사

# 세 원리 비교

| | VAE (우도 기반) | GAN (적대적) | Diffusion (스코어 기반 |
|---|---|---|---|
| 잠재변수 | 연속 **벡터** | **없음**(노이즈를 직접 변환) | 연속(노이즈 **단계**) |
| 학습 방법 | ELBO **최대화**(역전파) | **min-max 게임**의 균형 | 각 단계 **노이즈 예측** 오<br>최소화 |
| 학습 안정성 | **비교적 안정적** | **불안정하기 쉬움** | **안정적** |
| 생성 속도 | **빠름**(한 번에) | **빠름**(한 번에) | **느림**(반복 필요) |

# 잠재변수 행 다시 읽기

- **VAE**의 $z$ = **연속 벡터** — 가능치가 무한해서 E-step을 신경망으로 **근사**해야 함 (15.1절)
- **GAN**의 $z$ = **분포가 아니라 그냥 랜덤 입력** — "데이터를 설명하는 잠재변수"의 역할을 **하지 않고**, 생성자가 입력으로 받는 **다양성의 원천**일 뿐 ($z$의 분포를 학습하지도, $z \mid x$를 추론하지도 않음)
- **Diffusion**의 "잠재변수" = **중간 상태** $x_t$ — 연속적이지만 **단계** $t$**가 이산적으로** $T$**개인**, "점진적으로 오염된 데이터" 그 자체

# 학습 방법 행 다시 읽기: 안정성의 원인

- **VAE**: ELBO(단일 목적함수)를 역전파로 최대화하는 **보통의** 최적화 → **안정**
- **Diffusion**: MSE 회귀라 **가장 보통의** 최적화 → **안정**
- **GAN은 안정성 근거가 없음**

# 생성 속도 행: “안정성의 대가”

- 가장 **안정한** Diffusion은 생성에 $T$**회 반복** 필요 (DDIM으로 줄여도 수십 회)
- 가장 **빠른** GAN/VAE는 **한 번의** 순전파로 생성

## 장 전체를 관통하는 트레이드오프

“**데이터를 설명할 수 있다**(안정성, 평가 가능)” vs “**빨리 만들 수 있다**(속도)”

## 실전 시스템은 “하나씩 고르는 것”이 아니라 **조합**

Stable Diffusion = **VAE**(잠재 공간) $\times$ **Diffusion**(노이즈 제거). SceneDiffuser = **Diffusion** 원리를 **시간 축의 장면**으로 확장. $\Rightarrow$ “세 원리를 나란히 보고 나서야, “관측되지 않은 구조가 데이터를 만들어낸다”는 하나의 질문이 얼마나 다양한 방식으로 풀릴 수 있는지”가 보임.

# 자주 하는 실수 2·4: GAN/Diffusion 판독

## 실수 2 — "생성자의 loss가 계속 줄어야 정상"이라고 기대

GAN의 loss 곡선은 **등락** — $D$가 갱신될 때마다 $G$의 손실 함수 **자체**가 바뀌므로, "loss가 튀었다"가 반드시 실패를 뜻하지 않음. (반대로 EM의 우도처럼 **단조증가**하는 곡선을 기대하면 GAN의 "정상"을 "이상"으로 오독.)  실전에서는 **샘플 품질**을 직접 보고, $D$의 정확도가 50% 부근에서 **균형**을 유지하는지를 대시보드로.

## 실수 4 — "$D$의 정확도 50%"를 "잘 안 하고 있다"로 읽기

**반대**다 — 50%는 이 게임의 **목표** operating point(내쉬 균형). **정확도가 90%+로 치솟는 쪽**이 진짜 문제 신호 (위 "실전 학습"의 실수 1 참고).

# 확인 문제 (15.2)

1. **(손계산, Tier A)** 1차원 장난감 GAN에서 $\mu = 0.5$ 일 때 게임의 값 $V(D^*, G) = \log(1 + 1/\phi(0.5))$를 계산 ($\phi(0.5) = 0.3521$). 균형점 $\mu = 0$에서의 값 $V(D^*, G) = \log(1 + 1/\phi(0)) = \log(1 + 1/0.3989)$와 비교 — "$\mu = 0.5$에서는 아직 균형이 아니며, 생성자는 $\mu$를 어떤 방향으로 움직일 유인이 있는가"를 한 문장으로 (힌트: $\mu = 0$에서의 값이 **더 작아야** $\mu = 0$이 $G$의 최소 — 즉 $G$의 관점의 내쉬 균형).
2. **(개념 서술)** 1차원 장난감에서 생성자는 결국 $\mu = 0$ **하나의 점**을 만듦 — 게임 관점에서는 "판별자를 완전히 속였다"의 **성공**이지만, 생성 품질 관점에서는 "다양성 0"의 **실패**. VAE의 ELBO에는 이 문제를 막는 **명시적인 항**이 있는데, 그 항이 무엇이며 GAN의 목적함수에는 왜 대응하는 항이 없는지를 두세 문장.

# 자주 묻는 질문: 모드 붕괴 · VAE/GAN/Diffusion

## 모드 붕괴는 왜 생기나요?

생성자는 판별자를 속이기만 하면 손실이 줄어듦 — 어떤 **한 종류**의 가짜가 판별자를 아주 잘 속인다는 것을 발견하면, 굳이 다른 다양한 가짜를 만들 이유가 없음. 판별자가 그 "치팅"을 알아채고 대응하기 전까지, 생성자는 그 **좁은 영역에만 몰릴** 유인. 근본 원인: VAE의 ELBO처럼 "**다양성을 명시적으로 요구하는 항**"이 GAN 기본 목적함수에는 **없음**.

## Diffusion이 주류인데 VAE·GAN은 이제 안 쓰나요?

이미지 생성 분야에서는 Diffusion이 최근 주류가 됐지만, **VAE의 핵심 아이디어**(잠재 공간을 매끄럽게 만든다)는 여러 최신 시스템에서 Diffusion과 **결합**되어 사용 (예: 픽셀 공간이 아니라 **VAE로 압축한 잠재 공간**에서 Diffusion을 돌리는 구조 — Stable Diffusion이 정확히 이 방식). GAN도 **실시간성**이 중요한(반복 없이 한 번에 생성해야 하는) 응용에서는 여전히 사용 — "하나가 다른 셋을 완전히 대체했다"기보다, **각자 강점이 있는 도구로 함께**.

# 자주 묻는 질문: Diffusion 단계 수 · GAN 평가

## Diffusion은 정말 $T$번의 단계를 다 돌리나요?

원래 DDPM은 $T = 1000$인데, **DDIM**(2020)이 역방향 과정을 거의 **결정적**으로 만들어 **약 50단계**로 줄이고, 이후 **증류**(distillation) 계열 기법(**LCM**, **progressive distillation** 등)으로 **10단계 이하** 가능. 대가 = "완전한 DDPM에 비하면 품질이 조금 떨어짐". "GAN보다 느리다"는 GAN 기준에서 **상대적** — 50단계 $\times$ 0.1초 $\approx$ 5초의 이미지 생성은 실제 응용에 **충분히 빠름**. (영상 생성처럼 샘플 수백 장을 만들어야 하는 분야에서는 이 차이가 더 중요.)

## GAN은 ELBO 같은 "높을수록 좋은 단일 숫자"가 없는데, 학습 품질을 어떻게 평가?

GAN 계열은 단일 "우도" 숫자가 없어서 **샘플 기반** 지표가 따로 발전 — 대표적으로 **FID**(Fréchet Inception Distance): 실제 이미지와 생성 이미지를 InceptionNet 같은 **특징 추출기**로 변환한 뒤, 두 특징 분포의 **평균·공분산**(가우시안 근사) 사이의 **거리**. FID가 **작을수록** 생성 분포가 실제 분포에 **가깝**. VAE/GMM 계열은 "ELBO를 높인다"는 단일 숫자가 있어 비교가 쉬웠는데, GAN은 FID처럼 **외부 지표**가 필요 — 이(하나의 요인)가 이후 연구가 "**평가 가능한**" Diffusion 쪽으로 이동하는 데 일조.

# 연습문제 (코딩)

- **1.** `em_step`과 `kl_divergence_gaussian`(정규분포 $\mathcal{N}(\mu, \sigma^2)$와 표준정규분포 사이의 KL divergence) 완성. 핵심 줄: $D_{KL} = -0.5 \cdot (1 + \text{log_var} - \mu^2 - \exp(\text{log_var}))$.

# 연습문제 5: ELBO 유도 빈칸 폴백

**자유 유도가 어려운 경우** — 빈칸을 채워라:

```
Step 1: log p(x) = log integral[ q(z|x) * (p(x,z) / q(z|x)) dz ]
                 = log E_q[ _____________ ]

Step 2: 옌센부등식 (가log 오목함수) 적용:
  log E_q[ p(x,z)/q(z|x) ] >= E_q[ log(_____________) ]

Step 3: p(x,z) = p(x|z) * p(z)로 분해하면:
  = E_q[ log p(x|z) ] + E_q[ _____________ ]

Step 4: E_q[ log p(z) - log q(z|x) ] = -D_KL(q(z|x) || p(z))결론

: log p(x) >= E_q[log p(x|z)] - D_KL(q(z|x) || p(z))   [ELBO]
```

## 정확성 확인

Step 2에서 **부등호가 등호가 아니라 부등식**인 이유를 한 문장으로 — (옌센 부등식이 **언제 등식**이 되는지: $X$가 **상수**일 때).

# 이번 주차 정리

1. **15.1 VAE** — **"EM의 E-step을 신경망이 맡는다"**. ELBO = **복원 항** $-$ **KL 정규화 항** (옌센 부등식 한 번으로 유도). 갭 $= D_{KL}(q\|p(z|x))$ — ELBO 최대화 $=$ 변분 베이즈. $\mu^2$ **항**이 인코더 위치를 원점 쪽으로, $\sigma^2$ **항**이 너비를 제어. **생성 모드**는 인코더를 **버리고** 디코더만 통과. $\beta$-VAE가 "복원 품질 vs 잠재 공간 매끄러움"을 튜닝. "흐릿함"의 원인 = **기대값 최적화**.
2. **15.2 GAN** — min-max 게임의 **내쉬 균형** ($D(x) = 0.5, p_G = p_{\text{data}}$). 1차원 장난감에서 $V(D^*, G) = 2\,\text{JSD} - \log 4$로 **닫힌 형태**. 성공 신호 = $V$가 $-\log 4$ 근방에서 **안정**, $D^*(0) \to 0.5$. **모드 붕괴**의 원인 = 목적함수에 **다양성 항이 없음** (VAE에는 KL 항이 대응).
   WGAN/CycleGAN/StyleGAN/BigGAN = "**안정화**"가 3년의 주제.
3. **15.2 Diffusion + 비교** — 노이즈를 $T$단계로 **쪼갠 MSE 회귀**(가장 보통의 최적화 → **안정**). 역방향에도 $+\sigma_t z$(**다시 노이즈 추가**)가 **필요**. Stable Diffusion = **VAE 잠재 공간** $\times$ Diffusion. 세 원리: **잠재변수 · 학습 방법 · 안정성 · 생성 속도**로 비교 — 실전 시스템은 **조합**.

**다음 주 — Week 16. Block B 캡스톤: 팀 프로젝트와 ML1 총정리**

이번 장에서 배운 **세 원리(VAE · GAN · Diffusion)**가 팀 프로젝트의 **모델 선택** 도구 상자로 등장 — **안정성 · 생성 속도 · 품질**의 기준으로 선택하고 **정당화**.