고급 정책 최적화: PPO (Proximal Policy Optimization)

신뢰 영역과 확률비 · PPO 클리핑과 연속 제어 실습 · GAE와 PPO가 표준이 된 이유

Machine Learning 2 · 11주차

한국과학영재학교 (KSA)

Week 11

이번 주차 개요

이 주차를 마치면

- **신뢰 영역**: KL로 정책 이동 크기 제한
- $r_t = 1$에서 L^{IS} 그래디언트 $=$ 정책 그래디언트
- L^{CLIP}의 모양과 min의 비대칭
- **GAE**와 엔트로피 보너스의 역할
- PPO 한 반복의 흐름, Pendulum 학습

11.1 신뢰 영역과 확률비 — 클리핑의 "재료" 준비.

11.2 PPO 클리핑과 연속 제어 실습 — 한 줄의 식이 만드는 목적함수의 모양 + Pendulum 실습.

11.3 GAE와 PPO가 표준이 된 이유 — 실전용 마지막 두 조각, TRPO 비교, 전체 스택.

11.1 신뢰 영역과 확률비

위치: 이번 절이 해결할 문제

Week 10의 REINFORCE와 Actor-Critic에 공통된 한계 두 가지.

- **문제 1 — 데이터 한 번 쓰고 버린다.** 에피소드 한 번 모은 데이터를 그 자리에서 바로 쓰면 (온-폴리시, on-policy), 정책이 바뀌는 순간 "옛 정책이 그 행동을 얼마나 좋아했는가" 기반의 그래디언트는 더 이상 정확하지 않다.
- **문제 2 — 스텝이 한 번이라도 너무 크면.** 정책이 갑자기 나쁜 방향으로 확 바뀌어 이후 돌려놓기 어렵다. 로봇처럼 "한 번 무너지면 다시 세우기 어렵다"는 상황에서는 치명적.

이번 절의 두 도구

신뢰 영역(trust region): 한 번의 업데이트에서 정책이 얼마나 움직일 수 있는가의 상한.
확률비(probability ratio): 옛 정책 데이터의 재사용을 가능하게 하는 도구. 이 둘이 11.2절에서 **클리핑** 한 줄로 합쳐진다.

신뢰 영역이라는 직관

산에서 안개 낀 내리막

- 한 치 앞만 보이는 안개 속에서, 가장 가파른 방향으로 무작정 큰 걸음을 내디디면 절벽으로 떨어질 수 있다.
- 안전한 전략: **한 걸음의 크기를 "믿을 수 있는 범위"(신뢰 영역) 안으로 제한**.
- 매 스텝이 실제로 개선을 보장하는 좁은 범위 안에서만 이동하게 한다 — 이것이 PPO의 핵심 아이디어.

"한 걸음의 크기"는 어떻게 재는가? 정책은 행동의 **확률분포**이므로, 파라미터의 차 $\|\theta - \theta_{\text{old}}\|$ 로 재기보다 **분포 자체의 거리**로 재는 것이 자연스럽다.

표준적인 선택: KL 발산

$$D_{\text{KL}}(\pi_\theta \,\|\, \pi_{\theta_{\text{old}}}) = \mathbb{E}_{s\sim\rho}\Big[\mathbb{E}_{a\sim\pi_\theta(\cdot|s)} \log \frac{\pi_\theta(}{\pi_{\theta_{\text{old}}}}$$

ρ = 상태 방문 분포. 0이면 두 정책이 정확히 같고, 클수록 서로 다른 행동을 다르게 선호 — "정책 공간에서의 걸음 크기"를 재는 눈금.

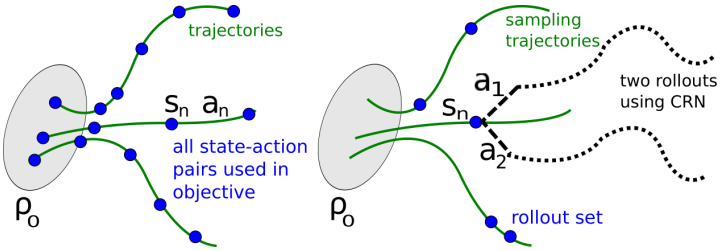
TRPO: 보장은 강력, 기계는 무거움

- **TRPO(Trust Region Policy Optimization, 2015)**: "KL 발산이 δ 를 넘지 않는 범위 안에서 $J(\theta)$ 를 최대화한다"는 **제약된 최적화**를 매 스텝마다 풀었다.
- **보장**: 제약이 충분히 작으면 매 업데이트가 성능을 절대 떨어뜨리지 않는 **단조 개선**을 증명.
- **대가**: 실제로 이 제약을 풀려면
  - 2차 미분 — **피셔 정보 행렬**
  - 역행렬 곱을 반복적으로 — **conjugate gradient**
  - 제안 방향으로 얼마나 가도 안전한지 — **line search**

  세 장치까지 동원해야 해서 무겁다.

PPO의 출발 질문: "이 강력한 보장을 유지하면서 이 기계장치를 어떻게 단순화할 수 있는가?" — 단순화의 핵심이 바로 확률비.

TRPO의 데이터 생성 절차 (원 논문 Figure 1)



single path (좌): 시뮬레이션한 단일 트래젝터리의 모든 상태-행동 쌍을 목적함수에 사용.

vine (우): 줄기(trunk) 트래젝터리의 도달 상태 일부에서 가지(branch) 롤아웃을 퍼뜨림 (공통 무작위 수) — 분산 감소 효과.

TRPO의 무거움은 “이 데이터에 어떤 최적화 장치를 붙이느냐”의 문제에서 온다.

확률비와 중요도 샘플링

핵심 도구 — **확률비**(probability ratio): 지금 업데이트하려는 정책 π_θ 와 데이터를 모을 때 썼던 정책 $\pi_{\theta_{\text{old}}}$ 가 **같은 행동**에 부여하는 확률의 비.

$$r_t(\theta) := \frac{\pi_\theta(a_t \mid s_t)}{\pi_{\theta_{\text{old}}}(a_t \mid s_t)}, \quad r_t(\theta_{\text{old}}) = 1$$

- $r_t > 1$: 그 행동을 전보다 **더** 선호. $r_t < 1$: **덜** 선호.
- 이 비율로 "옛 정책이 모은 데이터"를 "새 정책 관점에서" 재사용 — **중요도 샘플링**(Week 5.3의 MC off-policy 학습에서 처음 등장한 바로 그 도구).

$$L^{\text{IS}}(\theta) = \mathbb{E}_t[\, r_t(\theta)\, A_t \,]$$

A_t 는 10.3절의 어드밴티지 $A_t := G_t - V(s_t)$.

그냥 최대화하면 폭주 — 그리고 그래디언트

- L^{IS} 를 그냥 최대화하면 r_t 가 한없이 커지도록 (같은 행동만 계속 더 밀어주도록) 학습이 **폭주** — 데이터는 재사용되지만 "정책이 너무 멀리 움직이지 않는다"는 보장은 어디에도 없다.

왜 L^{IS} 를 최대화하면 원래 목표 $J(\theta)$ 를 최대화하는 것과 같은 방향인가? π_{old} 는 θ 와 무관한 상수(데이터 수집 때 고정했던 정책)이므로:

$$\nabla_\theta L^{\mathrm{IS}} = \mathbb{E}_t\left[\frac{\pi_\theta}{\pi_{\mathrm{old}}}\,\nabla_\theta \log \pi_\theta\, A_t\right] = \mathbb{E}_t\left[\, r_t(\theta)\,\nabla_\theta \log \pi_\theta\, A_t \,\right]$$

두 번째 등호는 10.1절 **로그미분 트릭** ($\nabla\pi = \pi\nabla \log \pi$)의 직접 적용.

첫 스텝에서는 “정직한 첫 걸음”

핵심 성립

L^{IS} 의 그래디언트는 **평범한 policy gradient** $\nabla_\theta \log \pi_\theta A_t$ **에 계수** r_t **가 곱해진 형태**다. 데이터를 방금 모은 시점 ($\theta = \theta_{\mathrm{old}}$)에서는 $r_t = 1$ 이므로 **10.3절 Actor-Critic의 그래디언트와 정확히 같다**.

- 즉, 확률비로 목적함수를 다시 쓴 순간 **“옛 데이터를 재사용해도 첫 스텝에서는 정직한 policy gradient”**가 자동으로 성립 — 이것이 확률비가 “재사용의 열쇠”인 이유.
- θ 가 θ_{old} 에서 멀어지면 계수 r_t 가 1에서 벗어나 이 동등성이 **약해진다** — “멀어지는 정도”를 막는 것이 11.2절의 클리핑.

손으로 한번: r_t 는 실제로 어떻게 움직이는가

2-행동 softmax 정책, 로짓 (θ_0, θ_1). 시작점 $\theta_{\text{old}} = (0, 0)$ 에서 두 행동 반반 ($p_0 = 0.5$). "행동 0이 좋다"며 θ_0 를 계속 올리고 $\theta_1 = 0$ 을 고정하면:

θ	p_0 (새 정책)	$r_0 = p_0/0.5$
$(0.0, 0.0)$	0.5000	**1.000** (처음)
$(1.1, 0.0)$	0.7503	1.501
$(2.2, 0.0)$	0.9002	1.800
$(4.4, 0.0)$	0.9879	1.976

세 가지가 보인다:

1. r_0 는 항상 **1에서 출발** (데이터 수집 시점에는 새·옛 정책이 같으므로).
2. 좋은 행동을 계속 밀면 r_0 가 1보다 커지며 **오르 다** — "더 선호하게 됐다"의 정량.
3. 이산 정책은 $p_0 \le 1$ 이므로 $r_0 \le 2$ — **위에서 유한**. 다만 경계(2)에 빠르게 붙는다.

클리핑(11.2)이 막는 것은 정확히 이 "경계에 붙는" 구간: $r_0 > 1.2$ 이후엔 목적함수에 기여 0, p_0 가 0.9 이상으로 확 밀리는 것을 허용하지 않음.

연속 정책: r_t 의 분산이 지수적으로 불어난다

이산 2-행동에서는 유한했지만, "r_t 가 커지면?" — **중요도 샘플링의 분산**이 문제. 가장 단순한 연속 사례: 같은 $\sigma = 1$ 인 가우시안 정책 둘, $\pi_{\text{old}} = \mathcal{N}(0, 1)$, $\pi_\theta = \mathcal{N}(\mu, 1)$ (평균만 μ 이동).

$$r(x) = \frac{\pi_\theta(x)}{\pi_{\text{old}}(x)} = \exp\left(-\tfrac{x^2}{2} + \tfrac{(x-\mu)^2}{2} \right) = \exp\left(\mu x - \tfrac{\mu^2}{2} \right)$$

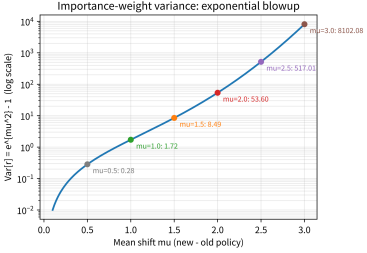
- 이것은 **로그정규분포**. 기댓값은 항상 1(재가중해도 평균 보존).
- **분산**은 $\text{Var}[r] = e^{\mu^2} - 1$ — μ^2 에 **지수적으로** 불어난다.

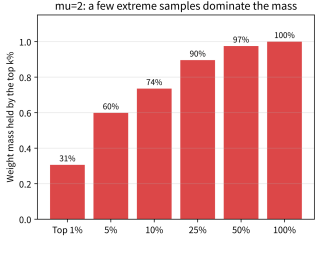
μ를 세 배로, 분산은 사천 배

평균 이동 μ	$\mathrm{Var}[r] = e^{\mu^2} - 1$	$\Pr(r > 5)$	r 의 99퍼센타일
0.5	0.284	0.00026	3.6
1.0	1.718	0.0175	16.9
1.5	8.488	0.0342	100.9
2.0	53.598	0.0356	774.8
2.5	517.013	0.0291	7636.9
3.0	8102.084	0.0209	96654.7

- $\mu = 1$ 이면 분산 1.7 (아직 괜찮아 보인다) $\to$ $\mu = 2$ 이면 53.6 $\to$ $\mu = 3$ 이면 **8102**.
- "새 정책이 옛 정책과 살짝 다를 뿐"이라고 느긋하게 넘길 수 없는 구간.

소수 극단 샘플이 업데이트를 지배한다





좌: μ 이동에 따른 $\mathrm{Var}[r] = e^{\mu^2} - 1$ (로그 축). 우: $\mu = 2$ 일 때 10,000개 샘플 중 상위 1%가 전체 가중치 합의 약 31% 차지.

$\mu = 2$ 로 10,000개 샘플:

- 가중치 평균은 1에 가까움 (0.91).
- **최댓값은 약 143**.
- **상위 1%(100개)** 샘플이 전체 가중치 합에서 약 **31%** 차지.

업데이트 방향을 정하는 것은 “대부분의 샘플”이 아니라 **소수의 극단 샘플** — 극단 샘플이 노이즈이므로 업데이트가 노이즈에 지배당해 정책이 흔들린다. 바로 11.2절 클리핑이 “극단 샘플의 기여를 $1 + \epsilon$ 으로 잘라버리는” 이유.

“분산이 크다” $\neq$ “한 샘플이 지배한다”

분산이 큰 것과 한 샘플이 지배하는 것은 같은 말인가? 관련되지만 **다르고, 여기서는 둘 다** 문제가 된다.

분산이 크다

- **반복 평균**으로 (데이터를 많이 모으면) 줄여줄 수 있다.

단일 스텝에서 한 샘플이 지배한다

- 데이터량이 충분해도, 극단 샘플이 *한 방향*으로 운 좋게 쏠리면 **그 한 스텝이 크게 틀어진다**.

신뢰 영역(클리핑)의 정확한 역할

“분산을 줄이는” 수단이 아니라, **단일 스텝에서 한 샘플이 영향을 줄 수 있는 최대 크기를 제한하는** 안전장치.

Week 5.3의 중요도 샘플링과 무엇이 다른가

Week 5.3 (도구로 쓰일 때)

- off-policy: target 정책의 데이터를 behavior 정책의 데이터로 근사.
- "무게가 크게 부등한 샘플들이 **편향 없이 평균은 맞히되**, 작은 데이터에서는 한 샘플에 지배당한다" — 평균만 맞히면 됐다.

여기서 (목적함수로 끌어다 쓸 때)

- $L^{\mathrm{IS}} = \mathbb{E}[r_t A_t]$ 를 최대화 **대상**으로.
- 같은 성질이 **학습의 불안정성**으로 직접 연결 — 민감한 것은 "평균"이 아니라 **매 스텝의 그래디언트 방향**.

이 절의 통찰

"Week 5.3의 도구가 여기서는 **안전문제**가 된다."

자주 하는 실수 1 — "$r_t = 1$ 로 고정하면 되지 않나?"

- $r_t = 1$ 을 유지하려면 $\pi_\theta = \pi_{\theta_{\text{old}}}$, 즉 정책을 **전혀 움직이지 말아야** 한다 — 그러면 학습 자체가 안 된다.
- 문제는 $r_t = 1$ 을 유지하는 것이 아니라, r_t **가 1에서 조금만 벗어나도록 허용하되 (ϵ 만큼), 그 이상은 잘라내는 것**.
- "아예 못 움직이는 것"과 "적당히만 움직이는 것"을 혼동하면 안 된다.

자주 하는 실수 2 — "확률비를 쓰면 편향이 사라지는가?"

아니다. L^{IS} 의 그래디언트가 첫 스텝($\theta = \theta_{\text{old}}$)에서 policy gradient와 같다는 것은, 그 이후에는 다르다는 뜻이기도 하다. r_t 를 여러 에폭에 걸쳐 재사용할수록 (θ 가 θ_{old} 에서 멀어질수록) 근사 오차가 쌓인다 — 그래서 PPO는 데이터를 **몇 에폭만** 쓰고 버린다(11.2 FAQ). 확률비는 "편향을 없애는" 도구가 아니라, **짧은 시간 안에 거의 bias-free로 데이터를 재사용하게 해주는** 도구다.

자주 하는 실수 3 — "ϵ 이 클수록 빨리 배울까?"

- ϵ 이 클수록 한 스텝에서 더 크게 움직일 수 있으니 "빠르게" **보일** 수는 있다.
- 하지만 r_t 가 클리핑 범위를 크게 벗어나는 일이 잦아지고, 위 가우시안 예에서 본 **분산 불어나기 / 한 샘플 지배**가 더 자주 일어나 학습이 **불안정**해진다.

ϵ 은 "속도"가 아니라 "안정성"의 노브

- 너무 작으면 (0.05 이하) 학습이 지나치게 느려진다.
- 너무 크면 (0.5 이상) 정책 붕괴 위험이 커진다.
- 실용적으로는 $\epsilon \approx 0.2$ 가 좋은 출발점.

자주 묻는 질문 — r_t 와 KL

- **Q. $r_t(\theta_{\text{old}}) = 1$ 이 항상 성립하는 이유는?** 방금 데이터를 모은 시점에는 “지금 정책”과 “데이터를 모은 정책”이 완전히 같으므로 같은 행동에 부여하는 확률도 같다(비율이 1). 그 이후 경사 상승 스텝을 거치며 θ 가 θ_{old} 에서 멀어지면 r_t 가 1에서 벗어난다.
- **Q. 중요도 샘플링 하나만으론 왜 부족한가?** 재가중은 해 주되, 그 재가중이 만드는 그래디언트의 **크기에는 아무 제약이 없다** — r_t 가 매우 크면 그 한 샘플이 전체 업데이트를 지배. 클리핑(11.2)이 바로 이 “크기 제한”.
- **Q. $A_t = 0$ 인 샘플은 r_t 가 아무리 커도 무관? 맞다** — $L^{\text{IS}} = r_t A_t$ 이므로 $A_t = 0$ 이면 기여는 항상 0. 단, A_t 가 0에 가까운 샘플은 r_t 가 크면 $r_t A_t$ 가 작지 않을 수 있어, “약하게 좋았다/나빴다”는 신호가 극단 샘플의 노이즈에 묻힌다.

자주 묻는 질문 — KL 발산의 방향

KL 발산은 비대칭인데, 방향($\pi_\theta \| \pi_{\text{old}}$ vs. 그 반대)이 왜 중요한가?

- $D_{\text{KL}}(\pi_\theta \| \pi_{\text{old}})$ 는 "새 정책이 옛 정책이 **거의 확률 0**로 보는 행동에 확률을 붙이는 것"을 **무겁게 벌**한다. 그 행동이 옛 정책에서 거의 안 나왔는데 새 정책에서 자주 나오면 로그비가 크게 음수, 그 부정이 커짐.
- 이 방향을 쓰면 **"새 정책이 옛 데이터에서 본 적 없는 영역으로 도망가지 못한다"**는 직감이 자연스럽게 붙는다 — 데이터 재사용의 전제가 "옛 정책이 실제로 방문한 상태·행동" 이므로, 그 영역 밖으로 나가는 걸 막는 방향.
- (실전 PPO는 KL 발산 대신 **확률비 클리핑**으로 이 역할을 근사한다.)

역사: “신뢰 영역”은 50년 된 아이디어

시기	사건
1960 ∼ 70년대	**미분없는 최적화**의 고전 기법: “목표함수의 2차 근사가 잘 맞는 작은 영역 안에서만 근사함수
1971	Maritz — 이 분리를 **확률적 시뮬레이션** 문맥에서 처리
1981	Moore — 미분없는 최적화에서 정식화
2015	**TRPO** — “KL 발산이 δ 안이면 policy gradient의 2차 근사가 안전하다”를 증명, 2차 계획
2017	**PPO**(Schulman 외) — “보장을 1차 기법(클리핑)으로 근사해도 실전에서 거의 같은 안정성

핵심 교훈

“TRPO는 이론적으로 정답, PPO는 실용적으로 정답”이 아니라 — **같은 신뢰 영역 원리를, 풀이를 쉬운 쪽으로 바꿨을 뿐**. 근사된 목적함수를 멀리서 믿지 말고, 가까운 영역에서만 믿는다는 태도 자체가 통계·최적화에서 오래된 지혜.

11.1절 요약 — 두 사실

- **신뢰 영역**은 “한 걸음의 크기를 믿을 수 있는 범위로 제한한다”는 직관.
- **확률비** $r_t = \pi_\theta / \pi_{\text{old}}$ 는 “옛 데이터를 새 정책 관점에서 재사용한다”는 도구.
- r_t 는 1에서 출발해 정책이 움직이는 만큼 벗어나고, $L^{\text{IS}} = \mathbb{E}[r_t A_t]$ 의 그래디언트는 **첫 스텝에서 policy gradient와 정확히 같아** “재사용해도 정직한 첫 걸음”을 보장.
- 하지만 r_t 가 크면 중요도 샘플링의 분산이 $e^{\mu^2} - 1$ 로 **지수적으로 불어나** 소수 극단 샘플이 업데이트를 지배.

PPO 전체의 설계 원리

첫 걸음은 정직, 큰 걸음은 위험 — 이 두 사실이 11.2절의 클리핑이 존재하는 이유.

11.2 PPO 클리핑과 연속 제어 실습

위치: 11.1절의 문제를 클리핑 한 줄로 바꾸기

11.1절은 문제를 정확히 짚었다: $L^{\mathrm{IS}}(\theta) = \mathbb{E}_t[r_t(\theta)A_t]$ 를 그냥 최대화하면 r_t 가 한없이 커지도록 학습이 폭주.

- **TRPO**(11.3절에서 다룸)는 이 문제를 "KL 발산이 Δ 를 넘지 않는다"는 명시적 제약을 2차 미분 도구로 풀어내려다 **무거워졌다**.
- **PPO**의 제안은 의외로 간단했다 — **제약을 식에 직접 박아 넣는 것**:

  "r_t 가 1 근처를 벗어나면, 벗어난 만큼의 이득은 인정하지 않겠다."

이 절: (1)반 — 그 한 줄(클리핑)이 만들어내는 목적함수의 모양을 손으로 확인. (2)반 — 연속 제어 환경(Pendulum)에서 PPO를 통째로 구현.

클리핑: 너무 멀리 못 가게 막기

r_t 가 $[1-\epsilon,\ 1+\epsilon]$ (보통 $\epsilon = 0.2$) 범위를 벗어나면, 그 구간 밖으로 나간 만큼의 이득을 깎아버린다:

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t\Big[\ \min\Big(r_t(\theta)A_t,\ \text{clip}\big(r_t(\theta),\ 1-\epsilon,\ 1+\epsilon\big)A_t\Big)\Big]$$

- **min을 쓰는 이유**: clip 안 한 값과 clip한 값 중 더 “비관적인”(작은) 쪽을 목적함수로 삼아, 한쪽으로 너무 밀려가는 것에 대한 보상을 스스로 제한.
- **직관**: $A_t > 0$(좋은 행동)인데 r_t 가 이미 $1+\epsilon$ 을 넘었으면 더 밀어붙여도 그래디언트 0(이미 충분히 밀었으니 그만). $A_t < 0$(나쁜 행동)인데 r_t 가 $1-\epsilon$ 밑으로 떨어졌으면 역시 그래디언트 0(이미 충분히 눌렀으니 그만).

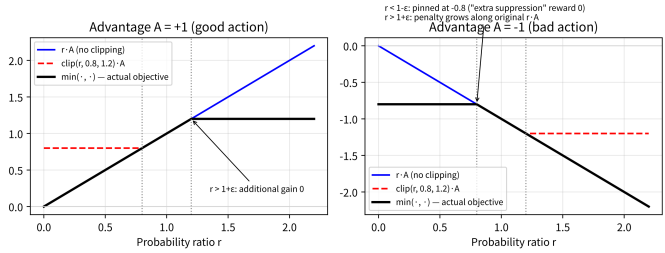
결과: “좋은 행동을 과도하게 밀어주지도, 나쁜 행동을 과도하게 눌러버리지도 않는” **암묵적 신뢰 영역**.

ppo_clip_loss — 핵심 5줄

```python
def ppo_clip_loss(ratio, advantage, epsilon=0.2):
    unclipped = ratio * advantage
    clipped = max(min(ratio, 1 + epsilon), 1 - epsilon) * advantage
    return min(unclipped, clipped)  # 목적함수최대화( 대상)의 한샘플분
```

- clip = max(min(r, $1+\epsilon$), $1-\epsilon$) — r_t 를 $[1-\epsilon, 1+\epsilon]$ 안으로 자름.
- 최종 목적함수는 두 값의 **min**(비관적 쪽).

그림으로 보는 클리핑: min이 만드는 "모서리"



한 샘플분, $\epsilon = 0.2$, r_t 를 0~2.2 까지. 파랑 실선 = $r_t A_t$, 검정 = 실제 목적함수, 빨강 점선 = clip$(r_t, 0.8, 1.2)\, A_t$, 회색 세로점선 = 클립 경계.

왼쪽 $A = +1$(좋은 행동)

- $r_t \in [0.8, 1.2]$ 안: 검은 곡선 = 파랑 실선 (원래 중요도 목적함수 그대로).
- $r_t > 1.2$ 순간: **수평으로 꺾임** — "좋은 행동을 추가로 더 밀어주는 것"의 보상이 0.

오른쪽 $A = -1$(나쁜 행동)

- $r_t < 0.8$: 목적함수가 **−0.8로 고정** — "나쁜 행동을 조금 더 덜 선호하게 하는 것"의 추가 보상 0.
- $r_t > 1.2$ (나쁜 것을 더 선호하는 방향): 벌금은 **상한 없이** 계속 커진다.

클리핑의 비대칭: 상한은 "개선 방향"에만

두 패널을 함께 읽으면 min의 역할이 정확히 보인다:

- **범위 안**($r_t \in [0.8, 1.2]$): 원래 중요도 목적함수 $r_t A_t$ 그대로 — $r_t = 1$ 근처(데이터 수집 직후)에서는 REINFORCE 계열 그래디언트와 본질적으로 같은 방향.
- **범위 밖, 개선 방향**: "좋은 것을 더 밀어주는 것"과 "나쁜 것을 더 억제하는 것"의 **추가 이득이 0** (검은 곡선 수평).
- **범위 밖, 악화 방향**: "나쁜 것을 더 밀어올리는 것" 에는 **상한이 없다**.

미분으로 보면 더 명확

목적함수가 수평인 구간에서는 r_t 에 대한 기울기가 정확히 0 — "추가 이득이 0"은 문자 그대로 "이 방향으로는 그만". **min이 "비관적(더 작은)쪽"을 고르기 때문에** 자연스럽게 생기는 비대칭.

손으로 계산해 보기 — $\epsilon = 0.2$

		$A_t = +1$ (좋은 행동)	$A_t = -1$ (나쁜 행동)
$r_t = 0.5$	clip 안 됨 (범위 안)	$\min(0.5,\ 0.5) = \mathbf{0.5}$	$\min(-0.5,\ -0.8) = -\mathbf{0.8}$ (clip 쪽 채택)
$r_t = 1.5$	clip 1.2 이 됨	$\min(1.5,\ 1.2) = \mathbf{1.2}$ (잘림)	$\min(-1.5,\ -1.2) = -\mathbf{1.5}$ (원래 곡선 채택)

- $A_t = +1,\ r_t = 1.5$: 초과분 이득(0.3)은 인정하지 않음 — “좋은 행동을 더” 방향에서 멈춤.
- $A_t = -1,\ r_t = 1.5$: **clip 안 한 쪽**이 더 작아서 그대로 — “나쁜 것을 더 선호하게 만드는” 방향에는 클립이 발동하지 않고 벌금이 계속 커진다.
- $A_t = -1,\ r_t = 0.5$: clip 쪽(-0.8)이 더 작아서 채택 — “나쁜 것을 덜 선호하게 만드는” 방향은 -0.8 $(= (1-\epsilon)A)$ 에서 멈춘다.

핵심

min은 “클립 안 한 값”을 무조건 고르는 것이 아니라, **항상 두 값 중 더 작은(비관적인) 쪽**을 고르는 기계적 장치. A_t 의 부호와 r_t 의 크기에 따라 “어디서 멈추는가”가 달라진다.

자주 하는 실수 — min/max, 절대 확률

- **실수 1: max를 쓰는 것.** 목적함수를 최대화 하므로 min(비관적 쪽)을 써야 하는데, max를 쓰면 역할이 뒤집힌다 — 좋은 행동($A_t > 0$)에서는 $r_t > 1 + \epsilon$ 일 때 max가 **클립 안 한 쪽** $r_t A_t$를 계속 고르므로 좋은 행동을 밀어주는 것에 상한이 **사라진다**(클리핑이 막으려던 폭주가 그대로 남는 방향).
- **실수 2: 클립 경계를 "절대 확률 0.8∼1.2"로 오해.** 클립 대상은 **비** r_t 이지 행동이나 확률 자체가 아니다.

올바른 뜻

"**옛 정책 대비** 이 행동의 상대적 선호가 20% 이내여야 한다" — 옛 정책이 확률 0.01을 준 행동에 대해 새 정책이 0.012까지, 0.5를 준 행동에 대해 0.6까지 올릴 수 있다. 같은 "20%"라도 절대값으로 바뀌면 극단적 확률의 행동이 영원히 갱신되지 못한다.

PPO 원 논문의 서브게이트 함수 (Figure 1)

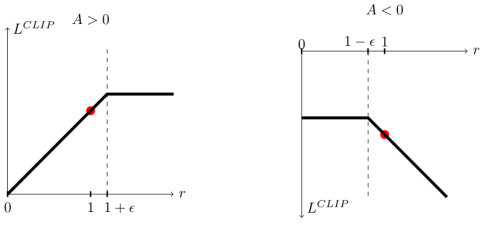


Figure 1: Plots showing one term (i.e., a single timestep) of the surrogate function L^{CLIP} as a function of the probability ratio r, for positive advantages (left) and negative advantages (right). The red circle on each plot shows the starting point for the optimization, i.e., $r = 1$. Note that L^{CLIP} sums many of these terms.

서브게이트 함수 L^{CLIP} 의 한 항(단일 timestep)을 확률비 r 의 함수로 그린 그래프.

좌: 이익이 양수 $(A > 0)$ — $r > 1 + \epsilon$ 에서 수평.

우: 이익이 음수 $(A < 0)$ — $r < 1 - \epsilon$ 에서 수평, $r > 1 + \epsilon$ 쪽은 계속 하강.

min이 만드는 “모서리”가 원 논문에서도 동일한 형태.

PPO의 전체 목적함수 — 세 항

실전 PPO는 Actor-Critic 구조(10.3절)이므로, L^{CLIP} 은 **정책(Actor) 부분**만. 실제 미니배치 갱신:

$$L(\theta) = \underbrace{\mathbb{E}_t\Big[\min\Big(r_t A_t,\ \text{clip}(r_t, 1-\epsilon, 1+\epsilon)A_t\Big)\Big]}_{\text{정책 손실(최대화)}} \underbrace{- c_v\,\mathbb{E}_t\big[(V_\theta(s_t) - \hat{R}_t)^2\big]}_{\text{Critic 손실(최소화)}} \underbrace{+ c_e\,\mathbb{E}_t\big[\mathcal{H}(\pi_\theta(\cdot \mid s_t))\big]}_{\text{엔트로피 보너스(탐험 유지)}}$$

- V_θ = 10.3절 Critic, $\hat{R}_t$ = Critic 업데이트 목표값 (실습: GAE로 계산한 어드밴티지 $+V$).
- c_v, c_e = 손실 스케일 정규화 상수 (실습: 0.5, 0.01).
- 엔트로피 항 = Week 5.2의 ϵ-greedy의 **연속 버전**.

엔트로피 보너스: $\log\sigma$ 를 잡아당기는 브레이크

왜 엔트로피 보너스를 넣으면 탐험이 유지되는가?

- 엔트로피 = 분포가 얼마나 퍼져 있는지의 척도 — Week 2 UCB와 같은 "탐험 유인"의 연속.
- **정규분포 정책에서는 엔트로피가 $\log\sigma$ 에 비례** — 이 항은 **표준편차를 줄이는 경향을 계속 반대 방향으로 잡아당기는 항**.
- 정책이 "이 토크가 정답이야"라고 확신을 가지는 속도를 조절하는 **브레이크** — 너무 빨리 **단정적으로** 하나에 수렴해서(탐험이 끝나버려서) 로컬 최적에 끼는 걸 늦춘다.

역사: PPO-1과 PPO-2

PPO 논문(Schulman, Moritz et al., 2017)에는 알고리즘이 **둘** 들어 있다. **PPO-1**: 경사 ascent 스텝 자체를 "KL 제약 이해를 확인하며" 잘게 쪼개는 방식 (TRPO line search의 단순형).
PPO-2: 클리핑만 한 버전 — 논문 공개 후 "더 단순하고 실전에서 거의 차이가 없거나 오히려 낫다"는 말이 빠르게 퍼져 **클리핑 버전(PPO-2)이 표준**. ML 역사에서 드문 경우: "더 단순한" 두 번째 버전이 커뮤니티에 의해 선택됨.

실습: Pendulum에서 PPO — 가우시안 정책

Pendulum-v1: 진자를 세워서 유지하는 고전 연속 제어 과제, 행동은 $-2 \sim +2$**Nm의 토크 하나**. 연속 행동공간에서는 정책이 정규분포의 평균·표준편차를 출력.

```
class GaussianPolicy(nn.Module):
    def __init__(self, state_dim, act_dim):
        super().__init__()
        self.net = nn.Sequential(nn.Linear(state_dim,64), nn.Tanh(),
                                 nn.Linear(64,64), nn.Tanh())
        self.mu = nn.Linear(64, act_dim)
        self.log_std = nn.Parameter(torch.zeros(act_dim) - 0.5)  # 학습가능한표준편차
    def forward(self, x):
        h = self.net(x)
        mu = torch.tanh(self.mu(h)) * act_high    # 행동범위에맞게스케일
        std = torch.exp(self.log_std)
        return mu, std
```

행동 샘플링: dist $=$ Normal(μ, std); $a =$ dist.sample(); $\log p =$ dist.log_prob(a).sum(). GAE로 advantage 계산 $\rightarrow$ 4 에폭 미니배치 재사용 $\rightarrow$ ppo_clip_loss로 정책 갱신.

연속 공간의 확률비 — 가우시안 로그가능도 미분

이산(softmax)에서는 $\pi_\theta(a \mid s)$ 가 단일 확률 값, 연속에서는 행동 a 가 연속 변수이므로 $\pi_\theta(a \mid s)$ 는 **정규분포** $\mathcal{N}(\mu_\theta(s), \sigma_\theta^2)$ **의 가능성(density)**.

$$\log \pi_\theta(a \mid s) = -\frac{1}{2}\Big(\frac{a - \mu_\theta(s)}{\sigma_\theta}\Big)^2 - \log \sigma_\theta + \text{const}$$

$$\nabla_\theta \log \pi_\theta(a \mid s) = \underbrace{\frac{a - \mu_\theta(s)}{\sigma_\theta^2}\, \nabla_\theta \mu_\theta(s)}_{\mu \text{ 항}} + \underbrace{\frac{(a - \mu_\theta(s))^2 - \sigma_\theta^2}{\sigma_\theta^3}\, \nabla_\theta \sigma_\theta}_{\sigma \text{ 항}}$$

정규분포 로그가능도의 $-\log \sigma$ 정규화 항이 없으면 σ 미분식에 $-1/\sigma$ 가 빠져 **틀어진다** — 빼먹기 쉬운 부분.

μ 항이 주인공, σ 항은 보조 변수

- 핵심 구조는 **Policy Gradient Theorem의 one-vs-rest 일반화**. 10.2절 softmax 그래디언트 $[(1-p_a)s,\ -p_a s]$ 의 "고른 행동 확률 올리고, 나머지는 내린다"가, 정규분포에서는 **"고른 행동 쪽으로 평균을 이동시킨다"**로 바뀜.
- μ **항**: 부호는 $a-\mu$ 의 부호로 정해짐. $A_t > 0$ 이면 고른 행동 쪽으로 평균이 당겨지고, $A_t < 0$ 이면 반대로 밀려남 — softmax의 "고른 행동을 올린다"가 정확히 이 μ 항.
- σ **항**: 부호가 $(a-\mu)^2 - \sigma^2$ 로 정해져 까다로움.
  - $|a-\mu| > \sigma$ ("의도하지 않은 극단적 행동") $\to \sigma$ **줄이는** 방향.
  - σ 이내(보통의 경우) $\to \sigma$ **늘리는** 방향.

기억하면 충분한 큰 그림

μ 가 주된 학습 대상이고, σ 는 A_t 의 부호와 엔트로피 보너스 사이에 놓인 보조 변수.

전체 알고리즘 루프

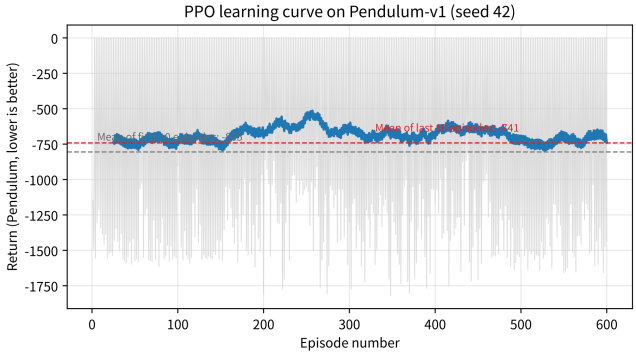
GaussianPolicy 만으로는 PPO가 아니다 — “데이터를 모은 뒤 여러 번 재사용하면서 클리핑으로 업데이트를 제한한다”는 절차가 PPO의 본체.

```
for iteration in range(N_ITER):           # 보통수백회
    # (1) 현재정책으로  STEPS 스텝상호작용 : (s,a,r,s') 수집
    #      + 각스텝의  logp_old = log pi_old(a|s), V_old(s) 저장
    # (2) 로GAE 각스텝의  A_t, 리턴목표  R_t 계산절 (11.3)
    #      A_t = A_t - mean / std 로정규화
    for epoch in range(N_EPOCH):          # (3) 같은데이터  4~10 에폭재사용
        for minibatch in shuffle_split(collected, MB_SIZE):
            mu, std, v = actor_critic(s_batch)
            logp_new = Normal(mu, std).log_prob(a_batch).sum()
            ratio = exp(logp_new - logp_old)    # <-- 절의11.1 r_t
            loss = -min(ratio*A, clip(ratio,1-eps,1+eps)*A).mean() \
                   + 0.5*((v - R_batch)**2).mean() \
                   - 0.01*Normal(mu, std).entropy().sum()
            optimizer.step()
    # (4) 이에 iteration 모은데이터버림   -> (1)로
```

세 가지 “왜”

- **왜 (1)에서 `logp_old`를 저장하는가?** $r_t = \pi_\theta / \pi_{\theta_{\text{old}}}$ 의 분모는 **데이터를 모았을 때의** 정책 — 그 당시 로그가능도를 저장해두고, (3)에서 현재 정책의 로그가능도를 계산해 비를 만든다. 저장하지 않으면 θ 가 이미 바뀐 뒤 재계산해 비가 1이 되는 시점이 “데이터 수집 시점”이 아니라 “갱신 시점”이 된다.
- **왜 (3)를 여러 에폭 돌리는가?** Week 9.4 재현 버퍼는 데이터를 영원히 저장, PPO는 **몇 에폭만** 쓰고 버림 — 클리핑이 “몇 에폭 재사용”이라는 제한 안에서만 안정성을 보장.
- **왜 (4)에서 버리는가?** on-policy 가정(데이터를 모은 정책 $\approx$ 현재 정책)이 에폭을 거듭할수록 깨져, r_t 가 클립 범위를 벗어나는 샘플이 많아지기 때문.

Pendulum 학습 결과 (300 반복 × 400 스텝)



시드 42, 총 12만 스텝. 연회색 = 에피소드별 리턴(항상 음수, 0에 가까울수록 좋음), 파랑 실선 = 25에피소드 이동평균.

처음 10 에피소드 평균	-805.3
마지막 10 에피소드 평균	-742.3

- 약 **8%** 개선, 여전히 절댓값이 크고 학습 곡선도 매끄럽지 않음 (중간 지점에서 오히려 나빠지는 구간도 있었음).
- 구현 오류가 아니라, Pendulum 같은 연속 제어는 완전 수렴에 **수십만∼수백만 스텝**이 필요 — 정직한 결과.
- DQN(CartPole, 300에피소드 만에 상당한 개선, 9.3절) 과 비교: 연속 제어가 이산보다 **더 오래** 걸림.

곡선의 “모양”에서 두 가지를 읽기

- **첫째 — 개별 에피소드의 변동폭이 크다.** Pendulum 리턴은 에피소드 초반에 쓰러지면 -1800 근처 (이번 실행 최소 -1820.6), 진자를 거의 수직으로 버티면 0 근처(최대 0.0 — upright 평형점 근처에 오래 머문 뜻)로 넓게 퍼짐. 10.2절 REINFORCE에서 배운 **“단일 에피소드 리턴의 분산이 크다”**는 문제와 **정확히 같은 본질** — PPO는 GAE(11.3)와 어드밴티지 정규화로 이 분산을 그래디언트 차원에서 줄이되, 에피소드 리턴 자체의 분산은 줄일 수 없다.
- **둘째 — 이동평균이 완만하게만 올라간다.** “학습이 안 된다”기보다 **12만 스텝이 이 과제에겐 부족하다** — Week 13∼14 로봇 시뮬레이션에서 보통 수백만 스텝을 계획하는 이유. (다른 seed에서는 마지막 10 에피소드 평균이 $\pm 100 \sim 200$ 차이, “완만한 상승”은 seed마다 안정적.)

자주 하는 실수 — θ_{old} 를 갱신 스텝마다 다시 계산하기

- (2)(∼)(3) 구간에서 "데이터를 모았을 때의 정책" 이 아니라 **"지금 이 갱신 스텝의 정책"**으로 r_t 의 분모를 계산하면,
- r_t 가 **항상 1 근처**(갱신 전의 현재 정책 대비 갱신 후의 현재 정책)로 압박되어 **클리핑이 거의 발동하지 않는다** —
- 결과적으로 PPO가 **"클리핑 없는 REINFORCE"로 전락**.

11.1절의 핵심을 기억하자

r_t 는 **옛 정책**(데이터 수집 시점)과 **새 정책**(갱신 시점)의 비이며, 분모의 "옛"은 **데이터 수집 시점**이지 갱신 직전이 아니다. 실습 코드의 `logp_old`를 (1) 구간에서 저장해두는 이유가 바로 이것.

자주 묻는 질문 — 구현 선택들

- **Q. `log_std`를 왜 상태와 무관한 파라미터로?** 구현 단순화 — "탐험 정도는 학습이 진행되며 전역적으로 줄어든다"는 가정 하나로 충분. (상태별 탐험을 원하면 신경망 출력으로 만들 수 있음.)
- **Q. 왜 매 반복마다 데이터를 새로 모으나요?** PPO는 on-policy의 연장선 — 클리핑은 "r_t 가 1에서 크게 벗어나지 않는다"는 전제로 설계. 오래된 데이터(정책이 많이 바뀜)는 애초에 r_t 가 클리핑 범위를 크게 벗어나 거의 기여 못 함. Week 9 경험재현(오래된 데이터 계속 재사용)과 **정반대**의 전략.
- **Q. `torch.exp(log_std)` 의 이유는?** $\sigma > 0$ 제약(표준편차는 양수)을 **파라미터 공간 자체에서** 강제 — $\log \sigma$ 는 $(-\infty, +\infty)$ 에서 자유롭게 움직여도 exp 후에는 항상 양수. Week 5 softmax가 logit 공간을 쓰는 것과 동일한 "제약을 파라미터 공간 밖으로 밀어낸다" 전략.

자주 묻는 질문 — ϵ 튜닝과 연속 vs 이산

- **Q. ϵ 을 0.05 또는 0.5로?**
  - 작으면 클립 구간 좁아져 한 번에 이동할 수 있는 거리 감소 — **안정성은 올라가지만 학습 느려짐**.
  - 크면 클립이 거의 발동하지 않아 사실상 **REINFORCE로 수렴**(더 공격적).
  - 실제 튜닝: 0.1∼0.3 사이 탐색, 0.2는 "안정성 vs 속도" 균형점의 경험적 기본값. (ϵ 과 GAE의 λ 는 독립적 하이퍼파라미터이나 함께 안정성에 영향 — 11.3 FAQ.)
- **Q. Pendulum이 DQN(CartPole)보다 느린 이유 (연속 vs 이산)?**
  - 이산: 최적점이 확률 벡터의 **꼭짓점** (예: $[1, 0]$) — softmax가 꼭짓점 근처까지만 밀어주면 됨.
  - 연속: 상태마다 "맞는 토크"가 연속 값 — $\mu_\theta(s)$ 가 **연속 매개변수 곡면 전체**를 상태별로 적절히 맞춰야 하고 σ_θ 도 함께 학습, 탐색할 파라미터 공간이 무한대. "근처까지"가 아니라 매 상태별 "적절한 값"에 접근해야 함 — 연속 제어가 근본적으로 어려운 점.

11.2절 요약

- PPO는 TRPO의 “신뢰 영역” 아이디어를, 2차 미분 최적화 대신 **목적함수 안의 min(클리핑) 한 줄**로 구현.
- min이 만드는 모서리: **개선 방향(좋은 것을 더, 나쁜 것을 덜)의 과도한 이동에만** 상한, 악화 방향에는 없음 — “비관적 쪽을 고르는” min의 비대칭.
- 전체 목적함수 = **정책 손실(L^{CLIP}) + Critic 손실 − 엔트로피 보너스** — 엔트로피 항이 $\log \sigma$를 잡아당겨 탐험을 유지.
- Pendulum 실습: 연속 제어는 이산 제어보다 느리지만, 그 느림은 구현의 결함이 아니라 **연속 행동공간의 탐색 체적**이라는 본질적 요인.

지금까지의 PPO

“구현하기 쉽고, 실전에서 잘 작동하는” 알고리즘 — 지금 가장 널리 쓰이는 정책기반 알고리즘.

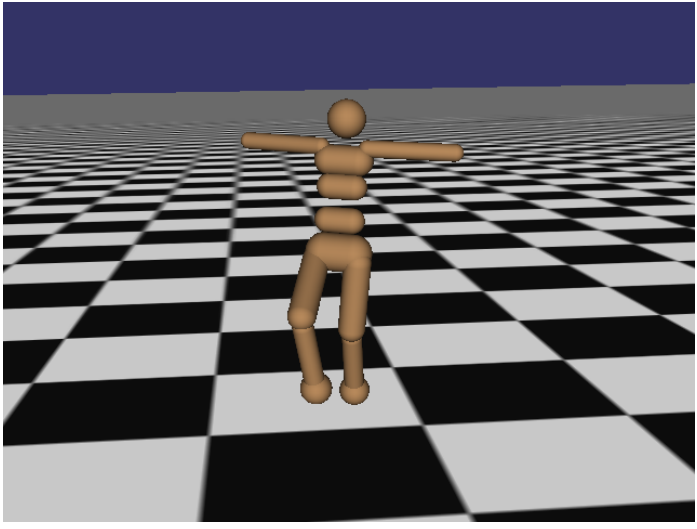
11.3 GAE와 PPO가 표준이 된 이유

위치: 골격만으로는 실전에 못 쓴다

11.2절까지 PPO의 골격(확률비 $\rightarrow$ 클리핑 $\rightarrow$ 미니배치 재사용)을 세웠지만, 골격만으로는 실전에 못 쓴다 — 11.2절 실습의 학습 곡선은 매끄럽지 않았고, Pendulum은 30만 스텝에도 -1092 에서 멈췄다.

- "PPO가 잘 동작한다"는 평판을 만들어준 **마지막 두 조각** = **GAE**(Generalized Advantage Estimation, 2016) + **엔트로피 보너스**.
- 이번 절: 그 둘을 배우고, 왜 PPO가 (1) 이론적으로는 TRPO(2015)에 못 미치고 (2) 구현은 **100배 단순**한데도 TRPO를 사실상 완전히 밀어내버렸는지 — "표준이 된 이유"를 정리.
- 마지막으로 "PPO를 돌린다"는 말이 실제로 어떤 코드 묶음을 의미하는지 실전 스택 전체를 훑음.

GAE 원 논문의 학습 곡선 (Figure 1)



3D 워커 환경 학습 곡선. **PPO+GAE** (청색)가 DDPG / TRPO / SAC 대비 **더 적은 반복 횟수로 높은 보상**을 달성.

GAE가 “평판”의 절반을 만들었다 — 11.2절의 골격만 으로는 이 곡선이 나오지 않는다.

GAE: TD와 MC 사이를 λ 다이얼로

10.3절의 어드밴티지 $A_t = G_t - V(s_t)$ 는 실제 리턴 G_t 를 그대로 쓰므로 여전히 **분산이 크다**.

GAE = Week 7의 n-step/적격흔적 아이디어를 **어드밴티지 추정**에 적용 — 여러 n-step 어드밴티지를 λ 로 가중평균, 분산은 낮추되 편향은 적당히만 감수:

$$A_t^{\text{GAE}} = \sum_{k=0}^{\infty} (\gamma\lambda)^k \, \delta_{t+k}, \qquad \delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$$

- δ_t 는 6.1절의 **TD 오차** 그 자체 — GAE는 "**여러 시점의 TD 오차를 적격흔적처럼 지수적으로 가중합**해서 하나의 어드밴티지 추정치를 만든다".
- $\lambda = 0$: **TD(0) 기반** (분산 작고 편향 큼). $\lambda = 1$: **몬테카를로 기반** (편향 없고 분산 큼).
- 7.2절의 다이얼이 여기서도 그대로 — 실전 PPO는 **거의 항상** GAE로 계산한 A_t 를 사용 (11.2절 `compute_gae` 가 바로 이 식).

n-step 어드밴티지와 GAE의 관계

n-step 어드밴티지를 따로 정의:

$$A_t^{(n)} := G_t^{(n)} - V(s_t) = \sum_{k=0}^{n-1} \gamma^k \, \delta_{t+k}$$

- **직접 확인할 것**: 두 식은 정확히 같다 — 좌변을 전개하면 실제 보상 $r_t + \gamma r_{t+1} + \cdots$ 가 나오고, 우변의 각 δ 를 정의대로 전개하면 같은 보상들이 γ^k 로 할인되어 합쳐지며, **가운데의 V 들이 연속적으로 상쇄**(telescoping: $\gamma V(s_{t+1}) - \gamma V(s_{t+1})$ 등).
- $n = 1$ 이면 $A_t^{(1)} = \delta_t$, 에피소드 길이보다 큰 n 이면 $A_t^{(n)} = G_t - V(s_t)$ (10.3절 원래 정의).

정리 (수식은 한 줄)

$$A_t^{\mathsf{GAE}} = (1-\lambda) \sum_{n=1}^{\infty} \lambda^{n-1} \, A_t^{(n)}$$

A_t^{GAE} 는 n-step 추정치들의 지수적 가중평균.

1. 각 $A_t^{(n)}$ 을 위 telescoping 식으로 바꾸면, 같은 δ_{t+k} 를 만드는 모든 n ($n > k$, 즉

손으로 계산: 3스텝 에피소드의 TD 오차

에피소드 3스텝: $s_0 \to s_1 \to s_2 \to s_3$ (s_3 터미널), $\gamma = 0.9$, critic의 값 $V = [2.0,\ 1.4,\ 0.6,\ 0]$, 보상 $r = [1,\ 1,\ 0]$.

TD 오차 $\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$:

스텝	계산	δ
$t = 0$	$1 + 0.9 \times 1.4 - 2.0$	$+0.26$
$t = 1$	$1 + 0.9 \times 0.6 - 1.4$	$+0.14$
$t = 2$	$0 + 0.9 \times 0 - 0.6$	-0.60

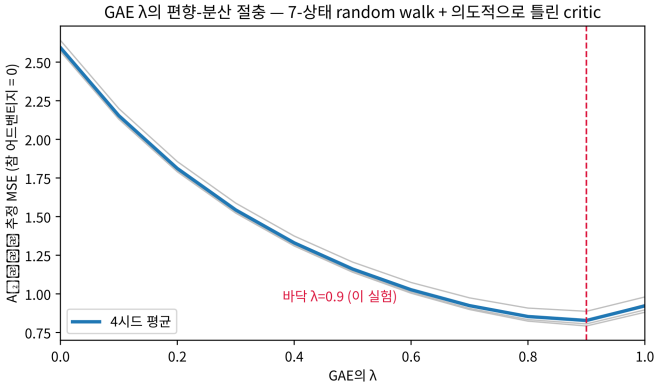
첫 스텝 s_0 의 GAE를 λ 별로 계산 — 각 항 가중계수 $(1,\ \gamma\lambda,\ \gamma^2\lambda^2)$:

λ 를 바꾸면 부호까지 바뀐다

λ	가중계수 $(1, \gamma\lambda, \gamma^2\lambda^2)$	A_0^{GAE}	읽기
0.0	$(1,\ 0,\ 0)$	0.26	δ_0 하나만 — "1스텝만 보고
0.5	$(1,\ 0.45,\ 0.2025)$	$0.26 + 0.45(0.14) + 0.2025(-0.60) = +0.20$	중간 — 세 항 다 포함
0.95	$(1,\ 0.855,\ 0.731)$	-0.059	거의 MC
1.0	$(1,\ 0.9,\ 0.81)$	$G_0 - V(s_0) = 1.9 - 2.0 = -0.10$	전체 리턴 기준 (MC)

- **같은 데이터**($\delta_0, \delta_1, \delta_2$)인데 λ 만 바꾸면 $+0.26$(좋았다)에서 -0.10(나빴다)까지 **부호까지** 바뀜.
- λ 가 "**신뢰하는 지평선의 길이**"이라는 뜻: 짧은 지평선($\lambda \approx 0$)은 "지금 당장의 TD 오차만 믿는다"(분산 적음, V 의 오차가 편향으로), 긴 지평선($\lambda = 1$)은 "에피소드 전체의 실제 리턴을 믿는다"(편향 없음, 리턴의 흔들림이 분산으로).
- 실전 기본값 $\lambda = 0.95$ = "긴 지평선에 거의 의존하되, 가장 먼 꼬리만 5% 정도로 얕은 신뢰"의 절충.

편향-분산 U자 — 이론이 아니라 실험



$\lambda = 0$(TD 기반, 편향↑분산↓) 에서 $\lambda = 1$(MC 기반, 편향↓분산↑) 사이의 U자 곡선.

실험(실습 1∼3절): 참값이 정확히 알려진 7-상태 random walk(7.2절과 같은 환경)에서, **의도 적으로 약간 틀린 critic**으로 TD 오차를 만들어 A^{GAE} 를 추정 — 참 어드밴티지가 0이므로 MSE가 곧 "편향^2+분산".

- λ 를 0→1로 훑으면 MSE가 **U자**, 바닥은 이 환경에서 $\lambda \approx 0.9$ 부근.
- n-step 어드밴티지로 같은 실험이면 바닥 $n \approx 3$ — GAE는 "n을 고정하고 λ 를 조정"하는 일반화.

7.2절의 교훈이 여기서도 그대로: 단일 실행(단일 시드)으로 최적 λ 를 정하면 안 된다 — 여러 시드의 평균으로 U자를 확인한 뒤, 바닥 근처 "0.90∼0.99" 사이의 값을 고르면 대체로 안전.

GAE 코드: 뒤에서부터 한 번만 스캔

무한합을 그대로 쓰면 각 t 마다 $O(T)$ 합 $\rightarrow O(T^2)$. 재귀를 쓰면 **뒤에서 앞에서 한 번만** 스캔:

```
def compute_gae(rewards, values, gamma=0.99, lam=0.95, last_value=0.0):
    T = len(rewards)
    gae, advantages = 0.0, [0.0] * T
    for t in reversed(range(T)):
        next_non_terminal = 1.0 if t < T - 1 else 0.0   # 터미널이면 0
        delta = rewards[t] + gamma * values[t+1] * next_non_terminal \
                - values[t]                              # δ_t
        gae = delta + gamma * lam * next_non_terminal * gae   # 재귀
        advantages[t] = gae
    return advantages
```

$$A_t^{\text{GAE}} = \delta_t + \gamma\lambda\, A_{t+1}^{\text{GAE}}$$

"지금의 TD 오차 + 할인된 미래 GAE" — `gae = delta + gamma * lam * gae` 한 줄이 바로 이 재귀식.
`next_non_terminal`: 터미널 상태 도달 시 "마지막 값" 0 처리 (그 뒤에 "계속될 에피소드"가 없음).
`last_value=0.0` = **에피소드가 끝난 뒤**의 값; 에피소드가 끝나지 않고 스텝 버퍼가 가득 찼다면 현재 정책으로 $V(s_T)$ 계산 (실습 5절 `collect` 가 이 둘을 구분).

GAE로 계산한 A_t 는 미니배치 단위로 정규화

$((A - \text{mean})/(\text{std} + 10^{-8}))$ 한 뒤 클리핑 목적함수에 씀 (11.2절 `ppo_clip_loss`). 역할은 10.2절 리턴 정규화와 동일 — 정규화하면 **학습률이 보상 스케일에 무관하게** 작동.

GAE의 두 가지 “자주 하는 실수”

1. **부호/위치 오류**: delta를 $r_t + \gamma V(s_t) - V(s_{t+1})$ 으로 쓰면(좌변·우변 뒤집음) **모든 어드밴티지의 부호가 반전**되어 정책이 **역으로** 학습. TD 오차 정의 = “실제로 벌어진 것 ($r_t + \gamma V(s_{t+1})$)”에서 “예측한 것 ($V(s_t)$)”을 뺀 것 — 6.1절과 대조하며 항상 한 번 확인.
2. **last value 0 처리 vs 정책 값 처리 혼동**: last_value는 *에피소드가 끝난 뒤*의 값.
   - 에피소드가 끝났다면(터미널) $\rightarrow$ **0**.
   - 끝나지 않고 스텝 버퍼가 가득 찼다면 $\rightarrow$ **현재 정책으로** 마지막 상태의 $V(s_T)$ 계산.

   “끝나지 않았는데 0 대입”하면, 좋은 상태일수록 마지막 스텝의 δ 가 음수로 과대평가(가치를 0으로 낮게 보는 셈)되어 정책이 끝 상태의 좋은 상태를 피하게 됨 — 학습이 느려지는 원흉 중 하나.

엔트로피 보너스: 탐험을 유지하는 작은 항

11.2절 실습의 `GaussianPolicy`는 $\exp(\texttt{log_std})$를 **학습 가능한** 파라미터로 두었는데, 무엇이 `log_std`를 줄여(탐험을 줄여) 갈까? 답은 세 번째 항:

$$L^{\text{PPO}}(\theta) = \mathbb{E}_t[L_t^{\text{CLIP}}] - c_v\,\mathbb{E}_t[(V_\theta(s_t) - R_t)^2] + c_e\,\mathbb{E}_t\Big[\underbrace{\mathcal{H}\big[\pi_\theta(\cdot \mid s_t)\big]}_{\text{엔트로피 보너스}}\Big]$$

- 세 항: **클리핑 항**(정책 = actor) + **Critic TD/리턴 손실**(V 를 어드밴티지 계산에 쓸 만큼 정확히 학습해야 GAE가 의미 있음) + **정책 엔트로피** 더하기.
- 클리핑은 "한 스텝의 이동"을 막는 **장치**일 뿐 — 정책이 천천히도 특정 행동에 확률을 1로 몰아붙일 수 있다. **탐험 소실(exploration collapse)**: 한 번 확률이 0에 가까워진 행동은 다시 샘플링될 기회가 없어 **영원히** 돌아오지 못함.
- 엔트로피 $\mathcal{H}[\pi(\cdot \mid s)] = -\sum_a \pi(a \mid s)\log\pi(a \mid s)$ 는 "정책이 얼마나 불확실한가(균등하면 최대)" — 최대화하면 **단일 행동에 수렴하는 것을 구조적으로 늦춤**, "한 행동에 확률을 몰아붙이지 마라"는 연료.

c_e 는 보통 $0.001 \sim 0.01$ — 작게

크게 하면 "무작위에 가까운 정책"을 장려해 성능 오히려 나빠짐. 가우시안 정책에서는 σ 가 클수록 엔트로피가 커지므로 이 항이 바로 `log_std`를 **올려** 주는 힘. 실전: `log_std`를 점진적으로 줄여 가는 (annealing) 방식도 함께 — "처음엔 많이 탐험, 수렴하면 줄여간다". 11.2절 Pendulum이 아주 느렸던

TRPO의 한 스텝이 왜 무거운가

PPO 이전에 같은 문제(너무 큰 업데이트로 인한 정책 붕괴)를 풀던 **TRPO**(2015): KL 제약을 명시적으로 걸고 2차 미분 도구로 최적화 — 한 스텝은 세 단계.

1. **KL 제약** $\mathbb{E}_t[D_{\mathrm{KL}}(\pi_{\theta_{\text{old}}} \,\|\, \pi_\theta)] \le \delta$ 를 명시적으로 해석 — 2차 근사(피셔 정보 행렬 $F = \mathbb{E}[\nabla \log \pi \, \nabla \log \pi^\top]$) 까지 쓰면 이 제약 아래 최대화는 F 의 **역행렬 곱**을 구해야 하는 **최대제곱(정준경로) 문제**.
2. F 는 파라미터 수 p 의 $p \times p$ 행렬 — 신경망 정책에서 p 가 수만∼수십만, **직접 역행렬은 불가**. "피셔-벡터 곱만 계산할 수 있으면 된다" 는 성질을 이용해 **conjugate gradient**(반복법)로 근사 해.
3. 근사해도 제약이 실제로 만족되는지 확인 — **line search**(제안 방향으로 얼마나 가도 안전한지).

세 단계 모두 "정책 그래디언트" 자체와 무관한 **최적화 장치**.

TRPO → PPO: 기계장치를 클리핑 한 줄로

- PPO는 이 세 단계를 **클리핑 한 줄**로 대체:

$$\min\Big(r_t A_t,\ \text{clip}\big(r_t, 1-\epsilon, 1+\epsilon\big) A_t\Big)$$

  r_t 가 $[1-\epsilon, 1+\epsilon]$ 범위를 벗어나면 밖으로 나간 만큼의 이득을 깎아버리는 **모노토닉 근사**.
- TRPO의 "단조 개선 **보장**"은 2차 근사 + line search가 **정확히** 동작할 때만 성립 — PPO는 그 보장을 **포기**하고 "보장이 안 되더라도 실전에서 잘 작동한다"는 경험적 증거로 승부.

구현 비용이 곧 채택의 차이

TRPO 참고 구현: 약 **300∼400줄**(피셔-벡터 곱, conjugate gradient, line search 포함). PPO: **100줄 안팎**. "같은 성능에 3배 적은 코드"가 아니라, **"대부분의 환경에서 충분히 좋은 성능에 3배 적은 코드"** — 연구실마다 TRPO 장치를 디버깅하는 시간 대신 PPO를 그냥 돌려보는 쪽으로 기울 수밖에 없었다.

역사적 일화: PPO-Clip vs PPO-Penalty

- PPO 논문(2017)은 실제로 TRPO를 “더 단순하게” 하고 싶다는 시도에서 출발 — 같은 연구팀(OpenAI, Schulman 외)이 먼저 TRPO(2015)로 “신뢰 영역” 개념을 세웠고, 다음 질문: “KL 제약을 풀어내는 그 무거운 최적화 없이, **클링(=클리핑)만으로** 비슷한 안정성을 얻을 수 있는가?”
- 논문에서는 클리핑(PPO-Clip) 외에도 **KL 페널티** 방식(PPO-Penalty: KL이 크면 목적함수에 벌을 부과)을 함께 제안.
- PPO-Penalty는 KL 벌의 계수를 **학습 중 동적으로 조정**해야 함 (너무 크면 탐험 부족, 너무 작으면 클리핑 없이 폭주) — **PPO-Clip 쪽이 훨씬 실용적**이라 실전에서 사실상 표준이 됨.

“PPO = 클리핑”이라는 현재 통념의 기원

이 선택의 결과 — “보장을 근사로” 바꾼 것이 이긴 드문 경우.

PPO는 TRPO보다 "나쁜" 알고리즘인가?

아니다 — "이론적 보장이 약하고, 실전 성능은 비견되는" 알고리즘.

- TRPO의 단조 개선은 2차 근사 + line search의 **정확성**에 의존 — 실전(큰 네트워크, 미니배치 샘플 노이즈)에서는 그 근사 자체가 충분히 정확하지 않음.
- 즉 **TRPO의 "보장"도 실전에서는 이론만큼 강하지 않다** — PPO가 "보장을 포기"하는 대가는 생각보다 작았고, **구현 단순성**이라는 이득은 컸다. 이것이 "표준이 된 이유"의 첫 번째 축.

이 실용성 덕분에

PPO는 지금 **가장 널리 쓰이는 정책기반 알고리즘** — 로봇 보행 제어, OpenAI Five(Dota 2, 2019), AlphaStar(스타크래프트 II, 2019)뿐 아니라, **RLHF**(인간 피드백으로 언어모델 조정)의 핵심 도구로도. **연속 제어(로봇의 관절 힘)와 이산 선택(다음 토큰 고르기) 양쪽 모두에 그대로 적용**될 만큼 범용적.

“범용적”이라는 말의 구체적 의미

PPO의 목적함수는 **행동공간이 이산이든 연속이든 같은 형태**.

이산 (CartPole, 언어모델의 토큰 선택)

- π 가 softmax.
- $\log \pi(a \mid s)$ 는 Categorical 분포의 로그확률.
- 행동은 argmax 대신 **샘플링** (10.2절 `torch.distributions.Categorical`).

연속 (Pendulum, 로봇 관절)

- π 가 **가우시안** $\mathcal{N}(\mu_\theta(s),\, \sigma_\theta^2 I)$.
- $\log \pi(a \mid s)$ 는 정규분포의 로그우도.
- 행동은 `dist.sample()` (11.2절 `GaussianPolicy`).

점

목적함수 $\mathbb{E}[L^{\text{CLIP}}]$ 과 GAE, 엔트로피 항의 **수학적 형식은 같다** — 변하는 건 “$\log \pi$ 를 어떤 분포에서 계산하느냐”뿐. (11.2절 FAQ의 “연속 정책이 tanh 로 스케일되는 이유”도 이 맥락: 가우시안의 지지공간이 실수 전체인데 실제 환경은 행동 범위가 $[-1, 1]$ 같이 제한 → tanh 로 압축.)

“PPO를 돌린다” — 실전 스택의 전체 그림

PPO 한 반복(1 iteration)이 실제로 하는 일, 위에서 아래로:

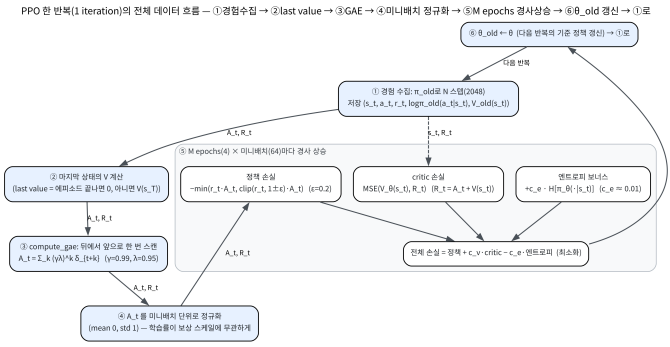
1. ① **경험 수집**: 현재 정책 $\pi_{\theta_{\text{old}}}$ 으로 N 스텝(예: 2048) 수집 — 스텝마다 $s_t,\ a_t,\ r_t,\ \log \pi_{\theta_{\text{old}}}(a_t \mid s_t),\ V_{\theta_{\text{old}}}(s_t)$ 저장.
2. ② **last value 계산**: 마지막 상태의 V 값.
3. ③ **compute_gae**: 각 스텝의 A_t ($\lambda = 0.95,\ \gamma = 0.99$).
4. ④ **정규화**: A_t 를 미니배치 단위로 (mean 0, std 1).
5. ⑤ M **epochs**(예: 4) 동안 미니배치(예: 64)마다 경사 상승: 정책 손실 $= -\min(r_t A_t,\ \text{clip}(r_t, 1 \pm \epsilon) A_t)$ ($\epsilon = 0.2$) + Critic 손실 MSE$(V_\theta(s_t), R_t)$ ($R_t = A_t + V(s_t)$) $-c_e\, \mathcal{H}[\pi_\theta]$.
6. ⑥ $\theta_{\text{old}} \leftarrow \theta$: 다음 반복의 기준 정책 갱신 $\rightarrow$ ①로.

스택의 각 단계 "왜 이렇게"

- ① N **스텝**: 너무 크면 수집 중에도 초기· 말기 정책이 달라져 r_t 가 클리핑 범위를 벗어나는 스텝 증가; 너무 작으면 GAE의 "긴 지평선" 이득 감소. 실전 $N = 2048,\ 4096$ 일반적.
- ③ **GAE($\lambda = 0.95$)**: 10.3절의 $A_t = G_t - V(s_t)$ ($= \lambda 1$, MC)를 **대신** — "거의 MC인데, 가장 먼 꼬리는 약간 얕게 본다".
- ④ **정규화**: 학습률을 보상 스케일에 무관하게 — **미니배치 단위**여야 함. 전체 N 스텝 단위로 하면 미니배치마다 스케일이 달라져(일부 미니배치의 A 가 0에 가까워져) 그 업데이트가 거의 사라짐.
- ⑤ M **epochs**: on-policy(REINFORCE)는 데이터 1회. PPO는 클리핑 덕분에 "데이터가 약간 오래돼도" 안전하게 재사용 — M 번(보통 4∼10). M 이 크면 on-policy에 가깝고(데이터 활용도↑) 클리핑 더 자주 발동. $M = 1$ **이면 사실상 A2C/A3C(10.3절)**와 같음.
- ⑥ θ_{old} **갱신**: 다음 반복에서 r_t 의 분모가 이번 반복 끝의 정책이 되도록 — 비율이 의미 있게 (1 근처에) 유지.

이 스택의 **모든 숫자**($N,\ M,\ \epsilon,\ \lambda,\ \gamma,\ c_v,\ c_e$, 학습률)가 하이퍼파라미터 — "PPO가 느리다/잘 못 배운다"는 불만의 상당 부분이 알고리즘이 아니라 이 숫자 조합에서 옴. ϵ 과 λ 는 독립적이지만 **함께** 학습 안정성에 영향.

PPO 한 반복의 전체 데이터 흐름



experience buffer가 GAE와 Critic 손실, 정책 손실(클리핑)로 분기, 엔트로피 항이 정책 손실에 더해지는 구조.

①경험수집 → ②last value → ③GAE → ④정규화 → ⑤M epochs 미니배치 경사상승 → ⑥ θ_{old} 갱신.

11.2절의 골격 + 11.3절의 GAE · 엔트로피 = **실전 스택**.

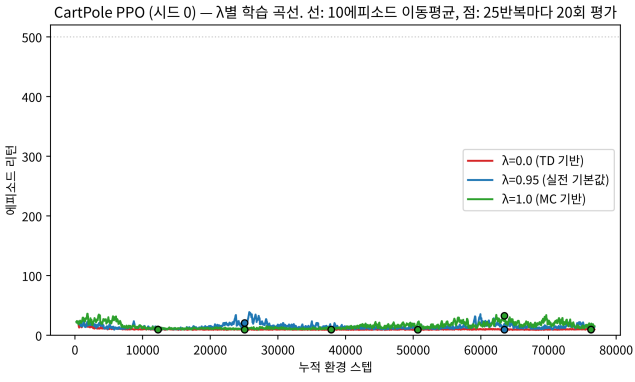
실습: CartPole에서 λ 를 바꿔가며 PPO

이론 검증 — CartPole(이산 행동)에서 PPO를 λ **를 바꿔가며** 학습, GAE의 절충점을 눈으로 확인. 11.2절 Pendulum(연속, 30만 스텝에도 -1092)과 달리 CartPole은 이산 보상(매 스텝 $+1$, 최대 500)이라 **5만 스텝 안에도** 명확한 차이.

세 가지 λ — 0.0 (TD(0) 기반, 편향↑분산↓), 0.95 (실전 기본값), 1.0 (MC 기반, 편향↓분산↑) — 을 **같은 시드(0), 같은 반복 수**(150×512 스텝 ≈ 7.7만 스텝)로.

λ	처음20 리턴	마지막20 리턴	최고 리턴	20에피소드 평가 (평균/최고)
0.0 (TD)	55.7	126.5	270	272 / 301
0.95 (기본)	29.8	141.2	442	274 / 317
1.0 (MC)	26.1	169.1	449	**500 / 500**

λ 학습 곡선 비교 — “모양”이 달라짐



CartPole, $\lambda = 0.0/0.95/1.0$ PPO 학습 곡선 비교 (시드 0, 150×512 스텝).

이번 단일 실행에서 세 λ 가 각각 다른 모양으로 학습:

- $\lambda = 0.0$: 가장 **빠르게 시작** (처음20 = 55.7)하지만 100 반복 이후 100∼140대 에서 **정체**(최고 270) — “지금의 TD 오차”만 믿는 편향이 방향을 자주 틀리게 하는 흔적.
- $\lambda = 1.0$: 시작은 느렸지만 **후반에 가장 멀리**(마지막20 = 169.1), 평가 20개 에피소드 **모두 500**(만점).
- $\lambda = 0.95$: 어느 지표에서도 단연 우월하지 않지만, **어디 하나 치명적 결함도 없음**.

중요: 단일 시드 실험이므로 “$\lambda = 0.95$ 가 항상 이긴다”(또는 “1.0이 이긴다”)는 **보장은 없다** — 7.2절의 교훈처럼 여러 시드로 평균해야 한다. 이번 실습은 “λ 에 따라 학습의 모양이 달라지는 절충의 존재”를 보는 것이지, 어느 λ 가 최적 인지를 증명하는 것이 아니다.

자주 묻는 질문 — GAE와 PPO의 하이퍼파라미터

- **Q. GAE의 λ 와 클리핑의 ϵ 은 독립적?** 역할은 다르지만 **함께** 학습 안정성에 영향 — λ 는 "어드밴티지 추정 자체의 편향-분산", ϵ 은 "그 추정을 바탕으로 정책을 얼마나 크게 바꿀 것인가". 어드밴티지 추정이 노이즈가 크면(λ 가 1에 가까우면) 클리핑이 그 노이즈로부터 정책을 **보호**하는 역할이 더 중요 — 실전에서는 둘 함께 튜닝.
- **Q. RLHF에서 PPO는 무엇을 "행동"으로 보나?** 언어모델을 정책으로 볼 때 **상태** = 지금까지 생성된 토큰들, **행동** = 다음에 고를 토큰, **보상** = 보상모델의 점수. 토큰 하나하나를 고르는 것이 이산 행동 선택이므로 이번 장의 **이산 행동공간 PPO가 사실상 그대로 적용** — 로봇(연속)과 언어모델(이산)이라는 완전히 다른 응용에 같은 알고리즘이 쓰이는 것 자체가 "행동공간 형태에 크게 의존하지 않는" 범용성의 증거.
- **Q. GAE의 λ 와 7절 적격흔적 TD(λ)의 λ 는 같은 것인가?** "같은 아이디어"지만 **적용 대상이 다름** — 적격흔적의 λ 는 가치함수 V의 갱신에 "어떤 n-step TD를 가중합할지", GAE의 λ 는 어드밴티지 A_t를 "어떤 n-step 어드밴티지를 가중합할지" 결정. 수학적 구조(지수 가중 λ^k 의 합)는 같음 — 적격흔적은 critic 학습에, GAE는 actor의 어드밴티지 계산에.
- **Q. 엔트로피 c_e 를 너무 크게?** "무작위에 가까운 정책"이 장려되어, 좋은 행동을 찾았을 때도 확률을 높이지 못해(엔트로피 최대화가 "균등한 확률"을 유지하려 함) 성능 오히려 나빠짐 — 실전 $c_e = 0.001 \sim 0.01$ 로 작게, 끝단계에서 0으로 줄여(annealing) "탐험 종료".

이번 주차 정리

- **11.1 신뢰 영역과 확률비** —
  - 신뢰 영역 = 한 걸음의 크기를 “믿을 수 있는 범위”(KL 발산)로 제한하는 직관.
  - 확률비 $r_t = \pi_\theta / \pi_{\text{old}}$: 첫 스텝에서는 정직한 policy gradient, r_t 가 크면 분산 $e^{\mu^2} - 1$ 으로 지수적 불어나기 → 소수 극단 샘플 지배.
- **11.2 PPO 클리핑과 연속 제어** —
  - 클리핑 한 줄: min의 모서리가 **개선 방향에만** 상한(비대칭). 전체 목적함수 = 정책 + Critic − 엔트로피.
  - Pendulum 실습: 연속 제어는 탐색 체적 때문에 본질적으로 느림(12만 스텝 ≈ 8% 개선).
- **11.3 GAE와 실전 스택** —
  - GAE = 여러 시점 TD 오차의 지수 가중합 (λ 로 TD↔MC 절충, 기본값 0.95) + 엔트로피 보너스가 탐험 소실을 늦춤.
  - TRPO의 300∼400줄 장치를 클리핑 100줄로 대체 → “보장은 근사로, 실용성은 그대로” — 표준이 된 이유.

PPO 공식

PPO = (11.1 확률비) × (11.2 클리핑) + (11.3 GAE · 엔트로피 · 실전 스택) — 각각 빠지면 “폭주(REINFORCE)”, “불안정(클립 없는 IS)”, “느리고 탐험 소실(GAE/엔트로피 없음)”.