k-means 클러스터링

라벨 없이 무리 나누기: 할당과 갱신의 반복

Machine Learning 1

한국과학영재학교 (KSA)

오늘의 질문



집 30곳에 배달 기지 3곳

집마다 가장 가까운 기지에서 배달한다

기지를 어디에 지어야
배달 거리가 가장 짧을까?

정답 라벨이 없는 학습

지도 학습 데이터 + **정답 라벨** kNN: 이웃의 라벨로 다수결

비지도 학습 데이터만 **k-means**: 비슷한 것끼리 k 개 무리로

k-means = k 개의 평균 (mean) 으로 데이터를 대표한다

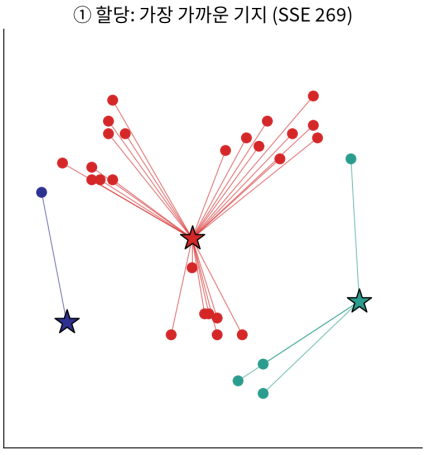
고객 나누기, 사진 색 줄이기, 문서 묶기 $\cdots$ 무리를 나누는 것 = 클러스터링 (clustering)

목표: 거리 제곱의 합을 가장 작게

$$\text{SSE} = \sum_{i=1}^{m} \left\| \mathbf{x}^{(i)} - \mathbf{c}_{a(i)} \right\|^2$$

$\mathbf{x}^{(i)}$	i 번째 집의 위치
$\mathbf{c}_j$	j 번째 기지의 위치 ($j = 1, \ldots, k$)
$a(i)$	i 번째 집을 맡은 기지 번호
SSE	sum of squared errors: 집과 맡은 기지 사이 거리 제곱의 합

① 할당: 집마다 가장 가까운 기지



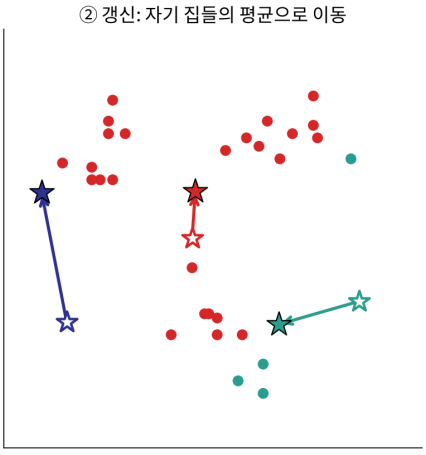
기지 3곳을 **아무 데나** 둔다

$$a(i) = \arg\min_{j} \left\| \mathbf{x}^{(i)} - \mathbf{c}_j \right\|$$

기지 위치를 고정하면, 집마다 가장 가까운 기지를 고르는 게 최선

지금 SSE = 269

② 갱신: 기지를 자기 집들의 평균으로



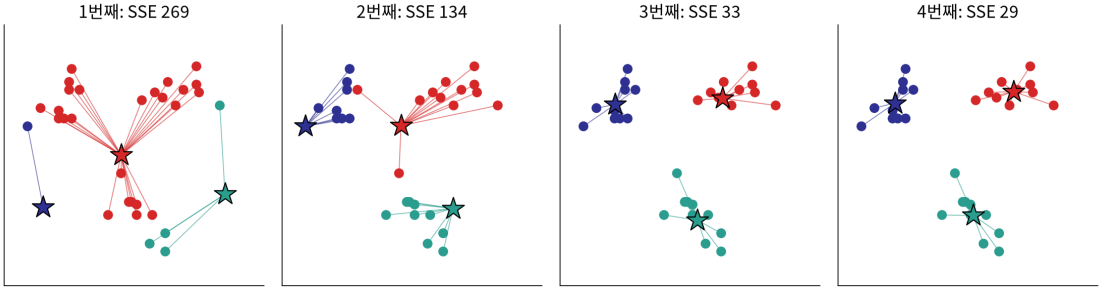
$$\mathbf{c}_j = \frac{1}{|S_j|} \sum_{i \in S_j} \mathbf{x}^{(i)}$$

S_j: 기지 j 가 맡은 집들

예: 집 $(2,6), (4,8), (6,7) \rightarrow$ 기지 $(4,\ 7)$

맡은 집이 정해지면, **평균 위치**가 거리 제곱 합을 가장 작게 한다

①② 를 반복하면



SSE 269 → 134 → 33 → **29** 더 움직이지 않으면 멈춘다

왜 반드시 멈출까

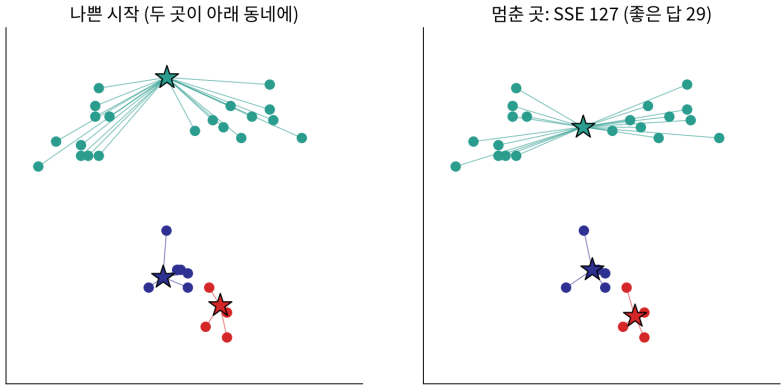
① 할당　기지를 고정하고 가장 가까운 곳을 고른다 → SSE **줄거나 그대로**

② 갱신　집을 고정하고 평균으로 옮긴다 → SSE **줄거나 그대로**

SSE 는 한 번도 늘지 않고, 집을 나누는 방법은 유한하다 → 언젠가 멈춘다

단, 멈춘 곳이 **가장 좋은 답**이라는 보장은 없다

시작이 나쁘면



두 기지가 아래 동네에서 시작 → SSE **127** 에서 멈춤 (좋은 답은 29) 집 6 · 4 · 20채

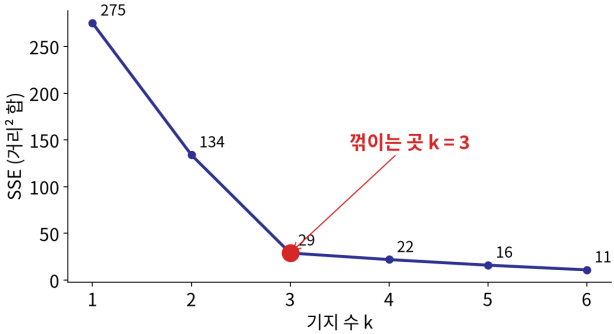
해결: 여러 번 시작하고, 똑똑하게 시작하기

여러 번 시작 시작점을 바꿔 여러 번 돌리고 SSE 가 가장 작은 것

k-means++ 첫 기지는 아무 집에, 다음은 **기존 기지에서 먼 집**일수록
잘 뽑히게 (거리^2 에 비례) $\rightarrow$ 한 동네에 몰려 시작하지 않는다

scikit-learn `KMeans` 의 기본값: k-means++ 시작, 여러 번 돌려 최선 (`n_init`)

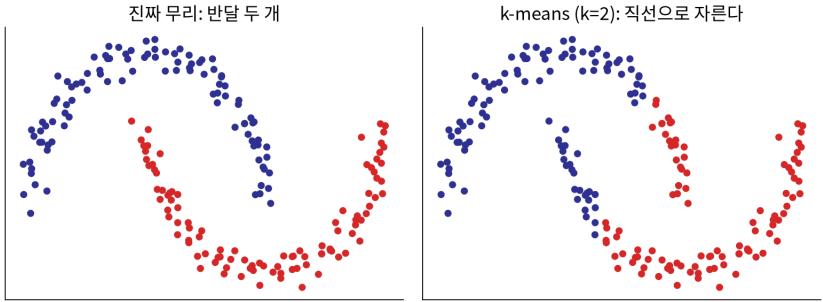
k 는 몇 개? 엘보우 방법



k 를 늘리면 SSE 는 계속 준다 (집마다 기지를 두면 0) $\rightarrow$ **꺾이는 곳**을 고른다

275 $\rightarrow$ 134 $\rightarrow$ 29 로 크게 줄다가, 그 뒤로는 22, 16, 11 로 조금씩. 팔꿈치(elbow) 모양

k-means 가 못 하는 것



무리 = **중심 하나 + 둥근 모양** → 휘어진 무리는 못 나눈다

거리로 나누니 kNN 처럼 **단위**도 문제 → 표준화 먼저 (실습)

문제풀이

1. 1차원 점 1, 2, 3, 10, 11, 12 와 기지 $c_1 = 2, c_2 = 5$. (a) 할당은? (b) 갱신 후 기지는? (c) 한 번 더 하면?
2. 집 4채 $(0,0), (2,0), (0,2), (2,2)$ 를 기지 하나가 맡는다. SSE 를 가장 작게 하는 기지 위치와 그때의 SSE 는?
3. 엘보우 그래프에서 SSE 가 $k = 1 \sim 5$ 에 100, 60, 40, 30, 25 였다. 어떤 k 를 고르겠나? 이 그래프만으로 정하기 어려운 이유는?

실습

1. 할당 · 갱신 직접 구현 $\rightarrow$ 슬라이드의 집 30곳으로 SSE 269 $\rightarrow$ 29, 나쁜 시작 127 재현
2. 실제 데이터: 펭귄 333마리를 종 라벨 **없이** 3무리로 $\rightarrow$ 진짜 종과 비교
3. 표준화 전후 비교 + 엘보우로 k 고르기

Palmer Penguins (Gorman et al., 2014)

▶ Colab에서 실습 노트북 열기

정리

k-means 라벨 없이 k 개 무리로 목표: 거리 제곱 합 (SSE) 최소

① 할당 (가장 가까운 중심) ② 갱신 (평균으로) 을 멈출 때까지 반복

SSE 는 늘지 않지만 **지역 최솟값**에 멈출 수 있다 $\rightarrow$ 여러 번 · k-means++

k 는 엘보우로 둥근 무리 가정, 단위 문제 $\rightarrow$ 표준화