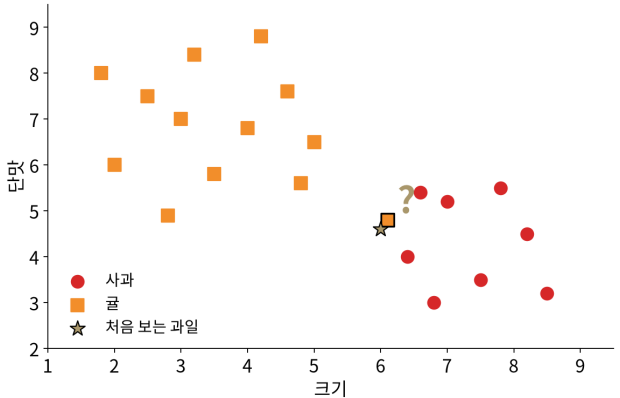
kNN 최근접 이웃 (k-Nearest Neighbors)

가장 가까운 k개에게 물어보기, 그리고 차원의 저주

Machine Learning 1

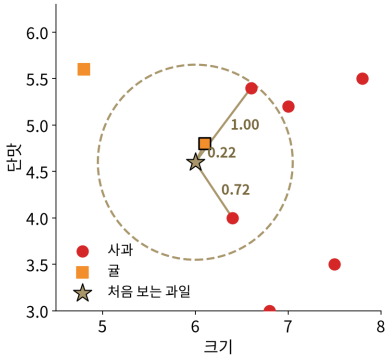
한국과학영재학교 (KSA)

오늘의 질문



크기와 단맛을 잰 과일 21개. **처음 보는 과일 (별) 은 사과일까, 귤일까?**

가장 가까운 3개에게 묻기



$k = 3$: 가장 가까운 3개

귤 1 · 사과 2

$\rightarrow$ 다수결로 **사과**

kNN = k-Nearest Neighbors
(k-최근접 이웃)

“가깝다” = 유클리드 거리

$$d(\mathbf{x}, \mathbf{q}) = \sqrt{\sum_{j=1}^{n} (x_j - q_j)^2}$$

별 $(6.0,\ 4.6)$ **과 사과** $(6.4,\ 4.0)$**:** $\sqrt{(6.4-6.0)^2 + (4.0-4.6)^2} = \sqrt{0.16 + 0.36} = 0.72$

n: 특징 수 (지금은 크기 · 단맛, 2개) 특징이 몇 개든 같은 식

학습이 없는 학습

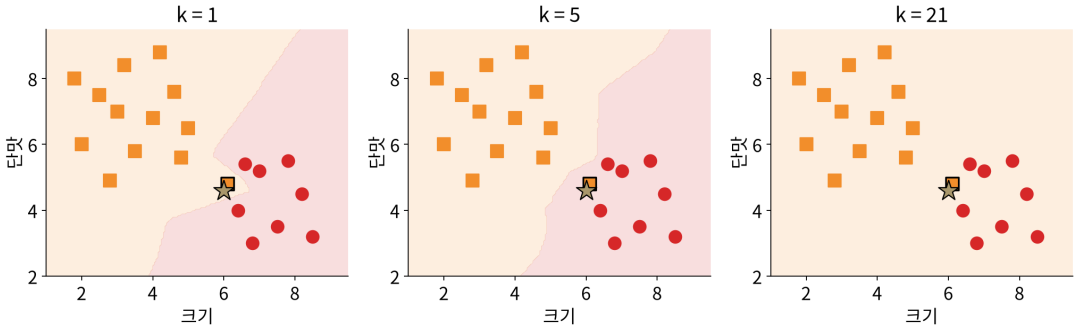
학습 데이터를 **외워 두기만** 한다 (가중치도, 경사하강법도 없다)

예측 ① 모든 점과 거리 재기 ② 가까운 순 정렬 ③ 앞의 k 개 다수결

데이터 m 개, 특징 n 개 $\rightarrow$ 예측 한 번에 거리 계산 m 번 (각각 n 개 더하기)

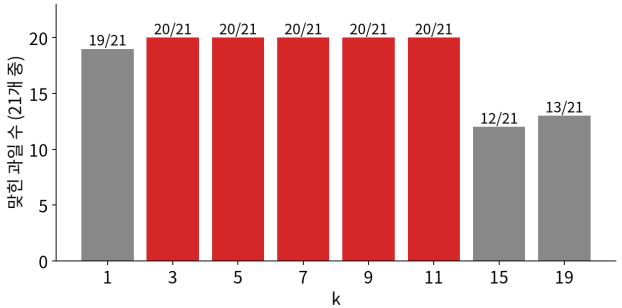
선형회귀는 학습이 느리고 예측이 빠르다. kNN 은 반대: **비용이 예측할 때 몰린다**

k 가 너무 작거나 너무 크면



$k = 1$: 잘못 적힌 귤 (검은 테두리) 하나에 속는다 $k = 21$: 전체 다수결 $\rightarrow$ **늘 귤**

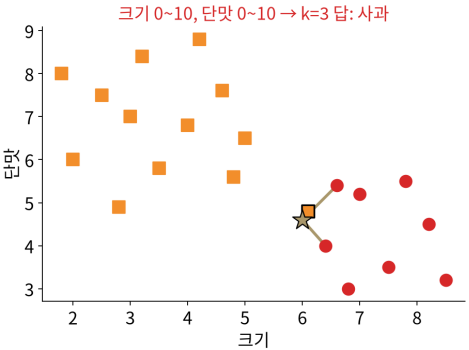
k 는 검증으로 고른다

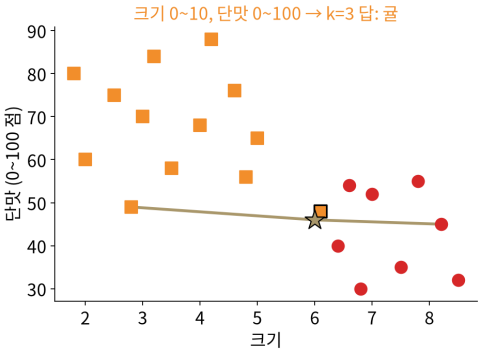


하나씩 빼 두고 나머지 20개로 맞혀 보기 $k = 3 \sim 11$ 이 **20/21**

leave-one-out: 조각 크기가 1 인 교차 검증

단맛을 100 점 만점으로 재면?





단위만 바꿨는데 $k = 3$ 의 답이 **귤**로 거리를 **단맛**이 혼자 정한다

해결: 특징마다 같은 목소리 (표준화)

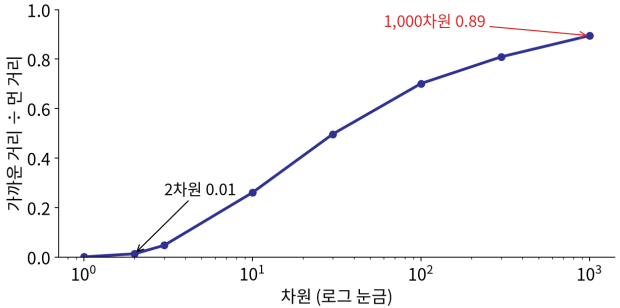
$$z_j = \frac{x_j - \mu_j}{\sigma_j}$$

특징마다 평균 0, 표준편차 1 로 맞춘 뒤 거리를 잰다 (가우시안 시간의 z 점수)

실제 데이터 (와인 178병, 특징 13개): 그대로 **71%** 표준화 후 **97%** ($k = 5$)

와인 데이터에서 프롤린은 수백 $\sim$ 1,600, 색 농도는 1 $\sim$ 13 $\rightarrow$ 그대로 두면 프롤린 하나가 거리를 정한다

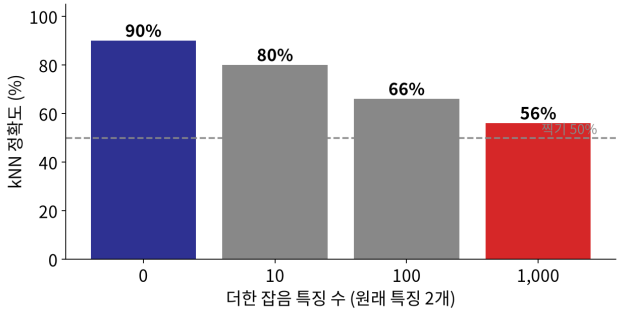
차원의 저주: 가까운 이웃이 사라진다



가장 가까운 거리 ÷ 가장 먼 거리 (점 1,000개): 2차원 **0.01** → 1,000차원 **0.9**

차원이 높으면 가장 가까운 점도 가장 먼 점만큼 멀다 Curse of Dimensionality (Bellman, 1957)

뜻 없는 특징을 더하면



두 반달 데이터 (특징 2개) 에 난수 특징을 더하면 90% → 80 → 66 → **56%**

특징은 많을수록 좋은 게 아니다 → 쓸모 있는 특징만 고르거나, 차원을 줄인다 (14주차 PCA)

문제풀이

1. 점 A $(1, 1)$ 사과, B $(2, 3)$ 귤, C $(4, 1)$ 사과, D $(3, 4)$ 귤. 새 점 $(2, 2)$ 에 대해 (a) 네 거리는? (b) $k = 1$, $k = 3$ 의 답은?
2. 학습 데이터 100만 개로 kNN 과 선형회귀를 만들었다. 예측 한 번이 더 오래 걸리는 쪽은? 이유는?
3. 키 (cm) 와 몸무게 (kg) 로 kNN 을 한다. 키를 mm 로 바꾸면 무슨 일이 생기나? 어떻게 막나?
4. 특징 2개로 90% 이던 kNN 에 특징을 50개 더했더니 70% 가 됐다. 무엇을 의심해야 하나?

실습

1. kNN 직접 구현: 거리 · 정렬 · 다수결 $\rightarrow$ 슬라이드의 과일로 $k = 1, 3, 21$ 재현
2. 실제 데이터: 와인 178병, 표준화 전후 비교 (71% $\rightarrow$ 97%)
3. 교차 검증으로 k 고르기 + 잡음 특징을 더하며 차원의 저주 보기

Wine (Forina et al.; UCI)

▶ Colab에서 실습 노트북 열기

정리

kNN 가장 가까운 k 개의 다수결 학습 없이 외우고, 예측 때 거리를 잰다

k 가 작으면 과대적합, 크면 과소적합 $\rightarrow$ **교차 검증**으로 고른다

단위가 다르면 거리가 왜곡된다 $\rightarrow$ **표준화** 먼저

특징이 많으면 이웃이 사라진다 $\rightarrow$ **차원의 저주**