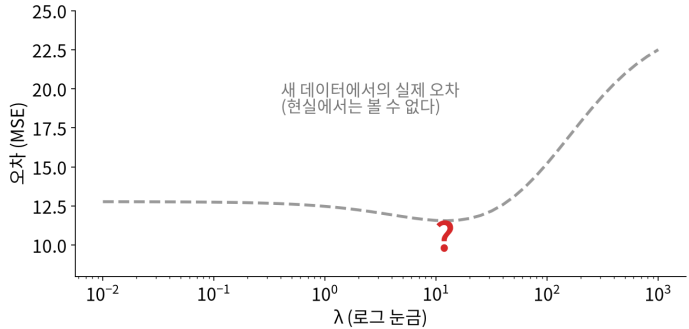
교차 검증 (Cross Validation)

λ 를 데이터로 정한다

Machine Learning 1

한국과학영재학교 (KSA)

오늘의 질문



λ 에 따른 오차는 U 자. **그런데 현실에서는 이 곡선이 안 보인다.**

오늘의 예시: 학생 60명, 특징 30개

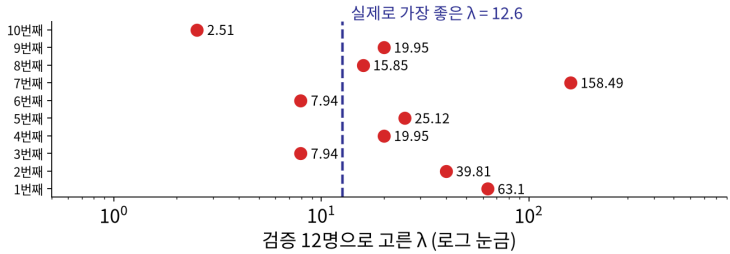
$$y = 3x_1 - 2x_2 + 1.5x_3 + \text{noise} \qquad (x_4 \sim x_{30} : \text{쓸모없는 특징 27개})$$

특징 30개에 데이터 60개 $\rightarrow$ 그냥 맞추면 잡음을 외우기 쉽다 $\rightarrow$ **릿지**

후보 λ 51개 ($0.01 \sim 1000$, 로그 간격) 중 하나를 골라야 한다

예시라서 새 데이터 2만 개로 “실제 오차”를 잴 수 있다 (채점용, 고를 때는 안 쓴다)

검증 데이터를 한 번만 떼어 두면



학습 48 · 검증 12 로 **무작위로** 10번 나누면 고른 λ: **2.5 ∼ 158**

검증 12명이 누구냐에 따라 답이 60배 넘게 달라진다 → 한 번의 분할은 운이다

k 겹 교차 검증: 모두가 한 번씩 검증 데이터

$$\mathrm{CV}(\lambda) = \frac{1}{k}\sum_{j=1}^{k} \mathrm{MSE}_j(\lambda)$$

1. 데이터를 k 조각으로 나눈다 (오늘은 $k = 5$, 한 조각 12명)
2. 조각 j 를 숨기고 나머지 48명으로 학습 $\rightarrow$ 숨긴 12명의 MSE_j
3. $j = 1, \ldots, k$ 반복해서 평균 $\rightarrow$ 모든 학생이 정확히 한 번 검증에 쓰인다
4. λ 후보마다 1~3 을 하고, $\mathrm{CV}(\lambda)$ 가 가장 작은 λ^* 를 고른다

손으로 한 번: 평균만 내는 모델

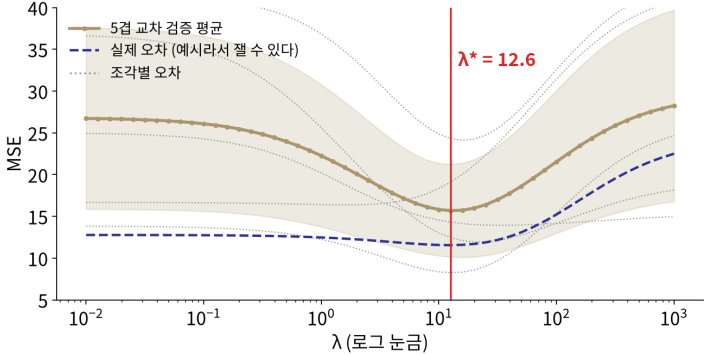
데이터 $y = 1, 2, \ldots, 10$ 모델: 학습 데이터의 **평균**으로 예측 순서대로 2개씩 5조각

조각	검증	학습 8개의 평균	MSE
1	1, 2	6.5	$\frac{(1-6.5)^2+(2-6.5)^2}{2} = 25.25$
2	3, 4	6.0	6.50
3	5, 6	5.5	0.25
4	7, 8	5.0	6.50
5	9, 10	4.5	25.25

$$\text{CV} = \frac{25.25 + 6.5 + 0.25 + 6.5 + 25.25}{5} = \mathbf{12.75}$$

조각마다 크게 다르다

5겹 교차 검증으로 고른 λ



교차 검증 바닥 $\lambda^* = \mathbf{12.6}$ = 실제 오차가 가장 작은 λ (11.56)

$\lambda = 0.01$: 실제 12.78 $\lambda = 1000$: 22.5 높이는 달라도 **바닥 위치**를 맞힌다

바닥에서도 조각마다 다르다

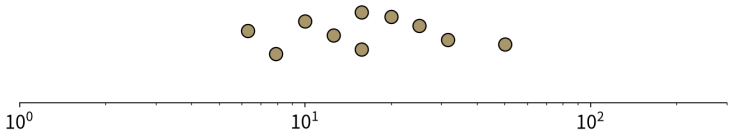
$\lambda^* = 12.6$ 에서 조각 5개의 MSE: 19.1, 8.3, 12.4, 24.3, 14.3

평균 **15.69** 표준편차 **5.54**

바닥 근처 λ 끼리의 차이 < 조각 사이 흩어짐 $\rightarrow$ **그 근처 범위**가 다 괜찮다

1SE 규칙: 바닥 + 표준편차 1개 안에서 가장 큰 λ (79.4, 실제 오차 14.4) $\rightarrow$ 더 단순, 조금 손해

데이터를 새로 뽑으면 λ^* 도 흔들린다



새로 뽑은 데이터 10개에서 5겹 CV 가 고른 λ* (로그 눈금)

같은 규칙으로 60명을 10번 새로 뽑으면 λ^*: **6.3 ∼ 50**

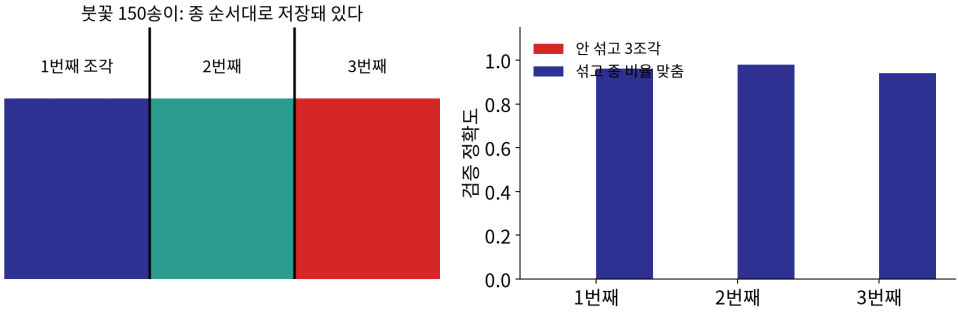
한 번 나눌 때 (2.5 ∼ 158) 보다 훨씬 좁다. 하지만 λ^* 도 데이터에서 나온 **추정값**이다

k 는 몇으로?

k	한 번 학습에 쓰는 비율	특징
2	50%	빠르지만 오차를 크게 본다
5, 10	80%, 90%	**가장 흔한 선택**
m (leave-one-out)	$m-1$ 개	학습 m 번, 데이터가 아주 적을 때

학습 횟수 $= k\times$ (후보 수) 오늘: $5 \times 51 = 255$ 번

흔한 실수: 정렬된 데이터를 섞지 않고 자르기



종 순서대로 저장된 붓꽃을 안 섞고 3조각 → 검증 정확도 **0, 0, 0**

학습에 없던 종만 검증에 나온다. 섞고 종 비율을 맞추면 (stratified) 0.96 · 0.98 · 0.94

고른 다음에: 최종 성능은 따로 잰다

1. 교차 검증으로 λ^* 를 고른다
2. 가진 데이터 **전부**로 λ^* 모델을 다시 학습한다
3. 최종 성능은 **한 번도 안 쓴 시험 데이터**로 잰다

고를 때 쓴 교차 검증 점수는 **조금 낙관적** (51개 중 가장 운 좋은 것)

$\rightarrow$ 다음 시간: train / val / test 분리와 데이터 누수

문제풀이

1. 데이터 $y = 2, 4, 6, 8$, 평균 모델, 순서대로 2조각 (2겹). 조각별 MSE 와 CV 는?
2. 데이터 1,000개, λ 후보 20개, 10겹 교차 검증. 모델을 모두 몇 번 학습하나? 마지막 재학습까지 치면?
3. 날짜 순으로 정렬된 주가 데이터에 섞어서 5겹 교차 검증을 했더니 정확도가 아주 높았다. 무엇이 의심스러운가?
4. 교차 검증 평균 오차가 $\lambda = 1$ 에서 10.0 (표준편차 2.0), $\lambda = 10$ 에서 10.5 였다. 어느 쪽을 고르겠나?

실습

1. k 겹 교차 검증 직접 구현 $\rightarrow$ 손 계산 12.75 와 $\lambda^* = 12.6$ 재현
2. 한 번 나누기 vs 5겹: 고른 λ 가 얼마나 흔들리나
3. 실제 데이터: 붓꽃 (안 섞으면 0%), 당뇨병 `LassoCV` 로 λ 고르기

Iris (Fisher, 1936) · Diabetes (Efron et al., 2004)

▶ Colab에서 실습 노트북 열기

정리

검증 데이터를 한 번만 떼면 **운**에 좌우된다 (λ: 2.5 $\sim$ 158)

k **겹 교차 검증** 돌아가며 숨기고 평균 $\rightarrow$ 바닥 $\lambda^* = 12.6$ (실제로도 최선)

조각마다 흩어짐이 있다 $\rightarrow$ 바닥 근처는 다 괜찮다 (1SE 규칙)

섞어서 자르고, 고른 뒤 최종 성능은 **시험 데이터**로