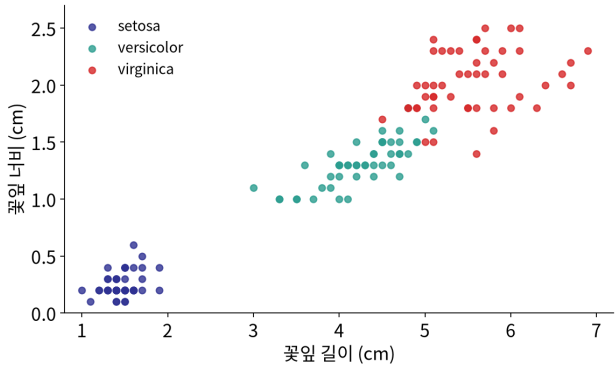
# 결정 트리 (Decision Tree)

## 스무고개처럼 질문으로 나누기, 좋은 질문 고르기

Machine Learning 1

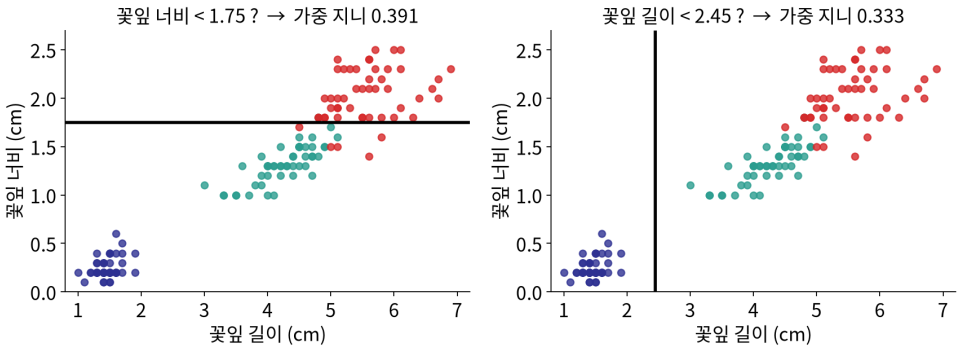
한국과학영재학교 (KSA)

# 오늘의 질문




붓꽃 150송이, 3종. 꽃잎 길이와 너비만 보고 **예 · 아니오 질문 몇 개로 가를 수 있을까?**

# 질문마다 나뉘는 정도가 다르다




왼쪽: 양쪽 다 여전히 섞여 있다　　오른쪽: 한쪽이 **setosa 만 50송이**

좋은 질문 = 나눈 뒤 **덜 섞이게** 만드는 질문

# 섞인 정도를 숫자로: 지니 불순도

$$\text{Gini} = 1 - \sum_{k} p_k^2$$

$p_k$: 그 칸에서 종 $k$ 의 비율

| | | | |
|---|---|---|---|
| 한 종만 | $1 - 1^2$ | **0** | (깨끗하다) |
| 두 종 반반 | $1 - 0.5^2 - 0.5^2$ | 0.5 | |
| 세 종 $\frac{1}{3}$ 씩 | $1 - 3 \times \left(\frac{1}{3}\right)^2$ | **0.667** | (붓꽃 150송이 전체) |

뜻: 칸에서 아무 꽃이나 하나 골라, 비율대로 아무렇게나 이름을 붙이면 틀릴 확률

# 손으로 한 번: 어느 질문이 더 좋은가

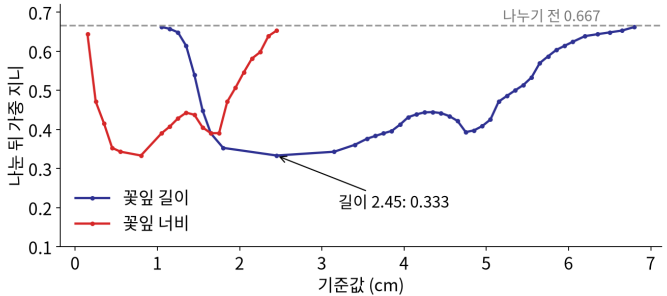
나눈 뒤의 불순도 = 양쪽 지니를 **꽃 수로 가중 평균**

$$\text{꽃잎 길이} < 2.45: \quad \frac{50}{150} \cdot 0 + \frac{100}{150} \cdot 0.5 = \mathbf{0.333}$$

$$\text{꽃잎 너비} < 1.75: \quad \frac{104}{150} \cdot 0.545 + \frac{46}{150} \cdot 0.043 = 0.391$$

0.667 에서 **0.333** 만큼 줄인 꽃잎 길이 질문을 고른다 (줄어든 양 = 정보 이득)

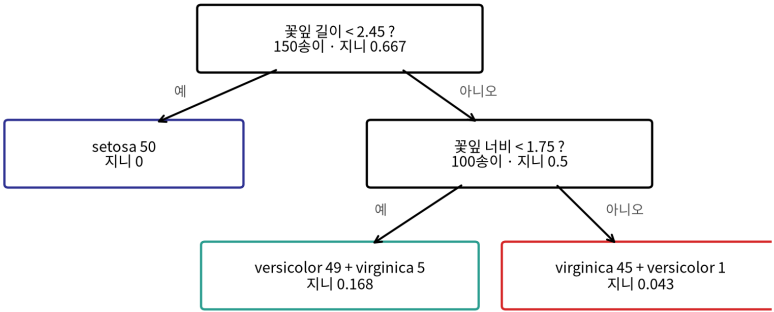
# 후보를 전부 재 본다




특징마다 정렬한 값들의 **중간점**이 모두 후보 → 가장 낮은 곳을 고른다

꽃잎 길이 2.45 와 꽃잎 너비 0.8 이 똑같이 0.333 (둘 다 setosa 만 깔끔히 떼어 낸다)

# 남은 칸에서 같은 일을 반복한다




남은 100송이를 꽃잎 너비 1.75 로 가중 지니 0.5 → **0.11** 질문의 끝 = **잎 (leaf)**

# 새 꽃은 질문을 따라 내려간다

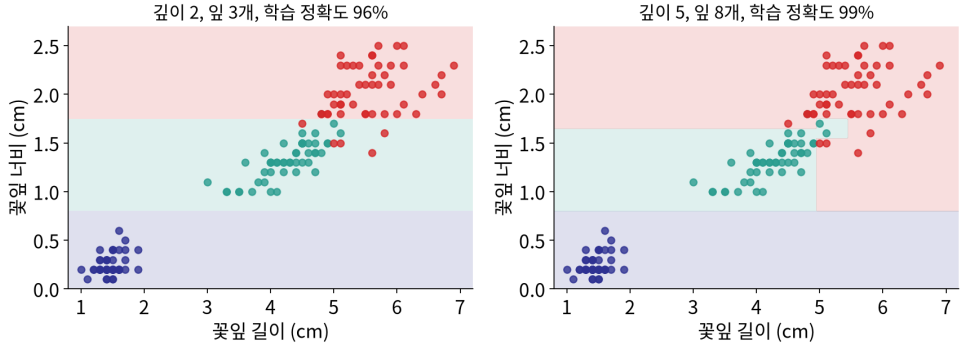
꽃잎 길이 5.1 cm, 너비 1.8 cm 인 새 꽃

길이 $< 2.45$? **아니오** $\rightarrow$ 너비 $< 1.75$? **아니오** $\rightarrow$ **virginica**

질문 2번이면 답이 나온다 그리고 **왜** 그렇게 답했는지 사람이 읽을 수 있다

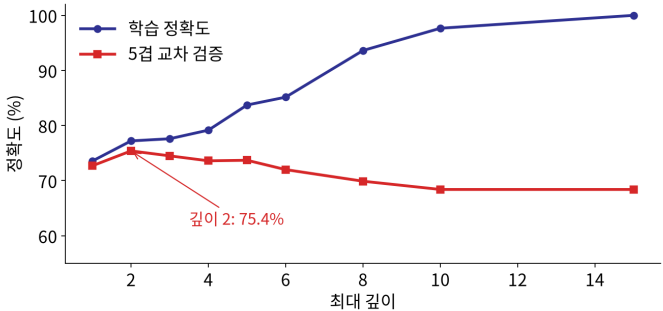
거리를 재지 않으니 단위가 달라도 상관없다 (표준화가 필요 없다)

# 끝까지 키우면




깊이 2: 잎 3개, 학습 96%  끝까지: 잎 8개, 학습 **99%** (경계의 몇 송이를 외운다)

# 섞인 데이터에서는: 깊을수록 시험에서 나빠진다




당뇨병 768명 (검사값 8개): 끝까지 키우면 학습 **100%** (잎 130개), 교차 검증 **68.6%**
깊이 2: 학습 77%, 교차 검증 **75.4%** → **최대 깊이**도 교차 검증으로 고른다

# 결정 트리의 장점과 약점

**장점** 사람이 읽을 수 있는 규칙 표준화 불필요 숫자 · 범주 특징 섞어 써도 된다

**약점** 깊으면 과대적합 데이터가 조금만 바뀌어도 트리 모양이 크게 바뀐다
경계가 축에 평행한 계단 모양뿐

약점을 메우는 방법: 트리를 **많이** 만들어 투표한다 → 랜덤 포레스트, GBDT

# 문제풀이

1. 한 칸에 사과 6, 귤 2 가 있다. 지니 불순도는?
2. 사과 4 · 귤 4 인 칸을 질문 A 는 (사과 4 · 귤 1) / (귤 3) 으로, 질문 B 는 (사과 2 · 귤 2) / (사과 2 · 귤 2) 로 나눈다. 각각의 가중 지니는? 어느 질문을 고르나?
3. 학습 정확도 100%, 교차 검증 정확도 65% 인 결정 트리. 무엇을 바꿔 보겠나?

# 실습

1. 지니 불순도와 가장 좋은 질문 찾기 직접 구현 → 붓꽃 0.333, 0.11 재현
2. scikit-learn 트리를 그려 보고, 새 꽃 판정 경로 따라가기
3. 실제 데이터: 타이타닉 891명 생존 예측, 최대 깊이를 교차 검증으로

Iris (Fisher, 1936) · Titanic (Kaggle / seaborn-data)

▶ Colab에서 실습 노트북 열기

# 정리

**결정 트리** 예 · 아니오 질문으로 칸을 나누고, 잎에서 다수결

좋은 질문 = 가중 **지니 불순도** $(1 - \sum p_k^2)$ 를 가장 많이 줄이는 질문

후보를 전부 재고 고른 뒤, 남은 칸에서 반복

깊으면 과대적합 $\rightarrow$ **최대 깊이**를 교차 검증으로 불안정 $\rightarrow$ 숲으로