# 트랜스포머와 그래프 신경망 (Transformer · GNN)

## 모든 단어가 이어진 그래프 위에서, 블록을 쌓는다

Machine Learning and Deep Learning

한국과학영재학교 (KSA)

# 오늘의 질문: ChatGPT 의 T 는?

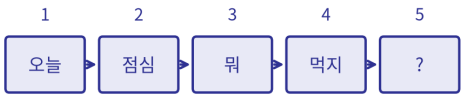
Chat Generative Pre-trained **T**ransformer

2017년 구글 논문 “**Attention Is All You Need**” (Vaswani 외 8명)

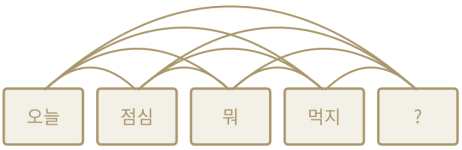
지금의 언어 모델 · 번역기 · 이미지 생성기 대부분이 이 구조 위에 있다

# RNN 은 차례로, 트랜스포머는 한 번에

RNN: 하나씩 차례로 (5걸음)




트랜스포머: 모든 쌍을 한 번에 (1걸음)




| | RNN | 트랜스포머 (셀프 어텐션) |
|---|---|---|
| 단어 $n$ 개를 읽는 차례 | $n$ 걸음 (앞이 끝나야 뒤) | **1** 걸음 (모두 동시에, GPU) |
| 첫 단어 $\leftrightarrow$ 끝 단어 | $n-1$ 걸음 거쳐 전달 | **바로** 연결 |
| 계산량 | $n$ 에 비례 | 모든 쌍: $n^2$ 에 비례 |

## 셀프 어텐션, 여러 개의 머리로

단어 벡터 $X$ ($n \times 512$) 에서 $Q = XW_Q,\ K = XW_K,\ V = XW_V$

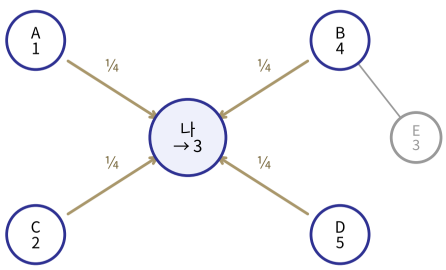
$$\text{head} = \text{softmax}\left(\frac{QK^\top}{\sqrt{64}}\right)V$$

**멀티헤드** 512칸을 **8개 머리** × 64칸으로 나눠 따로 → 이어 붙여 $W_O$

왜 여러 개? 머리마다 다른 관계 (주어 ↔ 동사, “피곤하다” ↔ 밤새: 이유)

지난 시간과 달리 $Q, K, V$ 를 **학습하는 행렬**로: 무엇을 찾을지 · 내걸지 · 줄지를 배운다

# 다른 눈으로: 그래프 신경망 (GNN) 한 층




점 = 사람, 선 = 친구 관계

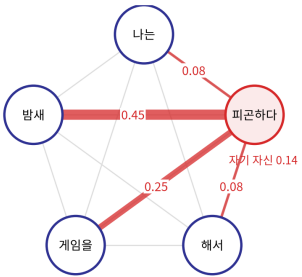
한 층에서 점마다 **이웃의 정보를 모아** 자기 정보를 고친다 (메시지 패싱)

$$\mathbf{h}'_i = \sum_{j \in N(i)} a_{ij}\, W \mathbf{h}_j$$

$N(i) = i$ 의 이웃 가장 단순하게: 친구 4명이면 $a_{ij} = \frac{1}{4}$ 씩 평균

E 는 친구의 친구: 이 층에서는 안 보이고, 층을 하나 더 쌓으면 닿는다 자세히는 다음 시간 GCN

# 트랜스포머 = 모든 단어가 이어진 그래프 위의 GNN




왜 피곤할까? 밤새 0.45 (어텐션 시간 손계산)

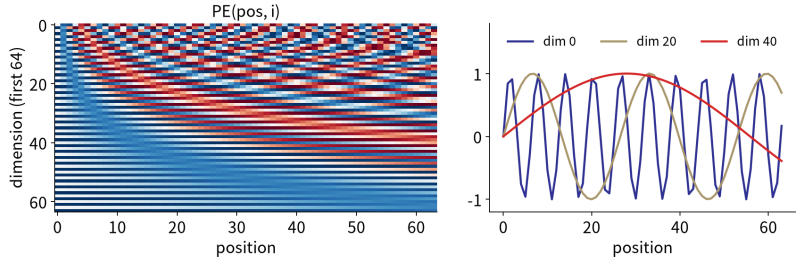
| | GNN | 트랜스포머 |
|---|---|---|
| 점 | 사람 | **단어** |
| 선 | 주어진 관계 | **모든 짝** (완전 그래프) |
| 무게 $a_{ij}$ | $\frac{1}{\text{이웃 수}}$ 고정 | $\text{softmax}\left(\frac{\mathbf{q}_i \cdot \mathbf{k}_j}{\sqrt{d}}\right)$ |
| 모으는 것 | $W\mathbf{h}_j$ | $\mathbf{v}_j$ |

어텐션 = 선마다 **계산한** 무게

Joshi (2020) “Transformers are Graph Neural Networks”

# 순서는? 위치 정보를 더한다

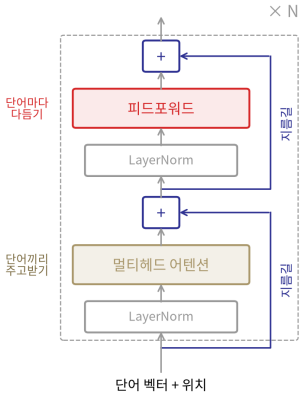
그래프에는 순서가 없다: Dog bites man = Man bites dog (**같은 그래프**)




입력 = 단어 벡터 + **위치 벡터** $\mathrm{PE}(pos, 2i) = \sin\left(pos/10000^{2i/d}\right)$, $2i+1$ 칸은 cos

칸마다 주기가 다른 물결 → 위치마다 다른 무늬 위치 벡터를 학습으로 정해도 비슷하다 (논문, GPT)

# 블록 하나: 주고받고, 다듬고




| | |
|---|---|
| 어텐션 | 단어끼리 정보를 **주고받는다** |
| 피드포워드 | 단어마다 따로 **다듬는다** |
| | $512 \to 2048 \to 512$ (ReLU) |
| 지름길 | $x + f(x)$: ResNet (11주차) |
| LayerNorm | 단어마다 평균 0 · 분산 1 로 |

이 블록을 **N 번** 쌓는다

그림은 GPT 등이 쓰는 순서 (정규화 먼저)  원 논문은 더한 뒤 정규화

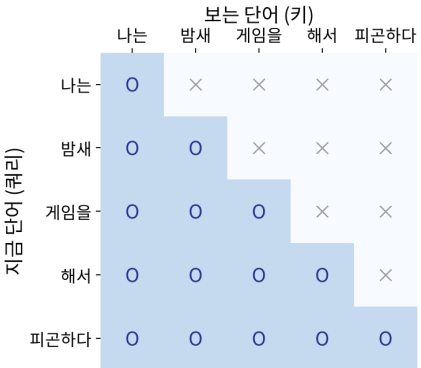
## 손으로 세기: 블록 하나의 가중치

| | | |
|---|---|---|
| 어텐션 | $W_Q, W_K, W_V, W_O$: $d \times d$ 네 개 | $4d^2$ |
| 피드포워드 | $d \times 4d$, $4d \times d$ | $8d^2$ |
| 블록 하나 | | $12d^2$ (편향 · 정규화 빼고) |

| | $d$ | 층 | 가중치 $\approx 12d^2 \times$ 층 |
|---|---|---|---|
| 원 논문 (인코더 6층) | 512 | 6 | $3.1\text{M} \times 6 \approx 19\text{M}$ |
| GPT-3 (2020) | 12,288 | 96 | $1.8\text{B} \times 96 \approx$ **174B** |

GPT-3 의 1,750억 개가 거의 이 식 하나로 나온다

# GPT: 앞 단어만 보고 다음 단어 맞히기




다음 단어를 맞히는데 뒤 단어를 보면 반칙
$\rightarrow$ 점수 행렬의 위쪽을 $-\infty$ 로 (softmax 후 0)

| | |
|---|---|
| 원 논문 | 인코더 6층 + 디코더 6층 (번역) |
| BERT (2018) | 인코더만: 양쪽 다 본다 |
| GPT (2018 $\sim$) | 디코더만: **앞만** 본다 |

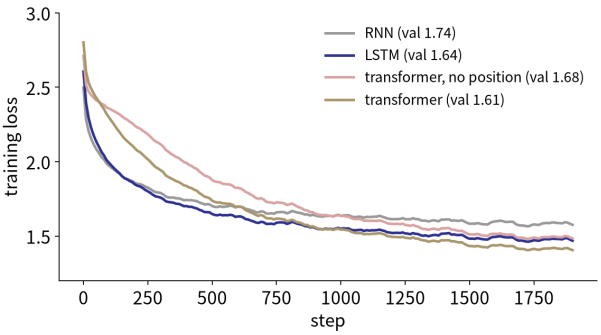
그래프로는: 선에 **방향**이 생겨 앞 단어에서만 정보가 온다
앞만 보기로 길이 $n$ 문장에서 $n$ 개 문제를 한 번에 학습

## 논문 결과 (2017)

| | | |
|---|---|---|
| 영어 → 독일어 (WMT'14) | BLEU **28.4** | 기존 최고 +2 점 넘게 |
| 영어 → 프랑스어 | BLEU **41.8** | GPU 8개로 3.5일 (훨씬 적은 계산) |
| base 모델 | | GPU 8개로 **12시간** |

RNN 없이 어텐션만으로 더 잘, 더 빨리 → 제목: Attention Is All You Need

# 실험: 셰익스피어 글자 모델, 트랜스포머로




| | 검증 손실 | 가중치 |
|---|---|---|
| RNN | 1.74 | 5만 |
| LSTM | 1.64 | 15만 |
| 트랜스포머 | **1.61** | 82만 |
| 위치 정보 뺌 | 1.68 | 82만 |

폭 128 · 4층 · 머리 4 12주차와 같은 조건 (조각 64, 2,000걸음)

이 작은 CPU 실험에서는 한 걸음이 LSTM 의 약 3배 느렸다: 장점은 GPU · 긴 글 · 큰 모델에서 나온다

## 블록을 쌓아 온 길

| | | | |
|---|---|---|---|
| 2017 | 원 논문 | 인코더 6층 + 디코더 6층 | 번역 |
| 2018 | BERT | 인코더 24층 (large) | 문장 이해 (14주차) |
| 2020 | GPT-3 | 디코더 **96층**, 1,750억 개 | 글 쓰기 |
| 2020 | ViT | 이미지 조각을 단어처럼 | 이미지 분류 |

블록은 거의 그대로, **층 · 폭 · 데이터**를 키웠다

# 문제풀이

1. $d = 768$, 12층 (GPT-2 small, BERT base) 의 블록 가중치는 대략 몇 개? ($12d^2 \times$ 층)
2. 단어 1,000개 문장에서 셀프 어텐션 점수는 몇 개 계산하나? 10,000개면 몇 배?
3. 그래프로 보면: 친구 3명의 값이 2, 6, 7 이고 이웃 평균을 쓰는 GNN 한 층이면 나의 새 값은? 트랜스포머에서 이 $\frac{1}{3}$ 자리에 오는 것은?
4. 앞만 보기 마스크에서 단어 5개 문장의 0 이 아닌 칸은 몇 개인가? (그래프로는 화살표 수)
5. 위치 정보를 빼도 앞만 보는 모델은 손실 1.68 로 꽤 배웠다. 어떻게 위치를 짐작할 수 있었을까?

# 실습

1. 위치 정보 만들기 (사인 · 코사인), 앞만 보기 마스크
2. 트랜스포머 블록 직접 쌓기 $\rightarrow$ 가중치 수를 $12d^2$ 와 비교
3. 셰익스피어 작은 GPT 학습 $\rightarrow$ 글 써 보기

Tiny Shakespeare (Karpathy, char-rnn)

▶ Colab에서 실습 노트북 열기

# 정리

**트랜스포머**: RNN 없이 셀프 어텐션으로 모든 단어를 **한 번에** (2017)

그래프로 보면: 모든 단어가 이어진 그래프 위의 GNN, **어텐션 = 선의 무게**

입력 = 단어 + 위치 블록 = 멀티헤드 어텐션 $\rightarrow$ 피드포워드, 지름길 · LayerNorm

블록 하나 $\approx 12d^2$ GPT-3: $12 \times 12288^2 \times 96 \approx 1{,}750$억

GPT = 앞만 보는 디코더 셰익스피어 검증 손실 1.64 (LSTM) $\rightarrow$ 1.61