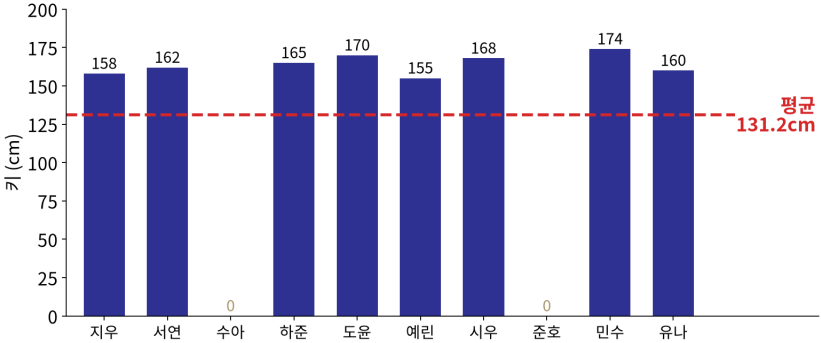
더티 데이터 (Dirty Data)

결측치 · 중복 · 이상치, 세 가지 모양

Machine Learning 1

한국과학영재학교 (KSA)

오늘의 질문



우리 반 10명의 키. **평균 키가 131cm?** 뭔가 이상하다

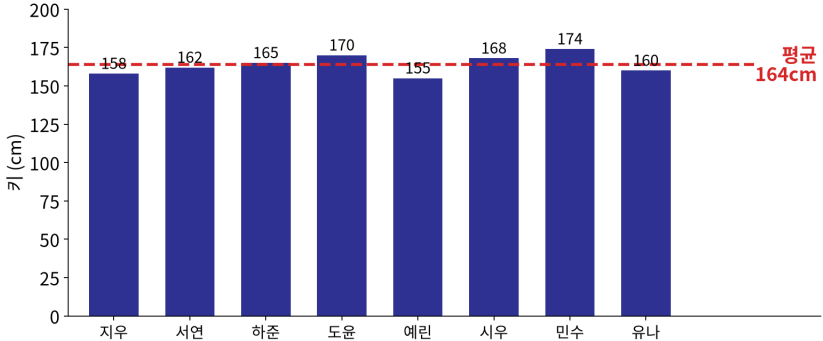
더티 데이터의 세 가지 모양

① 결측치	② 중복	③ 이상치
있어야 할 값이 없다	같은 기록이 여러 번	혼자 크게 튀는 값
Missing value	Duplicate	Outlier

모델을 고르기 전에, 데이터부터 본다

Garbage in, garbage out: 쓰레기를 넣으면 쓰레기가 나온다

① 결측치: 0을 빼면



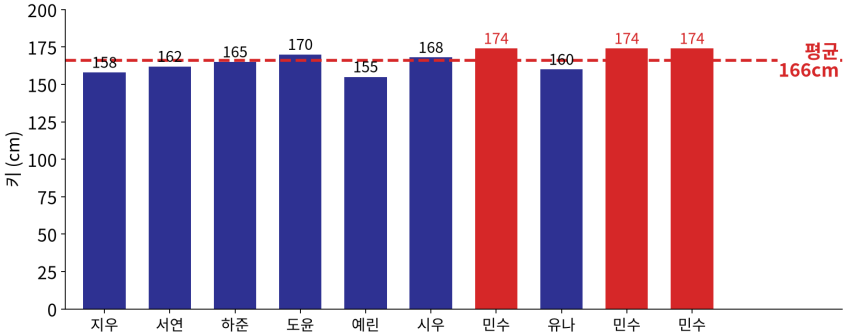
키를 안 적은 두 칸을 빼고 계산하면 **평균 164cm**

숫자인 척하는 결측치가 더 위험하다

적힌 값	컴퓨터가 보기에	
(빈칸)	비었음	**눈에 띈다**
NA, ?	글자	계산하다 오류가 난다
0, -999	**진짜 숫자**	**오류 없이 평균에 섞인다**

키 0cm, 나이 -999세처럼 **말이 안 되는 값**을 찾아서 빈칸으로 바꾼다

② 중복: 같은 기록이 여러 번



민수 기록이 세 번 들어가면 **평균 166cm** (원래 164cm)

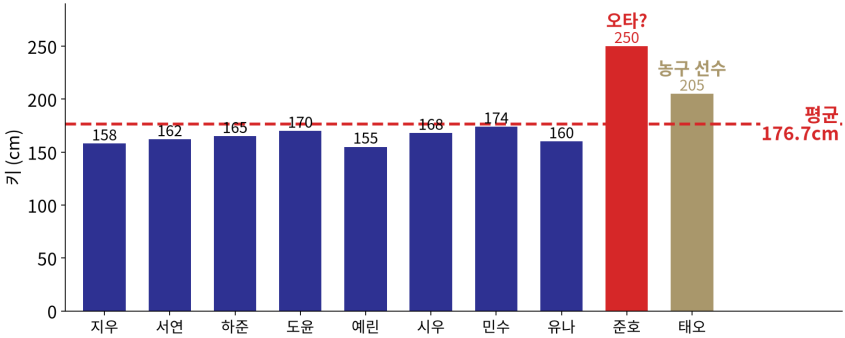
누가 “같은 사람”인가

줄 A		줄 B	컴퓨터의 판단
김민수, 174	=	김민수, 174	**같은 줄: 찾는다**
김민수, 174	≠	김␣민수, 174	**다른 줄 (띄어쓰기)**
김민수, 174	≠	김민수, **171**	같은 사람? 동명이인?

완전히 같은 줄은 컴퓨터가 찾지만, **같다의 기준은 사람이 정한다**

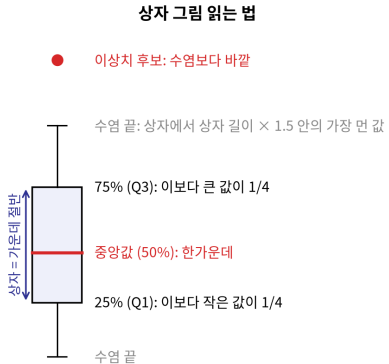
예: 이름 대신 학번으로 같은 사람을 판단한다

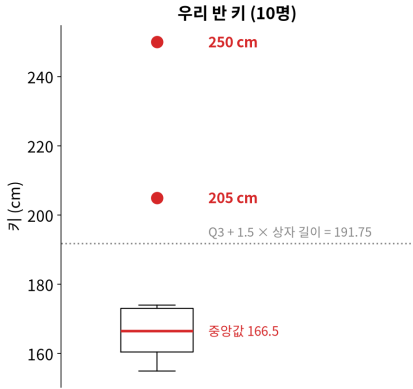
③ 이상치: 혼자 크게 튀는 값



준호 250cm는 **오타**, 태오 205cm는 **농구 선수**일 수도

그림으로 찾는다: 상자 그림





수염 밖에 홀로 떨어진 점이 이상치 후보

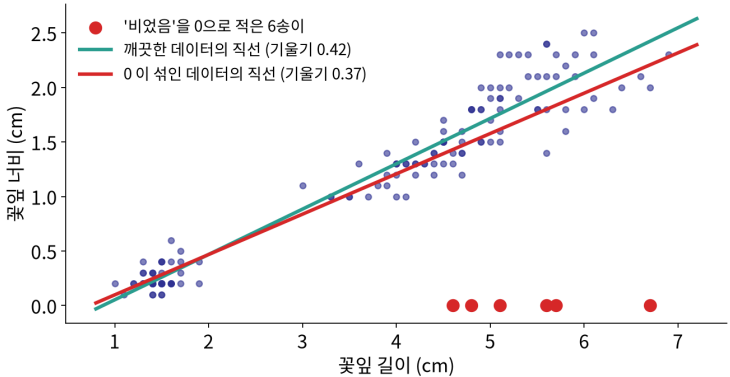
후보를 찾는 건 그림이, 지울지 남길지는 사람이 정한다

지울까, 고칠까, 남길까

경우	예	처리
분명한 오타	키 250cm	빈칸으로 (결측치처럼)
단위 실수	꽃받침 51cm (mm 로 적음)	고친다 ($\div 10$)
진짜일 수 있음	농구 선수 205cm	**남긴다**
모르겠음	?	표시해 두고, 지운 결과와 둘 다 보고

판단의 근거는 그 분야를 아는 지식 (도메인 지식)

모델도 속는다



붓꽃 150송이 중 **6송이**의 꽃잎 너비를 0으로 적었을 뿐인데, 직선이 끌려 내려간다

문제풀이

1. 키 기록 `[160, 0, 170, 0, 180]`. 평균은? 0을 결측치로 보고 빼면?
2. ”김민수”, ”김 민수”, ”김민수 ” 세 줄. 완전히 같은 줄 찾기로는 몇 쌍이 중복으로 잡히나? 공백을 모두 지운 뒤에는?
3. 다음 값은 오타일까, 진짜일까? 무엇을 더 알아야 할까?
   (a) 고등학생 몸무게 450kg (b) 하루 공부 시간 25시간 (c) 100m 달리기 9.8초

실습: 지저분한 iris 청소하기

0 일부러 더럽힌 붓꽃 데이터를 받아 `describe()` 로 훑어보기

1 결측치: 빈칸 · 0 · -999 를 찾아 진짜 빈칸으로

2 중복과 표기: 'Setosa', ' setosa' 맞추기 $\rightarrow$ 숨은 중복 찾기

3 이상치: 상자 그림으로 51cm 꽃받침 찾아 고치기

4 청소 전 vs 후: 같은 모델의 정확도 **86%** $\rightarrow$ **96%**

Iris (붓꽃 150송이, scikit-learn 내장)

▶ Colab에서 실습 노트북 열기

정리

결측치 빈칸보다 0, -999 처럼 숫자인 척하는 값이 더 위험

중복 완전히 같은 줄은 컴퓨터가, “같다”의 기준은 사람이

이상치 그림으로 찾고, 오타인지 진짜인지는 도메인 지식으로

모델도 속는다 모델을 고르기 전에 데이터부터 본다