문제 정형화와 평가지표

Problem Formulation · Metrics · Baselines — 무엇을 맞히고, 어떻게 채점하나

Machine Learning 1

한국과학영재학교 (KSA)

오늘의 질문

자금세탁 거래를 찾는 모델을 만들었다.

정확도 99.90%

좋은 모델일까?

IBM AML 데이터 (합성 은행 거래 5,078,345건)

머신러닝 문제 = 다섯 칸 채우기

①	**한 행은 무엇?**	예시 하나의 단위: 와인 한 병, 거래 한 건, 계좌 하나
②	**입력** X	예측할 때 **알 수 있는** 것만
③	**출력** y	맞히려는 것: 품종? 도수? 세탁 여부? 3D 구조?
④	**평가지표**	무엇으로 채점하나: 정확도, MAE, 정밀도 · 재현율 …
⑤	**기준선**	머리 안 쓰는 답의 점수: 가장 흔한 답, 평균, 지난달 그대로

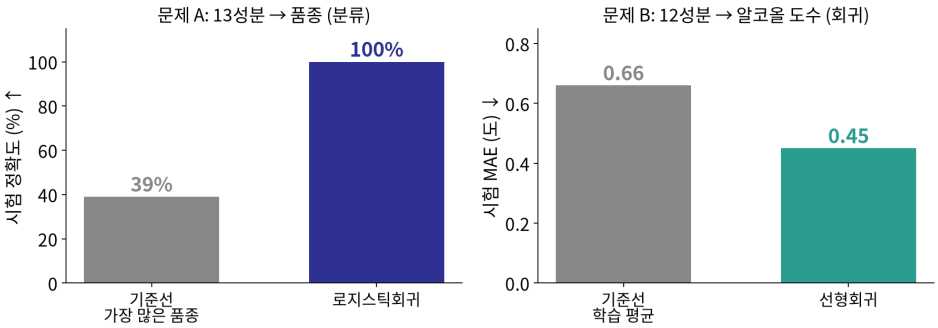
다섯 칸이 정해져야 **"잘했다"를 말할 수 있다**

출력 y 의 모양이 문제의 종류를 정한다

출력 y	문제 종류	예
범주 하나	**분류** (classification)	와인 품종 (3개 중 하나), 세탁인가 (예/아니오)
숫자 하나	**회귀** (regression)	알코올 도수, 다음 달 항공 승객 수
숫자 여러 개	구조 예측	단백질 원자 142개의 3D 좌표 (AlphaFold)
글 · 그림	생성	다음 단어, 그림 (14주차 이후)

같은 데이터라도 y **를 무엇으로 정하느냐**에 따라 다른 문제가 된다

같은 와인 178병, 두 문제



문제 A: y = 품종 → **정확도**　　문제 B: y = 알코올 도수 (11.03 ∼ 14.83도) → **MAE**

학습 70% · 시험 30% (54병), 표준화 + 로지스틱회귀 / 선형회귀. 문제 B 의 입력에는 알코올을 넣지 않는다 (답을 입력에 넣으면 안 된다)

회귀의 채점: MAE 와 RMSE

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n} |\, y_i - \hat{y}_i \,| \qquad \text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

y_i = 정답, $\hat{y}_i$ = 예측, 둘 다 y **와 같은 단위** (도, 명, cm)

오차 [1, 1, 1, 9]: $\text{MAE} = \frac{1+1+1+9}{4} = \mathbf{3}$ RMSE $= \sqrt{\frac{1+1+1+81}{4}} = \sqrt{21} = \mathbf{4.58}$

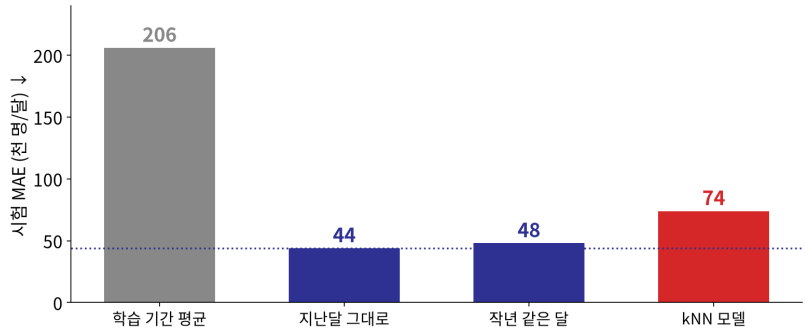
RMSE 는 제곱하니까 **크게 틀린 하나**에 더 큰 벌을 준다. 무엇이 더 나쁜지에 따라 고른다

기준선: 머리를 안 쓴 답은 몇 점인가

문제	기준선	점수
와인 품종 (분류)	늘 가장 많은 품종 (71병짜리) 이라고 답	정확도 **39%**
알코올 도수 (회귀)	늘 학습 데이터의 평균 도수라고 답	MAE **0.66도**
항공 승객 (시계열)	늘 지난달 승객 수라고 답	MAE **44천 명**
자금세탁 (분류)	늘 “정상”이라고 답	정확도 **99.90%**

모델 점수는 **기준선과 비교**해서 읽는다

모델이 기준선보다 못할 수도 있다



지난 12달을 보고 고른 kNN 모델 **74**, “지난달 그대로” **44**천 명

국제선 항공 승객 1949∼1960, 앞 10년 학습 · 뒤 2년 (24달) 시험, MAE (천 명/달). kNN: $k = 3$, 학습 기간 평균 · 표준편차로 표준화

시험 데이터 = 모델이 “실제로 만날” 데이터

데이터	어떻게 나누나
와인 178병	무작위로 70% 학습 · 30% 시험 (품종 비율은 맞춰서)
항공 승객	**시간 순서대로**: 1949∼1958 학습, 1959∼1960 시험
은행 거래	**시간 순서대로**: 앞 기간으로 학습, 뒤 기간으로 시험
단백질 구조	아직 **공개되지 않은** 구조로 시험 (CASP 대회)

미래를 섞어 학습하면 **시험 점수가 거짓말**을 한다

자금세탁 데이터 열어 보기: 한 행 = 거래 한 건

Timestamp	From (은행, 계좌)	To (은행, 계좌)	Amount Paid	Currency	Format	Is Laundering
2022/09/01 00:20	10, 8000EBD30	10, 8000EBD30	3,697.34	US Dollar	Reinvestment	0
2022/09/01 00:20	3208, 8000F4580	1, 8000F5340	0.01	US Dollar	Cheque	0

⋮

거래 5,078,345건, 그중 세탁 **5,177건 (0.10%)**

입력 X: 시각 · 보낸 쪽 · 받는 쪽 · 금액 · 통화 · 결제 형식　　출력 y: `Is Laundering` (0/1)

IBM 이 가상 세계(사람 · 회사 · 은행)를 시뮬레이션해 만든 합성 데이터 (Altman et al., NeurIPS 2023). 실제 은행 거래는 공개할 수 없어서 이렇게 만든다

정확도의 함정: 드문 것을 찾는 문제

	전부 “정상”	규칙: 결제 형식이 ACH (자동 이체)면 “세탁”
정확도	**99.90%**	88.24%
잡아낸 세탁 거래	**0 건**	**4,483건**

세탁을 **하나도 못 잡는** 쪽이 정확도는 더 높다

세탁이 드물어서, “정상”을 맞힌 수가 점수를 거의 다 차지한다

그래서 세는 법을 바꾼다: 정밀도와 재현율

	실제 세탁	실제 정상
“세탁”이라고 함	**4,483** (잡았다)	**596,314** (헛짚었다)
“정상”이라고 함	**694** (놓쳤다)	(나머지)

$$\text{재현율 (recall)} = \frac{\text{잡았다}}{\text{실제 세탁 전부}} = \frac{4{,}483}{4{,}483 + 694} = \mathbf{86.6\%}$$

$$\text{정밀도 (precision)} = \frac{\text{잡았다}}{\text{“세탁”이라고 한 것 전부}} = \frac{4{,}483}{4{,}483 + 596{,}314} = \mathbf{0.75\%}$$

전부 “정상”은 재현율 0%. 자세한 계산과 둘 사이의 줄다리기는 2주차 (정밀도와 재현율)

한 행을 무엇으로 정하나: 거래 vs 계좌

	한 행 = 거래 한 건	한 행 = 보낸 계좌 하나
행 수	5,078,345	496,999
$y = 1$ 인 행	5,177	3,376
세탁 비율	**0.10%**	**0.68%**
현실의 질문	이 송금을 막을까?	이 계좌를 조사할까?

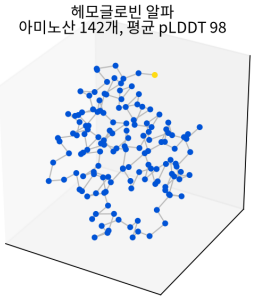
같은 파일, 다른 문제. 논문마다 “세탁 비율”이 다르게 적힌 이유

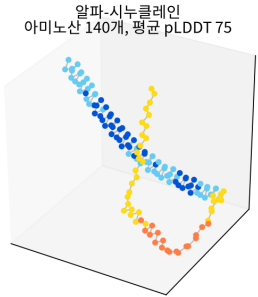
50년 된 문제의 정형화: 단백질 접힘

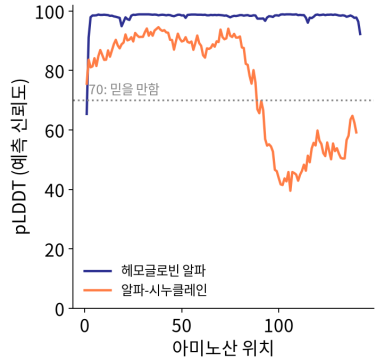
한 행	단백질 하나
입력 X	아미노산 서열: 글자 20종의 줄 `MVLSPADKTNVKAAWGKVGAHAGEYGAEALERMF`… (헤모글로빈 알파, 142글자)
출력 y	원자들의 **3D 좌표**: 142×3 개 이상의 숫자
평가지표	실험으로 잰 구조와 얼마나 겹치나 (GDT, $0 \sim 100$)
기준선	이전 대회의 최고 방법

서열 $\rightarrow$ 구조: 1960 년대부터 풀리지 않던 문제. 실험으로 구조 하나를 재는 데 몇 달 $\sim$ 몇 년

AlphaFold 의 출력: 좌표 + 얼마나 자신 있는지







원자마다 예측 신뢰도 **pLDDT** (0 ∼ 100) 도 함께 낸다

알파-시누클레인의 뒤쪽은 실제로도 정해진 모양 없이 흐느적거리는 부분. 파랑 = 자신 있음, 주황 = 자신 없음 (AlphaFold DB 색)

지표와 시험이 먼저 있었다: CASP

CASP	단백질 구조 예측 대회, **1994년부터 2년마다**
시험 문제	실험으로 막 재었지만 **아직 공개 안 된** 구조
채점	GDT: 예측과 실제가 겹치는 정도 (0 ∼ 100)
2020 (CASP14)	AlphaFold2 중앙값 GDT **92.4**: 실험과 맞먹는 수준

문제 · 지표 · 시험 데이터가 26년 동안 **고정**되어 있었기에 “풀렸다”고 말할 수 있었다

지표를 정하면, 모델은 그 지표만 쫓는다

지표	이 점수를 최대로 만드는 가장 쉬운 방법
정확도	전부 “정상” → 99.90%
재현율	전부 “세탁” → 100% (그런데 은행이 멈춘다)
정밀도	가장 확실한 한 건만 “세탁” → 100% (나머지는 다 놓친다)

지표는 **현실에서 무엇이 손해인지**에서 거꾸로 정한다

놓친 세탁 한 건의 손해 vs 헛짚어 정상 고객을 막은 한 건의 손해

문제풀이

1. 다섯 칸을 채워 보자: (a) 스팸 문자 거르기 (b) 내일 서울 최고 기온 (c) 사진 속 고양이 위치 찾기
2. 예측 $[10, 20, 30, 40]$, 정답 $[12, 18, 30, 50]$. MAE 와 RMSE 는?
3. 환자 1,000명 중 20명이 병에 걸렸다. “전부 건강”의 정확도는? 재현율은?
4. 내일 주가를 맞히는 모델의 입력에 “내일 거래량”을 넣었더니 성능이 크게 올랐다. 무엇이 잘못됐나?
5. 학생 성적 데이터에서 시험 데이터를 무작위로 뽑았는데, 같은 학생의 다른 학기 기록이 학습 데이터에 있다. 무엇이 문제일까?

실습: 문제를 직접 정해 보기

1. 와인: 같은 데이터로 분류 · 회귀 두 문제 만들기, 정확도 · MAE · 기준선 직접 구현
2. 항공 승객: 지난달 그대로 · 작년 같은 달 vs kNN (**74** vs **44**)
3. IBM AML: 거래 5,078,345건 열기, 전부 “정상” 99.90%, 규칙 하나의 정밀도 · 재현율, 한 행을 계좌로 바꾸면 (0.10% $\rightarrow$ 0.68%)
4. AlphaFold: API 로 구조 파일 받기, 서열 X · 좌표 y · pLDDT 꺼내 3D 로 그리기

AML 은 Hugging Face 사본에서 받는다 (로그인 없이, 압축 약 90MB)

▶ Colab에서 실습 노트북 열기

정리

문제 = **다섯 칸**: 한 행 · 입력 X · 출력 y · 평가지표 · 기준선

같은 데이터라도 y 와 **한 행**을 다르게 정하면 다른 문제 (와인, 거래 vs 계좌)

점수는 **기준선과 비교**해서 읽는다 (모델이 “지난달 그대로”에 질 수도)

시험 데이터는 실제로 만날 데이터처럼: 시간 순서, 아직 공개 안 된 구조

지표는 현실의 손해에서 거꾸로 정한다. AlphaFold 는 문제 · 지표가 먼저 있었다

이미지 · 데이터 출처

- 자금세탁 거래: IBM Transactions for Anti Money Laundering (HI-Small), Kaggle `ealtman2019` (실습은 Hugging Face 사본); Altman et al., “Realistic Synthetic Financial Transactions for Anti-Money Laundering Models” (NeurIPS 2023 Datasets and Benchmarks)
- 단백질 구조: AlphaFold Protein Structure Database (EMBL-EBI, CC BY 4.0), P69905 · P37840; Jumper et al., Nature 596 (2021)
- CASP14 결과: DeepMind, “AlphaFold: a solution to a 50-year-old grand challenge in biology” (2020)
- 와인: UCI Wine (Aeberhard & Forina, 1991) 항공 승객: Box & Jenkins, Time Series Analysis (1976)