

나이프 베이즈

베이즈 정리로 확률을 뒤집어 분류하기

Machine Learning 1


한국과학영재학교 (KSA)

제목: [안내] 무료 쿠폰 당첨을 축하합니다

지금 확인하시면 쿠폰을 즉시 지급해 드립니다.

스팸일까, 정상일까?

조건부 확률 = 범위를 좁혀서 세기



$$P(\text{glasses} \mid \text{soccer}) = \frac{3}{8}$$

순서를 바꾸면?



$$P(\text{soccer} \mid \text{glasses}) = \frac{3}{9} \neq \frac{3}{8}$$

베이즈 정리: 한쪽에서 다른 쪽으로

$$P(\text{soccer} \mid \text{glasses}) = \frac{P(\text{glasses} \mid \text{soccer}) P(\text{soccer})}{P(\text{glasses})} = \frac{\frac{3}{8} \times \frac{8}{20}}{\frac{9}{20}} = \frac{3}{9}$$

직접 센 값과 똑같다

아는 것 vs 알고 싶은 것

데이터로 셀 수 있는 것: $P(\text{'free'} \mid \text{spam})$

우리가 알고 싶은 것: $P(\text{spam} \mid \text{'free'})$

방향이 반대다

수식에서는 '무료'를 'free', 스팸을 spam, 정상을 ham 으로 쓴다

베이즈 정리


$$\underbrace{P(y \mid x)}_{\text{posterior}} = \frac{\overbrace{P(x \mid y)}^{\text{likelihood}} \overbrace{P(y)}^{\text{prior}}}{\underbrace{P(x)}_{\text{evidence}}}$$

베이즈 정리: 용어 (한글)


$$\underbrace{P(y \mid x)}_{\text{사후확률}} = \frac{\overbrace{P(x \mid y)}^{\text{가능도}} \overbrace{P(y)}^{\text{사전확률}}}{\underbrace{P(x)}_{\text{증거}}}$$

사후확률	posterior	증거 x 를 본 뒤에 y 일 확률
가능도	likelihood	y 라면 x 가 나올 확률
사전확률	prior	아무것도 보기 전에 y 일 확률
증거	evidence	x 가 나올 전체 확률 (스팸이든 정상이든)

1000통으로 세어 보기



증거가 쌓이면




1000통에서 단어가 든 메일만 남기며 센다

	스팸	정상	스팸 비율
처음	300	700	30%
‘무료’	180	35	83.7%
‘당첨’	120	140	46.2%
‘무료’+‘당첨’	72	7	91.1%

곱하는 비율 (스팸 / 정상)


‘무료’ 0.6 / 0.05 ‘당첨’ 0.4 / 0.2

스팸이 드문 메일함이라면?



스팸이 1%뿐인 메일함, 같은 '무료'

사전확률의 힘



같은 '무료'를 봐도 스팸이 드문 메일함(1%)이면 **11%**, 흔한 메일함(30%)이면 **84%**
→ 결론은 **처음 비율(사전확률)**에 따라 달라진다

사전확률의 힘: 스팸 30% 메일함

$$\underbrace{P(\text{spam} \mid \text{'free'})}_{\text{posterior}} = \frac{0.60 \times 0.30}{\underbrace{0.60 \times 0.30 + 0.05 \times 0.70}_{\text{evidence}}} \approx \mathbf{84\%}$$

0.60, 0.05 **likelihood (가능도):** $P(\text{'free'} \mid \text{spam}), P(\text{'free'} \mid \text{ham})$

0.30, 0.70 **prior (사전확률):** $P(\text{spam}), P(\text{ham}) = 1 - P(\text{spam})$

분모 전체 **evidence (증거):** $P(\text{'free'}) = \text{'무료'가 든 모든 메일}$

84% **posterior (사후확률):** 구하려는 값

사전확률의 힘: 스팸 1% 메일함

$$\underbrace{P(\text{spam} \mid \text{'free'})}_{\text{posterior}} = \frac{0.60 \times 0.01}{\underbrace{0.60 \times 0.01 + 0.05 \times 0.99}_{\text{evidence}}} \approx \mathbf{11\%}$$

0.60, 0.05 **likelihood (가능도):** $P(\text{'free'} \mid \text{spam}), P(\text{'free'} \mid \text{ham})$

0.01, 0.99 **prior (사전확률):** $P(\text{spam}), P(\text{ham}) = 1 - P(\text{spam})$

분모 전체 **evidence (증거):** $P(\text{'free'}) = \text{'무료'가 든 모든 메일}$

11% **posterior (사후확률):** 구하려는 값

$$\hat{y} = \arg \max_y P(y) P(x \mid y)$$

분모 $P(x)$ 는 모든 y 에 같으니 비교할 땐 빼도 된다

문제: 단어가 많으면?

$$P(x_1, x_2, \dots, x_n \mid y)$$

x_i : 단어 i 가 메일에 있으면 1, 없으면 0

단어 1만 개 $\Rightarrow$ 가능한 조합 2^{10000} 개

정확한 식: 연쇄 법칙

단어 두 개

$$P(x_1, x_2 \mid y) = P(x_2 \mid x_1, y) P(x_1 \mid y)$$

단어 n 개


$$P(x_1, \dots, x_n \mid y) = P(x_1 \mid y) P(x_2 \mid x_1, y) P(x_3 \mid x_1, x_2, y) \cdots P(x_n \mid x_1, \dots, x_{n-1}, y)$$

항상 성립하는 식 뒤로 갈수록 조건이 늘어난다 $\Rightarrow$ 데이터로 세기 어렵다

나이브 가정: 단어끼리 독립

$$P(x_1, \dots, x_n \mid y) \approx \prod_{i=1}^n P(x_i \mid y)$$

$P(x_i \mid x_1, \dots, x_{i-1}, y) \rightarrow P(x_i \mid y)$ 앞 단어들을 조건에서 **지운다**



0 하나가 전부를 지운다

‘내일 회의 **당첨**’ (정상 메일인데 ‘당첨’이 우연히 들어갔다)

	$P(\text{present} \mid \text{ham})$	$P(\text{present} \mid \text{spam})$
내일	3/14	0/10
회의	2/14	0/10
당첨	0/14	4/10
곱	0	0

둘 다 0 $\Rightarrow$ 어느 쪽인지 판단할 수 없다

정상 14통, 스팸 10통 기준. 없는 단어는 $1 - P$ 를 곱하지만 여기서는 생략

해결: 가상 메일을 1통씩 더한다

$$P(x_i = 1 \mid y) = \frac{n_{i,y} + 1}{M_y + 2}$$

	$P(\text{present} \mid \text{ham})$	$P(\text{present} \mid \text{spam})$
내일	4/16	1/12
회의	3/16	1/12
당첨	1/16	5/12

정상 **58.6%** 스팸 41.4% $\Rightarrow$ **정상으로 분류** (세 단어만 계산)

$n_{i,y}$: 단어 i 가 든 y 메일 수 M_y : y 메일 수 (정상 14, 스팸 10)

+2: '있다'와 '없다' 두 경우에 가상 메일 1통씩

유도: 로그 사후확률

$$\begin{aligned}\log P(y \mid x_1, \dots, x_n) &= \log \frac{P(x_1, \dots, x_n \mid y) P(y)}{P(x_1, \dots, x_n)} && \text{Bayes} \\ &= \log P(x_1, \dots, x_n \mid y) + \log P(y) - \log P(x_1, \dots, x_n) && \text{log} \\ &\approx \sum_{i=1}^n \log P(x_i \mid y) + \log P(y) - \log P(x_1, \dots, x_n) && \text{naive (p.17)} \\ &= \log P(y) + \sum_{i=1}^n \log P(x_i \mid y) + C\end{aligned}$$

$C = -\log P(x_1, \dots, x_n)$ 은 y 와 무관한 상수 $\Rightarrow$ **비교할 땐 빼도 된다**

곱 대신 로그의 합

$$\log P(y \mid x_1, \dots, x_n) \propto \log P(y) + \sum_{i=1}^n \log P(x_i \mid y)$$

작은 확률을 수백 번 곱하면 컴퓨터에선 0이 된다
(0.01을 200번 곱하면 $10^{-400} \Rightarrow$ 로그를 취해 합으로 계산한다)

문제풀이

- 1 메일의 20%가 스팸이다. ‘할인’은 스팸의 50%, 정상의 10%에 나온다. ‘할인’이 든 메일이 스팸일 확률은?
- 2 정상 메일 14통 중 ‘당첨’(win)이 든 메일이 0통이다. 라플라스 스무딩 후 $P(\text{win} \mid \text{ham})$ 은?

- 1 베이즈 정리로 'free' 메시지가 스팸일 확률 · 직접 세기 · 사전확률 바꿔 보기
- 2 나이브 베이즈 직접 구현 (스무딩 · 로그 합) 후 테스트 정확도
- 3 scikit-learn BernoulliNB와 비교

영어 문자메시지 5,574건 (UCI SMS Spam Collection)

▶ Colab: 실습 노트북

베이즈 정리 사후 $\propto$ 가능도 $\times$ 사전

사전확률 원래 얼마나 흔한가가 결론을 바꾼다

나이브 가정 단어별 확률의 곱

실전 라플라스 스무딩 + 로그 합