랜덤 포레스트 (Random Forest)

서로 다른 나무 여럿의 다수결

Machine Learning 1

한국과학영재학교 (KSA)

오늘의 질문: 1906년 영국의 황소 무게 맞히기

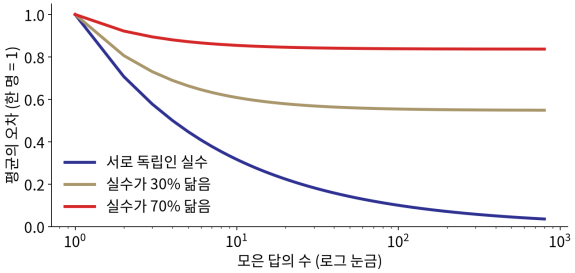
가축 품평회에서 **787명**이 황소 무게를 적어 냈다

답은 제각각. 그런데 가운데 값은 **1,207 파운드**

실제 무게 (도축 후): **1,198 파운드**

한 명 한 명은 틀려도, 모으면 정답에 아주 가깝다 (F. Galton, “Vox Populi”, Nature, 1907)

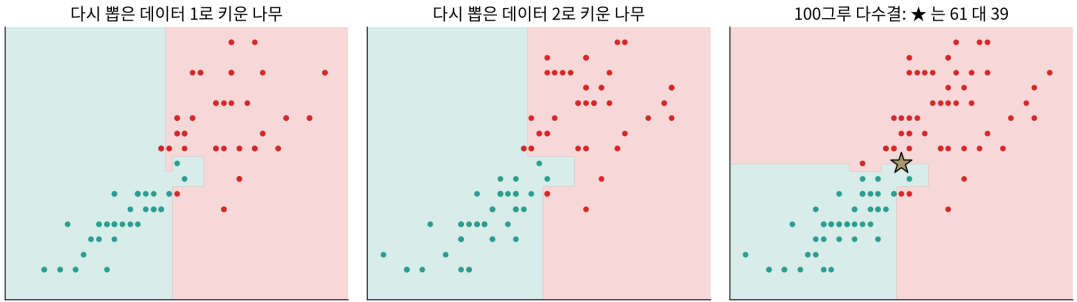
모으면 왜 맞을까: 실수가 서로 달라야 한다



$$\text{평균의 오차} = \sigma\sqrt{\rho + \frac{1-\rho}{n}}$$

독립 ($\rho = 0$) 이면 0 으로 같은 쪽으로 틀리면 (ρ 큼) **모아도 안 줄어든다**

나무 한 그루는 불안정하다



조금만 다르게 뽑아도 경계가 바뀐다 (왼쪽 둘) 100그루를 모으면 **부드러워진다**

서로 다른 나무 만들기 1: 부트스트랩

데이터 m 개에서 **복원 추출**로 m 개를 다시 뽑는다 (같은 것이 여러 번 뽑힐 수 있다)

카드 1 $\sim$ 10 에서 10번: 9, 7, 6, 3, 4, 1, 1, 1, 2, 9

$\rightarrow$ 7 종류만 들어 있다 5, 8, 10 은 **한 번도 안 뽑힘**

$$P(\text{한 번도 안 뽑힘}) = \left(1 - \frac{1}{m}\right)^m \approx \frac{1}{e} = 0.368$$

나무마다 데이터의 약 **63%** 로 학습 나머지 37% 는 그 나무에게 처음 보는 데이터

서로 다른 나무 만들기 2: 질문 후보도 무작위로

나무가 질문을 고를 때마다 특징 전부가 아니라 **무작위 일부**만 후보로 (분류는 보통 $\sqrt{d}$ 개)

특징이 8개면 질문마다 $\sqrt{8} \approx 2$ **개**만 보고 고른다

왜? 강한 특징 하나 (예: 혈당) 를 모든 나무가 첫 질문으로 써서 **서로 닮는다**

$\rightarrow$ 가끔은 다른 특징으로 시작하게 해서 실수를 덜 닮게 만든다 (p.2)

부트스트랩 + 질문 후보 무작위 = 랜덤 포레스트 (L. Breiman, 2001; 앞서 T. K. Ho, 1995)

예측: 다수결, 그리고 표의 비율

꽃잎 길이 5.0, 너비 1.7 인 꽃 → versicolor **61** : virginica **39**

답: versicolor 그리고 **확신 61%** 라는 것도 함께 알 수 있다

92 : 8 이면 자신 있는 답, 51 : 49 면 사실상 모르는 답

회귀 (숫자 예측) 는 다수결 대신 나무들의 예측을 **평균** (골턴의 황소처럼)

덤으로 얻는 검증: OOB (out-of-bag)

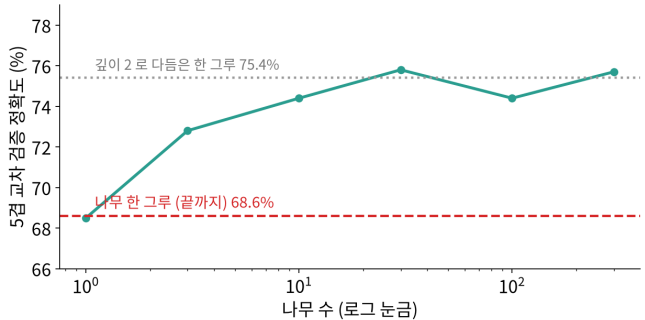
각 나무는 데이터의 약 37% 를 **안 봤다** (p.4) → 그 데이터로 채점할 수 있다

데이터마다: 그 데이터를 안 본 나무들만 모아 다수결 → 맞았나?

당뇨병 768명, 나무 300그루	정확도
OOB (따로 떼지 않음)	**75.8%**
5겹 교차 검증	75.7%

교차 검증을 따로 안 돌려도 거의 같은 추정 scikit-learn `oob_score=True`

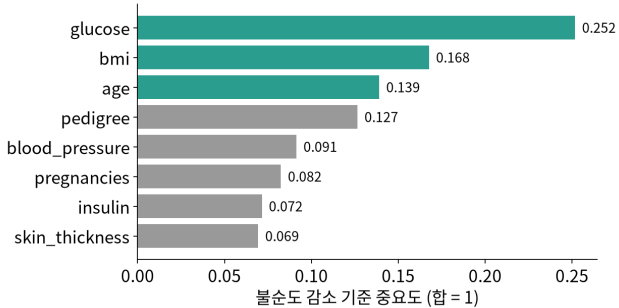
나무를 늘리면



한 그루 **68.6%** → 숲 300그루 **75.7%** (다듬은 한 그루 75.4% 만큼, **튜닝 없이**)

나무를 늘려도 과대적합되지 않는다 (평균이 안정될 뿐) 대신 계산 시간이 는다

어떤 특징이 중요했나



특징마다 **불순도를 줄인 양**을 모든 나무에서 더한다 혈당 · BMI · 나이 순

주의: 값의 종류가 많은 특징을 과대평가하는 경향 → 다음 시간 SHAP 로 더 정확히

랜덤 포레스트의 장점과 약점

장점 튜닝을 거의 안 해도 잘 된다 과대적합에 강하다 OOB · 특징 중요도 덤
표준화 불필요, 나무끼리 독립이라 **병렬**로 빠르게 키울 수 있다

약점 한 그루처럼 읽을 수는 없다 모델이 크다 (나무 수백 그루)
학습 범위 밖의 값은 예측 못 한다 (나무는 본 값의 평균만 낸다)

표 데이터에서는 지금도 가장 먼저 시도해 볼 만한 모델 다음: 나무를 **차례로** 쌓는 GBDT

문제풀이

1. 데이터 4개 {A, B, C, D} 에서 부트스트랩으로 4개를 뽑았더니 B, B, D, A 였다. 이 나무의 OOB 데이터는?
2. 나무 5그루가 각각 “고양이, 개, 고양이, 고양이, 개” 라고 답했다. 숲의 답과 확신은?
3. 한 명의 오차가 10 kg, 실수의 상관이 0 일 때 100명의 평균 오차는? 상관이 0.5 면?
4. 특징이 100개인 분류 문제에서 랜덤 포레스트는 질문마다 보통 몇 개의 특징을 후보로 보나?

실습

1. 부트스트랩 + 나무 + 다수결로 숲 직접 만들기 → 61 : 39 같은 표 세어 보기
2. OOB 점수 직접 계산 vs `oob_score_`, 나무 수에 따른 정확도
3. 실제 데이터: 당뇨병 · 타이타닉에서 한 그루 vs 숲, 특징 중요도

Pima Indians Diabetes (UCI) · Titanic (seaborn-data)

▶ Colab에서 실습 노트북 열기

정리

여럿의 답을 모으면 정확해진다 단, **실수가 서로 달라야** 한다 (골턴 1907)

랜덤 포레스트 = 부트스트랩 + 질문 후보 무작위 ($\sqrt{d}$) 로 서로 다른 나무 + 다수결

표의 비율 = 확신 안 본 37% 로 **OOB** 검증

한 그루 68.6% $\rightarrow$ 숲 75.7% (당뇨병) 나무를 늘려도 과대적합 없음