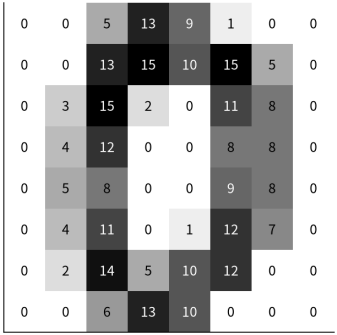
t-SNE 데이터 지도

가까운 이웃은 지도에서도 이웃으로

Machine Learning 1

한국과학영재학교 (KSA)

오늘의 질문: 64차원 점 1,797개를 지도 한 장에?

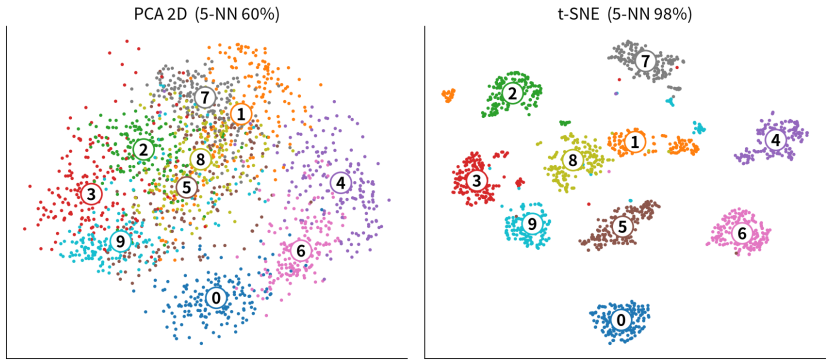


숫자 한 장 = 8 × 8 = 숫자 **64**개
= 64차원 공간의 점 하나

1,797장을 2차원 지도에 그려
비슷한 것끼리 모였는지 보고 싶다

PCA 두 축: 퍼짐의 28.5% 만 남는다

PCA 지도 vs t-SNE 지도



지도에서 가까운 5개로 숫자 맞히기 (5-NN): PCA **60%** t-SNE **98%**

두 지도 모두 숫자 이름표는 쓰지 않았다 (색은 나중에 칠함)

아이디어: 이웃 관계를 지킨다

	PCA	t-SNE (2008)
지키려는 것	큰 퍼짐 (먼 거리)	**가까운 이웃**
방법	직선 방향의 그림자	점을 하나씩 옮겨 가며 맞춘다 (경사 하강)
결과	축에 뜻이 있다 (PC1 = · · ·)	축에 뜻이 없다, 무리가 보인다
새 점	바로 투영	다시 계산해야

“64차원에서 가까운 점은 지도에서도 가깝게, 먼 점은 신경 쓰지 말자”

식으로: 두 가지 “가까움” 을 맞춘다

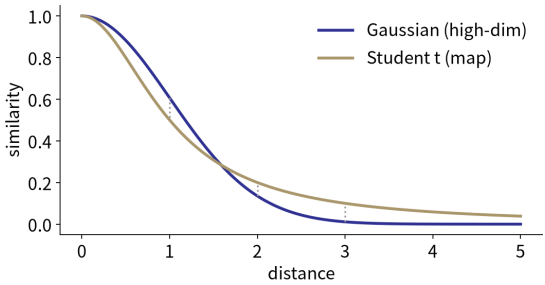
64차원 (정규분포) $$p_{j|i} = \frac{\exp(-\|\mathbf{x}_i - \mathbf{x}_j\|^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|\mathbf{x}_i - \mathbf{x}_k\|^2 / 2\sigma_i^2)}, \qquad p_{ij} = \frac{p_{j|i} + p_{i|j}}{2N}$$

지도 (t 분포) $$q_{ij} = \frac{(1 + \|\mathbf{y}_i - \mathbf{y}_j\|^2)^{-1}}{\sum_{k \neq l} (1 + \|\mathbf{y}_k - \mathbf{y}_l\|^2)^{-1}}$$

맞추기 $$\mathrm{KL}(P \,\|\, Q) = \sum_{i \neq j} p_{ij} \log \frac{p_{ij}}{q_{ij}}$$ 를 지도 좌표 **y** 로 경사 하강

σ_i: 점마다 이웃이 약 **perplexity** 개 들어오도록 정한다 (빽빽한 곳은 좁게, 성긴 곳은 넓게)

손으로 한 번 · 왜 t 분포인가



이웃 셋까지 거리 1, 2, 3

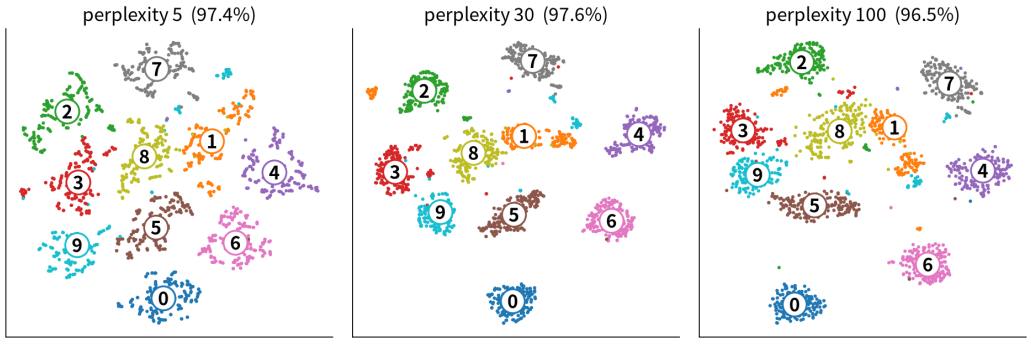
	1	2	3
$e^{-d^2/2}$	0.607	0.135	0.011
나눠 합 1	**0.81**	0.18	**0.01**
$1/(1+d^2)$	0.5	0.2	0.1
나눠 합 1	0.625	0.25	**0.125**

t 분포는 꼬리가 두껍다: 조금 먼 점도 몫이 남는다

작은 몫을 맞추려면 지도에서는 먼 점을 **더 멀리** → 섬 사이에 틈

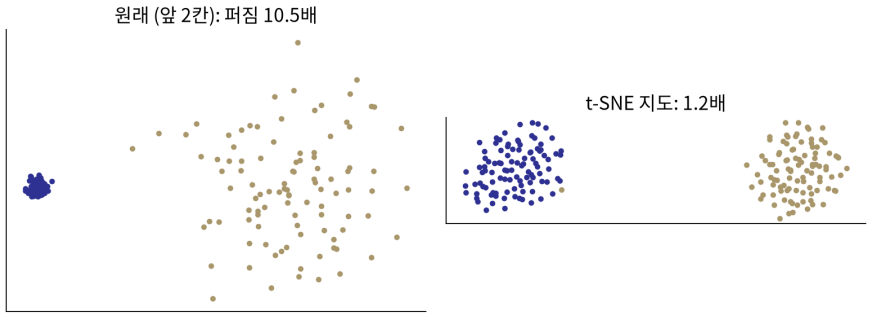
64차원의 이웃을 2차원에 다 넣을 자리가 없는 문제 (crowding problem)

설정에 따라 달라진다: perplexity



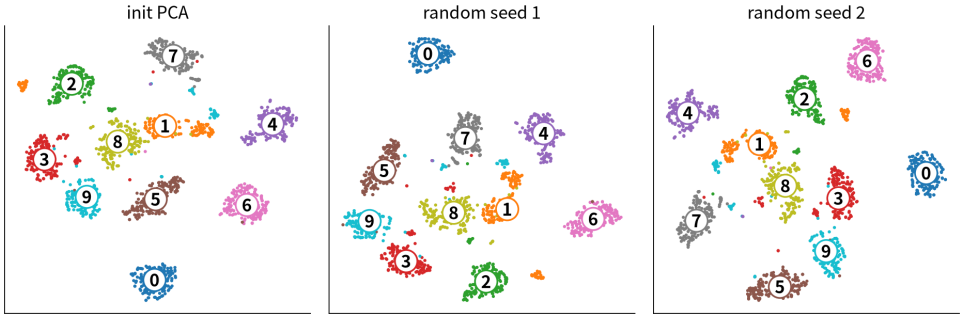
perplexity = 점마다 대략 몇 개를 이웃으로 볼지 (보통 5 ~ 50)
작으면 잘게 쪼개지고, 크면 전체 모양을 더 본다 (5-NN 은 97% 안팎)

주의 1: 섬의 크기는 뜻이 없다



10차원 두 무리, 퍼짐 **10.5배** 차이 $\rightarrow$ 지도에서는 **1.2배**
점마다 σ_i 를 따로 정하니 빽빽한 무리는 늘고 성긴 무리는 준다

주의 2: 섬 사이 거리 · 실행마다 다른 지도



시작점만 바꿨다 섬은 그대로, **배치**는 제각각 (5-NN 97 ∼ 98%)

섬 사이 거리 · 위치로 "0 과 6 이 가깝다" 고 결론 내리지 말 것

Wattenberg, Viégas, Johnson (2016) "How to Use t-SNE Effectively" (Distill)

어디에 쓰나

신경망 들여다보기	중간층 벡터 (임베딩) 를 지도로: 비슷한 것끼리 모였나?
단일 세포 유전체	세포 수만 개 × 유전자 2만 개 → 세포 종류가 섬으로
단어 · 문서	word2vec · BERT 벡터를 지도로 (다음 덱들)
UMAP (2018)	비슷한 생각, 더 빠르고 전체 모양을 조금 더 지킨다

지도는 **보기 위한** 것: 지도 좌표로 분류 · 군집을 하지는 않는다

문제풀이

1. 이웃 거리가 0 과 1 일 때 t 분포 유사도 $1/(1+d^2)$ 는? 합이 1 이 되게 나누면?
2. 정규분포로는 거리 3 인 점의 몫이 0.01, t 분포로는 0.125 였다. 지도에서 0.01 을 맞추려면 그 점을 가깝게 둬야 할까, 멀게 둬야 할까?
3. t-SNE 지도에서 섬 A 가 섬 B 보다 3배 크다. “A 가 3배 다양하다” 고 말할 수 있나?
4. PCA 와 달리 t-SNE 는 새 데이터 한 장을 바로 지도에 올릴 수 없다. 왜일까?

실습

1. 정규분포 vs t 분포 유사도 손 계산, KL 발산 재기
2. 손글씨 숫자 PCA 지도 vs `sklearn TSNE` 지도 → 5-NN 60% vs 98%
3. perplexity · 시드 바꾸기, 크기가 다른 두 무리 실험

▶ Colab에서 실습 노트북 열기

정리

t-SNE: 64차원에서 **가까운 이웃**은 지도에서도 이웃으로 (2008)

고차원은 정규분포, 지도는 꼬리가 두꺼운 **t 분포** $\rightarrow$ KL 발산을 경사 하강

숫자 1,797장: PCA 지도 60% $\rightarrow$ t-SNE 지도 98% (가까운 5개로 맞히기)

주의: 섬 크기 (10.5배 $\rightarrow$ 1.2배) · 섬 사이 거리 · 배치에는 뜻이 없다