

강의계획서

2027학년도 2학기

과목명	강화학습	교과목 번호	MC0000	학점	3	강의실	창의관 5701호
		교과 구분	선택 과목	시수	3		

담당교원	이름	분반	Office	Office Hour	연락처	이메일	
	한수민	1	창의관 5701호	[추후 공지]	051-606-2353	suminhan@ksa.hs.kr	

1. 교과목 개요

강화학습 교과에서는 에이전트가 환경과의 상호작용을 통해 스스로 좋은 행동을 학습하는 강화학습의 원리를 다룬다. 교과 내용의 약 70%는 Sutton과 Barto의 표준 교재(Reinforcement Learning: An Introduction)를 따르는 이론 중심으로 구성되며, 멀티암 밴딧과 마르코프 결정과정(MDP) 같은 기본 개념에서 출발하여 동적계획법, 몬테카를로 방법, 시간차 학습 등 표 기반 강화학습을 익힌 뒤, 같은 교재가 다루는 함수근사와 정책 경사 이론으로 자연스럽게 확장한다. 나머지 약 30%는 이 이론을 실전에 적용하는 응용 기법으로, PPO 등 안정화된 심층강화학습, 모방학습과 인간 피드백 기반 강화학습(RLHF), 로봇 시뮬레이션, 몬테카를로 트리 탐색을 다룬다. 본 교과는 "기계학습과 심층학습"의 후속 과목으로, 신경망에 대한 사전 지식을 전제로 한다.

가. 교과목 목표

- 에이전트가 환경과 상호작용하며 보상을 최대화해가는 원리를 이해하고, 여러 가지 기본적인 강화학습 알고리즘을 표를 이용해 직접 구현한다.
- 신경망을 결합한 심층강화학습과, 사람의 시연이나 피드백을 활용하는 최신 방법들의 기본 아이디어를 이해하며, 팀 프로젝트를 통해 정직한 실험 절차로 시뮬레이션 환경에 직접 적용해 본다.

나. 교과목 내용

- 멀티암 밴딧과 MDP 기초
 - 탐험-활용 전략(ϵ -greedy, UCB)
 - MDP의 다섯 요소와 벨만 방정식
- 동적계획법, 몬테카를로, 시간차 학습 등 표 기반 강화학습
 - 정책 반복과 가치 반복
 - TD(0), SARSA, Q-learning 등 대표 알고리즘
- 함수근사와 정책경사 이론
 - 신경망으로 가치를 근사하는 DQN
 - 정책을 직접 학습하는 REINFORCE, Actor-Critic
- 안정화된 심층강화학습과 모방학습
 - PPO 등 안정적인 정책경사 기법
 - 모방학습과 인간 피드백 기반 강화학습(RLHF)
- 로봇 시뮬레이션과 모델기반 강화학습
 - MuJoCo, Isaac Sim 등 물리 시뮬레이터
 - 모델기반 강화학습과 몬테카를로 트리 탐색(MCTS)

2. 중점 목표 역량

교과 핵심 역량			
problem-solving skills	logical thinking	problem discovery and definition	creativity

3. 교재 및 참고도서

가. 주교재 : 자체 제작 수업 자료

나. 참고 서적

- "Reinforcement Learning: An Introduction (2nd ed.)", Richard S. Sutton and Andrew G. Barto

4. 수업 방법

가. 강의

5. 평가 기준 및 방법

가. 평가 기준

퀴즈	중간고사	기말고사	팀 프로젝트	출결 및 태도	합계
10%	25%	25%	30%	10%	100%

나. 평가 방법

- 퀴즈: 매 주차 수업 내용에 대한 퀴즈로 개념 이해도를 확인한다.
- 중간고사/기말고사: 지필고사로 전반부(1~6주차, 표 기반 강화학습)와 후반부(9~14주차, 심층강화학습) 학습 내용의 이해도를 각각 평가한다.
- 팀 프로젝트: 7주차(Block A, 표 기반 강화학습)와 15주차(Block B, 심층강화학습) 두 차례에 걸쳐 보고서, 발표, 동료 평가(peer-review)로 평가한다. 결과의 우수성보다 실험 절차의 정직성(시드 반복, 베이스라인 비교, 결과에 대한 정직한 보고)을 중요하게 평가한다.

6. 학점 부여 기준

- 출결 및 태도: 총 수업 시간의 3/4 이상 출석 시 100% 부여
- 병결/공결 등으로 정규 중간고사와 기말고사에 미응시한 경우: 대체시험을 실시하여 그대로 점수로 반영
- 과목우수상 기준: 원점수 기준으로 정렬하여 결정

7. 주별 강의 계획

※ 정확한 개강일, 중간고사, 기말고사 날짜는 2027학년도 학사일정 확정 후 반영 예정 (아래 날짜란은 공란으로 둠).

※ 전반부(1~8주, 표 기반 강화학습)와 후반부(9~16주, 심층강화학습) 모두 "6주 수업 + 1주 캡스톤 발표 + 1주 시험" 구조로 구성한다.

※ 9~10주차는 표 기반 방법을 신경망으로 확장하는 이론(함수근사, 정책경사)을 다루며, 이론에서 응용으로의 전환은 11주차부터 점진적으로 이루어진다.

주(기간)	주제 및 내용	비고
제1주	1. 강화학습이란 무엇인가, 그리고 이번 학기 로드맵 • 지도학습과 구별되는 강화학습의 정체성: 에이전트, 환경, 보상, 리턴 • 보상이 한참 뒤에야 주어지는 문제와, 보상을 잘 설계하는 것의 중요성 • 이번 학기 로드맵: 표 기반 강화학습에서 심층강화학습으로 2. 신경망 미니 리뷰 • 순전파, 역전파, 연쇄법칙 등 신경망 핵심 복습 • 비선형 활성화함수(ReLU)의 필요성 3. 실습 환경 세팅: Gymnasium • Gymnasium 표준 인터페이스와 CartPole 환경 • 관측, 행동, 종료 조건의 구성	
핵심역량	problem discovery and definition, logical thinking	

주(기간)	주제 및 내용	비고
제2주	4. 탐험과 활용: ϵ -greedy • 탐험-활용 딜레마와 멀티암 밴딧 문제 • 무작위 시도와 최선의 선택을 섞는 ϵ-greedy 전략 5. 낙관적 초기화와 UCB: 불확실성을 이용한 탐험 • 낙관적 초기화를 이용한 탐험 유도 • 아직 잘 모르는 선택지를 한 번 더 시도해보게 만드는 UCB 방법 6. 밴딧 vs 완전한 MDP: 다음 장으로 가는 다리 • 밴딧을 상태가 하나뿐인 MDP로 재해석 • 미래에 받을 보상을 지금 얼마로 쳐줄지 정하는 할인율 개념	
핵심역량	logical thinking, problem-solving skills	
제3주	7. MDP의 다섯 요소와 마르코프 성질 • 상태, 행동, 전이확률, 보상, 할인율로 구성된 MDP • 현재 상태만 알면 미래를 예측할 수 있다는 마르코프 성질 8. 누적 보상, 할인율, 그리고 실습 • 지금부터 앞으로 받을 보상을 모두 더한 값(리턴)의 정의 • 할인율이 최적 정책의 목표를 바꾸는 사례 9. 가치함수와 벨만 기대방정식 • 상태가치함수 V와 행동가치함수 Q의 정의 • 지금의 가치를 다음 상태의 가치로 나타내는 벨만 방정식	
핵심역량	logical thinking, problem-solving skills	
제4주	10. 벨만 최적방정식과 정책평가 • 정책을 따랐을 때의 가치를 반복 계산으로 구하는 방법 • 가장 좋은 정책의 가치를 나타내는 벨만 최적방정식 11. 정책 반복과 GridWorld 실습 • 정책평가와 정책개선을 반복하는 정책 반복(policy iteration) • GridWorld 환경에서의 최적 정책, 가치함수 실습 12. 가치 반복, 수렴 증명, 그리고 모델 기반이라는 전제 • 가치 반복(value iteration)과 정책 반복의 관계 • 가치 반복을 반복할수록 결국 정답에 가까워지는 이유 • 환경의 규칙을 미리 정확히 알아야 한다는 한계와, 이를 보완하는 Dyna-Q	
핵심역량	logical thinking, creativity	
제5주	13. 모델 없이 배운다: MC 예측 • 환경의 규칙을 몰라도 직접 경험만으로 가치를 추정하는 몬테카를로 방법 • DP와 MC의 차이: 모델 유무 14. MC 제어와 블랙잭 실습 • 직접 겪은 경험을 바탕으로 더 좋은 행동을 찾아가는 몬테카를로 제어 • 블랙잭 환경에서 학습한 전략과 기본 전략표 비교 15. 중요도 샘플링과 MC의 한계 • 다른 방식으로 행동하며 얻은 경험을 재활용하는 방법 • 이 방법의 한계와, 한 에피소드가 끝나야만 배울 수 있는 몬테카를로의 단점	
핵심역량	logical thinking, problem-solving skills	

주(기간)	주제 및 내용	비고
제6주	16. TD(0): 한 스텝만 보고 갱신한다, TD vs MC - 한 스텝만 경험하고 바로 예측을 수정하는 TD(0)의 기본 원리 - TD와 몬테카를로 방식의 장단점 비교, 그리고 그 사이를 조절하는 방법들 17. SARSA와 CliffWalking 실습 - 실제로 선택한 행동을 그대로 사용해 학습하는 SARSA - CliffWalking 환경에서 안전 경로를 학습하는 이유 18. Q-learning과 SARSA, Q-learning 경로 비교 - 항상 최선의 행동을 가정하고 학습하는 Q-learning - SARSA와 Q-learning이 서로 다른 경로를 학습하는 이유	
핵심역량	logical thinking, problem-solving skills	
제7주	19. 팀 프로젝트 발표와 Peer-Review (Block A 캡스톤: 표 기반 강화학습) - 환경 선정과 2개 이상 알고리즘 비교 실험 결과 발표 (1~6주차 내용 적용) - 여러 번 반복 실험하고 비교 기준을 명확히 하는 등, 실험을 정직하게 수행했는지에 대한 동료 평가	
핵심역량	problem discovery and definition, creativity, problem-solving skills, logical thinking	
제8주	1~6주차 범위 지필고사	중간고사
제9주	20. Q-테이블의 한계와 함수근사 - 상태 공간이 클 때 Q-테이블의 한계와 함수근사의 필요성 - 신경망으로 Q값을 예측하는 DQN의 기본 구조 21. DQN의 안정화 장치와 실습 - 학습이 흔들리지 않도록 목표값을 잠시 고정해두는 방법 22. 경험 재현과 CartPole 학습곡선 실습 - 과거 경험을 저장해두었다가 다시 꺼내 학습하는 경험 재현 - CartPole 환경에서의 DQN 학습곡선 분석	
핵심역량	logical thinking, problem-solving skills	
제10주	23. 정책 그라디언트 정리 - 가치기반과 정책기반 강화학습의 차이 - 행동을 선택하는 확률 자체를 조금씩 개선해나가는 방법 24. REINFORCE와 실습 - 얻은 보상에 비례해 행동 확률을 조정하는 REINFORCE 알고리즘 25. Actor-Critic - 행동을 정하는 부분과 그 행동을 평가하는 부분을 함께 학습하는 Actor-Critic - 같은 환경을 여러 개 동시에 복사해서 돌리며 경험을 빠르게 모으고, 그만큼 더 안정적으로 학습하는 방법(A2C, A3C)	
핵심역량	logical thinking, creativity	

주(기간)	주제 및 내용	비고
제11주	26. 신뢰 영역과 확률비 - 정책이 한 번에 너무 많이 바뀌지 않도록 제한하는 신뢰 영역이라는 개념 - 이 개념을 실제로 구현한 초기 방법과 그 한계 27. PPO 클리핑과 연속 제어 실습 - 정책이 한 번에 급격히 바뀌지 않도록 제한을 걸어 안정적으로 학습하는 PPO - Pendulum 환경에서의 연속 제어 실습 28. GAE와 PPO가 표준이 된 이유 - 학습 신호의 정확도와 안정성 사이 균형을 맞추는 방법(GAE) - PPO가 범용 강화학습 알고리즘으로 자리잡은 이유	
핵심역량	logical thinking, problem-solving skills	
제12주	29. 모방학습: 행동 복제와 DAgger - 전문가의 행동을 그대로 따라 하며 배우는 행동 복제와, 작은 실수가 점점 커지는 문제 - 학습 중 새로 마주치는 상황에 대해서도 전문가의 조언을 추가로 받는 방법(DAgger) 30. 선호 기반 보상모델과 실습 - 두 행동 중 어느 쪽이 더 나은지 비교한 데이터로 보상 기준을 학습하는 방법 - 사람의 선호를 반영해 학습하는 RLHF의 과정과, 평가 기준을 편법으로 악용하는 문제 31. 모방학습 vs 강화학습: 언제 무엇을 쓰는가 - 시연 데이터와 보상 신호 등 가용 자원에 따른 방법 선택 - 두 방법을 함께 사용하는 실전 방식	
핵심역량	creativity, problem discovery and definition	
제13주	32. 로봇공학 기초와 Sim-to-Real - 로봇 팔의 각도와 위치를 계산하고 제어하는 기초 이론 - 시뮬레이션과 실제 환경의 차이를 줄이기 위한 방법 33. 로봇 환경 탐색 실습 - 로봇팔, 사족보행 등 연속제어 환경 탐색과 평가 프로토콜 34. 연속제어환경에 PPO 적용하기 - 힘의 크기처럼 연속적인 값을 다루는 정책 구조 - Reacher 환경에서의 PPO 적용 실습	
핵심역량	problem-solving skills, creativity	

주(기간)	주제 및 내용	비고
제14주	35. World Models: 학습된 모델로 상상하며 계획하기 • 학습된 모델 위에서 상상 속 계획을 세우는 World Models • 모델 오차 누적의 한계 36. MuJoCo와 Isaac Sim: 물리 시뮬레이터와 GPU 가속 • 물체 사이의 충돌과 접촉까지 정교하게 계산하는 물리 시뮬레이터 MuJoCo • 그래픽카드를 이용해 수많은 시뮬레이션을 동시에 돌리는 Isaac Sim • 목적에 따라 알맞은 시뮬레이션 도구를 고르는 기준(자율주행 시뮬레이션 사례 포함) 37. 모델기반 강화학습과 몬테카를로 트리 탐색(MCTS) • Dyna-Q 재조명: 학습된 모델로 가상 경험을 만들어 학습을 가속 • 여러 수를 미리 시뮬레이션해보고 가장 좋은 수를 찾는 몬테카를로 트리 탐색(MCTS)과 바둑 AI(AlphaGo)에서의 활용	
핵심역량	logical thinking, problem-solving skills, creativity	
제15주	38. 팀 프로젝트 발표와 Peer-Review (Block B 캡스톤: 심층강화학습) • 여러 번 반복 실험한 결과를 비교해 발표 (9~14주차 내용 적용) • 신경망 기반 강화학습에 특화된 체크리스트를 이용한 동료 평가 • 한 학기 개념지도 복습과 학기 이후 학습 방향(최신 동향) 안내	
핵심역량	problem discovery and definition, creativity, problem-solving skills, logical thinking	
제16주	9~14주차 범위 지필고사	기말고사